

Verificación de calidad de los datos del SIMA

Issue #11 — MA2003B, equipo 7

Tabla de contenidos

Qué ya estaba verificado	1
1. Cuántas observaciones aporta cada estación	2
2. Nulos y tipos por columna	3
Cómo leer esta tabla	4
Los faltantes en el tiempo	4
Ojo: un nulo no siempre fue un nulo	5
3. Valores fuera del rango físico	6
Hallazgos de la sección 3	9
4. ¿Hay texto donde debería haber número?	10
Resultado: no se perdió nada	11
5. Consistencia entre el catálogo de estaciones y los datos	11
Hallazgos: el catálogo está incompleto y tiene una errata	12
6. ¿Sirven el padrón vehicular y el inventario de emisiones?	13
Conclusión: no son cruzables a nivel de observación	13
7. Conclusiones	14

Issue #11. Auditoría del consolidado `data/processed/sima_horario.parquet` (754,603 observaciones horarias, 2020-01-01 a 2025-12-31, 15 estaciones).

No se limpió nada, solamente se dieron insights.

Qué ya estaba verificado

La issue #9 dejó documentado en [data/README.md](#):

- El porcentaje de faltantes por parámetro (de 3.7 % en SR a 25.2 % en PM2.5).
- Sin fechas nulas y sin pares (`estación`, `fecha`) duplicados.
- Cobertura temporal continua, sin huecos de días completos.
- Las **23 banderas de calidad** de `Etiquetas.xlsx` no aparecen en ninguno de los archivos entregados: se revisaron las 87 hojas de los seis libros y no hay una sola celda con letra de bandera.

```

from pathlib import Path

import matplotlib.pyplot as plt
import pandas as pd

# El documento puede renderizarse con el cwd en notebooks/ o en la raiz del repo,
# segun como se lance. Esto lo resuelve en los dos casos.
RAIZ = Path.cwd()
if RAIZ.name == "notebooks":
    RAIZ = RAIZ.parent
RUTA_PROCESSED = RAIZ / "data" / "processed"

# Columnas que identifican la observacion; el resto son mediciones.
LLAVES = ["fecha", "estacion", "anio"]

pd.set_option("display.max_columns", None)
pd.set_option("display.width", 120)

sima = pd.read_parquet(RUTA_PROCESSED / "sima_horario.parquet")
PARAMETROS = [c for c in sima.columns if c not in LLAVES]

print(f"filas x columnas : {sima.shape[0]:,} x {sima.shape[1]}")
print(f"cobertura       : {sima['fecha'].min()} -> {sima['fecha'].max()}")
print(f"estaciones        : {sima['estacion'].nunique()}")
print(f"parametros         : {len(PARAMETROS)}")

```

```

filas x columnas : 754,603 x 18
cobertura       : 2020-01-01 00:00:00 -> 2025-12-31 23:00:00
estaciones      : 15
parametros      : 15

```

1. Cuántas observaciones aporta cada estación

La rejilla temporal tiene **52,608 horas** (2,192 días × 24). Si las 15 estaciones hubieran reportado siempre, habría 789,120 filas; hay 754,603. Pero no es ruido, solo dice cuándo entró en operación cada estación y dónde faltan renglones enteros.

```
sima['estacion'].value_counts()
```

```

estacion
CE      52605
SE      52599
NO      52597
SO      52597
NE      52595

```

```

NTE      52595
SE2      52595
N02      52594
NE2      52593
NTE2     52593
SE3      52593
S02      52593
SUR      52592
NE3      43817
N03      27045
Name: count, dtype: int64

```

IMPORTANTE: hay huecos que no son nulos, son renglones enteros ausentes.

Dos estaciones entraron en operación tarde, que son: NE3 y N03. Lo que explica la diferencia que hay. 43,817 horas (arranca en 2021) y solo 27,045 (arranca a media hoja de 2022, como ya documentaba [data/README.md](#)).

Pero el resto de las estaciones tampoco llega a las 52,608 horas: pierden entre 3 (CE) y 16 (SUR) renglones cada una. Con la primera versión de BD 2025.xlsx (cortada al 30 de junio) S0 perdía 151; la versión completa cerró ese hueco. Eso es una categoría de faltante distinta a la que mide `pct_nulo`:

Un renglón ausente **no aparece como nulo**, porque la fila no existe. El porcentaje de nulos de la sección siguiente se calcula sobre las filas que sí están, así que no es lo mismo del faltante real.

2. Nulos y tipos por columna

```

resumen = pd.DataFrame(
    {
        "tipo": sima.dtypes.astype(str),
        "n_nulos": sima.isna().sum(),
        "pct_nulo": (sima.isna().mean() * 100).round(2),
        "n_distintos": sima.nunique(dropna=True),
    }
)
resumen.index.name = "columna"
resumen

```

	tipo	n_nulos	pct_nulo	n_distintos
columna				
fecha	datetime64[us]	0	0.00	52608
estacion	category	0	0.00	15
anio	int64	0	0.00	6

columna	tipo	n_nulos	pct_nulo	n_distintos
CO	float64	100441	13.31	2041
NO	float64	126381	16.75	2969
NO2	float64	131104	17.37	1262
NOX	float64	126946	16.82	3354
O3	float64	111159	14.73	1368
PM10	float64	34927	4.63	13301
PM2.5	float64	190352	25.23	8956
PRS	float64	38332	5.08	691
RAINF	float64	35760	4.74	545
RH	float64	85864	11.38	127
SO2	float64	113447	15.03	957
SR	float64	27603	3.66	1680
TOUT	float64	52437	6.95	5055
WSR	float64	51866	6.87	1210
WDR	float64	63021	8.35	369

Cómo leer esta tabla

- **Las tres llaves no tienen nulos.** Las tres variables identificadoras no tienen ningún nulo, que es la condición mínima para poder cruzar o agregar.
- **Todos los parámetros son float64.** PERO leer la nota al final de esta sección.
- **n_distintos marca la resolución del instrumento.** Un parámetro con pocos valores distintos sobre cientos de miles de filas está reportando en escalones, no en continuo.

Los faltantes en el tiempo

```
nulos_anio = (
    sima.set_index("anio")[PARAMETROS].isna().groupby(level=0).mean().mul(100)
)

fig, ax = plt.subplots(figsize=(11, 3.4))

# Rampa secuencial de un solo tono: el dato es magnitud (% faltante), no
↪ identidad.
# La escala arranca en 0 y termina en el maximo observado; fijarla en 100 dejaria
# todas las celdas casi blancas y el patron no se veria. El numero exacto va
↪ escrito
# en cada celda, asi que al color le basta con ordenar.
tope = float(nulos_anio.to_numpy().max())
malla = ax.imshow(nulos_anio, cmap="Blues", vmin=0, vmax=tope, aspect="auto")

ax.set_xticks(range(len(PARAMETROS)), PARAMETROS, rotation=45, ha="right")
```

```

ax.set_yticks(range(len(nulos_anio)), nulos_anio.index)
ax.set_title("% de observaciones faltantes por parámetro y año", pad=12,
    ↪ loc="left")

# El valor va escrito en cada celda: el color ordena, el número precisa.
for i in range(nulos_anio.shape[0]):
    for j in range(nulos_anio.shape[1]):
        pct = nulos_anio.iat[i, j]
        ax.text(
            j, i, f"{pct:.0f}",
            ha="center", va="center", fontsize=8,
            color="white" if pct > 0.55 * tope else "#333333",
        )

for lado in ax.spines.values():
    lado.set_visible(False)
ax.tick_params(length=0)
fig.colorbar(malla, ax=ax, label="% faltante", pad=0.01)
fig.tight_layout()
plt.show()

```




Figura 1: % de observaciones faltantes por parámetro y año.

Ojo: un nulo no siempre fue un nulo

Hallazgo importante para interpretar todo lo anterior. En [src/importar_datos.py](#) la conversión a número se hace así:

```

hoja[parametro] = pd.to_numeric(hoja[parametro], errors="coerce")

```

`errors="coerce"` convierte a nulo, y en silencio, todo lo que no sea numérico. Es la decisión correcta para consolidar (si no, el script truena con la primera celda rara), pero tiene una consecuencia directa para esta auditoría:

Una parte de los nulos contados arriba **no eran celdas vacías en el origen**: eran texto que no se pudo convertir.

La issue #11 pide reportar específicamente *texto donde debería haber número*, y eso **no se puede auditar desde processed/** — ahí la evidencia ya se perdió. Hay que ir a *data/raw/*. Queda pendiente para la sección siguiente.

3. Valores fuera del rango físico

Fuente: [docs/Rangos de los parámetros del SIMA.pdf](#). Define dos criterios:

- **Operación** — lo que SIMA considera plausible. Cambia año con año. Salirse es *sospechoso*.
- **Fabricante** — lo que el sensor puede reportar. Salirse es *imposible*.

El PDF nombra cinco parámetros distinto al parquet: NOx→NOX, WS→WSR, TEMP→TOUT, BP→PRS, WD→WDR.

```
ANIOS = [2020, 2021, 2022, 2023, 2024, 2025]
TRADUCE = {"NOx": "NOX", "WS": "WSR", "TEMP": "TOUT", "BP": "PRS", "WD": "WDR"}

# Rango de operación: un (min, max) por año, en el orden de ANIOS.
OPERACION = {
    "PM10": [(0, 800), (0, 800), (0, 999), (0, 900), (0, 999), (0, 820)],
    "PM2.5": [(0, 205.94), (0, 325), (0, 450), (0, 800), (0, 999), (0, 350)],
    "O3": [(0, 153), (0, 175), (0, 160), (0, 175), (0, 180), (0, 185)],
    "NO": [(0, 500), (0, 350), (0, 400), (0, 500), (0, 400), (0, 350)],
    "NO2": [(0, 200), (0, 100), (0, 175), (0, 175), (0, 130), (0, 175)],
    "NOx": [(0, 500), (0, 400), (0, 420), (0, 500), (0, 500), (0, 400)],
    "SO2": [(0, 200), (0, 300), (0, 200), (0, 250), (0, 150), (0, 405)],
    "CO": [(0, 20), (0, 10), (0, 8), (0, 14), (0, 18), (0, 10)],
    "RH": [(0, 100)] * 6,
    "WS": [(0, 75), (0, 40), (0, 35), (0, 40), (0, 38), (0, 40)],
    "TEMP": [(0, 41), (-6.5, 45), (-5, 45), (0, 45), (-4, 45.5), (-4.5, 45)],
    "SR": [(0, 1), (0, 1), (0, 1.25), (0, 1), (0, 1.26), (0, 1.2)],
    "BP": [(690, 750), (690, 740), (700, 740), (690, 740), (687.5, 740), (688,
        ↪ 740)],
    "WD": [(0, 360)] * 6,
    "RAINF": [(0, 30), (0, 80), (0, 25), (0, 70), (0, 50), (0, 25)],
}

# Rango del fabricante: fijo. RAINF no tiene (el PDF solo dice "conteo pulso
    ↪ 0.01").
FABRICANTE = {
    "PM10": (0, 1000), "PM2.5": (0, 1000), "O3": (0, 1000),
    "NO": (0, 500), "NO2": (0, 500), "NOx": (0, 500), "SO2": (0, 500),
    "CO": (0, 50), "RH": (0, 100), "WS": (0, 180), "TEMP": (-50, 50),
    "SR": (0, 1.4), "BP": (449.9, 824.9), "WD": (0, 360),
}
```

```
def cuenta_fuera_operacion():
    """Observaciones fuera del rango de SU año, por parámetro y año."""
    filas = {}
    for nombre, tramos in OPERACION.items():
        col = TRADUCE.get(nombre, nombre)
        filas[col] = {}
        for anio, (bajo, alto) in zip(ANIOS, tramos):
            valores = sima.loc[sima["anio"] == anio, col]
            filas[col][anio] = int(((valores < bajo) | (valores > alto)).sum())
    return pd.DataFrame(filas).T

fuera_op = cuenta_fuera_operacion()
fuera_op["TOTAL"] = fuera_op.sum(axis=1)
fuera_op.sort_values("TOTAL", ascending=False)
```

	2020	2021	2022	2023	2024	2025	TOTAL
PRS	101	429	6305	486	405	446	8172
WSR	6	1184	126	360	24	4	1704
SR	1	45	717	180	151	92	1186
TOUT	450	16	2	9	40	0	517
RH	0	3	155	95	25	16	294
NO	0	5	8	0	2	269	284
NOX	0	5	11	0	0	207	223
RAINF	0	6	0	0	2	24	32
CO	0	22	0	1	2	0	25
O3	1	5	0	0	2	0	8
PM10	0	0	1	3	0	0	4
PM2.5	0	0	0	0	1	0	1
SO2	0	0	0	0	1	0	1
WDR	0	0	0	0	0	1	1
NO2	0	0	0	0	0	0	0

```
# Fuera del rango del FABRICANTE: valores que el sensor no puede haber medido.
for nombre, (bajo, alto) in FABRICANTE.items():
    col = TRADUCE.get(nombre, nombre)
    fuera = sima.loc[(sima[col] < bajo) | (sima[col] > alto), ["fecha",
↪ "estacion", col]]
    if fuera.empty:
        continue
    print(f"{col}: {len(fuera):,} observaciones fuera de [{bajo}, {alto}]"
          f" (min {fuera[col].min()}, max {fuera[col].max()}")
    print(fuera.nlargest(3, col).to_string(index=False), "\n")
```

PM10: 1 observaciones fuera de [0, 1000] (min 1001.0, max 1001.0)

fecha estacion PM10

2022-12-18 05:00:00 NTE 1001.0

PM2.5: 1 observaciones fuera de [0, 1000] (min -1.0, max -1.0)

fecha estacion PM2.5

2024-12-07 06:00:00 SE3 -1.0

O3: 1 observaciones fuera de [0, 1000] (min -9.0, max -9.0)

fecha estacion O3

2024-09-17 13:00:00 NTE2 -9.0

NO: 11 observaciones fuera de [0, 500] (min 515.8, max 945.1)

fecha estacion NO

2022-03-15 12:00:00 NO 945.1

2022-01-04 11:00:00 NO 895.2

2022-03-15 13:00:00 NO 858.6

NOX: 30 observaciones fuera de [0, 500] (min -9999.0, max 971.8)

fecha estacion NOX

2022-03-15 12:00:00 NO 971.8

2022-01-04 11:00:00 NO 897.0

2022-03-15 11:00:00 NO 874.9

CO: 1 observaciones fuera de [0, 50] (min -0.01, max -0.01)

fecha estacion CO

2024-12-29 05:00:00 SO2 -0.01

RH: 294 observaciones fuera de [0, 100] (min -9999.0, max 725.0)

fecha estacion RH

2025-10-16 12:00:00 SE2 725.0

2025-11-12 11:00:00 SE2 725.0

2025-10-08 15:00:00 SE2 723.8

WSR: 41 observaciones fuera de [0, 180] (min -9999.0, max 337.0)

fecha estacion WSR

2025-03-01 00:00:00 NE3 337.0

2021-10-02 07:00:00 SO2 227.1

2021-10-02 04:00:00 SO2 218.2

TOUT: 405 observaciones fuera de [-50, 50] (min -9999.0, max 785.0)

fecha estacion TOUT

2024-11-30 23:00:00 NE 785.00

2022-12-28 15:00:00 NE2 112.39

2024-06-15 22:00:00 NE2 84.47

SR: 1,091 observaciones fuera de [0, 1.4] (min -9999.0, max 604.0)

fecha estacion SR


```
2025-10-22 15:00:00      NE3 604.0
2021-10-27 16:00:00      NE3 501.0
2020-11-10 19:00:00      SE  64.0
```

PRS: 2 observaciones fuera de [449.9, 824.9] (min 0.0, max 0.0)

```
      fecha estacion  PRS
2020-11-10 19:00:00      SE  0.0
2025-09-24 11:00:00      SE  0.0
```

WDR: 1 observaciones fuera de [0, 360] (min -9999.0, max -9999.0)

```
      fecha estacion  WDR
2025-02-02 05:00:00      S02 -9999.0
```

```
# -9999 no es una medición: es el código de "sin dato" del sensor.
# Sobrevivió a la importación porque es un número válido y to_numeric lo aceptó.
centinelas = {}
for col in PARAMETROS:
    for valor in (-9999, -999, -99):
        n = int((sima[col] == valor).sum())
        if n:
            centinelas[(col, valor)] = n

pd.Series(centinelas, name="n_observaciones").rename_axis(["parametro",
↪ "centinela"])
```

```
parametro  centinela
NOX        -9999      2
RAINF      -9999      1
RH         -9999      9
SR         -9999     11
TOUT       -9999      1
WSR        -9999      1
WDR        -9999      1
Name: n_observaciones, dtype: int64
```

Hallazgos de la sección 3

-9999 es un código de “sin dato”, no una medición. Son 26 celdas repartidas en SR, RH, NOX, TOUT, WSR, WDR y RAINF. Entró al parquet como número real, así que **cualquier media o desviación calculada sin quitarlo sale disparatada**. Es el hallazgo más accionable para la #13.

Fuera del rango de operación (12,452 observaciones, sospechosas):

	total	se concentra en
PRS	8,172	2022 (6,305)
WSR	1,704	2021 (1,184)
SR	1,186	2022 (717)
TOUT	517	2020 (450)
RH	294	2022 (155)
NO	284	2025 (269)
NOX	223	2025 (207)

NO y NOX son novedad del segundo semestre de 2025: el rango de operación de ese año baja el tope a 350 y 400 ppb, y la estación S0 acumula 220 y 159 lecturas por encima. Son picos de precursores, no imposibles físicamente, así que se marcan y se conservan, igual que el resto de esta tabla.

Fuera del rango del fabricante (imposibles, 1,879 en total): SR 1,091 · TOUT 405 · RH 294 · WSR 41 · NOX 30 · NO 11 · PRS 2, más una observación suelta en PM10, PM2.5, O3, CO y WDR. NO2 sale limpio.

Sospecha de unidades en SR. Llega a 501 cuando el tope del sensor es 1.4 kW/m². 501 W/m² es radiación solar normal, así que parte de las lecturas parecen venir en W/m² y no en kW/m². Hay que confirmarlo con SIMA antes de afirmarlo.

Las fallas son por estación, no por sensor. 2020-11-10 19:00 en SE tiene SR=64 y PRS=0.0 a la vez; NO y NOX comparten los mismos timestamps del 2022-03-15 en la estación NO; SE2 reporta RH de 725 % nueve veces entre septiembre y noviembre de 2025. Conviene descartar la observación completa, no el valor suelto.

4. ¿Hay texto donde debería haber número?

La sección 2 dejó esta duda abierta: `to_numeric(..., errors="coerce")` manda a nulo cualquier celda no numérica **sin avisar**. Para saber cuánto se perdió hay que ir a `data/raw/` y leer las celdas tal cual llegaron.

Este bloque relee los seis Excel. Tarda unos 3 minutos.

```
import sys

if str(RAIZ) not in sys.path:
    sys.path.insert(0, str(RAIZ))

# Se reutilizan las funciones de la importación para leer los Excel EXACTAMENTE
# igual que ella; si se replicaran aquí, se estaría auditando otro proceso.
from src.importar_datos import (
    ANIOS, RUTA_RAW, _normalizar_encabezado, _es_fila_de_unidades, _es_numero,
)

no_numericas = {}
for anio in ANIOS:
```

```

hojas = pd.read_excel(RUTA_RAW / f"BD {anio}.xlsx", sheet_name=None,
                      engine="openpyxl", dtype=object)
for estacion, hoja in hojas.items():
    hoja = hoja.rename(columns=_normalizar_encabezado)
    hoja = hoja.loc[:, [c for c in ["fecha", *PARAMETROS] if c in
↪ hoja.columns]]
    hoja = hoja[~hoja.apply(_es_fila_de_unidades, axis=1)]
    for p in PARAMETROS:
        if p not in hoja.columns:
            continue
        col = hoja[p]
        malas = col[col.notna() & ~col.map(_es_numero)]
        if len(malas):
            no_numericas[(anio, estacion.strip().upper(), p)] =
↪ list(malas.unique()[:5])

print(f"celdas no numéricas encontradas: {len(no_numericas)}")
no_numericas or "Ninguna: to_numeric no descartó ningún dato."

```

celdas no numéricas encontradas: 0

'Ninguna: to_numeric no descartó ningún dato.'

Resultado: no se perdió nada

Cero celdas no numéricas en los seis archivos. El `coerce` no descartó un solo dato.

El texto sí es convertible a número. Los nulos de la sección 2 son huecos reales.

Queda descartado el error “texto donde debería haber número”. El error de valor que sí existe es el -9999 de la sección 3. No es texto, es un número que finge ser medición.

5. Consistencia entre el catálogo de estaciones y los datos

```

catalogo = pd.read_csv(RUTA_PROCESSED / "etiquetas_estaciones.csv")

en_datos = set(sima["estacion"].unique())
en_catalogo = set(catalogo["Abreviatura"])

print(f"catálogo : {len(catalogo)} filas, {catalogo['Abreviatura'].nunique()}
↪ abreviaturas únicas")
print(f"datos      : {len(en_datos)} estaciones\n")
print(f"En datos y NO en catálogo : {sorted(en_datos - en_catalogo)}")
print(f"En catálogo y NO en datos : {sorted(en_catalogo - en_datos)}")

```

```
print(f"Chocan con un parámetro : {sorted(en_catalogo & set(PARAMETROS))}\n")
print("Abreviaturas duplicadas en el catálogo:")
catalogo[catalogo["Abreviatura"].duplicated(keep=False)]
```

catálogo : 13 filas, 12 abreviaturas únicas
 datos : 15 estaciones

En datos y NO en catálogo : ['NE3', 'N03', 'SUR']
 En catálogo y NO en datos : []
 Chocan con un parámetro : ['N0', 'N02', 'S02']

Abreviaturas duplicadas en el catálogo:

	Abreviatura	Descripción	Estación	Municipio
0	SE	Sureste	La Pastora	Guadalupe
10	SE	Sur	Pueblo Serena	NaN

Hallazgos: el catálogo está incompleto y tiene una errata

Faltan tres estaciones. NE3, N03 y SUR aparecen en los datos y no en el catálogo. Las dos primeras son justamente las que entraron en operación en 2021 y 2022 (sección 1): el catálogo nunca se actualizó.

SE está duplicada. Dos filas distintas comparten abreviatura:

	Abreviatura	Descripción	Estación	Municipio
	SE	Sureste	La Pastora	Guadalupe
	SE	Sur	Pueblo Serena	(vacío)

La segunda dice “Sur” y es casi con seguridad SUR — el código que sí está en los datos y falta en el catálogo. Conviene confirmarlo con SIMA antes de darlo por hecho.

Tres códigos de estación chocan con nombres de contaminante: N0, N02 y S02 son a la vez estación y columna del parquet. Hoy no rompe nada porque viven en dimensiones distintas, pero cualquier merge o pivote que mezcle ambas los va a confundir.

Ninguna estación del catálogo falta en los datos, así que el problema es solo de documentación desactualizada, no de datos huérfanos.

6. ¿Sirven el padrón vehicular y el inventario de emisiones?

La issue pregunta si aportan variables cruzables con el SIMA. Para cruzar hace falta una llave común, y el SIMA solo tiene `fecha` y `estacion`.

```
padron = pd.read_parquet(RUTA_PROCESSED / "padron_vehicular.parquet")
inventario = pd.read_parquet(RUTA_PROCESSED / "inventario_nl_2018.parquet")

for nombre, tabla in [("sima_horario", sima), ("padron_vehicular", padron),
                      ("inventario_nl_2018", inventario)]:
    print(f"{nombre:<20} {tabla.shape[0]:>10,} filas {list(tabla.columns[:6])}")

# ¿Comparten alguna llave? El único candidato es el municipio.
print("\nmunicipios en el padrón      :", padron["municipio"].nunique())
print("municipios en el inventario :", inventario["Nom_Mun"].nunique())
print("municipios en el catálogo   :", catalogo["Municipio"].nunique(),
      f"({catalogo['Municipio'].isna().sum()} estaciones sin municipio)")
```

<code>sima_horario</code>	754,603 filas	<code>['fecha', 'estacion', 'anio', 'CO', 'NO', 'NO2']</code>
<code>padron_vehicular</code>	1,000,473 filas	<code>['municipio', 'marca', 'linea', 'tipo', 'modelo', 'cilindros']</code>
<code>inventario_nl_2018</code>	2,816 filas	<code>['F_emi', 'Nom_Edo', 'CVE_Edo', 'CV_ZM', 'Nom_ZM', 'CVE_ZM']</code>

<code>municipios en el padrón</code>	<code>: 104</code>
<code>municipios en el inventario</code>	<code>: 51</code>
<code>municipios en el catálogo</code>	<code>: 9 (3 estaciones sin municipio)</code>

Conclusión: no son cruzables a nivel de observación

Ninguna de las dos fuentes tiene fecha ni estación:

	Granularidad	Temporalidad
<code>sima_horario</code>	estación × hora	2020–2025, horaria
<code>padron_vehicular</code>	vehículo	sin fecha
<code>inventario_*)_2018</code>	municipio × categoría de fuente	un solo año: 2018

El único puente posible es **municipio**, y llegar ahí exige pasar por el catálogo (estación → municipio), que como vimos está incompleto: le faltan tres estaciones y tres de sus trece filas traen el municipio vacío.

Aun resolviendo eso, el cruce sería débil:

- El **inventario es de 2018** y el SIMA arranca en 2020: no hay traslape temporal.
- El **padrón no tiene fecha**, así que entraría como una constante por municipio — la misma cifra repetida en las 52,608 horas. No aporta varianza al análisis multivariado.
- El padrón lista **104 municipios** y Nuevo León tiene 51: los nombres no están normalizados y habría que limpiarlos antes de cualquier cruce.

Recomendación: usarlos como contexto descriptivo en el reporte (qué se emite y dónde, cuántos vehículos hay por municipio), no como variables del modelo.

7. Conclusiones

Lo que esta auditoría agrega a lo ya documentado por la issue #9:

1. **-9999 está guardado como si fuera una medición** en siete parámetros (26 celdas). Es el hallazgo más urgente: contamina cualquier media o desviación. Quitarlo es lo primero que debe hacer la #13.
2. **12,452 observaciones caen fuera del rango de operación** de SIMA, concentradas en PRS (8,172) y WSR (1,704). De esas, **1,879 son físicamente imposibles** según el rango del fabricante.
3. **Faltan renglones enteros, no solo valores.** Cada estación pierde entre 3 y 16 horas de la rejilla. Un renglón ausente no cuenta como nulo, así que el % de faltantes reportado está subestimado.
4. **El catálogo de estaciones está desactualizado:** le faltan NE3, N03 y SUR, y tiene SE duplicada.
5. **No hay texto donde debería haber número.** La importación no descartó datos.
6. **El padrón y el inventario no son cruzables** con el SIMA a nivel de observación.

Dos cosas que conviene **preguntarle a SIMA** antes de afirmarlas en el reporte: si **SR** mezcla lecturas en W/m^2 y kW/m^2 , y si la fila “Sur / Pueblo Serena” del catálogo corresponde al código **SUR**.

Para las siguientes issues: los puntos 1, 2 y 3 son trabajo directo de la #13 (limpieza); el 4 conviene reportarlo a SIMA; el 6 acota el alcance de la #17.