

Estacionalidad del ozono en el AMM

Bloque 0 del cambio de objetivo — MA2003B, equipo 7

Tabla de contenidos

0. Carga y variables de agrupación	1
1. ¿El invierno tiene el ozono más alto?	3
2. Control del artefacto de ventana	3
3. Desagregación por zona	5
4. Elevación y ozono	7
5. Composición estacional de la partición de validación	9
6. Conclusiones	10
7. Criterios de aceptación	11
Uso de IA en esta notebook	11

Esta notebook responde una sola pregunta, y existe porque el reporte afirma algo que nunca se verificó contra nuestros propios datos. `secciones/objetivo.tex` dice, sin cita:

En el área metropolitana de Monterrey, sin embargo, los niveles más altos no coinciden necesariamente con los meses más cálidos: durante el invierno se registran concentraciones más elevadas de O₃.

Esa frase sostiene el encuadre de todo el trabajo. Antes de reescribir el objetivo hay que saber si es cierta. La pregunta se contesta con el dataset diario que ya produce `src/limpieza.py` (#13), sin datos nuevos.

De paso se resuelven dos cosas que el modelado necesita decidir: si la agrupación de estaciones por zona tiene respaldo empírico, y qué composición estacional tiene la partición de validación elegida.

Opera sobre `sima_limpiar_diario.csv`, la salida diaria de la limpieza. Las figuras se escriben en `reports/figuras/`.

0. Carga y variables de agrupación

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt
from pathlib import Path
# Sin matplotlib.use("Agg"): ese backend es no interactivo, así que plt.show()
```

```
# no emite nada y Quarto no captura la figura. El PDF sale con el caption y sin
# la gráfica. Con el backend inline del kernel, savefig() escribe el archivo
# para reports/figuras/ y show() además incrusta la figura en este documento.
```

```
RAIZ = Path.cwd().parent
PROC = RAIZ / "data" / "processed"
FIGS = RAIZ / "reports" / "figuras"
FIGS.mkdir(parents=True, exist_ok=True)

D = pd.read_csv(PROC / "sima_limpio_diario.csv", parse_dates=["fecha"])
print(f"diario: {D.shape}")
```

diario: (23931, 9)

temporada se reconstruye con el mismo corte de `src/limpieza.py:364`, para que sea la misma variable que el resto del proyecto y no una definición paralela.

```
D["mes"], D["anio"] = D.fecha.dt.month, D.fecha.dt.year
D["temporada"] = pd.cut(
    D.mes, bins=[0, 2, 5, 8, 11, 12],
    labels=["invierno", "primavera", "verano", "otoño", "invierno"],
    ordered=False)
ORD = ["invierno", "primavera", "verano", "otoño"]
```

zona y la elevación vienen de `docs/Ubicación de las estaciones de monitoreo.docx`, que es el catálogo oficial del SIMA. La agrupación se fija **a priori sobre geografía**: derivarla del comportamiento del ozono y después usarla para explicar ozono sería circular.

Estas dos constantes son provisionales aquí; su lugar definitivo es el módulo de agregación diaria, donde el modelado las va a consumir.

```
ZONA = {**{k: "Noroeste" for k in ["NO", "NO2", "NO3"]},
        **{k: "Suroeste" for k in ["SO", "SO2"]},
        **{k: "Noreste" for k in ["NE", "NE2", "NE3"]},
        **{k: "Sureste" for k in ["SE", "SE2", "SE3"]},
        **{k: "Norte" for k in ["NTE", "NTE2"]},
        "CE": "Centro", "SUR": "Sur"}
ELEV = {"SE3": 334, "NE3": 346, "SE2": 387, "NE2": 432, "NE": 474, "SE": 500,
        "NTE": 503, "NTE2": 520, "SUR": 555, "CE": 562, "NO": 568, "NO3": 607,
        "SO2": 636, "SO": 674, "NO2": 702}

D["zona"] = D.estacion.map(ZONA)
D["msnm"] = D.estacion.map(ELEV)
assert D.zona.notna().all() and D.msnm.notna().all()
```

El análisis usa solo los días-estación con MDA8 válido, es decir los que pasaron el criterio de completitud de 18 de 24 ventanas móviles. Las indicadores de excedencia son nulas exactamente en esas mismas filas, así que el filtro es común a todas las cifras de aquí en adelante.

```
V = D[D.MDA8.notna()].copy()
print(f"días-estación válidos: {len(V):,} de {len(D):,} "
      f"({len(V)/len(D)*100:.2f} %)")
```

días-estación válidos: 22,529 de 23,931 (94.14 %)

1. ¿El invierno tiene el ozono más alto?

```
t = V.groupby("temporada", observed=True).agg(
    n=("MDA8", "size"), media=("MDA8", "mean"), mediana=("MDA8", "median"),
    p95=("MDA8", lambda s: s.quantile(.95)),
    exc51=("excede_anio_5", "mean"), exc65=("excede_anio_1", "mean"))
t[["exc51", "exc65"]] *= 100
t = t.reindex(ORD).round(2)
t
```

	n	media	mediana	p95	exc51	exc65
temporada						
invierno	5429	38.11	37.50	63.00	15.82	4.00
primavera	6527	50.68	49.38	80.71	45.67	17.63
verano	5519	45.16	43.00	73.75	28.23	9.77
otoño	5054	43.15	41.94	71.88	30.06	9.75

No. **El invierno es la temporada con el ozono más bajo de las cuatro**, en las tres medidas: media, mediana y percentil 95. La primavera es la más alta.

El contraste es grande, no marginal: el MDA8 medio de primavera supera al de invierno en 12.6 ppb, y la tasa de excedencia del umbral de 51 ppb pasa de 15.8 % en invierno a 45.7 % en primavera, casi el triple. Al umbral vigente de 65 ppb la razón es todavía mayor, de 4.0 % a 17.6 %.

El orden completo es primavera > verano > otoño > invierno, consistente con el mecanismo fotoquímico: el ozono troposférico se forma por reacción de sus precursores bajo radiación solar, de modo que el mínimo invernal es lo que cabe esperar y no una anomalía.

2. Control del artefacto de ventana

El resultado anterior podría deberse a la ventana de observación y no al fenómeno: la serie termina el 30 de junio de 2025, así que el periodo contiene cinco tramos enero-marzo pero solo cuatro

noviembre–diciembre. El invierno está sobrerrepresentado y con una composición de años distinta a la del otoño.

La forma de descartarlo es calcular la estacionalidad **dentro de cada año**, que elimina la mezcla desigual.

```
piv = V.pivot_table(index="anio", columns="temporada", values="MDA8",
                    aggfunc="mean", observed=True)[ORD]
piv.round(2)
```

temporada	invierno	primavera	verano	otoño
anio				
2021	40.16	48.49	42.45	43.00
2022	34.71	50.33	44.91	40.31
2023	37.00	42.05	50.49	44.18
2024	39.74	55.63	43.52	44.98
2025	40.24	56.78	41.63	NaN

```
pex = V.pivot_table(index="anio", columns="temporada", values="excede_anio_5",
                    aggfunc="mean", observed=True)[ORD] * 100
pex.round(1)
```

temporada	invierno	primavera	verano	otoño
anio				
2021	20.5	38.8	23.3	28.7
2022	14.5	45.0	24.5	26.0
2023	8.4	23.9	38.3	30.5
2024	17.6	60.5	28.1	34.6
2025	21.5	59.7	21.6	NaN

El patrón se sostiene: **el invierno es la temporada más baja en los cinco años, sin una sola excepción**. La primavera es la más alta en cuatro de los cinco; 2023 es el único año donde el verano la supera. El resultado no es un artefacto de la ventana.

```
plt.rcParams.update({"font.size": 9, "font.family": "serif",
                    "axes.spines.top": False, "axes.spines.right": False,
                    "figure.dpi": 150})
GRIS, AZUL, ROJO, CLARO = "#8c8c8c", "#3b6ea5", "#b5443a", "#d9d9d9"

# El año es una variable ORDENADA, no categórica: la rampa secuencial de un solo
# tono (claro 2021 -> oscuro 2025) lo codifica correctamente. Cinco tonos
# categóricos distintos sugerirían que los años no tienen orden entre sí.
rampa = plt.get_cmap("Blues")(np.linspace(.40, .95, len(piv)))
```

```

fig, ax = plt.subplots(figsize=(3.4, 2.5))
x = np.arange(len(ORD))
for (anio, fila), c in zip(piv.iterrows(), rampa):
    ax.plot(x, fila.values, marker="o", ms=4, lw=1.6, color=c, label=str(anio))
ax.set_xticks(x); ax.set_xticklabels([o.capitalize() for o in ORD], fontsize=8)
ax.set_ylabel("MDA8 medio (ppb)", fontsize=8)
ax.tick_params(axis="y", labelsize=8)
ax.grid(axis="y", lw=.4, color=CLARO, zorder=0); ax.set_axisbelow(True)
ax.legend(fontsize=6.5, ncol=5, frameon=False, loc="upper center",
          bbox_to_anchor=(.5, 1.16), columnspacing=1., handlelength=1.2)
fig.tight_layout(pad=.3)
fig.savefig(FIGS / "estacionalidad_mda8_anio.pdf", bbox_inches="tight");
↪ plt.show()

```




Figura 1: MDA8 medio por temporada, una serie por año. El invierno es el mínimo en los cinco años.

3. Desagregación por zona

Falta descartar una versión más débil de la afirmación. El invierno podría no ser el máximo absoluto y aun así ser un **efecto relativo**: que en las estaciones del núcleo urbano, con más NO_x , el ozono quede suprimido por titulación, y que en la periferia esa supresión sea menor bajo condiciones de estancamiento. Ese contraste no aparecería en el promedio metropolitano.

```

pz = V.pivot_table(index="zona", columns="temporada", values="excede_anio_5",
                    aggfunc="mean", observed=True)[ORD] * 100
pz["global"] = V.groupby("zona", observed=True).excede_anio_5.mean() * 100
pz = pz.sort_values("global", ascending=False)
pz.round(1)

```

temporada zona	invierno	primavera	verano	otoño	global
Noroeste	20.8	57.1	45.6	38.8	41.4
Suroeste	15.4	57.7	45.3	39.1	40.1
Centro	16.8	56.4	34.1	39.5	37.7
Sur	22.2	53.4	33.2	28.5	35.5
Norte	12.8	43.9	22.2	23.0	26.5
Sureste	16.2	41.2	16.3	26.2	25.6
Noreste	10.7	26.9	13.5	23.1	19.0

```

razon = (V.pivot_table(index="zona", columns="temporada", values="MDA8",
                        aggfunc="mean", observed=True)
         .pipe(lambda d: d["invierno"] / d["primavera"])
         .sort_values().round(3))

```

razon

```

zona
Suroeste    0.661
Centro      0.711
Norte       0.718
Noroeste    0.736
Sur         0.749
Sureste     0.806
Noreste     0.832
dtype: float64

```

La supresión invernal existe y **varía entre zonas**, pero nunca cambia de signo: la razón invierno/primavera del MDA8 medio va de 0.661 en el Suroeste a 0.832 en el Noreste. En todas las zonas el invierno queda por debajo de la primavera. La afirmación tampoco se sostiene en su versión relativa.

Lo que sí aparece es un ordenamiento espacial nítido y estable: el poniente —Noroeste y Suroeste— concentra las tasas de excedencia más altas (41.4 % y 40.1 %) y el Noreste la más baja (19.0 %), un rango de más del doble.

```

m = pz[ORD].values
fig, ax = plt.subplots(figsize=(3.4, 2.6))
im = ax.imshow(m, cmap="Blues", aspect="auto", vmin=0, vmax=m.max())
ax.set_xticks(range(len(ORD)))
ax.set_xticklabels([o.capitalize() for o in ORD], fontsize=7.5)
ax.set_yticks(range(len(pz))); ax.set_yticklabels(pz.index, fontsize=7.5)
# Etiqueta directa en cada celda: el mapa de calor da la forma, el número da el
# valor exacto sin obligar a leer una barra de color.
for i in range(m.shape[0]):
    for j in range(m.shape[1]):

```

```

ax.text(j, i, f"{m[i,j]:.0f}", ha="center", va="center", fontsize=7,
        color="white" if m[i, j] > m.max() * .72 else "#333333")
ax.set_title("% de días-estación que exceden 51 ppb", loc="left", fontsize=8.5)
for lado in ("top", "right", "left", "bottom"):
    ax.spines[lado].set_visible(False)
ax.tick_params(length=0)
fig.tight_layout(pad=.3)
fig.savefig(FIGS / "excedencia_zona_temporada.pdf", bbox_inches="tight");
↪ plt.show()

```

% de días-estación que exceden 51 ppb

Noroeste	21	57	46	39
Suroeste	15	58	45	39
Centro	17	56	34	40
Sur	22	53	33	28
Norte	13	44	22	23
Sureste	16	41	16	26
Noreste	11	27	14	23
	Invierno	Primavera	Verano	Otoño

Figura 2: Tasa de excedencia del MDA8 a 51 ppb por zona y temporada (%).

4. Elevación y ozono

El ordenamiento poniente-oriente de la sección anterior coincide con la topografía del valle. El catálogo del SIMA da la elevación de cada estación, que va de 334 msnm en SE3, hacia la planicie, a 702 msnm en N02, contra la Sierra Madre. Conviene medir esa relación explícitamente, porque es lo que justifica agrupar por zona en vez de por estación.

```

est = V.groupby("estacion", observed=True).agg(
    MDA8=("MDA8", "mean"), exc=("excede_anio_5", "mean"))
est["msnm"] = est.index.map(ELEV)
est["zona"] = est.index.map(ZONA)
print(f"r(msnm, MDA8 medio)      = {est.msnm.corr(est.MDA8):.3f}")
print(f"r(msnm, tasa excedencia) = {est.msnm.corr(est.exc):.3f}")

```

```

r(msnm, MDA8 medio)      = 0.670
r(msnm, tasa excedencia) = 0.806

```

La correlación entre elevación y tasa de excedencia es 0.806 sobre las 15 estaciones. Es una asociación fuerte para una variable puramente geográfica, fijada sin mirar los datos de ozono, y respalda la decisión de agrupar por zona: las zonas no son etiquetas arbitrarias, separan estaciones que efectivamente se comportan distinto.

Conviene ser explícito sobre qué **no** demuestra: con $n = 15$ y estaciones vecinas correlacionadas entre sí, esto es una descripción, no una estimación del efecto de la altitud. Y la elevación no es la causa —covaría con distancia a las fuentes de NO_x, con el patrón de vientos y con el uso de suelo—. Se reporta como evidencia de que la partición espacial tiene contenido, nada más.

```
fig, ax = plt.subplots(figsize=(3.4, 2.5))
ax.scatter(est.msnm, est.exc * 100, s=26, color=AZUL, zorder=3,
           edgecolor="white", linewidth=.6)
# Etiquetas alternadas arriba/abajo recorriendo las estaciones en orden de
# elevación: los pares que se encimaban (SE3-NE3, SE-NTE, SUR-CE, SO-NO2) son
# vecinos en ese orden, así que alternar los separa sin colocarlas a mano.
for k, (nombre, f) in enumerate(est.sort_values("msnm").iterrows()):
    ax.annotate(nombre, (f.msnm, f.exc * 100), textcoords="offset points",
                xytext=(4, 3) if k % 2 == 0 else (4, -9),
                fontsize=6, color=GRIS)
b, a = np.polyfit(est.msnm, est.exc * 100, 1)
xs = np.array([est.msnm.min(), est.msnm.max()])
ax.plot(xs, a + b * xs, lw=1, ls="--", color=ROJO, zorder=2)
ax.set_xlabel("Elevación (msnm)", fontsize=8)
ax.set_ylabel("% de días que exceden 51 ppb", fontsize=8)
ax.tick_params(labelsize=8)
# Holgura en los dos ejes: sin ella las etiquetas de las estaciones extremas
# (SE3 a la izquierda, NE2 abajo) se recortan contra el marco.
ax.margins(x=.09, y=.14)
ax.grid(lw=.4, color=CLARO, zorder=0); ax.set_axisbelow(True)
ax.set_title(f"r = {est.msnm.corr(est.exc):.3f}    (n = 15 estaciones)",
             loc="left", fontsize=8.5)
fig.tight_layout(pad=.3)
fig.savefig(FIGS / "elevacion_vs_excedencia.pdf", bbox_inches="tight"); plt.show()
```





Figura 3: Elevación de la estación contra su tasa de excedencia del MDA8 a 51 ppb.

NE2 es el caso que se aparta de la recta: a 432 msnm registra la tasa de excedencia más baja de la red, 10.0 %. Vale la pena tenerlo presente al leer los coeficientes de zona del modelo, porque queda dentro del Noreste y arrastra el promedio de esa zona hacia abajo.

5. Composición estacional de la partición de validación

El equipo decidió entrenar con 2021–2024 y validar con 2025. Como 2025 termina el 30 de junio, conviene cuantificar qué tan parecidos son los dos conjuntos antes de interpretar cualquier métrica de desempeño.

```
V["particion"] = np.where(V.anio == 2025, "validación (2025)",
                           "entrenamiento (2021-24)")
comp = pd.crosstab(V.particion, V.temperada, normalize="index") [ORD] * 100
comp.round(1)
```

temporada	invierno	primavera	verano	otoño
particion				
entrenamiento (2021-24)	23.1	26.0	25.7	25.3
validación (2025)	32.2	52.3	15.5	0.0

```
V.groupby("particion").agg(n=("MDA8", "size"), MDA8_medio=("MDA8", "mean"),
                           exc51_pct=("excede_anio_5", lambda s: s.mean() * 100)
                           ).round(2)
```

	n	MDA8_medio	exc51_pct
particion			
entrenamiento (2021-24)	19958	44.03	29.31
validación (2025)	2571	49.11	41.50

Los dos conjuntos no son comparables en composición. El de entrenamiento está repartido casi por igual entre las cuatro temporadas (23.1 % a 26.0 %); el de validación es **52.3 % primavera, 32.2 % invierno, 15.5 % verano y 0 % otoño**.

La consecuencia es cuantificable: la tasa base de excedencia es 29.31 % en entrenamiento y 41.50 % en validación, una diferencia de 12.2 puntos que no proviene del modelo sino del calendario. Como la primavera es la temporada de ozono más alto, la validación sobrerrepresenta justo los días fáciles de clasificar como excedencia.

A modo de referencia, la misma cuenta con 2024 como año de validación:

```
V["p2024"] = np.where(V.anio == 2024, "validación (2024)", "resto")
(pd.crosstab(V.p2024, V.temporada, normalize="index") [ORD] * 100).round(1)
```

temporada	invierno	primavera	verano	otoño
p2024				
resto	24.0	30.0	24.3	21.6
validación (2024)	24.3	25.5	25.1	25.1

Un año completo reparte 24.3 / 25.5 / 25.1 / 25.1, prácticamente la misma composición que el entrenamiento.

Esto no invalida la partición elegida, que se conserva. Sí obliga a dos cosas al reportar resultados: declarar la composición como limitación, y no comparar la métrica de validación contra la de entrenamiento como si midieran lo mismo. El AUC es menos sensible a la tasa base que la exactitud, lo que amortigua el problema pero no lo elimina.

6. Conclusiones

1. **La afirmación del reporte es falsa y hay que retirarla.** El invierno es la temporada con menor ozono, en las tres medidas centrales, en los cinco años por separado y en las siete zonas. No se sostiene ni como máximo absoluto ni como efecto relativo.
2. La estacionalidad real es primavera > verano > otoño > invierno, consistente con la formación fotoquímica y con lo reportado para el AMM en la literatura reciente.
3. **La agrupación por zona tiene respaldo empírico:** las tasas de excedencia van de 19.0 % en el Noreste a 41.4 % en el Noroeste, y la correlación entre elevación y excedencia es 0.806 sobre las 15 estaciones.
4. La partición de validación elegida tiene una composición estacional muy distinta a la de entrenamiento y 12.2 puntos más de tasa base. Se conserva la decisión y se declara la limitación.

Para `secciones/objetivo.tex`: el párrafo que atribuye al invierno las concentraciones más altas se sustituye por la estacionalidad medida, citando esta notebook. El encuadre del trabajo no depende de esa frase —el objetivo es clasificar excedencias a partir de precursores y meteorología, y eso no cambia—, pero mantenerla dejaría el reporte contradiciendo sus propios datos.

7. Criterios de aceptación

OK	Las cuatro temporadas cubren los 12 meses
OK	Toda estación tiene zona y elevación asignadas
OK	Las 15 estaciones caen en las 7 zonas del catálogo
OK	El invierno es el mínimo de MDA8 en los cinco años
OK	El invierno es el mínimo de excedencia en las siete zonas
OK	Las excedencias son nulas exactamente donde el MDA8 es nulo
OK	Total de días-estación válidos = 22,529 (obtenido 22,529)

Uso de IA en esta notebook

Se usó Claude Code para tres cosas: (1) extraer el catálogo de zonas y elevaciones del `.docx` de ubicaciones, que estaba en una tabla de Word y no en formato tabular; (2) escribir el código de agregación y las tres figuras; y (3) señalar que la partición de validación elegida quedaba desbalanceada por temporada, lo que motivó la sección 5. Todas las cifras se reprodujeron ejecutando la notebook contra los datos reales del equipo antes de escribir el texto, y la decisión de conservar 2025 como año de validación pese al desbalance se tomó en discusión del equipo, no se delegó.