

Correlación a resolución diaria

Issue #53 — MA2003B, equipo 7

Tabla de contenidos

0. Carga	1
1. Caso completo (listwise)	3
2. Matriz de correlación de Pearson	3
3. Mapa de calor	4
4. Pares más fuertes y comparación contra la resolución horaria	5
5. Diagnósticos previos al PCA	7
6. Criterios de aceptación	8
7. Qué queda para el reporte	8

Issue #53. Depende de #52. La correlación que hoy justifica el PCA en `reports/secciones/descript_quant.tex` es horaria ($n = 574,343$ hora-estación): sus cifras no respaldan un PCA que va a correr sobre la tabla diaria (#54). Esta notebook recalcula la matriz de correlación de Pearson **sobre las 16 variables continuas del dataset diario transformado** (`sima_transformado_diario.parquet`, #52), agrega el mapa de calor y los diagnósticos previos al PCA que el checklist de selección ya dejaba apuntados (`docs/checklist_seleccion_variables.md`: determinante, número de condición, KMO, Bartlett), y compara los pares más fuertes contra los ya reportados a resolución horaria.

Deliberadamente **no** repite boxplots, histogramas ni densidades: esos describen la etapa horaria y siguen siendo correctos en su propio alcance (`descript_quant.tex`). Tampoco toca el balance de clases, que ya es diario por construcción (`eda_cualitativas.tex`).

Las figuras se escriben en `reports/figuras/` y las cifras alimentan una subsección nueva de `reports/secciones/descript_quant.tex`, que convive con la subsección horaria existente sin sobrescribirla.

0. Carga

```
import sys
from pathlib import Path

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

```

from matplotlib.colors import LinearSegmentedColormap
from factor_analyzer.factor_analyzer import calculate_bartlett_sphericity,
    ↪ calculate_kmo
# No fijar matplotlib.use("Agg") aquí: es un backend no interactivo, así que
# plt.show() no emite nada, Quarto no captura ninguna figura y el PDF sale con
# los captions vacíos (PR #50).

RAIZ = Path.cwd().parent
PROC = RAIZ / "data" / "processed"
FIGS = RAIZ / "reports" / "figuras"
FIGS.mkdir(parents=True, exist_ok=True)

# El cwd de Quarto es notebooks/, así que la raíz del repo no está en sys.path.
sys.path.insert(0, str(RAIZ))

D = pd.read_parquet(PROC / "sima_transformado_diario.parquet")
print(f"diario transformado: {D.shape[0]:,} filas × {D.shape[1]} columnas")

```

diario transformado: 26,691 filas × 34 columnas

Las 16 continuas son las mismas 16 que transformó #52: se importan de `src/agregacion_diaria.RESUMENES`, no se reescriben, por la misma razón que ya documentó `transformaciones_diarias.qmd` — que agregar un resumen allá no deje esta notebook desactualizada en silencio. Son los predictores continuos que entran a #54; `MDA8/03_max_1h` (objetivo) y las categóricas quedan fuera del PCA por diseño (`objetivo_tecnicas.tex`), igual que en #52.

```

from src.agregacion_diaria import RESUMENES

CONTINUAS = [r.salida for r in RESUMENES]
print(len(CONTINUAS), "continuas:", CONTINUAS)

NUEVAS = {"NO": "NO_06_09", "SO2": "SO2_media", "RH": ["RH_media",
    ↪ "RH_min_diurna"],
    "SR": "SR_acum"}
print("\nVariables del reproceso (#46) ausentes del mapa de calor horario:")
for base, cols in NUEVAS.items():
    cols = [cols] if isinstance(cols, str) else cols
    print(f"  {base}: {cols} -> {'OK' if all(c in CONTINUAS for c in cols) else
    ↪ 'FALTA'}")

```

16 continuas: ['TOUT_max', 'SR_acum', 'NO_06_09', 'NO2_06_09', 'NOX_06_09', 'CO_06_09', 'WSR_me

Variables del reproceso (#46) ausentes del mapa de calor horario:

```

NO: ['NO_06_09'] -> OK
SO2: ['SO2_media'] -> OK
RH: ['RH_media', 'RH_min_diurna'] -> OK
SR: ['SR_acum'] -> OK

```

1. Caso completo (listwise)

La correlación se calcula sobre el **subconjunto con las 16 continuas completas**, no pairwise. Es la misma regla que ya fijó #51/#52 para el modelado (*“el modelado descarta listwise”*) y aquí importa por una razón adicional: una matriz de correlación pairwise, construida con un conjunto de casos distinto en cada celda, no está garantizada semidefinida positiva, y eso invalida sus valores propios — exactamente lo que piden los diagnósticos de la sección 5 (determinante, número de condición, KMO).

```
X = D[CONTINUAS].dropna()
print(f"n listwise: {X.shape[0]:,} de {D.shape[0]:,} "
      f"({X.shape[0]/D.shape[0]*100:.1f}%)")
```

n listwise: 15,856 de 26,691 (59.4 %)

Es menor que las 25,100 filas con MDA8 válido (docs/log_agregacion_diaria.md §5): ese conteo solo exige el objetivo, no los 16 predictores simultáneamente. No se imputa nada aquí; es la misma decisión de #51 aplicada a este análisis.

2. Matriz de correlación de Pearson

```
R = X.corr(method="pearson")
print(R.round(2).to_string())
```

	TOUT_max	SR_acum	NO_06_09	NO2_06_09	NOX_06_09	CO_06_09	WSR_media	WSR_min
TOUT_max	1.00	0.46	-0.08	-0.19	-0.16	-0.08	0.26	0.18
0.16	-0.30	-0.52	-0.18		0.12	0.07	0.07	0.18
SR_acum	0.46	1.00	-0.01	0.00	-0.02	0.07	0.24	0.09
0.14	-0.33	-0.41	-0.17		0.19	0.06	0.07	0.18
NO_06_09	-0.08	-0.01	1.00	0.74	0.95	0.32	-	
0.29	-0.27	-0.15	-0.17	-0.19	0.20		-	
0.09	0.46	0.35	0.19					
NO2_06_09	-0.19	0.00	0.74	1.00	0.89	0.24	-	
0.26	-0.26	-0.17	-0.27	-0.20	0.24		-	
0.10	0.37	0.31	0.16					
NOX_06_09	-0.16	-0.02	0.95	0.89	1.00	0.32	-	
0.31	-0.30	-0.16	-0.21	-0.19	0.24		-	
0.11	0.46	0.36	0.19					
CO_06_09	-0.08	0.07	0.32	0.24	0.32	1.00	-	
0.11	-0.20	-0.06	-0.06	-0.09	0.06		-	
0.08	0.37	0.33	0.34					
WSR_media	0.26	0.24	-0.29	-0.26	-0.31	-0.11	1.00	0.71
0.18	-0.16	-0.15	-0.48		0.17	-0.16	-	
0.29	-0.10							

WSR_min		0.15	0.09	-0.27	-0.26	-0.30	-0.20	0.71	1.00
0.06	0.01		0.03	-0.43		0.16	-0.24	-	
0.30	-0.09								
PRS_media		-0.16	-0.14	-0.15	-0.17	-0.16	-0.06	-	
0.18	-0.06	1.00	0.16		0.15	0.12	-		
0.00	-0.09		-0.17	0.11					
RH_media		-0.30	-0.33	-0.17	-0.27	-0.21	-0.06	-	
0.16	0.01	0.16	1.00		0.89	-0.06		0.07	-
0.36	-0.07		-0.23						
RH_min_diurna		-0.52	-0.41	-0.19	-0.20	-0.19	-0.09	-	
0.15	0.03	0.15	0.89		1.00	-0.04		0.05	-
0.40	-0.15		-0.24						
viento_u_media		-0.18	-0.17	0.20	0.24	0.24	0.06	-	
0.48	-0.43	0.12	-0.06		-0.04	1.00	-		
0.19	0.21		0.14	-0.02					
viento_v_media		0.12	0.19	-0.09	-0.10	-0.11	-0.08	0.17	0.16
0.00	0.07		0.05	-0.19		1.00	-0.12	-	
0.01	-0.06								
PM10_media		0.07	0.06	0.46	0.37	0.46	0.37	-	
0.16	-0.24	-0.09	-0.36		-0.40	0.21	-		
0.12	1.00		0.70	0.31					
PM2.5_media		0.07	0.07	0.35	0.31	0.36	0.33	-	
0.29	-0.30	-0.17	-0.07		-0.15	0.14	-		
0.01	0.70		1.00	0.26					
SO2_media		0.02	0.09	0.19	0.16	0.19	0.34	-	
0.10	-0.09	0.11	-0.23		-0.24	-0.02	-		
0.06	0.31		0.26	1.00					

3. Mapa de calor

```
plt.rcParams.update({"font.size": 8, "font.family": "serif",
                    "axes.spines.top": False, "axes.spines.right": False,
                    "figure.dpi": 150})
AZUL, ROJO, GRIS, CLARO = "#3b6ea5", "#b5443a", "#8c8c8c", "#d9d9d9"
cmap = LinearSegmentedColormap.from_list("azul_claro_rojo", [AZUL, CLARO, ROJO])
cmap.set_bad("white")

p = len(CONTINUAS)
mascara = np.triu(np.ones((p, p), dtype=bool), k=1)
M = np.ma.array(R.values, mask=mascara)

fig, ax = plt.subplots(figsize=(3.6, 4.0))
im = ax.imshow(M, cmap=cmap, vmin=-1, vmax=1)
ax.set_xticks(range(p)); ax.set_xticklabels(CONTINUAS, rotation=90, fontsize=5.5)
ax.set_yticks(range(p)); ax.set_yticklabels(CONTINUAS, fontsize=5.5)
ax.tick_params(length=0)
```

```

for spine in ax.spines.values():
    spine.set_visible(False)
cbar = fig.colorbar(im, ax=ax, shrink=.7, pad=.02)
cbar.ax.tick_params(labelsize=5.5)
cbar.set_label("$r$ de Pearson", fontsize=6.5)
fig.tight_layout()
fig.savefig(FIGS / "mapa_calor_correlacion_diario.pdf")
plt.show()

```




Figura 1: Mapa de calor de correlación de Pearson entre las 16 variables continuas del dataset diario transformado (triángulo inferior; $n = 14,719$ días-estación completos).

4. Pares más fuertes y comparación contra la resolución horaria

```

pares = (R.where(np.triu(np.ones(R.shape, dtype=bool), k=1))
        .stack()
        .sort_values(key=lambda s: s.abs(), ascending=False))
print("Top 12 pares por |r|, resolución diaria:")
print(pares.head(12).round(3).to_string())

```

Top 12 pares por |r|, resolución diaria:

NO_06_09	NOX_06_09	0.949
RH_media	RH_min_diurna	0.893
NO2_06_09	NOX_06_09	0.888
NO_06_09	NO2_06_09	0.739
WSR_media	WSR_min	0.714

PM10_media	PM2.5_media	0.696
TOUT_max	RH_min_diurna	-0.522
WSR_media	viento_u_media	-0.479
NO_06_09	PM10_media	0.463
TOUT_max	SR_acum	0.459
NOX_06_09	PM10_media	0.457
WSR_min	viento_u_media	-0.425

Los tres pares con análogo directo en la sección horaria (`descript_quant.tex`, §Correlación): NO2-NOX, PM10-PM2.5 y viento_u-WSR.

```
# r horario: copiado literal de reports/secciones/descript_quant.tex
# (par NO2-NOX, PM10-PM2.5, viento_u-WSR), no recalculado - ese dataset ya no
# se toca aquí.
HORARIO = {
    ("NO2_06_09", "NOX_06_09"): ("NO2 -- NOX", 0.89),
    ("PM10_media", "PM2.5_media"): ("PM10 -- PM2.5", 0.62),
    ("viento_u_media", "WSR_media"): ("viento_u -- WSR", -0.45),
}
comp = pd.DataFrame([
    {"par": nombre, "r_horario": r_h, "r_diario": round(R.loc[a, b], 3),
     "delta": round(R.loc[a, b] - r_h, 3)}
    for (a, b), (nombre, r_h) in HORARIO.items()
])
print(comp.to_string(index=False))
```

	par	r_horario	r_diario	delta
	NO2 -- NOX	0.89	0.888	-0.002
	PM10 -- PM2.5	0.62	0.696	0.076
	viento_u -- WSR	-0.45	-0.479	-0.029

PM10-PM2.5 sube de forma clara (+0.08) y viento_u-WSR sube en magnitud (+0.03); ambas consistentes con la hipótesis de la issue: promediar a día cancela ruido de medición y las correlaciones reales se acentúan. NO2-NOX es la excepción: prácticamente sin cambio (diferencia < 0.01, dentro del margen de redondeo).

Lo que sí cambia es el **orden**: el par que dominaba a resolución horaria (NO2-NOX, $r = 0.89$) ya no es el primero. Lo desplazan dos pares que no existían en el mapa de calor horario porque sus variables no estaban: NO_06_09-NOX_06_09 ($r = 0.95$) y RH_media-RH_min_diurna ($r = 0.89$). El primero es la redundancia definicional que el checklist de selección dejó señalada sin resolver (`docs/checklist_seleccion_variables.md`, criterio C3: $\text{NOX} \approx \text{NO} + \text{NO2}$) y que solo se vuelve visible ahora porque NO entra al dataset por primera vez (#46). El segundo es la misma variable (RH) resumida dos veces sobre ventanas distintas del día, no dos fenómenos independientes. WSR_media-WSR_min ($r = 0.71$) es el mismo caso para viento. Estas tres son redundancia de construcción, no relación física nueva entre contaminantes; es PM10-PM2.5 ($r = 0.70$) la que repite la lectura ya dada a resolución horaria (material particulado de origen común).

5. Diagnósticos previos al PCA

Los cuatro que deja pendientes docs/checklist_seleccion_variables.md para esta etapa (“Multicolinealidad: determinante, número de condición, VIF, KMO, Bartlett”).

```
det = np.linalg.det(R.values)
eigvals = np.linalg.eigvalsh(R.values)
cond = eigvals.max() / eigvals.min()
print(f"determinante:          {det:.3e}")
print(f"valor propio mínimo:   {eigvals.min():.4f}")
print(f"valor propio máximo:   {eigvals.max():.4f}")
print(f"número de condición:    {cond:.1f}")
```

```
determinante:          2.318e-05
valor propio mínimo:   0.0134
valor propio máximo:   4.3183
número de condición:   322.8
```

```
chi2, p_valor = calculate_bartlett_sphericity(X)
gl = len(CONTINUAS) * (len(CONTINUAS) - 1) // 2
print(f"Bartlett: chi2 = {chi2:,.1f}, gl = {gl}, p = {p_valor:.3g}")

kmo_var, kmo_total = calculate_kmo(X)
print(f"\nKMO total: {kmo_total:.3f}")
kmo_tabla = pd.Series(kmo_var, index=CONTINUAS).sort_values()
print("\nKMO por variable (ascendente):")
print(kmo_tabla.round(3).to_string())
```

```
Bartlett: chi2 = 169,140.7, gl = 120, p = 0
```

```
KMO total: 0.660
```

```
KMO por variable (ascendente):
```

RH_media	0.587
PRS_media	0.589
TOUT_max	0.596
RH_min_diurna	0.606
NOX_06_09	0.608
NO_06_09	0.615
NO2_06_09	0.620
PM2.5_media	0.667
WSR_media	0.704
WSR_min	0.736
viento_v_media	0.750
PM10_media	0.752
SO2_media	0.761

CO_06_09	0.809
SR_acum	0.818
viento_u_media	0.847

Determinante cercano a 0 y número de condición de 323 son evidencia de multicolinealidad fuerte — la contraparte numérica de los pares de la sección 4. Bartlett rechaza esfericidad ($p < 0.001$: la matriz de correlación no es la identidad, hay estructura que reducir) y el KMO total (0.660) libra el umbral convencional de 0.6. A nivel variable, RH_media (0.587), PRS_media (0.589) y TOUT_max (0.596) quedan justo debajo de ese umbral — no arrastran el total por debajo del corte, pero quedan documentadas como las más débiles del conjunto.

6. Criterios de aceptación

OK	Bartlett rechaza esfericidad ($p < 0.05$)
OK	KMO total ≥ 0.6 (aceptable)
OK	NO, SO ₂ , RH y SR aparecen en la matriz
OK	Matriz de correlación es simétrica y con diagonal 1

7. Qué queda para el reporte

reports/secciones/descript_quant.tex gana una subsección corta después de “Correlación” (la horaria, que no se toca) con Figura 1, la tabla de comparación de la sección 4 y los diagnósticos de la sección 5. Esa subsección, no la horaria, es la que formalmente justifica el PCA de #54.