

# Correlación a resolución diaria

Issue #53 — MA2003B, equipo 7

## Tabla de contenidos

|                                                                           |   |
|---------------------------------------------------------------------------|---|
| 0. Carga . . . . .                                                        | 1 |
| 1. Caso completo (listwise) . . . . .                                     | 3 |
| 2. Matriz de correlación de Pearson . . . . .                             | 3 |
| 3. Mapa de calor . . . . .                                                | 4 |
| 4. Pares más fuertes y comparación contra la resolución horaria . . . . . | 5 |
| 5. Diagnósticos previos al PCA . . . . .                                  | 7 |
| 6. Criterios de aceptación . . . . .                                      | 8 |
| 7. Qué queda para el reporte . . . . .                                    | 8 |
| Uso de IA en este notebook . . . . .                                      | 8 |

**Issue #53.** Depende de #52. La correlación que hoy justifica el PCA en `reports/secciones/descript_quant.tex` es horaria ( $n = 574,343$  hora-estación): sus cifras no respaldan un PCA que va a correr sobre la tabla diaria (#54). Esta notebook recalcula la matriz de correlación de Pearson **sobre las 16 variables continuas del dataset diario transformado** (`sima_transformado_diario.parquet`, #52), agrega el mapa de calor y los diagnósticos previos al PCA que el checklist de selección ya dejaba apuntados (`docs/checklist_seleccion_variables.md`: determinante, número de condición, KMO, Bartlett), y compara los pares más fuertes contra los ya reportados a resolución horaria.

Deliberadamente **no** repite boxplots, histogramas ni densidades: esos describen la etapa horaria y siguen siendo correctos en su propio alcance (`descript_quant.tex`). Tampoco toca el balance de clases, que ya es diario por construcción (`eda_cualitativas.tex`).

Las figuras se escriben en `reports/figuras/` y las cifras alimentan una subsección nueva de `reports/secciones/descript_quant.tex`, que convive con la subsección horaria existente sin sobrescribirla.

## 0. Carga

```
import sys
from pathlib import Path

import numpy as np
import pandas as pd
```

```

import matplotlib.pyplot as plt
from matplotlib.colors import LinearSegmentedColormap
from factor_analyzer.factor_analyzer import calculate_bartlett_sphericity,
    ↪ calculate_kmo
# No fijar matplotlib.use("Agg") aquí: es un backend no interactivo, así que
# plt.show() no emite nada, Quarto no captura ninguna figura y el PDF sale con
# los captions vacíos (PR #50).

RAIZ = Path.cwd().parent
PROC = RAIZ / "data" / "processed"
FIGS = RAIZ / "reports" / "figuras"
FIGS.mkdir(parents=True, exist_ok=True)

# El cwd de Quarto es notebooks/, así que la raíz del repo no está en sys.path.
sys.path.insert(0, str(RAIZ))

D = pd.read_parquet(PROC / "sima_transformado_diario.parquet")
print(f"diario transformado: {D.shape[0]:,} filas × {D.shape[1]} columnas")

```

diario transformado: 23,931 filas × 34 columnas

Las 16 continuas son las mismas 16 que transformó #52: se importan de `src/agregacion_diaria.RESUMENES`, no se reescriben, por la misma razón que ya documentó `transformaciones_diarias.qmd` — que agregar un resumen allá no deje esta notebook desactualizada en silencio. Son los predictores continuos que entran a #54; `MDA8/03_max_1h` (objetivo) y las categóricas quedan fuera del PCA por diseño (`objetivo_tecnicas.tex`), igual que en #52.

```

from src.agregacion_diaria import RESUMENES

CONTINUAS = [r.salida for r in RESUMENES]
print(len(CONTINUAS), "continuas:", CONTINUAS)

NUEVAS = {"NO": "NO_06_09", "SO2": "SO2_media", "RH": ["RH_media",
    ↪ "RH_min_diurna"],
    "SR": "SR_acum"}
print("\nVariables del reproceso (#46) ausentes del mapa de calor horario:")
for base, cols in NUEVAS.items():
    cols = [cols] if isinstance(cols, str) else cols
    print(f" {base}: {cols} -> {'OK' if all(c in CONTINUAS for c in cols) else
    ↪ 'FALTA'}")

```

16 continuas: ['TOUT\_max', 'SR\_acum', 'NO\_06\_09', 'NO2\_06\_09', 'NOX\_06\_09', 'CO\_06\_09', 'WSR\_me

Variables del reproceso (#46) ausentes del mapa de calor horario:

NO: ['NO\_06\_09'] -> OK

SO2: ['SO2\_media'] -> OK

```
RH: ['RH_media', 'RH_min_diurna'] -> OK
SR: ['SR_acum'] -> OK
```

## 1. Caso completo (listwise)

La correlación se calcula sobre el **subconjunto con las 16 continuas completas**, no pairwise. Es la misma regla que ya fijó #51/#52 para el modelado (“*el modelado descarta listwise*”) y aquí importa por una razón adicional: una matriz de correlación pairwise, construida con un conjunto de casos distinto en cada celda, no está garantizada semidefinida positiva, y eso invalida sus valores propios — exactamente lo que piden los diagnósticos de la sección 5 (determinante, número de condición, KMO).

```
X = D[CONTINUAS].dropna()
print(f"n listwise: {X.shape[0]:,} de {D.shape[0]:,} "
      f"({X.shape[0]/D.shape[0]*100:.1f} %)")
```

n listwise: 14,719 de 23,931 (61.5 %)

Es menor que las 22,529 filas con MDA8 válido (docs/log\_agregacion\_diaria.md §5): ese conteo solo exige el objetivo, no los 16 predictores simultáneamente. No se imputa nada aquí; es la misma decisión de #51 aplicada a este análisis.

## 2. Matriz de correlación de Pearson

```
R = X.corr(method="pearson")
print(R.round(2).to_string())
```

|           | TOUT_max | SR_acum | NO_06_09 | NO2_06_09 | NOX_06_09 | CO_06_09 | WSR_media | WSR_min |
|-----------|----------|---------|----------|-----------|-----------|----------|-----------|---------|
| TOUT_max  | 1.00     | 0.49    | -0.07    | -0.18     | -0.15     | -0.05    | 0.26      | 0.15    |
| 0.17      | -0.31    | -0.52   | -0.19    |           | 0.11      | 0.10     | 0.08      | 0.0     |
| SR_acum   |          | 1.00    | -0.01    | -0.01     | -0.03     | 0.08     | 0.26      | 0.10    |
| 0.16      | -0.35    | -0.44   | -0.19    |           | 0.18      | 0.05     | 0.06      | 0.0     |
| NO_06_09  |          |         | 1.00     | 0.74      | 0.95      | 0.32     | -         |         |
| 0.28      | -0.28    | -0.15   | -0.17    | -0.19     | 0.20      |          | -         |         |
| 0.08      | 0.47     | 0.35    | 0.19     |           |           |          |           |         |
| NO2_06_09 |          |         |          | 1.00      | 0.89      | 0.23     | -         |         |
| 0.26      | -0.27    | -0.16   | -0.27    | -0.20     | 0.23      |          | -         |         |
| 0.09      | 0.36     | 0.31    | 0.16     |           |           |          |           |         |
| NOX_06_09 |          |         |          |           | 1.00      | 0.31     | -         |         |
| 0.31      | -0.30    | -0.16   | -0.21    | -0.19     | 0.23      |          | -         |         |
| 0.10      | 0.45     | 0.36    | 0.19     |           |           |          |           |         |
| CO_06_09  |          |         |          |           |           | 1.00     | -         |         |
| 0.12      | -0.21    | -0.08   | -0.06    | -0.11     | 0.06      |          | -         |         |
| 0.07      | 0.34     | 0.32    | 0.34     |           |           |          |           |         |

|                |       |       |       |       |       |       |       |      |      |
|----------------|-------|-------|-------|-------|-------|-------|-------|------|------|
| WSR_media      |       | 0.26  | 0.26  | -0.28 | -0.26 | -0.31 | -0.12 | 1.00 | 0.72 |
| 0.18           | -0.16 |       | -0.15 | -0.48 |       | 0.17  | -0.18 | -    |      |
| 0.31           | -0.10 |       |       |       |       |       |       |      |      |
| WSR_min        |       | 0.15  | 0.10  | -0.28 | -0.27 | -0.30 | -0.21 | 0.72 | 1.00 |
| 0.06           | 0.01  |       | 0.03  | -0.43 |       | 0.16  | -0.26 | -    |      |
| 0.31           | -0.10 |       |       |       |       |       |       |      |      |
| PRS_media      |       | -0.17 | -0.16 | -0.15 | -0.16 | -0.16 | -0.08 | -    |      |
| 0.18           | -0.06 |       | 1.00  | 0.16  | 0.15  | 0.12  | -     |      |      |
| 0.01           | -0.09 |       | -0.17 | 0.12  |       |       |       |      |      |
| RH_media       |       | -0.31 | -0.35 | -0.17 | -0.27 | -0.21 | -0.06 | -    |      |
| 0.16           | 0.01  |       | 0.16  | 1.00  | 0.89  | -0.06 |       | 0.07 | -    |
| 0.37           | -0.07 |       | -0.23 |       |       |       |       |      |      |
| RH_min_diurna  |       | -0.52 | -0.44 | -0.19 | -0.20 | -0.19 | -0.11 | -    |      |
| 0.15           | 0.03  |       | 0.15  | 0.89  | 1.00  | -0.04 |       | 0.05 | -    |
| 0.41           | -0.14 |       | -0.24 |       |       |       |       |      |      |
| viento_u_media |       | -0.19 | -0.19 | 0.20  | 0.23  | 0.23  | 0.06  | -    |      |
| 0.48           | -0.43 |       | 0.12  | -0.06 | -0.04 | 1.00  | -     |      |      |
| 0.20           | 0.23  |       | 0.15  | -0.01 |       |       |       |      |      |
| viento_v_media |       | 0.11  | 0.18  | -0.08 | -0.09 | -0.10 | -0.07 | 0.17 | 0.16 |
| 0.01           | 0.07  |       | 0.05  | -0.20 |       | 1.00  | -0.11 | -    |      |
| 0.01           | -0.06 |       |       |       |       |       |       |      |      |
| PM10_media     |       | 0.10  | 0.05  | 0.47  | 0.36  | 0.45  | 0.34  | -    |      |
| 0.18           | -0.26 |       | -0.09 | -0.37 | -0.41 | 0.23  | -     |      |      |
| 0.11           | 1.00  |       | 0.69  | 0.29  |       |       |       |      |      |
| PM2.5_media    |       | 0.08  | 0.06  | 0.35  | 0.31  | 0.36  | 0.32  | -    |      |
| 0.31           | -0.31 |       | -0.17 | -0.07 | -0.14 | 0.15  | -     |      |      |
| 0.01           | 0.69  |       | 1.00  | 0.24  |       |       |       |      |      |
| SO2_media      |       | 0.02  | 0.11  | 0.19  | 0.16  | 0.19  | 0.34  | -    |      |
| 0.10           | -0.10 |       | 0.12  | -0.23 | -0.24 | -0.01 | -     |      |      |
| 0.06           | 0.29  |       | 0.24  | 1.00  |       |       |       |      |      |

### 3. Mapa de calor

```
plt.rcParams.update({"font.size": 8, "font.family": "serif",
                    "axes.spines.top": False, "axes.spines.right": False,
                    "figure.dpi": 150})
AZUL, ROJO, GRIS, CLARO = "#3b6ea5", "#b5443a", "#8c8c8c", "#d9d9d9"
cmap = LinearSegmentedColormap.from_list("azul_claro_rojo", [AZUL, CLARO, ROJO])
cmap.set_bad("white")

p = len(CONTINUAS)
mascara = np.triu(np.ones((p, p), dtype=bool), k=1)
M = np.ma.array(R.values, mask=mascara)

fig, ax = plt.subplots(figsize=(3.4, 4.3))
im = ax.imshow(M, cmap=cmap, vmin=-1, vmax=1)
```

```

ax.set_xticks(range(p)); ax.set_xticklabels(CONTINUAS, rotation=90, fontsize=5.5)
ax.set_yticks(range(p)); ax.set_yticklabels(CONTINUAS, fontsize=5.5)
ax.tick_params(length=0)
for spine in ax.spines.values():
    spine.set_visible(False)
cbar = fig.colorbar(im, ax=ax, shrink=.6, pad=.03, location="bottom")
cbar.ax.tick_params(labelsize=5.5)
cbar.set_label("$r$ de Pearson", fontsize=6.5)
fig.tight_layout()
fig.savefig(FIGS / "mapa_calor_correlacion_diario.pdf")
plt.show()

```




Figura 1: Mapa de calor de correlación de Pearson entre las 16 variables continuas del dataset diario transformado (triángulo inferior;  $n = 14,719$  días-estación completos).

#### 4. Pares más fuertes y comparación contra la resolución horaria

```

pares = (R.where(np.triu(np.ones(R.shape, dtype=bool), k=1))
        .stack()
        .sort_values(key=lambda s: s.abs(), ascending=False))
print("Top 12 pares por |r|, resolución diaria:")
print(pares.head(12).round(3).to_string())

```

```

Top 12 pares por |r|, resolución diaria:
NO_06_09    NOX_06_09    0.949

```

|            |                |        |
|------------|----------------|--------|
| RH_media   | RH_min_diurna  | 0.893  |
| NO2_06_09  | NOX_06_09      | 0.886  |
| NO_06_09   | NO2_06_09      | 0.735  |
| WSR_media  | WSR_min        | 0.716  |
| PM10_media | PM2.5_media    | 0.690  |
| TOUT_max   | RH_min_diurna  | -0.523 |
|            | SR_acum        | 0.490  |
| WSR_media  | viento_u_media | -0.478 |
| NO_06_09   | PM10_media     | 0.465  |
| NOX_06_09  | PM10_media     | 0.454  |
| SR_acum    | RH_min_diurna  | -0.438 |

Los tres pares con análogo directo en la sección horaria (`descript_quant.tex`, §Correlación): NO2-NOX, PM10-PM2.5 y viento\_u-WSR.

```
# r horario: copiado literal de reports/secciones/descript_quant.tex
# (par NO2-NOX, PM10-PM2.5, viento_u-WSR), no recalculado - ese dataset ya no
# se toca aquí.
HORARIO = {
    ("NO2_06_09", "NOX_06_09"): ("NO2 -- NOX", 0.89),
    ("PM10_media", "PM2.5_media"): ("PM10 -- PM2.5", 0.62),
    ("viento_u_media", "WSR_media"): ("viento_u -- WSR", -0.45),
}
comp = pd.DataFrame([
    {"par": nombre, "r_horario": r_h, "r_diario": round(R.loc[a, b], 3),
     "delta": round(R.loc[a, b] - r_h, 3)}
    for (a, b), (nombre, r_h) in HORARIO.items()
])
print(comp.to_string(index=False))
```

|  | par             | r_horario | r_diario | delta  |
|--|-----------------|-----------|----------|--------|
|  | NO2 -- NOX      | 0.89      | 0.886    | -0.004 |
|  | PM10 -- PM2.5   | 0.62      | 0.690    | 0.070  |
|  | viento_u -- WSR | -0.45     | -0.478   | -0.028 |

PM10-PM2.5 sube de forma clara (+0.07) y viento\_u-WSR sube en magnitud (+0.03); ambas consistentes con la hipótesis de la issue: promediar a día cancela ruido de medición y las correlaciones reales se acentúan. NO2-NOX es la excepción: prácticamente sin cambio (diferencia < 0.01, dentro del margen de redondeo).

Lo que sí cambia es el **orden**: el par que dominaba a resolución horaria (NO2-NOX,  $r = 0.89$ ) ya no es el primero. Lo desplazan dos pares que no existían en el mapa de calor horario porque sus variables no estaban: NO\_06\_09-NOX\_06\_09 ( $r = 0.95$ ) y RH\_media-RH\_min\_diurna ( $r = 0.89$ ). El primero es la redundancia definicional que el checklist de selección dejó señalada sin resolver (`docs/checklist_seleccion_variables.md`, criterio C3:  $\text{NOX} \approx \text{NO} + \text{NO2}$ ) y que solo se vuelve visible ahora porque NO entra al dataset por primera vez (#46). El segundo es la misma variable (RH) resumida dos veces sobre ventanas distintas del día, no dos fenómenos independientes.

WSR\_media-WSR\_min ( $r = 0.72$ ) es el mismo caso para viento. Estas tres son redundancia de construcción, no relación física nueva entre contaminantes; es PM10-PM2.5 ( $r = 0.69$ ) la que repite la lectura ya dada a resolución horaria (material particulado de origen común).

## 5. Diagnósticos previos al PCA

Los cuatro que deja pendientes docs/checklist\_seleccion\_variables.md para esta etapa (“Multicolinealidad: determinante, número de condición, VIF, KMO, Bartlett”).

```
det = np.linalg.det(R.values)
eigvals = np.linalg.eigvalsh(R.values)
cond = eigvals.max() / eigvals.min()
print(f"determinante:      {det:.3e}")
print(f"valor propio mínimo: {eigvals.min():.4f}")
print(f"valor propio máximo: {eigvals.max():.4f}")
print(f"número de condición: {cond:.1f}")
```

```
determinante:      2.192e-05
valor propio mínimo: 0.0133
valor propio máximo: 4.3169
número de condición: 324.3
```

```
chi2, p_valor = calculate_bartlett_sphericity(X)
gl = len(CONTINUAS) * (len(CONTINUAS) - 1) // 2
print(f"Bartlett: chi2 = {chi2:,.1f}, gl = {gl}, p = {p_valor:.3g}")

kmo_var, kmo_total = calculate_kmo(X)
print(f"\nKMO total: {kmo_total:.3f}")
kmo_tabla = pd.Series(kmo_var, index=CONTINUAS).sort_values()
print("\nKMO por variable (ascendente):")
print(kmo_tabla.round(3).to_string())
```

```
Bartlett: chi2 = 157,831.6, gl = 120, p = 0
```

```
KMO total: 0.661
```

```
KMO por variable (ascendente):
```

```
RH_media      0.589
PRS_media     0.590
NOX_06_09     0.606
TOUT_max      0.606
RH_min_diurna 0.613
NO_06_09      0.614
NO2_06_09     0.615
PM2.5_media   0.668
```

|                |       |
|----------------|-------|
| WSR_media      | 0.711 |
| WSR_min        | 0.742 |
| S02_media      | 0.750 |
| PM10_media     | 0.751 |
| viento_v_media | 0.760 |
| CO_06_09       | 0.805 |
| SR_acum        | 0.818 |
| viento_u_media | 0.845 |

Determinante cercano a 0 y número de condición de 324 son evidencia de multicolinealidad fuerte — la contraparte numérica de los pares de la sección 4. Bartlett rechaza esfericidad ( $p < 0.001$ : la matriz de correlación no es la identidad, hay estructura que reducir) y el KMO total (0.661) libra el umbral convencional de 0.6. A nivel variable, RH\_media (0.589) y PRS\_media (0.590) quedan justo debajo de ese umbral — no arrastran el total por debajo del corte, pero quedan documentadas como las más débiles del conjunto.

## 6. Criterios de aceptación

OK Bartlett rechaza esfericidad ( $p < 0.05$ )  
 OK KMO total  $\geq 0.6$  (aceptable)  
 OK NO, S02, RH y SR aparecen en la matriz  
 OK Matriz de correlación es simétrica y con diagonal 1

## 7. Qué queda para el reporte

reports/secciones/descript\_quant.tex gana una subsección corta después de “Correlación” (la horaria, que no se toca) con Figura 1, la tabla de comparación de la sección 4 y los diagnósticos de la sección 5. Esa subsección, no la horaria, es la que formalmente justifica el PCA de #54.

## Uso de IA en este notebook

Se usó Claude Code como asistente para: (1) explorar `descript_quant.tex`, `docs/log_agregacion_diaria.md` y `docs/checklist_seleccion_variables.md` antes de escribir, para fijar qué variables entran, qué comparar contra lo horario y qué diagnósticos ya estaban pendientes de una etapa anterior; (2) escribir el código de la matriz, el mapa de calor (paleta y triángulo inferior siguiendo el estilo de casa) y los diagnósticos con `factor_analyzer`; y (3) redactar la comparación de la sección 4, incluida la lectura de que NO-NOX y RH\_media-RH\_min\_diurna desplazan a NO2-NOX del primer lugar — un hallazgo que salió de correr el código, no estaba anticipado en la issue. Cada cifra citada en el texto y en `descript_quant.tex` se verificó corriendo el código contra `sima_transformado_diario.parquet` antes de escribirla.