

Análisis factorial: adecuación de la matriz de correlación

Bloque 6b — MA2003B, equipo 7

Tabla de contenidos

0. Carga y bloque de predictores	2
1. Partición y re-estandarización	3
2. La estructura de la matriz de correlación	3
3. Factores de inflación de varianza	4
3.1 El VIF alto no es un accidente estadístico	4
4. Prueba de esfericidad de Bartlett	5
5. Medida de adecuación muestral de Kaiser–Meyer–Olkin	6
6. Qué sigue	7

El análisis de componentes principales de #54 describe su producto como **ejes con nombre**: carga primaria de combustión, forzamiento fotoquímico, estancamiento atmosférico. Esa es una afirmación factorial, no una afirmación sobre componentes. Decir que existe un eje de estancamiento que las variables manifiestan es postular una **variable latente**; el PCA no postula nada, solo rota los datos hacia la dirección de máxima varianza y deja que el lector le ponga nombre a la dirección.

La diferencia no es de vocabulario. El PCA descompone la varianza **total** y cada componente es una combinación lineal exacta de las variables observadas. El análisis factorial descompone solo la varianza **común** y separa, para cada variable, una **unicidad** que ningún factor explica. Preguntarle a los datos cuánta varianza de la presión barométrica es compartida y cuánta es idiosincrática es una pregunta que el PCA no puede contestar, porque su modelo no la admite.

Este documento **no extrae factores todavía**. Antes de descomponer hay que establecer que la matriz de correlación admite una descomposición factorial, y ese es un requisito que el PCA no impone y que por lo tanto #54 nunca verificó. El orden es deliberado: si la adecuación se midiera después de ver las cargas, el resultado decidiría el criterio.

Opera sobre `sima_transformado_diario.parquet`, la salida de #52, con el mismo bloque de predictores y la misma partición que #54, para que la comparación entre ambos enfoques sea sobre el método y no sobre los datos.

0. Carga y bloque de predictores

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt
from scipy import stats
from pathlib import Path

RAIZ = Path.cwd().parent
PROC = RAIZ / "data" / "processed"
FIGS = RAIZ / "reports" / "figuras"
FIGS.mkdir(parents=True, exist_ok=True)

plt.rcParams.update({"font.size": 9, "font.family": "serif",
                    "axes.spines.top": False, "axes.spines.right": False,
                    "figure.dpi": 150})
AZUL, ROJO, GRIS, CLARO = "#3b6ea5", "#b5443a", "#8c8c8c", "#d9d9d9"

D = pd.read_parquet(PROC / "sima_transformado_diario.parquet")
D["anio"] = D.fecha.dt.year
print(f"diario transformado: {D.shape}")
```

diario transformado: (23931, 34)

El bloque se define por exclusión, con los mismos tres criterios de #54 y por las mismas razones: las categóricas no tienen una dirección de máxima varianza que signifique algo, las derivadas de O3 son la respuesta y meterlas sería fuga de información, y PM2.5_media se excluye porque exigirla completa no descarta observaciones sino **estaciones enteras** — NE3 no tiene un solo registro y NO3 apenas 12.5%.

```
RESPUESTA = ["MDA8", "O3_max_1h", "excede_anio_1", "excede_anio_3",
             "excede_anio_5", "excede_1h"]
CATEGORICAS = ["zona", "tipo_dia", "temporada", "festivo", "fin_de_semana",
               "llovio"]
IDENTIFICA = ["estacion", "fecha", "anio", "mes", "msnm", "ventanas_validas"]
SIN = "PM2.5_media"

PRED = [c for c in D.columns
        if c not in RESPUESTA + CATEGORICAS + IDENTIFICA + [SIN]]
print(f"{len(PRED)} predictores: {PRED}")
```

15 predictores: ['TOUT_max', 'SR_acum', 'NO_06_09', 'NO2_06_09', 'NOX_06_09', 'CO_06_09', 'WSR_

1. Partición y re-estandarización

Idéntica a #54: el ajuste usa **solo 2021–2024** y 2025 queda para aplicar. Las continuas ya vienen estandarizadas de #52, pero con los momentos del periodo completo; restringidas a entrenamiento la media no es cero ni la desviación uno, y todo lo que sigue opera sobre la matriz de correlación.

```
es_tr      = D.anio.between(2021, 2024)
completa   = D[PRED].notna().all(axis=1)

TR = D[es_tr & completa]
VA = D[~es_tr & completa]

mu, sd = TR[PRED].mean(), TR[PRED].std(ddof=0)
X = ((TR[PRED] - mu) / sd).to_numpy()
n, p = X.shape

print(f"ajuste 2021-2024: {n:,} filas x {p} variables"
      f"      aplicación 2025: {len(VA):,} filas")
print(f"control - |media| máx {np.abs(X.mean(0)).max():.1e}, "
      f"|sd-1| máx {np.abs(X.std(0, ddof=0) - 1).max():.1e}")
```

```
ajuste 2021-2024: 16,008 filas x 15 variables      aplicación 2025: 1,340 filas
control - |media| máx 4.6e-17, |sd-1| máx 2.2e-16
```

2. La estructura de la matriz de correlación

Tres números describen la matriz antes de cualquier prueba formal. El **determinante** mide cuánta redundancia hay en conjunto: vale 1 si las variables son independientes y tiende a 0 conforme alguna se vuelve predecible desde las demás. El **eigenvalor mínimo** y el **número de condición** miden lo mismo por el lado numérico.

```
R = np.corrcoef(X, rowvar=False)
ev = np.linalg.eigvalsh(R)
det = np.linalg.det(R)

print(f"determinante(R) = {det:.3e}")
print(f"eigenvalor mínimo = {ev.min():.4f}")
print(f"número de condición = {ev.max() / ev.min():.1f}")
```

```
determinante(R) = 6.424e-05
eigenvalor mínimo = 0.0133
número de condición = 293.5
```

El determinante es del orden de 10^{-5} : hay redundancia fuerte, que es justamente lo que motivó el análisis. Pero no es cero ni cercano a la precisión de máquina, de modo que la matriz es invertible y el VIF y el KMO —que dependen de R^{-1} — se pueden calcular sin que el resultado sea ruido numérico.

3. Factores de inflación de varianza

El VIF de una variable es $1/(1 - R_i^2)$, donde R_i^2 es el coeficiente de determinación de esa variable regresada contra **todas las demás**. Sobre datos estandarizados no hace falta ajustar quince regresiones: los VIF son exactamente la diagonal de la inversa de la matriz de correlación.

```
Rinv = np.linalg.inv(R)
vif = pd.Series(np.diag(Rinv), index=PRED).sort_values(ascending=False)
vif_tab = pd.DataFrame({"VIF": vif, "R2": 1 - 1 / vif})
print(vif_tab.round(3).to_string())
```

	VIF	R2
NOX_06_09	47.157	0.979
NO_06_09	21.791	0.954
NO2_06_09	10.299	0.903
RH_min_diurna	8.366	0.880
RH_media	6.622	0.849
WSR_media	2.554	0.608
TOUT_max	2.238	0.553
WSR_min	2.128	0.530
PM10_media	1.672	0.402
SR_acum	1.528	0.346
viento_u_media	1.495	0.331
CO_06_09	1.408	0.290
SO2_media	1.322	0.244
PRS_media	1.231	0.188
viento_v_media	1.095	0.087

La convención más usada marca 5 como preocupante y 10 como severo. Aquí el resultado no está repartido: se concentra. NOX alcanza 47.2, lo que equivale a decir que el 97.9% de su varianza es predecible desde las otras catorce variables; las diez últimas de la tabla viven por debajo de 2.6.

```
print(f"VIF > 10: {list(vif[vif > 10].index)}")
print(f"VIF entre 5 y 10: {list(vif[(vif > 5) & (vif <= 10)].index)}")
print(f"mediana de los restantes: {vif[vif <= 5].median():.2f}")
```

```
VIF > 10: ['NOX_06_09', 'NO_06_09', 'NO2_06_09']
VIF entre 5 y 10: ['RH_min_diurna', 'RH_media']
mediana de los restantes: 1.51
```

3.1 El VIF alto no es un accidente estadístico

NOX es, por definición química, la suma de NO y NO2. La correlación lo confirma sobre estos datos:

```

Xd = pd.DataFrame(X, columns=PRED)
r_suma = np.corrcoef(Xd.NOX_06_09, Xd.NO_06_09 + Xd.NO2_06_09)[0, 1]
print(f"corr(NOX, NO + NO2) = {r_suma:.4f}")
print(f"corr(NOX, NO) = {Xd.NOX_06_09.corr(Xd.NO_06_09):.4f}")
print(f"corr(NOX, NO2) = {Xd.NOX_06_09.corr(Xd.NO2_06_09):.4f}")
print(f"corr(RH_media, RH_min_diurna) = "
      f"{Xd.RH_media.corr(Xd.RH_min_diurna):.4f}")

```

```

corr(NOX, NO + NO2) = 0.9848
corr(NOX, NO) = 0.9419
corr(NOX, NO2) = 0.8744
corr(RH_media, RH_min_diurna) = 0.8917

```

Esto es lo que distingue al análisis factorial del PCA en la práctica. El PCA absorbe la redundancia sin protestar: concentra NO, NO2 y NOX en un solo componente y produce un resultado numéricamente válido. El modelo factorial reparte la varianza de cada variable entre comunidad y unicidad, y una variable que es combinación lineal casi exacta de otras dos no deja unicidad que repartir — el ajuste devuelve comunialidades mayores que 1, que son imposibles. Son los **casos Heywood**, y aparecen aquí.

4. Prueba de esfericidad de Bartlett

Contrasta $H_0 : R = I$, es decir, que las variables no correlacionan entre sí y no hay nada que factorizar. El estadístico es $\chi^2 = -[(n-1) - (2p+5)/6] \ln |R|$ con $p(p-1)/2$ grados de libertad.

```

chi2 = -((n - 1) - (2 * p + 5) / 6) * np.log(det)
gl = p * (p - 1) / 2
pval = stats.chi2.sf(chi2, gl)
print(f"chi2 = {chi2:,.0f}    gl = {gl:.0f}    p = {pval:.3g}")

```

```

chi2 = 154,458    gl = 105    p = 0

```

El rechazo es contundente y no informa casi nada. Conviene decirlo antes de que la cifra se cite como evidencia. El estadístico crece linealmente con n , y con 16,008 observaciones cualquier apartamiento de la identidad, por trivial que sea, produce un χ^2 enorme. La prueba solo descartaría el caso patológico de variables ortogonales entre sí, que ya sabíamos que no era el nuestro: NO2 y NOX correlacionan a 0.89.

Hay una segunda razón para no apoyarse en ella. Bartlett supone observaciones independientes, y las filas son un panel día-estación con autocorrelación temporal y espacial: la calidad del aire de hoy se parece a la de ayer y la de NE3 a la de NE2. El n efectivo es bastante menor que 16,008, así que el χ^2 está inflado además por esa vía.

Se reporta porque el procedimiento estándar la incluye, no porque decida algo. Quien decide es el KMO.

5. Medida de adecuación muestral de Kaiser–Meyer–Olkin

El KMO compara las correlaciones simples contra las **parciales**. La idea: si un factor común genera la covariación, controlar por las demás variables debe dejar poco residuo, y las parciales serán chicas frente a las simples. Si en cambio cada correlación es un asunto bilateral entre dos variables, las parciales sobreviven y no hay estructura común que extraer.

$$\text{KMO} = \frac{\sum_{i \neq j} r_{ij}^2}{\sum_{i \neq j} r_{ij}^2 + \sum_{i \neq j} a_{ij}^2}$$

donde a_{ij} es la correlación parcial, que se obtiene de R^{-1} sin ajustar regresión alguna: es la anti-imagen normalizada.

```
d = np.sqrt(np.diag(Rinv))
A = -Rinv / np.outer(d, d)          # correlaciones parciales
np.fill_diagonal(A, 0)
Ro = R.copy()
np.fill_diagonal(Ro, 0)

kmo_global = (Ro ** 2).sum() / ((Ro ** 2).sum() + (A ** 2).sum())
kmo_var = (Ro ** 2).sum(0) / ((Ro ** 2).sum(0) + (A ** 2).sum(0))
print(f"KMO global = {kmo_global:.3f}")
```

KMO global = 0.646

La escala convencional de Kaiser: <0.50 inaceptable, 0.50–0.60 pobre, 0.60–0.70 mediocre, 0.70–0.80 aceptable, 0.80–0.90 meritorio, >0.90 admirable.

0.646 cae en «mediocre». Pasa el umbral mínimo, y no es un resultado que convenga adornar: el bloque admite factorización, pero sin holgura. El KMO por variable dice dónde se pierde.

```
kmo_tab = pd.Series(kmo_var, index=PRED).sort_values()
print(kmo_tab.round(3).to_string())
print(f"\nbajo 0.60: {list(kmo_tab[kmo_tab < .60].index)}")
```

NO_06_09	0.571
NOX_06_09	0.580
NO2_06_09	0.584
RH_media	0.598
RH_min_diurna	0.602
TOUT_max	0.617
PRS_media	0.645
WSR_min	0.698
WSR_media	0.713
SO2_media	0.722
CO_06_09	0.735

viento_v_media	0.739
SR_acum	0.816
viento_u_media	0.827
PM10_media	0.903

bajo 0.60: ['NO_06_09', 'NOX_06_09', 'NO2_06_09', 'RH_media']

Las tres peores son NO, NOX y NO2 — las mismas tres que encabezan el VIF, y en el mismo orden. No es coincidencia: una variable casi determinada por otras dos produce correlaciones parciales grandes con ellas, que es exactamente lo que el KMO penaliza. Ambos índices se leen de R^2 , así que están midiendo la misma redundancia desde dos ángulos. RH_media completa el grupo bajo 0.60, otra vez en compañía de la variable con la que se solapa.

Kaiser recomienda considerar la eliminación de variables con KMO individual bajo 0.50; ninguna llega a ese punto, de modo que el criterio no obliga a podar nada por sí solo. La poda que sigue se justifica por el VIF y por la identidad química, no por el KMO.

6. Qué sigue

Establecido lo anterior, la extracción de factores queda para el siguiente documento, y entra con dos decisiones ya justificadas por lo que se midió aquí:

1. **NOX_06_09 sale del bloque.** Es la suma de NO y NO2 ($r = 0.985$ contra la suma), tiene el VIF más alto y un KMO individual de 0.580. No aporta información que NO y NO2 no tengan; sí aporta el caso Heywood que impide ajustar el modelo. La poda no pierde señal, quita una identidad contable.
2. **RH_min_diurna queda en observación.** Correlaciona 0.892 con RH_media y es la otra fuente de comunalidad inadmisibles. A diferencia de NOX no es una identidad, así que la decisión se toma con el ajuste en la mano y no antes.

El KMO de 0.646 se arrastra como limitación declarada del enfoque, no como trámite aprobado. Y queda pendiente la pregunta que decide si el análisis factorial puede además sustituir al PCA en su papel instrumental: **si los puntajes factoriales sirven como predictores no colineales para #55**. Los puntajes de regresión correlacionan entre sí aun con rotación ortogonal, así que el VIF de esta sección tendrá que recalcularse sobre ellos antes de dar por hecho el reemplazo.