

Regresión logística y análisis discriminante

Issue #55 — MA2003B, equipo 7 (sobre los factores comunes)

Tabla de contenidos

Escala de los puntajes	3
Unión con la matriz de diseño	4
Catóricas: referencia explícita y dummies k−1	5
Partición	7
Regresión logística	8
Razones de momios	9
Razones de momios por factor	10
Evaluación en validación: AUC, sensibilidad, especificidad	12
Análisis de umbral	13
Análisis discriminante lineal	13
Verificación de supuestos	14
Ajuste	15
Evaluación en validación	16
Comparación de los dos modelos	17
Curvas ROC de ambos modelos	18
Matrices de confusión	19
Contraste con las componentes principales	21
Corrección de errores	24
Tasa de error: del aparente al corregido	24
Errores estándar bajo dependencia	26
Limitaciones	29

```
library(nanoparquet)
library(dplyr)

sima_scores <- read_parquet("../data/processed/af_puntajes_diarios.parquet")
sima_modelado <- read_parquet("../data/processed/sima_diario_modelado.parquet")

# fecha es hora local de pared sin zona horaria (ver CLAUDE.md); nanoparquet la
# lee como UTC y R la despliega en America/Monterrey, corriéndola 6 horas.
# Fijar el atributo, no convertir (as.POSIXct(tz=) sí correría los datos).
attr(sima_scores$fecha, "tzone") <- "UTC"
attr(sima_modelado$fecha, "tzone") <- "UTC"
```

```
summary(sima_scores)
```

```
#>      estacion      fecha      particion
#> Length :17399 Min. :2021-01-01 00:00:00 Length :17399
#> N.unique : 15 1st Qu.:2022-03-22 00:00:00 N.unique : 2
#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-20 17:11:43 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#>      F1      F2      F3
#> Min. :-3.536390 Min. :-5.310439 Min. :-3.906081
#> 1st Qu.: -0.846128 1st Qu.: -0.618912 1st Qu.: -0.802547
#> Median : -0.042404 Median : 0.024735 Median : 0.052235
#> Mean :-0.006957 Mean : 0.001833 Mean :-0.004547
#> 3rd Qu.: 0.794218 3rd Qu.: 0.647795 3rd Qu.: 0.850836
#> Max. : 4.202685 Max. : 9.929991 Max. : 4.728334
```

```
summary(sima_modelado)
```

```
#>      estacion      fecha      zona
#> Length :23931 Min. :2021-01-01 00:00:00 Length :23931
#> N.unique : 15 1st Qu.:2022-03-04 00:00:00 N.unique : 7
#> N.blank : 0 Median :2023-04-25 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-04-15 06:31:43 Min.nchar: 3
#> Max.nchar: 4 3rd Qu.:2024-05-28 00:00:00 Max.nchar: 8
#> Max. :2025-06-30 00:00:00
#>
#>      msnm      anio      mes      temporada
#> Min. :334.0 Min. :2021 Min. : 1.000 Length :23931
#> 1st Qu.:432.0 1st Qu.:2022 1st Qu.: 3.000 N.unique : 4
#> Median :520.0 Median :2023 Median : 6.000 N.blank : 0
#> Mean :517.5 Mean :2023 Mean : 6.188 Min.nchar: 5
#> 3rd Qu.:568.0 3rd Qu.:2024 3rd Qu.: 9.000 Max.nchar: 9
#> Max. :702.0 Max. :2025 Max. :12.000
#>
#>      tipo_dia      festivo      fin_de_semana      TOUT_max
#> Length :23931 Min. :0.0000 Min. :0.0000 Min. : -0.55
#> N.unique : 4 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:24.76
#> N.blank : 0 Median :0.0000 Median :0.0000 Median :30.17
#> Min.nchar: 6 Mean :0.0435 Mean :0.2862 Mean :28.84
#> Max.nchar: 9 3rd Qu.:0.0000 3rd Qu.:1.0000 3rd Qu.:33.93
#> Max. :1.0000 Max. :1.0000 Max. :47.58
#> NAs :1272
#>      SR_acum      NO_06_09      NO2_06_09      NOX_06_09
#> Min. : 0.000 Min. : 0.500 Min. : 0.00 Min. : 0.55
#> 1st Qu.: 2.214 1st Qu.: 5.725 1st Qu.: 9.65 1st Qu.: 16.68
#> Median : 3.590 Median : 11.175 Median : 15.00 Median : 26.85
#> Mean : 3.475 Mean : 20.855 Mean : 17.02 Mean : 37.69
#> 3rd Qu.: 4.808 3rd Qu.: 24.375 3rd Qu.: 22.20 3rd Qu.: 46.55
#> Max. :23.791 Max. :379.300 Max. :119.42 Max. :443.45
```

```

#> NAs      :1018      NAs      :1598      NAs      :1624      NAs      :1584
#>      CO_06_09      WSR_media      WSR_min      PRS_media
#> Min.      : 0.0000      Min.      : 0.4367      Min.      : 0.100      Min.      :681.3
#> 1st Qu.: 0.7602      1st Qu.: 6.2698      1st Qu.: 1.700      1st Qu.:709.8
#> Median : 1.2900      Median : 8.2625      Median : 2.700      Median :714.4
#> Mean      : 1.4283      Mean      : 8.6782      Mean      : 3.154      Mean      :715.3
#> 3rd Qu.: 1.9225      3rd Qu.: 10.3917      3rd Qu.: 4.100      3rd Qu.:721.6
#> Max.      :11.3925      Max.      :147.6317      Max.      :129.300      Max.      :747.9
#> NAs      :1554      NAs      :959      NAs      :959      NAs      :751
#>      RH_media      RH_min_diurna      viento_u_media      viento_v_media
#> Min.      : 0.9874      Min.      : 0.00      Min.      : -115.158      Min.      : -98.9563
#> 1st Qu.:47.1250      1st Qu.:25.00      1st Qu.: -7.129      1st Qu.: -1.9403
#> Median :57.6250      Median :36.00      Median : -4.124      Median : 0.5571
#> Mean      :56.6028      Mean      :37.06      Mean      : -4.245      Mean      : 0.2831
#> 3rd Qu.:67.2083      3rd Qu.:48.00      3rd Qu.: -1.479      3rd Qu.: 2.6366
#> Max.      :99.3889      Max.      :95.00      Max.      : 31.490      Max.      : 39.1337
#> NAs      :2067      NAs      :1995      NAs      :1387      NAs      :1387
#>      PM10_media      PM2.5_media      SO2_media      llovio
#> Min.      : 4.00      Min.      : 2.182      Min.      : 0.5045      Min.      :0.00000
#> 1st Qu.: 40.51      1st Qu.: 12.812      1st Qu.: 3.1208      1st Qu.:0.00000
#> Median : 54.69      Median : 18.169      Median : 4.1333      Median :0.00000
#> Mean      : 60.18      Mean      : 20.524      Mean      : 4.7485      Mean      :0.08185
#> 3rd Qu.: 73.82      3rd Qu.: 25.602      3rd Qu.: 5.7250      3rd Qu.:0.00000
#> Max.      :317.87      Max.      :167.979      Max.      :61.7750      Max.      :1.00000
#> NAs      :805      NAs      :5229      NAs      :1720      NAs      :706
#>      MDA8      ventanas_validas      O3_max_1h      excede_anio_1
#> Min.      : 2.344      Min.      : 0.00      Min.      : 1.00      Min.      :0.0000
#> 1st Qu.: 33.375      1st Qu.:24.00      1st Qu.: 39.00      1st Qu.:0.0000
#> Median : 43.125      Median :24.00      Median : 53.00      Median :0.0000
#> Mean      : 44.610      Mean      :22.87      Mean      : 55.73      Mean      :0.1065
#> 3rd Qu.: 54.000      3rd Qu.:24.00      3rd Qu.: 69.00      3rd Qu.:0.0000
#> Max.      :147.875      Max.      :24.00      Max.      :265.00      Max.      :1.0000
#> NAs      :1402      NAs      :709      NAs      :1402
#> excede_anio_3      excede_anio_5      excede_1h
#> Min.      :0.0000      Min.      :0.000      Min.      :0.0000
#> 1st Qu.:0.0000      1st Qu.:0.000      1st Qu.:0.0000
#> Median :0.0000      Median :0.000      Median :0.0000
#> Mean      :0.1604      Mean      :0.307      Mean      :0.0799
#> 3rd Qu.:0.0000      3rd Qu.:1.000      3rd Qu.:0.0000
#> Max.      :1.0000      Max.      :1.000      Max.      :1.0000
#> NAs      :1402      NAs      :1402

```

Escala de los puntajes

Los puntajes factoriales **no tienen varianza unitaria**, y esto tiene consecuencias que conviene resolver antes de ajustar nada.

```
tr <- sima_scores$particion == "entrenamiento"
round(sapply(sima_scores[tr, c("F1", "F2", "F3")], sd), 4)
#>      F1      F2      F3
#> 1.1425 1.1000 1.2048
```

Un coeficiente de regresión se lee “por unidad del predictor”, así que con escalas distintas entre ejes las razones de momios **no son comparables entre sí**: un eje con mayor dispersión produce un momio por unidad más chico sin que eso signifique que importa menos.

Esto corrige un error de la versión anterior de este documento, que trabajaba sobre las puntuaciones del PCA y afirmaba que sus razones de momios eran por desviación estándar. No lo eran. Una puntuación de componente principal tiene varianza igual a su eigenvalor, de modo que las tres desviaciones estándar valían 1.98, 1.72 y 1.23 — no 1 — y los momios de 1.47, 1.58 y 1.22 que están hoy en el reporte son **por unidad**, no por desviación estándar, y no son comparables entre ejes como el texto afirmaba.

La solución es reescalar a varianza unitaria **con los momentos de entrenamiento**, nunca con los de 2025:

```
mu_f <- sapply(sima_scores[tr, c("F1", "F2", "F3")], mean)
sd_f <- sapply(sima_scores[tr, c("F1", "F2", "F3")], sd)

for (v in c("F1", "F2", "F3")) {
  sima_scores[[v]] <- (sima_scores[[v]] - mu_f[[v]]) / sd_f[[v]]
}

# control: entrenamiento en 0 y 1; validación no tiene por qué estarlo
round(sapply(sima_scores[tr, c("F1", "F2", "F3")], sd), 6)
#> F1 F2 F3
#>  1  1  1
round(sapply(sima_scores[!tr, c("F1", "F2", "F3")], sd), 3)
#>      F1      F2      F3
#> 1.128 0.775 1.042
```

A partir de aquí, cada razón de momios sí es por desviación estándar del factor y las tres son comparables entre sí.

Unión con la matriz de diseño

Los puntajes factoriales (`sima_scores`) solo traen `estacion`, `fecha`, `particion` y los tres factores. Zona, calendario y la variable respuesta viven en `sima_modelado`, así que se unen por (`estacion`, `fecha`).

```
sima_disc <- sima_scores |>
  inner_join(
    sima_modelado |>
```

```

        select(estacion, fecha, zona, tipo_dia, temporada, excede_anio_5),
        by = c("estacion", "fecha")
    )

stopifnot(nrow(sima_disc) == nrow(sima_scores))
summary(sima_disc)
#>      estacion      fecha      particion
#> Length :17399 Min. :2021-01-01 00:00:00 Length :17399
#> N.unique : 15 1st Qu.:2022-03-22 00:00:00 N.unique : 2
#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-20 17:11:43 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#>
#>      F1      F2      F3      zona
#> Min. :-3.095212 Min. :-4.827839 Min. :-3.242120 Length :17399
#> 1st Qu.: -0.740571 1st Qu.: -0.562667 1st Qu.: -0.666129 N.unique : 7
#> Median :-0.037114 Median : 0.022487 Median : 0.043356 N.blank : 0
#> Mean :-0.006089 Mean : 0.001667 Mean :-0.003774 Min.nchar: 3
#> 3rd Qu.: 0.695136 3rd Qu.: 0.588925 3rd Qu.: 0.706210 Max.nchar: 8
#> Max. : 3.678384 Max. : 9.027577 Max. : 3.924606
#>
#>      tipo_dia      temporada      excede_anio_5
#> Length :17399 Length :17399 Min. :0.0000
#> N.unique : 4 N.unique : 4 1st Qu.:0.0000
#> N.blank : 0 N.blank : 0 Median :0.0000
#> Min.nchar: 6 Min.nchar: 5 Mean :0.3035
#> Max.nchar: 9 Max.nchar: 9 3rd Qu.:1.0000
#> Max. :1.0000
#> NAs :370

```

Categorías: referencia explícita y dummies k—1

Referencia por variable (issue #55):

- **zona: Noreste**, la de menor tasa de excedencia (19.0 %, docs/05_estacionalidad_ozono.pdf) — baseline de menor riesgo.
- **tipo_dia: laborable**, el nivel más frecuente y el orden natural de NIVELES_TIPO_DIA en src/agregacion_diaria.py.
- **temporada: invierno**, temporada de menor actividad fotoquímica.

festivo no se agrega aparte: por construcción (src/agregacion_diaria.py, marcar_calendario) tipo_dia == "festivo" es idéntico a festivo == 1 — son la misma indicadora. Incluir ambas duplicaría la columna y generaría colinealidad perfecta; la dummy tipo_dia_festivo ya la cubre.

```

sima_disc <- sima_disc |>
  mutate(

```

```

    zona = relevel(factor(zona), ref = "Noreste"),
    tipo_dia = factor(tipo_dia,
        levels = c("laborable", "sabado", "domingo", "festivo")
    ),
    temporada = factor(temporada,
        levels = c("invierno", "primavera", "verano", "otoño")
    )
)

dummies <- model.matrix(~ zona + tipo_dia + temporada, data = sima_disc)[, -1]
colnames(dummies) <- gsub("^zona|^tipo_dia|^temporada", "", colnames(dummies))
colnames(dummies) <- c(
    paste0("zona_", colnames(dummies)[1:6]),
    paste0("tipo_dia_", colnames(dummies)[7:9]),
    paste0("temporada_", colnames(dummies)[10:12])
)

sima_disc <- cbind(sima_disc, dummies)
stopifnot(ncol(dummies) == 12) # 6 zona + 3 tipo_dia + 3 temporada
summary(sima_disc)
#>      estacion      fecha      particion
#> Length :17399 Min. :2021-01-01 00:00:00 Length :17399
#> N.unique : 15 1st Qu.:2022-03-22 00:00:00 N.unique : 2
#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-20 17:11:43 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#>
#>      F1      F2      F3      zona
#> Min. :-3.095212 Min. :-4.827839 Min. :-3.242120 Noreste :3160
#> 1st Qu.: -0.740571 1st Qu.: -0.562667 1st Qu.: -0.666129 Centro :1494
#> Median :-0.037114 Median : 0.022487 Median : 0.043356 Noroeste:2407
#> Mean :-0.006089 Mean : 0.001667 Mean :-0.003774 Norte :2080
#> 3rd Qu.: 0.695136 3rd Qu.: 0.588925 3rd Qu.: 0.706210 Sur :1347
#> Max. : 3.678384 Max. : 9.027577 Max. : 3.924606 Sureste :4114
#> Suroeste:2797
#>      tipo_dia      temporada      excede_anio_5      zona_Centro
#> laborable:11822 invierno :4291 Min. :0.0000 Min. :0.00000
#> sabado : 2421 primavera:4822 1st Qu.:0.0000 1st Qu.:0.00000
#> domingo : 2393 verano :4196 Median :0.0000 Median :0.00000
#> festivo : 763 otoño :4090 Mean :0.3035 Mean :0.08587
#> 3rd Qu.:1.0000 3rd Qu.:0.00000
#> Max. :1.0000 Max. :1.00000
#> NAs :370
#> zona_Noroeste      zona_Norte      zona_Sur      zona_Sureste
#> Min. :0.0000 Min. :0.0000 Min. :0.00000 Min. :0.0000
#> 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:0.00000 1st Qu.:0.0000
#> Median :0.0000 Median :0.0000 Median :0.00000 Median :0.0000

```

```
#> Mean      :0.1383    Mean      :0.1195    Mean      :0.07742    Mean      :0.2365
#> 3rd Qu.:0.0000    3rd Qu.:0.0000    3rd Qu.:0.00000    3rd Qu.:0.0000
#> Max.       :1.0000    Max.       :1.0000    Max.       :1.00000    Max.       :1.0000
#>
#> zona_Suroeste    tipo_dia_sabado    tipo_dia_domingo    tipo_dia_festivo
#> Min.      :0.0000    Min.      :0.0000    Min.      :0.0000    Min.      :0.00000
#> 1st Qu.:0.0000    1st Qu.:0.0000    1st Qu.:0.0000    1st Qu.:0.00000
#> Median :0.0000    Median :0.0000    Median :0.0000    Median :0.00000
#> Mean      :0.1608    Mean      :0.1391    Mean      :0.1375    Mean      :0.04385
#> 3rd Qu.:0.0000    3rd Qu.:0.0000    3rd Qu.:0.0000    3rd Qu.:0.00000
#> Max.       :1.0000    Max.       :1.0000    Max.       :1.0000    Max.       :1.00000
#>
#> temporada_primavera    temporada_verano    temporada_otoño
#> Min.      :0.0000    Min.      :0.0000    Min.      :0.0000
#> 1st Qu.:0.0000    1st Qu.:0.0000    1st Qu.:0.0000
#> Median :0.0000    Median :0.0000    Median :0.0000
#> Mean      :0.2771    Mean      :0.2412    Mean      :0.2351
#> 3rd Qu.:1.0000    3rd Qu.:0.0000    3rd Qu.:0.0000
#> Max.       :1.0000    Max.       :1.0000    Max.       :1.0000
#>
```

Partición

Entrenamiento 2021–2024, validación 2025, como decidió el equipo (#54, #55). `sima_scores` ya trae `particion` calculada así desde el PCA — se reutiliza en vez de recalcularla a partir de `fecha`, para garantizar que el PCA y los modelos de clasificación usan exactamente la misma frontera y que ninguno vio 2025 durante el ajuste.

```
table(sima_disc$particion)
#>
#> entrenamiento    validacion
#>          16058          1341

sima_train <- sima_disc |> filter(particion == "entrenamiento")
sima_valid <- sima_disc |> filter(particion == "validacion")

range(sima_train$fecha)
#> [1] "2021-01-01 UTC" "2024-12-31 UTC"
range(sima_valid$fecha)
#> [1] "2025-01-01 UTC" "2025-06-30 UTC"
```

Limitación de la partición (cuantificada en docs/05_estacionalidad_ozono.pdf): como 2025 termina el 30 de junio, la validación es 52.3 % primavera, 32.2 % invierno, 15.5 % verano y 0 % otoño, contra un entrenamiento repartido casi por igual (23.1–26.0 %). La tasa base de excedencia pasa de 29.31 % a 41.50 %, 12.2 puntos que vienen del calendario y no del modelo. El AUC es menos

sensible a la tasa base que la exactitud, lo que amortigua el problema pero no lo elimina — por eso la exactitud no se usa como métrica de decisión más adelante.

```
mean(sima_train$excede_anio_5, na.rm = TRUE)
#> [1] 0.2940652
mean(sima_valid$excede_anio_5, na.rm = TRUE)
#> [1] 0.4150943
```

Regresión logística

Respuesta `excede_anio_5`; predictores los tres factores comunes extraídos en `docs/09_extraccion_factorial.pdf` más los 12 dummies (zona, tipo_dia, temporada) del paso anterior. Se arma la fórmula a partir de los nombres de columna en vez de escribirla a mano, para que quede ligada a los dummies que de verdad existen en `sima_disc` — si cambia el catálogo de zonas, la fórmula lo sigue sin que haya que tocarla.

```
predictores <- c(
  "F1", "F2", "F3",
  grep("^zona_|^tipo_dia_|^temporada_", names(sima_disc), value = TRUE)
)
formula_log <- reformulate(predictores, response = "excede_anio_5")
formula_log
#> excede_anio_5 ~ F1 + F2 + F3 + zona_Centro + zona_Noroeste +
#>      zona_Norte + zona_Sur + zona_Sureste + zona_Suroeste + tipo_dia_sabado +
#>      tipo_dia_domingo + tipo_dia_festivo + temporada_primavera +
#>      temporada_verano + temporada_otoño
```

Ajuste sobre `sima_train` únicamente — `sima_valid` no participa del ajuste, solo de la evaluación:

```
modelo_log <- glm(formula_log, data = sima_train, family = binomial)
summary(modelo_log)
#>
#> Call:
#> glm(formula = formula_log, family = binomial, data = sima_train)
#>
#> Coefficients:
#>
#>             Estimate Std. Error z value Pr(>|z|)
#> (Intercept)   -2.74134    0.08013  -34.212   < 2e-16 ***
#> F1              0.65329    0.02642   24.723   < 2e-16 ***
#> F2             -0.10279    0.02464   -4.171 3.03e-05 ***
#> F3              1.02058    0.02927   34.869   < 2e-16 ***
#> zona_Centro    0.99142    0.08347   11.878   < 2e-16 ***
#> zona_Noroeste   1.32235    0.07329   18.044   < 2e-16 ***
#> zona_Norte      0.55689    0.08152    6.831 8.42e-12 ***
#> zona_Sur        1.06285    0.08744   12.156   < 2e-16 ***
#> zona_Sureste    0.61570    0.06913    8.907   < 2e-16 ***
```



```
#> zona_Suroeste      1.24327    0.07254   17.139 < 2e-16 ***
#> tipo_dia_sabado    0.12578    0.05986    2.101  0.0356 *
#> tipo_dia_domingo   0.36157    0.06108    5.919 3.24e-09 ***
#> tipo_dia_festivo   0.16145    0.10571    1.527  0.1267
#> temporada_primavera 1.25520    0.07229   17.364 < 2e-16 ***
#> temporada_verano   0.41434    0.08613    4.811 1.50e-06 ***
#> temporada_otoño    1.10732    0.06991   15.840 < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> (Dispersion parameter for binomial family taken to be 1)
#>
#> Null deviance: 19025  on 15703  degrees of freedom
#> Residual deviance: 15102  on 15688  degrees of freedom
#> (354 observations deleted due to missingness)
#> AIC: 15134
#>
#> Number of Fisher Scoring iterations: 5
```

Razones de momios

La tabla que cuenta la historia (issue #55): `exp(coeficiente)` convierte la escala logit a razón de momios, e IC 95% viene de `broom::tidy` con `conf.int = TRUE` (Wald, no perfil de verosimilitud — más rápido y suficiente para reportar signo y magnitud).

```
library(broom)

momios_log <- tidy(modelo_log, exponentiate = TRUE, conf.int = TRUE) |>
  filter(term != "(Intercept)")
momios_log
#> # A tibble: 15 x 7
#>   term                estimate std.error statistic  p.value conf.low
#>   <chr>                <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
#>   <dbl>
#> 1 F1                  1.92      0.0264     24.7 6.07e-135    1.83      2.02
#>   ↪
#> 2 F2                  0.902     0.0246     -4.17 3.03e- 5     0.860
#>   ↪ 0.947
#> 3 F3                  2.77      0.0293     34.9 2.16e-266    2.62      2.94
#>   ↪
#> 4 zona_Centro         2.70      0.0835     11.9 1.55e- 32    2.29      3.17
#>   ↪
#> 5 zona_Noroeste       3.75      0.0733     18.0 8.83e- 73    3.25      4.33
#>   ↪
#> 6 zona_Norte          1.75      0.0815      6.83 8.42e- 12    1.49      2.05
#>   ↪
```

```

#> 7 zona_Sur 2.89 0.0874 12.2 5.34e- 34 2.44 3.44
↵
#> 8 zona_Sureste 1.85 0.0691 8.91 5.24e- 19 1.62 2.12
↵
#> 9 zona_Suroeste 3.47 0.0725 17.1 7.58e- 66 3.01 4.00
↵
#> 10 tipo_dia_sabado 1.13 0.0599 2.10 3.56e- 2 1.01 1.27
↵
#> 11 tipo_dia_domingo 1.44 0.0611 5.92 3.24e- 9 1.27 1.62
↵
#> 12 tipo_dia_festivo 1.18 0.106 1.53 1.27e- 1 0.953 1.44
↵
#> 13 temporada_primavera 3.51 0.0723 17.4 1.56e- 67 3.05 4.04
↵
#> 14 temporada_verano 1.51 0.0861 4.81 1.50e- 6 1.28 1.79
↵
#> 15 temporada_otoño 3.03 0.0699 15.8 1.64e- 56 2.64 3.47

```

Razones de momios por factor

Los tres factores comunes, con su nombre interpretativo (no solo “F1/F2/F3”): sin nombre, una razón de momios sobre un eje latente es ilegible.

Ojo con el signo del segundo. **La ventilación apunta al revés que el eje de estancamiento** que usaba la versión con componentes: valores altos significan viento fuerte y buena dispersión, así que la razón de momios esperada es *menor* que 1. Un momio por debajo de 1 aquí no contradice al análisis anterior, dice lo mismo con el eje orientado en sentido contrario.

```

nombres_factor <- c(
  F1 = "Combustión primaria",
  F2 = "Ventilación",
  F3 = "Forzamiento fotoquímico"
)

momios_factor <- momios_log |>
  filter(term %in% names(nombres_factor)) |>
  mutate(eje = nombres_factor[term], .before = 1) |>
  select(eje,
    termino = term, momios = estimate,
    ic_inf = conf.low, ic_sup = conf.high, p.value
  )
momios_factor
#> # A tibble: 3 x 6
#>   eje termino momios ic_inf ic_sup p.value
#>   <chr>   <chr>   <dbl> <dbl> <dbl> <dbl>
#> 1 Combustión primaria F1      1.92  1.83  2.02 6.07e-135
#> 2 Ventilación        F2      0.902 0.860 0.947 3.03e- 5

```


```
#> 3 Forzamiento fotoquímico F3      2.77    2.62    2.94  2.16e-266
```

Cada razón de momios es **por desviación estándar** del factor, no por unidad arbitraria, gracias al reescalado de la sección anterior — y es eso, y no la construcción de los puntajes, lo que hace comparables los tres momios entre sí.

```
library(ggplot2)

fig_momios <- ggplot(momios_factor, aes(x = momios, y = reorder(eje, momios))) +
  geom_vline(xintercept = 1, linetype = "dashed", colour = "grey60") +
  geom_pointrange(aes(xmin = ic_inf, xmax = ic_sup), colour = "#2c7fb8",
    ↪ linewidth = 0.8) +
  geom_text(aes(label = sprintf("%.2f", momios)), vjust = -1, size = 3.5) +
  labs(
    title = "Razones de momios por factor",
    subtitle = "Excedencia MDA8 > 51 ppb - IC 95%",
    x = "Razón de momios", y = NULL
  ) +
  theme_minimal()

fig_momios
```



```
ggsave("../reports/figuras/momios_factores.pdf", fig_momios,
  width = 6, height = 3.6, units = "in"
)
```

Los tres quedan por encima de 1 con el intervalo lejos de esa línea: subir una desviación estándar en cualquiera de los tres ejes se asocia con mayores momios de excedencia, controlando por zona y calendario. El de mayor efecto es el forzamiento fotoquímico, seguido de la combustión primaria — consistente con que el ozono es un contaminante secundario que necesita tanto precursores como las condiciones para formarse fotoquímicamente, no solo lo primero.

Evaluación en validación: AUC, sensibilidad, especificidad

Nunca exactitud — con 41.50 % de excedencia base en validación, un clasificador constante ya acierta bien sin distinguir nada.

```
library(pROC)

p_valid <- predict(modelo_log, newdata = sima_valid, type = "response")
roc_log <- roc(sima_valid$excede_anio_5, p_valid, quiet = TRUE)

auc(roc_log)
#> Area under the curve: 0.8995
```

Criterio de logro del issue: AUC 0.75 en validación. Umbral de clasificación para sensibilidad/especificidad y matriz de confusión — el que maximiza sensibilidad + especificidad (Youden), declarado explícitamente en vez de asumir 0.5:

```
umbral_log <- coords(roc_log, "best", best.method = "youden", ret = "threshold")
umbral_log <- as.numeric(umbral_log)
umbral_log
#> [1] 0.2733512

pred_log <- factor(p_valid >= umbral_log,
  levels = c(FALSE, TRUE),
  labels = c("no_excede", "excede")
)
obs_log <- factor(sima_valid$excede_anio_5,
  levels = c(0, 1),
  labels = c("no_excede", "excede")
)

matriz_log <- table(observado = obs_log, predicho = pred_log)
matriz_log
#>           predicho
#> observado  no_excede excede
#>  no_excede      635    140
#>   excede       82    468

coords(roc_log, umbral_log, ret = c("sensitivity", "specificity"))
#>  sensitivity specificity
#> 1    0.8509091    0.8193548
```

La curva ROC y la matriz de confusión no se grafican aquí: se construyen más abajo con los dos modelos en una sola figura ([roc_modelos.pdf](#) y [matriz_confusion.pdf](#)), que es como las pide el issue #55. Las versiones provisionales solo del logístico ([roc_log.pdf](#), [matriz_confusion_log.pdf](#)) quedaron retiradas al existir la comparativa.

Análisis de umbral

Cada punto de la curva ROC es un umbral distinto; esta tabla lo hace explícito para un puñado de candidatos, en vez de comprometerse solo con el de Youden. Se incluye exactitud a propósito, para mostrar por qué **no** se usa como criterio: sube con el umbral más alto (clasifica casi todo como “no excede”, la clase mayoritaria) mientras la sensibilidad se desploma — exactamente el efecto que el checklist de la issue #55 advierte.

```
candidatos <- c(
  youden = umbral_log, `0.5` = 0.5,
  tasa_base_train = mean(sima_train$excede_anio_5, na.rm = TRUE),
  tasa_base_valid = mean(sima_valid$excede_anio_5, na.rm = TRUE)
)

tabla_umbrales <- coords(roc_log, candidatos,
  ret = c("threshold", "sensitivity", "specificity", "accuracy")
) |>
  mutate(criterio = names(candidatos), .before = 1)

tabla_umbrales
#>               criterio threshold sensitivity specificity accuracy
#> youden               youden 0.2733512    0.8509091    0.8193548 0.8324528
#> 0.5                  0.5 0.5000000    0.4963636    0.9509677 0.7622642
#> tasa_base_train tasa_base_train 0.2940652    0.8181818    0.8438710 0.8332075
#> tasa_base_valid tasa_base_valid 0.4150943    0.6309091    0.9135484 0.7962264
```

Sensibilidad y especificidad se mueven en direcciones opuestas al mover el umbral — no hay un punto que maximice ambas a la vez, por eso Youden (maximizar su suma) es un criterio razonable por defecto y no un óptimo universal: si el costo de una excedencia no detectada fuera mucho mayor que el de una falsa alarma, convendría un umbral más bajo que sacrifique especificidad por sensibilidad.

Análisis discriminante lineal

La segunda técnica de `tab:tecnicas` (`reports/secciones/objetivo_tecnicas.tex`) sobre la misma matriz de diseño y la misma respuesta que la logística. El contraste es lo que interesa: el discriminante sí supone normalidad multivariada dentro de cada clase y homocedasticidad entre clases, supuestos que la logística no necesita. Si ambos coinciden, el resultado no depende de esos supuestos; si difieren, la diferencia se lee contra ellos.

Verificación de supuestos

Box-Cox (#52) dejó los predictores originales con $|\text{sesgo}| < 0.5$. Los puntajes factoriales son combinaciones lineales de esos predictores —los pesos de Bartlett de `af_pesos.csv`— así que la aproximación debería trasladarse. Se verifica sobre los puntajes, que es donde el supuesto opera, y por clase, que es como lo exige el discriminante:

```
sesgo <- function(x) {
  x <- x[!is.na(x)]
  sum((x - mean(x))^3) / (length(x) * sd(x)^3)
}

sima_train |>
  filter(!is.na(excede_anio_5)) |>
  group_by(excede_anio_5) |>
  summarise(across(c(F1, F2, F3), ~ round(sesgo(.x), 3)), n = n())
#> # A tibble: 2 x 5
#>   excede_anio_5    F1    F2    F3    n
#>   <dbl> <dbl> <dbl> <dbl> <int>
#> 1         0 0.244 0.391 -0.06 11086
#> 2         1 0.051 0.508 0.072 4618
```

Los seis sesgos quedan por debajo de 0.51 en valor absoluto, así que la aproximación a normalidad se sostiene sobre los puntajes.

La homocedasticidad es otra historia. No se usa la M de Box: con más de 15,000 observaciones rechaza cualquier diferencia por pequeña que sea, así que su p -valor no informa. Se comparan las matrices de covarianza directamente:

```
cov_por_clase <- function(y) {
  sima_train |>
    filter(excede_anio_5 == y) |>
    dplyr::select(F1, F2, F3) |>
    cov()
}

S0 <- cov_por_clase(0)
S1 <- cov_por_clase(1)

round(sqrt(diag(S1)) / sqrt(diag(S0)), 3) # razón de desviaciones estándar
#>   F1    F2    F3
#> 0.895 0.888 0.746
c(det_no_excede = det(S0), det_excede = det(S1))
#> det_no_excede  det_excede
#>   1.0771349    0.3485807
```

Las razones son 0.895, 0.888 y 0.746: los días de excedencia son **menos dispersos** que los de no excedencia, sobre todo en el eje fotoquímico (F3), y la varianza generalizada cae de 1.077 a 0.349.

El supuesto de covarianzas iguales no se cumple estrictamente. Se declara aquí y se retoma al comparar los dos modelos, en vez de sustituirlo por un discriminante cuadrático: la issue pide el lineal como contraste de la logística, y cambiar de técnica a medio camino cambiaría lo que se está contrastando.

Un segundo desvío, más grosero: los 12 dummies son binarios, y una indicadora no es normal bajo ninguna transformación. El discriminante lineal es conocido por tolerarlo — el clasificador resultante sigue siendo una frontera lineal razonable — pero la evidencia de que aquí lo tolera es empírica, y está en la comparación de más abajo, no en el supuesto.

Ajuste

Misma fórmula, misma partición de entrenamiento. Las probabilidades previas se dejan en las proporciones observadas (el comportamiento por defecto de `MASS::lda`) en vez de fijarlas en 0.5: la tasa base de excedencia es información del problema, no un artefacto del muestreo.

`MASS::select` no existe, pero `MASS` sí enmascara otras funciones de `dplyr` al cargarse después; por eso los `select` de aquí en adelante van calificados como `dplyr::select`.

```
library(MASS)

modelo_lda <- lda(formula_log, data = sima_train)
modelo_lda$prior
#>           0           1
#> 0.7059348 0.2940652
```

Coefficientes de la única función discriminante — con dos clases hay $\min(k-1, p) = 1$:

```
coef_lda <- data.frame(
  termino = rownames(modelo_lda$scaling),
  LD1 = round(as.numeric(modelo_lda$scaling), 4)
)
coef_lda
#>           termino      LD1
#> 1                F1  0.5057
#> 2                F2 -0.1074
#> 3                F3  0.7989
#> 4          zona_Centro  0.8198
#> 5        zona_Noroeste  1.1262
#> 6            zona_Norte  0.3943
#> 7            zona_Sur   0.8247
#> 8          zona_Sureste  0.4363
#> 9          zona_Suroeste  1.0686
#> 10      tipo_dia_sabado  0.0855
#> 11    tipo_dia_domingo  0.2751
#> 12    tipo_dia_festivo -0.0051
#> 13 temporada_primavera  1.0404
```

```
#> 14      temporada_verano 0.1545
#> 15      temporada_otoño 0.7645
```

El orden y el signo reproducen los de la logística: primavera y otoño pesan más que verano, el Noroeste y el Suroeste son las zonas de mayor riesgo, y entre los factores manda el forzamiento fotoquímico (F3, 0.799) sobre la combustión primaria (F1, 0.506), con la ventilación (F2, -0.107) en contra, que es el signo correcto para un eje que mide dispersión. Los coeficientes no son razones de momios y no se leen como tales; son la dirección en la que las dos clases se separan al máximo.

Evaluación en validación

Se usa la probabilidad posterior de la clase “excede” como puntaje continuo, para que la ROC sea comparable con la de la logística — no la clase que `predict` asigna por defecto, que ya trae incorporado un umbral de 0.5.

```
p_valid_lda <- predict(modelo_lda, newdata = sima_valid)$posterior[, "1"]
roc_lda <- roc(sima_valid$excede_anio_5, p_valid_lda, quiet = TRUE)

auc(roc_lda)
#> Area under the curve: 0.8997
```

Mismo criterio de umbral que en la logística (Youden), para que la comparación de sensibilidad y especificidad no confunda el efecto del modelo con el de una regla de corte distinta:

```
umbral_lda <- as.numeric(coords(roc_lda, "best",
  best.method = "youden",
  ret = "threshold"
))
umbral_lda
#> [1] 0.3045608

pred_lda <- factor(p_valid_lda >= umbral_lda,
  levels = c(FALSE, TRUE),
  labels = c("no_excede", "excede")
)
matriz_lda <- table(observado = obs_log, predicho = pred_lda)
matriz_lda
#>           predicho
#> observado  no_excede excede
#>   no_excede      650    125
#>   excede       95    455

coords(roc_lda, umbral_lda, ret = c("sensitivity", "specificity"))
#>   sensitivity specificity
#> 1    0.8272727  0.8387097
```


Comparación de los dos modelos

```
comparacion <- data.frame(
  modelo = c("Regresión logística", "Discriminante lineal"),
  auc = c(as.numeric(auc(roc_log)), as.numeric(auc(roc_lda))),
  umbral = c(umbral_log, umbral_lda),
  sensibilidad = c(
    coords(roc_log, umbral_log, ret = "sensitivity")[[1]],
    coords(roc_lda, umbral_lda, ret = "sensitivity")[[1]]
  ),
  especificidad = c(
    coords(roc_log, umbral_log, ret = "specificity")[[1]],
    coords(roc_lda, umbral_lda, ret = "specificity")[[1]]
  )
)
comparacion
#>           modelo      auc    umbral sensibilidad especificidad
#> 1  Regresión logística 0.8994604 0.2733512    0.8509091    0.8193548
#> 2 Discriminante lineal 0.8996950 0.3045608    0.8272727    0.8387097
```

Ambos superan el criterio de logro del issue (AUC = 0.75) con holgura. La diferencia de AUC se contrasta con la prueba de DeLong, que es la adecuada porque las dos curvas están correlacionadas — se calculan sobre las mismas 1,325 observaciones de validación con respuesta observada:

```
roc.test(roc_log, roc_lda, method = "delong")
#>
#> DeLong's test for two correlated ROC curves
#>
#> data:  roc_log and roc_lda
#> Z = -0.24807, p-value = 0.8041
#> alternative hypothesis: true difference in AUC is not equal to 0
#> 95 percent confidence interval:
#> -0.002088208  0.001619000
#> sample estimates:
#> AUC of roc1 AUC of roc2
#>  0.8994604  0.8996950
```

```
cor(p_valid, p_valid_lda) # correlación de los puntajes
#> [1] 0.9975212
mean((p_valid >= umbral_log) == (p_valid_lda >= umbral_lda)) # concordancia
#> [1] 0.9701715
```

Las dos técnicas son indistinguibles en estos datos: los AUC difieren en el cuarto decimal (0.8995 contra 0.8997, DeLong $p = 0.80$), los puntajes correlacionan a 0.998 y las clasificaciones coinciden en el 97.0% de los días de validación. Donde difieren es en el reparto de errores, y aquí el intercambio se

invierte respecto de la versión con componentes: ahora es la **logística** la que detecta más excedencias (sensibilidad 0.851 contra 0.827) a cambio de más falsas alarmas (especificidad 0.819 contra 0.839). Sigue siendo un intercambio dentro del ruido de muestreo.

Esa coincidencia es el resultado, no un anticlímax. La heterocedasticidad documentada arriba es real y aun así no mueve el desempeño: la frontera que ambos trazan es prácticamente la misma. La lectura que sigue —las razones de momios de la [sección de momios]— no depende entonces del supuesto de normalidad que la logística no hace y el discriminante sí, que era exactamente la razón de ajustar los dos.


Curvas ROC de ambos modelos

Una sola figura con las dos curvas, como pide el issue #55:

```
# El AUC va en la leyenda y no como anotación suelta: el texto no se recorta
# contra el panel y cada curva queda etiquetada con su propio valor.
etiqueta <- function(nombre, r) sprintf("%s (AUC =%.3f)", nombre, auc(r))
rocs <- setNames(
  list(roc_log, roc_lda),
  c(
    etiqueta("Regresión logística", roc_log),
    etiqueta("Discriminante lineal", roc_lda)
  )
)

# Las dos curvas se superponen casi por completo, así que el discriminante va
# punteado: sin eso la de abajo queda invisible y parecería haber una sola.
fig_roc <- ggroc(rocs, aes = c("colour", "linetype"), linewidth = 0.8) +
  geom_abline(intercept = 1, slope = 1, linetype = "dashed", colour = "grey60")
  +
  scale_colour_manual(values = c("#2c7fb8", "#d95f02")) +
  scale_linetype_manual(values = c("solid", "22")) +
  labs(
    title = "Curvas ROC en validación (2025)",
    subtitle = "Excedencia MDA8 > 51 ppb",
    x = "Especificidad", y = "Sensibilidad",
    colour = NULL, linetype = NULL
  ) +
  coord_equal() +
  theme_minimal() +
  theme(
    legend.position = "bottom", legend.direction = "vertical",
    legend.spacing.y = unit(0, "pt")
  )

fig_roc
```



```
ggsave("../reports/figuras/roc_modelos.pdf", fig_roc,
        width = 6, height = 4.2, units = "in"
)
```

Las curvas se superponen en casi todo su recorrido, que es la versión gráfica de la prueba de DeLong.

Matrices de confusión

Las dos matrices al umbral de Youden de cada modelo, en la misma figura y con la misma escala para que se comparen de un vistazo:

```
prop_por_fila <- function(m, modelo) {
  as.data.frame(m) |>
  group_by(observado) |>
  mutate(prop = Freq / sum(Freq)) |>
  ungroup() |>
  mutate(modelo = modelo)
}

matrices <- bind_rows(
  prop_por_fila(matriz_log, sprintf("Logística (umbral%.3f)", umbral_log)),
  prop_por_fila(matriz_lda, sprintf("Discriminante (umbral%.3f)", umbral_lda))
) |>

# bind_rows preserva el orden, pero facet_wrap ordena los paneles por el
# factor: sin fijar los niveles quedarían alfabéticos y el discriminante
# aparecería antes que la logística, al revés de como se leen en el texto.
```

```


mutate(
  modelo = factor(modelo, levels = unique(modelo)),
  across(
    c(observado, predicho),
    ~ factor(.x,
      levels = c("no_excede", "excede"),
      labels = c("No excede", "Excede")
    )
  )
)

fig_matrices <- ggplot(matrices, aes(x = predicho, y = observado, fill = prop)) +
  geom_tile(colour = "white") +
  # El texto se pinta claro sobre las celdas oscuras y oscuro sobre las claras:
  # en blanco fijo, los conteos de las celdas de proporción baja no se leen.
  geom_text(
    aes(
      label = sprintf("%d\n(%.1f%%)", Freq, prop * 100),
      colour = prop > 0.5
    ),
    fontface = "bold", size = 3, show.legend = FALSE
  ) +
  facet_wrap(~modelo) +
  scale_fill_gradient(
    low = "#deebf7", high = "#08519c", limits = c(0, 1),
    guide = "none"
  ) +
  scale_colour_manual(values = c(`FALSE` = "#08306b", `TRUE` = "white")) +
  labs(
    title = "Matrices de confusión en validación (2025)",
    x = "Predicho", y = "Observado"
  ) +
  theme_minimal()

fig_matrices

```

Matrices de confusión en validación (2025)



```
ggsave("../reports/figuras/matriz_confusion.pdf", fig_matrices,
        width = 6, height = 3.2, units = "in"
)
```

Contraste con las componentes principales

El cambio de insumo hay que justificarlo con desempeño, no solo con el argumento conceptual de que un eje con nombre es una afirmación factorial. La pregunta concreta: ¿pierde o gana el modelo al pasar de las tres componentes de #54 a los tres factores comunes?

Se ajustan ambos bloques **sobre exactamente las mismas filas** —la intersección de los dos conjuntos de puntajes, ya que la poda de NOX y RH_min_diurna cambió ligeramente qué días quedan completos— para que la prueba de DeLong sea pareada y la comparación no confunda desempeño con cobertura.

```
pca_scores <- read_parquet("../data/processed/pca_puntuaciones_diarias.parquet")
attr(pca_scores$fecha, "tzone") <- "UTC"

comp <- pca_scores |>
  dplyr::select(estacion, fecha, PC1, PC2, PC3) |>
  inner_join(sima_disc, by = c("estacion", "fecha"))

# mismo reescalado que se aplicó a los factores, con momentos de entrenamiento
tr_c <- comp$particion == "entrenamiento"
for (v in c("PC1", "PC2", "PC3")) {
  comp[[v]] <- (comp[[v]] - mean(comp[[v]][tr_c])) / sd(comp[[v]][tr_c])
}
```

```

comp_train <- comp |> filter(particion == "entrenamiento")
comp_valid <- comp |> filter(particion == "validacion")
c(filas_totales = nrow(comp), entrenamiento = nrow(comp_train),
  validacion = nrow(comp_valid))
#> filas_totales entrenamiento      validacion
#>           17348           16008           1340

```

```

dummies_nom <- grep("^zona_|^tipo_dia_|^temporada_", names(comp), value = TRUE)

ajusta <- function(ejes) {
  fml <- reformulate(c(ejes, dummies_nom), response = "excede_anio_5")
  g <- glm(fml, data = comp_train, family = binomial)
  d <- lda(fml, data = comp_train)
  list(
    log = roc(comp_valid$excede_anio_5,
              predict(g, comp_valid, type = "response"), quiet = TRUE),
    lda = roc(comp_valid$excede_anio_5,
              predict(d, comp_valid)$posterior[, "1"], quiet = TRUE)
  )
}

r_fac <- ajusta(c("F1", "F2", "F3"))
r_pca <- ajusta(c("PC1", "PC2", "PC3"))

data.frame(
  insumo = c("Factores comunes", "Componentes principales"),
  auc_logistica = c(as.numeric(auc(r_fac$log)), as.numeric(auc(r_pca$log))),
  auc_discriminante = c(as.numeric(auc(r_fac$lda)), as.numeric(auc(r_pca$lda)))
)
#>               insumo auc_logistica auc_discriminante
#> 1 Factores comunes      0.9001362      0.9004252
#> 2 Componentes principales      0.8927719      0.8927602

```

```

roc.test(r_fac$log, r_pca$log, method = "delong")
#>
#> DeLong's test for two correlated ROC curves
#>
#> data:  r_fac$log and r_pca$log
#> Z = 2.7584, p-value = 0.005809
#> alternative hypothesis: true difference in AUC is not equal to 0
#> 95 percent confidence interval:
#>  0.002131606 0.012597076
#> sample estimates:
#> AUC of roc1 AUC of roc2
#>  0.9001362  0.8927719

```

Los factores ganan, y la ganancia es real pero pequeña: **0.9001 contra 0.8928** de AUC en la logística, siete milésimas, con DeLong $p = 0.006$. Con 1,325 observaciones de validación la prueba detecta una diferencia de ese tamaño, así que el resultado es que los factores **no cuestan desempeño** y lo mejoran marginalmente. El discriminante se comporta igual (0.9004 contra 0.8928).

Esto confirma por la vía empírica lo que el solapamiento de subespacios ya anticipaba en docs/09_extraccion_factorial.pdf: las correlaciones canónicas entre ambos conjuntos de puntajes valen 0.996, 0.976 y 0.804, de modo que los dos bloques cargan casi la misma información. **El argumento para cambiar de insumo no es el desempeño, es la interpretación** — y el desempeño confirma que cambiar no cuesta nada.

Donde sí hay diferencia grande es en cómo se leen los coeficientes. La tabla siguiente pone las razones de momios por desviación estándar de ambos bloques; las filas **no están pareadas**, son dos listas independientes puestas lado a lado, porque los ejes de un método no corresponden uno a uno con los del otro.

```
# razones de momios por desviación estándar, lado a lado
momios_de <- function(ejes, nombres) {
  fml <- reformulate(c(ejes, dummies_nom), response = "excede_anio_5")
  tidy(glm(fml, data = comp_train, family = binomial),
    exponentiate = TRUE) |>
  filter(term %in% ejes) |>
  transmute(eje = nombres[term], momios = round(estimate, 3))
}

fac <- momios_de(c("F1", "F2", "F3"), nombres_factor)
pca <- momios_de(c("PC1", "PC2", "PC3"),
  c(PC1 = "Carga primaria de combustión",
    PC2 = "Forzamiento fotoquímico",
    PC3 = "Estancamiento atmosférico"))

data.frame(
  factor = fac$eje, momios_af = fac$momios,
  componente = pca$eje, momios_pca = pca$momios
)

#>           factor momios_af           componente momios_pca
#> F1      Combustión primaria      1.926 Carga primaria de combustión      2.154
#> F2           Ventilación      0.902   Forzamiento fotoquímico      2.210
#> F3 Forzamiento fotoquímico      2.771   Estancamiento atmosférico      1.275
```

Tres lecturas de esa tabla:

Los momios del PCA que están hoy en el reporte están mal escalados. Por desviación estándar valen 2.154, 2.210 y 1.275, no 1.47, 1.58 y 1.22. Esas últimas son por unidad de puntuación, y como las tres componentes tienen desviaciones estándar distintas (1.98, 1.72 y 1.23), tampoco eran comparables entre sí como el texto afirmaba. Hay que corregirlo en reports/secciones/regresion_logistica.tex se cambie de insumo o no.

La ventilación sale por debajo de 1 (0.902, IC 95 % de 0.860 a 0.947): más viento, menores momios de excedencia. Es el mismo fenómeno que el eje de estancamiento del PCA describía con un

momio de 1.275, leído con el eje orientado al revés. Que el intervalo no cruce el 1 confirma que el efecto existe, aunque sea el más débil de los tres.

El forzamiento fotoquímico domina con claridad (2.771 contra 1.926 de la combustión primaria). Con las componentes esa jerarquía no se veía: 2.210 contra 2.154 las dejaba prácticamente empatadas. La estructura simple del análisis factorial separa mejor los dos mecanismos, y la consecuencia sustantiva es que la condición meteorológica pesa más que la carga de precursores — lo cual, sin mediciones de COV, se describe pero no se explica.

Corrección de errores

Dos correcciones distintas que comparten nombre. La primera es sobre la **tasa de error** del clasificador: la que se calcula sobre los mismos datos con que se ajustó (error aparente) es optimista, y hay que corregirla con datos que el modelo no vio. La segunda es sobre los **errores estándar** de la logística: las observaciones no son independientes y eso los hace demasiado chicos. Aplican a ambos modelos la primera; sólo a la logística la segunda, porque el discriminante no produce errores estándar.

Tasa de error: del aparente al corregido

Cinco estimadores de la misma cantidad, la fracción de días mal clasificados con la regla $p \geq 0.5$. Del más optimista al más exigente: resustitución (APER), el holdout de Lachenbruch (dejar una observación fuera; exacto para el discriminante, `lda(CV = TRUE)`), validación cruzada de 10 pliegues con filas al azar, la misma pero con **días completos** en cada pliegue —para que las estaciones de un mismo día no queden repartidas entre ajuste y prueba—, y el holdout temporal de 2025 que ya se usó arriba.

```
tr_cc <- sima_train |> filter(!is.na(excede_anio_5))
va_cc <- sima_valid |> filter(!is.na(excede_anio_5))
tasa <- function(y, p) mean((p >= 0.5) != y)
auc_de <- function(y, p) as.numeric(auc(roc(y, p, quiet = TRUE)))

p_tr_log <- predict(modelo_log, tr_cc, type = "response")
p_tr_lda <- predict(modelo_lda, tr_cc)$posterior[, "1"]
p_loo_lda <- lda(formula_log, data = tr_cc, CV = TRUE)$posterior[, "1"]

# k pliegues sobre unidades `bloques`: filas (aleatorio) o fechas (bloqueado).
set.seed(2003)
kfold <- function(bloques, k = 10) {
  ids <- unique(bloques)
  fold <- sample(rep(1:k, length.out = length(ids)))[match(bloques, ids)]
  pl <- pd <- numeric(nrow(tr_cc))
  for (j in 1:k) {
    ent <- fold != j
    pl[!ent] <- predict(glm(formula_log, binomial, tr_cc[ent, ]),
                        tr_cc[!ent, ], type = "response")
    pd[!ent] <- predict(lda(formula_log, data = tr_cc[ent, ]),
```



```

        tr_cc[!ent, ])$posterior[, "1"]
    }
    list(log = pl, lda = pd)
}
cv_alea <- kfold(seq_len(nrow(tr_cc)))
cv_bloq <- kfold(as.character(tr_cc$fecha))

y_tr <- tr_cc$excede_anio_5; y_va <- va_cc$excede_anio_5
p_va_log <- predict(modelo_log, va_cc, type = "response")
p_va_lda <- predict(modelo_lda, va_cc)$posterior[, "1"]

errores <- data.frame(
  estimador = c("APER (resustitucion)", "Lachenbruch (L00)", "10 pliegues, filas",
    "10 pliegues, dias completos", "Holdout 2025"),
  err_log = c(tasa(y_tr, p_tr_log), NA, tasa(y_tr, cv_alea$log),
    tasa(y_tr, cv_bloq$log), tasa(y_va, p_va_log)),
  err_lda = c(tasa(y_tr, p_tr_lda), tasa(y_tr, p_loo_lda), tasa(y_tr,
    ↪ cv_alea$lda),
    tasa(y_tr, cv_bloq$lda), tasa(y_va, p_va_lda)),
  auc_log = c(auc_de(y_tr, p_tr_log), NA, auc_de(y_tr, cv_alea$log),
    auc_de(y_tr, cv_bloq$log), auc_de(y_va, p_va_log)),
  auc_lda = c(auc_de(y_tr, p_tr_lda), auc_de(y_tr, p_loo_lda), auc_de(y_tr,
    ↪ cv_alea$lda),
    auc_de(y_tr, cv_bloq$lda), auc_de(y_va, p_va_lda)))
print(transform(errores, err_log = round(err_log, 4), err_lda = round(err_lda, 4),
  auc_log = round(auc_log, 3), auc_lda = round(auc_lda, 3)),
  row.names = FALSE)
#>           estimador err_log err_lda auc_log auc_lda
#>   APER (resustitucion) 0.2283 0.2303  0.801  0.800
#>   Lachenbruch (L00)      NA 0.2308      NA 0.799
#>   10 pliegues, filas 0.2284 0.2309  0.800 0.799
#> 10 pliegues, dias completos 0.2304 0.2320 0.798 0.796
#>   Holdout 2025 0.2377 0.2325 0.899 0.900

```

La corrección de la tasa de error es de dos milésimas. El error aparente de la logística es 0.228 y el corregido con días completos 0.230; el discriminante va de 0.230 a 0.232, y Lachenbruch da 0.231. Es lo esperable: el optimismo de la resustitución es del orden de p/n , y con 16 parámetros sobre 15,704 observaciones ese cociente es 0.001. Los dos clasificadores están lejos de sobreajustar.

Lo que la tabla sí revela es otra cosa, y está en la columna del AUC: **dentro de 2021–2024 el modelo discrimina a 0.80, no a 0.90.** El 0.90 es del holdout de 2025 y no se reproduce en ninguna validación cruzada sobre los años de ajuste. Se desagrega por año, cada uno predicho por un modelo que no lo vio:

```

todo <- bind_rows(sima_train, sima_valid) |> filter(!is.na(excede_anio_5))
todo$anio <- as.integer(format(todo$fecha, "%Y"))
do.call(rbind, lapply(2021:2025, function(Y) {

```

```

g <- glm(formula_log, binomial, todo[todo$anio != Y, ])
v <- todo[todo$anio == Y, ]
p <- predict(g, v, type = "response")
data.frame(anio = Y, n = nrow(v), prevalencia = round(mean(v$excede_anio_5), 3),
            AUC = round(auc_de(v$excede_anio_5, p), 3),
            error = round(tasa(v$excede_anio_5, p), 3))
})) |> print(row.names = FALSE)
#>   anio    n prevalencia   AUC error
#> 2021 3264      0.286 0.767 0.238
#> 2022 4442      0.278 0.772 0.238
#> 2023 4296      0.237 0.766 0.239
#> 2024 3702      0.387 0.845 0.250
#> 2025 1325      0.415 0.899 0.238

```

Los años 2021–2023 quedan en 0.77; 2024 sube a 0.845 y 2025 a 0.90. Es un efecto de año, no de calendario —[autorregresivo_logistico.pdf §8.7](#) lo documenta con el mismo corte sobre la serie de área metropolitana y descarta prevalencia y cobertura como explicación. La tasa de error, en cambio, apenas se mueve entre años (0.238 a 0.250), porque con la regla de 0.5 la domina la tasa base. **Para reportar desempeño esperado en un año cualquiera, el AUC es 0.80; el 0.90 es el de 2025.**

Errores estándar bajo dependencia

Los errores estándar de `summary(modelo_log)` suponen observaciones independientes. No lo son: las 15 estaciones de un día comparten el clima, y los días consecutivos se parecen. Se corrigen con el estimador sandwich agrupado por **conglomerados** (Liang-Zeger), que permite cualquier correlación dentro de un grupo y sólo exige independencia entre grupos.

```

# Sandwich por conglomerado, a mano para no agregar `sandwich` al lockfile.
# Verificado contra sandwich::vcovCL(type = "HCO"): coincide a 1e-7.
# V = G/(G-1) * B (sum_g U_g U_g') B, B = vcov(m), U_g = sum_{i in g} x_i (y_i
#   - p_i)
vcov_cl <- function(m, grupo) {
  X <- model.matrix(m); e <- residuals(m, type = "response")
  U <- rowsum(X * e, grupo); G <- nrow(U); B <- vcov(m)
  G / (G - 1) * B %%% crossprod(U) %%% B
}
ee <- function(V) sqrt(diag(V))
b <- coef(modelo_log)
ee_iid <- ee(vcov(modelo_log))
ee_dia <- ee(vcov_cl(modelo_log, tr_cc$fecha))
# Dos vias (dia + estacion): V_dia + V_est - V_interseccion
#   (Cameron-Gelbach-Miller).
ee_2v <- ee(vcov_cl(modelo_log, tr_cc$fecha) + vcov_cl(modelo_log,
#   tr_cc$estacion)
#   - vcov_cl(modelo_log, paste(tr_cc$fecha, tr_cc$estacion)))

```

```

pval <- function(se) 2 * pnorm(-abs(b / se))

cat(sprintf("conglomerados: %d dias, %d estaciones\n\n",
            n_distinct(tr_cc$fecha), n_distinct(tr_cc$estacion)))
#> conglomerados: 1460 dias, 15 estaciones
cat("Conglomerado por dia:\n")
#> Conglomerado por dia:
data.frame(termino = names(b), OR = round(exp(b), 3),
            EE_iid = round(ee_iid, 4), EE_dia = round(ee_dia, 4),
            inflacion = round(ee_dia / ee_iid, 2),
            p_iid = signif(pval(ee_iid), 2), p_dia = signif(pval(ee_dia), 2))[-1, ]
  <- |>
print(row.names = FALSE)
#>      termino      OR EE_iid EE_dia inflacion      p_iid      p_dia
#>      F1 1.922 0.0264 0.0461      1.75 6.1e-135 1.5e-45
#>      F2 0.902 0.0246 0.0365      1.48 3.0e-05 4.9e-03
#>      F3 2.775 0.0293 0.0565      1.93 2.2e-266 7.4e-73
#>      zona_Centro 2.695 0.0835 0.0682      0.82 1.5e-32 6.9e-48
#>      zona_Noroeste 3.752 0.0733 0.0755      1.03 8.8e-73 1.2e-68
#>      zona_Norte 1.745 0.0815 0.0723      0.89 8.4e-12 1.3e-14
#>      zona_Sur 2.895 0.0874 0.0859      0.98 5.3e-34 3.7e-35
#>      zona_Sureste 1.851 0.0691 0.0628      0.91 5.2e-19 1.1e-22
#>      zona_Suroeste 3.467 0.0725 0.0769      1.06 7.6e-66 7.4e-59
#>      tipo_dia_sabado 1.134 0.0599 0.1233      2.06 3.6e-02 3.1e-01
#>      tipo_dia_domingo 1.436 0.0611 0.1288      2.11 3.2e-09 5.0e-03
#>      tipo_dia_festivo 1.175 0.1057 0.2640      2.50 1.3e-01 5.4e-01
#>      temporada_primavera 3.509 0.0723 0.1661      2.30 1.6e-67 4.2e-14
#>      temporada_verano 1.513 0.0861 0.1899      2.20 1.5e-06 2.9e-02
#>      temporada_otoño 3.026 0.0699 0.1580      2.26 1.6e-56 2.4e-12

cat("\nDos vias (dia + estacion):\n")
#>
#> Dos vias (dia + estacion):
data.frame(termino = names(b), EE_2vias = round(ee_2v, 4),
            inflacion = round(ee_2v / ee_iid, 2),
            p_2vias = signif(pval(ee_2v), 2))[-1, ] |> print(row.names = FALSE)
#>      termino EE_2vias inflacion p_2vias
#>      F1      0.1154      4.37 1.5e-08
#>      F2      0.0888      3.61 2.5e-01
#>      F3      0.1180      4.03 5.3e-18
#>      zona_Centro 0.4741      5.68 3.7e-02
#>      zona_Noroeste 0.4821      6.58 6.1e-03
#>      zona_Norte 0.6754      8.29 4.1e-01
#>      zona_Sur 0.4606      5.27 2.1e-02
#>      zona_Sureste 0.5830      8.43 2.9e-01
#>      zona_Suroeste 0.5105      7.04 1.5e-02
#>      tipo_dia_sabado 0.1257      2.10 3.2e-01
#>      tipo_dia_domingo 0.1387      2.27 9.1e-03

```

```
#>      tipo_dia_festivo    0.2561      2.42 5.3e-01
#>      temporada_primavera 0.2153      2.98 5.6e-09
#>      temporada_verano    0.2790      3.24 1.4e-01
#>      temporada_otoño    0.2037      2.91 5.4e-08
```

Agrupando por día, que es la corrección bien fundada (1,460 conglomerados), los errores estándar se inflan entre $\times 1.5$ y $\times 2.5$. El patrón es informativo: los factores suben $\times 1.75$ a $\times 1.93$; las indicadores de calendario —que son constantes dentro de un día y por tanto las más afectadas— $\times 2.1$ a $\times 2.5$; las de zona **no cambian** ($\times 0.8$ a $\times 1.1$), porque la zona varía *dentro* de cada día. El único término que pierde significancia al 5% es **tipo_dia_sabado**. Los tres factores, las siete zonas y las temporadas conservan $p < 0.01$. Las conclusiones del modelo no dependen del supuesto de independencia.

Agrupando también por estación el cuadro es distinto y hay que leerlo con cuidado. Las zonas inflan $\times 5$ a $\times 8$ y **zona_Norte**, **zona_Sureste** y **F2** dejan de ser significativas. Pero sólo hay **15 estaciones**, y el estimador sandwich necesita del orden de 30–50 conglomerados para ser confiable; con menos, tiende a *subestimar* la varianza, así que esas cifras son, si acaso, todavía optimistas. Lo que la corrección a dos vías dice de fondo es correcto aunque su magnitud no sea precisa: la zona es constante dentro de cada estación, de modo que **los siete contrastes de zona descansan en 15 unidades**, no en 15,704 filas, y su precisión es la que 15 unidades pueden dar.

```
ic <- data.frame(eje = nombres_factor[c("F1", "F2", "F3")], OR =
  ↪ exp(b[c("F1","F2","F3")]),
      inf_iid = exp(b[c("F1","F2","F3")] - 1.96 *
  ↪ ee_iid[c("F1","F2","F3")]),
      sup_iid = exp(b[c("F1","F2","F3")] + 1.96 *
  ↪ ee_iid[c("F1","F2","F3")]),
      inf_dia = exp(b[c("F1","F2","F3")] - 1.96 *
  ↪ ee_dia[c("F1","F2","F3")]),
      sup_dia = exp(b[c("F1","F2","F3")] + 1.96 *
  ↪ ee_dia[c("F1","F2","F3")]))
fig_ic <- ggplot(ic, aes(y = eje)) +
  geom_vline(xintercept = 1, linetype = "dashed", colour = "grey60") +
  geom_errorbar(aes(xmin = inf_iid, xmax = sup_iid), width = 0, colour = "grey70",
    linewidth = 2.2) +
  geom_errorbar(aes(xmin = inf_dia, xmax = sup_dia), width = .25, colour =
    ↪ "#2c7fb8",
    linewidth = .7) +
  geom_point(aes(x = OR), colour = "#2c7fb8", size = 2.2) +
  labs(x = "razón de momios (por desviación estándar)", y = NULL) +
  theme_minimal(base_size = 9)
ggsave("../reports/figuras/momios_ic_corregido.pdf", fig_ic, width = 5.5, height =
  ↪ 2.4)
fig_ic
```




Figura 1: Razones de momios de los factores con intervalos del 95 % bajo independencia (gris) y agrupando por día (color). Los intervalos corregidos son mas anchos y ninguno cruza el 1.

Los intervalos corregidos de los tres factores son casi el doble de anchos que los originales y siguen sin cruzar el 1: la ventilación queda en $[0.84, 0.97]$ y el forzamiento fotoquímico en $[2.48, 3.10]$. Estas son las cifras que deben ir al reporte en lugar de las de `momios_log`.

Limitaciones

Autocorrelación. Las 15 estaciones de un mismo día comparten el clima sinóptico y los días consecutivos correlacionan entre sí, de modo que las 17,029 filas día-estación que entran al ajuste y la validación no son observaciones independientes: la n efectiva está mucho más cerca de los 1,641 días distintos que cubre la serie. Medida sobre los puntajes factoriales, la correlación entre estaciones dentro de un mismo día promedia 0.53 en la respuesta y llega a 0.86 en el factor fotoquímico, mientras que la autocorrelación de la respuesta a un día de distancia es de 0.44: la dependencia transversal es la mayor de las dos. Los errores estándar de `momios_log` y los p -valores de `summary(modelo_log)` son, por lo tanto, optimistas. **Se corrigen en la sección anterior** con errores estándar agrupados por día: se inflan $\times 1.5$ a $\times 2.5$ y las conclusiones sobreviven, salvo el efecto del sábado. Lo que no se puede corregir bien es la dimensión de estación —15 conglomerados son pocos para el estimador— y ahí queda declarado que los contrastes de zona descansan en 15 unidades.

Sin COV, ninguna afirmación de mecanismo. El SIMA no mide compuestos orgánicos volátiles, así que los ejes se describen como *consistentes con* combustión primaria, ventilación o forzamiento fotoquímico, nunca como una atribución de régimen NO_x-COV. Una razón de momios de 2.77 sobre F3 dice que los días con más forzamiento fotoquímico tienen mayores momios de excedencia; no dice cuál de los dos precursores limita la formación de ozono, y esa pregunta no es contestable con estos datos.

Modelo explicativo, no de pronóstico. Los predictores son del mismo día que la respuesta. El modelo describe qué condiciones acompañan a una excedencia; no anticipa el ozono de mañana con los datos de hoy, y por eso no se validó como serie de tiempo.

Partición estacionalmente desbalanceada. Ya cuantificada arriba: la validación de 2025 no tiene otoño y le sobra primavera. El AUC amortigua el sesgo de tasa base, pero las cifras de sensibilidad y

especificidad se leen sobre una validación más cargada de días propensos a excedencia que un año completo.

Verificación espacial pendiente. El reajuste por zona para ver si las razones de momios de las componentes se mueven entre zonas está marcado como opcional en el issue #55 y no se realizó. Queda como extensión natural.