

Regresión logística y análisis discriminante

Issue #55 — MA2003B, equipo 7

Tabla de contenidos

Unión con la matriz de diseño	3
Catóricas: referencia explícita y dummies k−1	4
Partición	6
Regresión logística	7
Razones de momios	8
Razones de momios por componente	9
Evaluación en validación: AUC, sensibilidad, especificidad	10
Curva ROC y matriz de confusión	11
Análisis de umbral	13

```
library(nanoparquet)
library(dplyr)

sima_scores = read_parquet("../data/processed/pca_puntuaciones_diarias.parquet")
sima_modelado = read_parquet("../data/processed/sima_diario_modelado.parquet")

# fecha es hora local de pared sin zona horaria (ver CLAUDE.md); nanoparquet la
# lee como UTC y R la despliega en America/Monterrey, corriéndola 6 horas.
# Fijar el atributo, no convertir (as.POSIXct(tz=) sí correría los datos).
attr(sima_scores$fecha, "tzone") <- "UTC"
attr(sima_modelado$fecha, "tzone") <- "UTC"

summary(sima_scores)
#>      estacion      fecha      particion
#> Length :17348 Min. :2021-01-01 00:00:00 Length :17348
#> N.unique : 15 1st Qu.:2022-03-23 00:00:00 N.unique : 2
#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-21 05:57:50 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#>      PC1      PC2      PC3
#> Min. :-6.879315 Min. :-6.568987 Min. :-10.85356
#> 1st Qu.: -1.443756 1st Qu.: -1.074870 1st Qu.: -0.78362
```

```

#> Median :-0.183288 Median : 0.147917 Median : -0.02443
#> Mean :-0.009084 Mean : 0.004186 Mean : 0.01801
#> 3rd Qu.: 1.365239 3rd Qu.: 1.252383 3rd Qu.: 0.82063
#> Max. : 6.676396 Max. : 5.551524 Max. : 4.62946
summary(sima_modelado)
#> estacion fecha zona
#> Length :23931 Min. :2021-01-01 00:00:00 Length :23931
#> N.unique : 15 1st Qu.:2022-03-04 00:00:00 N.unique : 7
#> N.blank : 0 Median :2023-04-25 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-04-15 06:31:43 Min.nchar: 3
#> Max.nchar: 4 3rd Qu.:2024-05-28 00:00:00 Max.nchar: 8
#> Max. :2025-06-30 00:00:00
#>
#> msnm anio mes temporada
#> Min. :334.0 Min. :2021 Min. : 1.000 Length :23931
#> 1st Qu.:432.0 1st Qu.:2022 1st Qu.: 3.000 N.unique : 4
#> Median :520.0 Median :2023 Median : 6.000 N.blank : 0
#> Mean :517.5 Mean :2023 Mean : 6.188 Min.nchar: 5
#> 3rd Qu.:568.0 3rd Qu.:2024 3rd Qu.: 9.000 Max.nchar: 9
#> Max. :702.0 Max. :2025 Max. :12.000
#>
#> tipo_dia festivo fin_de_semana TOUT_max
#> Length :23931 Min. :0.0000 Min. :0.0000 Min. : -0.55
#> N.unique : 4 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:24.76
#> N.blank : 0 Median :0.0000 Median :0.0000 Median :30.17
#> Min.nchar: 6 Mean :0.0435 Mean :0.2862 Mean :28.84
#> Max.nchar: 9 3rd Qu.:0.0000 3rd Qu.:1.0000 3rd Qu.:33.93
#> Max. :1.0000 Max. :1.0000 Max. :47.58
#> NAs :1272
#> SR_acum NO_06_09 NO2_06_09 NOX_06_09
#> Min. : 0.000 Min. : 0.500 Min. : 0.00 Min. : 0.55
#> 1st Qu.: 2.214 1st Qu.: 5.725 1st Qu.: 9.65 1st Qu.: 16.68
#> Median : 3.590 Median : 11.175 Median : 15.00 Median : 26.85
#> Mean : 3.475 Mean : 20.855 Mean : 17.02 Mean : 37.69
#> 3rd Qu.: 4.808 3rd Qu.: 24.375 3rd Qu.: 22.20 3rd Qu.: 46.55
#> Max. :23.791 Max. :379.300 Max. :119.42 Max. :443.45
#> NAs :1018 NAs :1598 NAs :1624 NAs :1584
#> CO_06_09 WSR_media WSR_min PRS_media
#> Min. : 0.0000 Min. : 0.4367 Min. : 0.100 Min. :681.3
#> 1st Qu.: 0.7602 1st Qu.: 6.2698 1st Qu.: 1.700 1st Qu.:709.8
#> Median : 1.2900 Median : 8.2625 Median : 2.700 Median :714.4
#> Mean : 1.4283 Mean : 8.6782 Mean : 3.154 Mean :715.3
#> 3rd Qu.: 1.9225 3rd Qu.: 10.3917 3rd Qu.: 4.100 3rd Qu.:721.6
#> Max. :11.3925 Max. :147.6317 Max. :129.300 Max. :747.9
#> NAs :1554 NAs :959 NAs :959 NAs :751
#> RH_media RH_min_diurna viento_u_media viento_v_media
#> Min. : 0.9874 Min. : 0.00 Min. : -115.158 Min. : -98.9563
#> 1st Qu.:47.1250 1st Qu.:25.00 1st Qu.: -7.129 1st Qu.: -1.9403

```

```

#> Median :57.6250 Median :36.00 Median : -4.124 Median : 0.5571
#> Mean :56.6028 Mean :37.06 Mean : -4.245 Mean : 0.2831
#> 3rd Qu.:67.2083 3rd Qu.:48.00 3rd Qu.: -1.479 3rd Qu.: 2.6366
#> Max. :99.3889 Max. :95.00 Max. : 31.490 Max. : 39.1337
#> NAs :2067 NAs :1995 NAs :1387 NAs :1387
#> PM10_media PM2.5_media SO2_media llovio
#> Min. : 4.00 Min. : 2.182 Min. : 0.5045 Min. :0.00000
#> 1st Qu.: 40.51 1st Qu.: 12.812 1st Qu.: 3.1208 1st Qu.:0.00000
#> Median : 54.69 Median : 18.169 Median : 4.1333 Median :0.00000
#> Mean : 60.18 Mean : 20.524 Mean : 4.7485 Mean :0.08185
#> 3rd Qu.: 73.82 3rd Qu.: 25.602 3rd Qu.: 5.7250 3rd Qu.:0.00000
#> Max. :317.87 Max. :167.979 Max. :61.7750 Max. :1.00000
#> NAs :805 NAs :5229 NAs :1720 NAs :706
#> MDA8 ventanas_validas O3_max_1h excede_anio_1
#> Min. : 2.344 Min. : 0.00 Min. : 1.00 Min. :0.0000
#> 1st Qu.: 33.375 1st Qu.:24.00 1st Qu.: 39.00 1st Qu.:0.0000
#> Median : 43.125 Median :24.00 Median : 53.00 Median :0.0000
#> Mean : 44.610 Mean :22.87 Mean : 55.73 Mean :0.1065
#> 3rd Qu.: 54.000 3rd Qu.:24.00 3rd Qu.: 69.00 3rd Qu.:0.0000
#> Max. :147.875 Max. :24.00 Max. :265.00 Max. :1.0000
#> NAs :1402 NAs :709 NAs :1402
#> excede_anio_3 excede_anio_5 excede_1h
#> Min. :0.0000 Min. :0.000 Min. :0.0000
#> 1st Qu.:0.0000 1st Qu.:0.000 1st Qu.:0.0000
#> Median :0.0000 Median :0.000 Median :0.0000
#> Mean :0.1604 Mean :0.307 Mean :0.0799
#> 3rd Qu.:0.0000 3rd Qu.:1.000 3rd Qu.:0.0000
#> Max. :1.0000 Max. :1.000 Max. :1.0000
#> NAs :1402 NAs :1402

```

Unión con la matriz de diseño

Las puntuaciones del PCA (`sima_scores`) solo traen `estacion`, `fecha`, `particion` y las tres componentes. Zona, calendario y la variable respuesta viven en `sima_modelado`, así que se unen por (`estacion`, `fecha`).

```

sima_disc <- sima_scores |>
  inner_join(
    sima_modelado |>
      select(estacion, fecha, zona, tipo_dia, temporada, excede_anio_5),
    by = c("estacion", "fecha")
  )

stopifnot(nrow(sima_disc) == nrow(sima_scores))
summary(sima_disc)
#>      estacion      fecha      particion

```

```

#> Length :17348 Min. :2021-01-01 00:00:00 Length :17348
#> N.unique : 15 1st Qu.:2022-03-23 00:00:00 N.unique : 2
#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-21 05:57:50 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#>
#> PC1 PC2 PC3 zona
#> Min. :-6.879315 Min. :-6.568987 Min. :-10.85356 Length :17348
#> 1st Qu.: -1.443756 1st Qu.: -1.074870 1st Qu.: -0.78362 N.unique : 7
#> Median :-0.183288 Median : 0.147917 Median : -0.02443 N.blank : 0
#> Mean :-0.009084 Mean : 0.004186 Mean : 0.01801 Min.nchar: 3
#> 3rd Qu.: 1.365239 3rd Qu.: 1.252383 3rd Qu.: 0.82063 Max.nchar: 8
#> Max. : 6.676396 Max. : 5.551524 Max. : 4.62946
#>
#> tipo_dia temporada excede_anio_5
#> Length :17348 Length :17348 Min. :0.0000
#> N.unique : 4 N.unique : 4 1st Qu.:0.0000
#> N.blank : 0 N.blank : 0 Median :0.0000
#> Min.nchar: 6 Min.nchar: 5 Mean :0.3041
#> Max.nchar: 9 Max.nchar: 9 3rd Qu.:1.0000
#> Max. :1.0000
#> NAs :362

```

Categorías: referencia explícita y dummies k–1

Referencia por variable (issue #55):

- **zona: Noreste**, la de menor tasa de excedencia (19.0 %, docs/05_estacionalidad_ozono.pdf) — baseline de menor riesgo.
- **tipo_dia: laborable**, el nivel más frecuente y el orden natural de NIVELES_TIPO_DIA en src/agregacion_diaria.py.
- **temporada: invierno**, temporada de menor actividad fotoquímica.

festivo no se agrega aparte: por construcción (src/agregacion_diaria.py, marcar_calendario) `tipo_dia == "festivo"` es idéntico a `festivo == 1` — son la misma indicadora. Incluir ambas duplicaría la columna y generaría colinealidad perfecta; la dummy `tipo_dia_festivo` ya la cubre.

```

sima_disc <- sima_disc |>
  mutate(
    zona = relevel(factor(zona), ref = "Noreste"),
    tipo_dia = factor(tipo_dia,
                      levels = c("laborable", "sabado", "domingo", "festivo")),
    temporada = factor(temporada,
                       levels = c("invierno", "primavera", "verano", "otoño"))
  )

```

```

dummies <- model.matrix(~ zona + tipo_dia + temporada, data = sima_disc)[, -1]
colnames(dummies) <- gsub("^zona|^tipo_dia|^temporada", "", colnames(dummies))
colnames(dummies) <- c(
  paste0("zona_", colnames(dummies)[1:6]),
  paste0("tipo_dia_", colnames(dummies)[7:9]),
  paste0("temporada_", colnames(dummies)[10:12])
)

sima_disc <- cbind(sima_disc, dummies)
stopifnot(ncol(dummies) == 12) # 6 zona + 3 tipo_dia + 3 temporada
summary(sima_disc)
#>      estacion      fecha      particion
#> Length      :17348  Min.      :2021-01-01 00:00:00  Length      :17348
#> N.unique    :   15  1st Qu.  :2022-03-23 00:00:00  N.unique    :    2
#> N.blank     :    0  Median   :2023-03-09 00:00:00  N.blank     :    0
#> Min.nchar   :    2  Mean     :2023-03-21 05:57:50  Min.nchar   :   10
#> Max.nchar   :    4  3rd Qu.  :2024-03-05 00:00:00  Max.nchar   :   13
#>      Max.      :2025-06-30 00:00:00
#>
#>      PC1      PC2      PC3      zona
#> Min.      :-6.879315  Min.      :-6.568987  Min.      :-10.85356  Noreste :3152
#> 1st Qu.   :-1.443756  1st Qu.   :-1.074870  1st Qu.   :-0.78362  Centro  :1488
#> Median    :-0.183288  Median    : 0.147917  Median    :-0.02443  Noroeste:2402
#> Mean      :-0.009084  Mean      : 0.004186  Mean      : 0.01801  Norte   :2072
#> 3rd Qu.   : 1.365239  3rd Qu.   : 1.252383  3rd Qu.   : 0.82063  Sur     :1346
#> Max.      : 6.676396  Max.      : 5.551524  Max.      : 4.62946  Sureste :4111
#>      Suroeste:2777
#>      tipo_dia      temporada      excede_anio_5      zona_Centro
#> laborable:11782  invierno :4259  Min.      :0.0000  Min.      :0.00000
#> sabado      : 2415  primavera:4817  1st Qu.   :0.0000  1st Qu.   :0.00000
#> domingo     : 2389  verano   :4193  Median    :0.0000  Median    :0.00000
#> festivo     :  762  otoño    :4079  Mean      :0.3041  Mean      :0.08577
#>      3rd Qu. :1.0000  3rd Qu.   :0.00000
#>      Max.      :1.0000  Max.      :1.00000
#>      NAs       :362
#>      zona_Noroeste      zona_Norte      zona_Sur      zona_Sureste
#> Min.      :0.0000  Min.      :0.0000  Min.      :0.00000  Min.      :0.000
#> 1st Qu.   :0.0000  1st Qu.   :0.0000  1st Qu.   :0.00000  1st Qu.   :0.000
#> Median    :0.0000  Median    :0.0000  Median    :0.00000  Median    :0.000
#> Mean      :0.1385  Mean      :0.1194  Mean      :0.07759  Mean      :0.237
#> 3rd Qu.   :0.0000  3rd Qu.   :0.0000  3rd Qu.   :0.00000  3rd Qu.   :0.000
#> Max.      :1.0000  Max.      :1.0000  Max.      :1.00000  Max.      :1.000
#>
#>      zona_Suroeste      tipo_dia_sabado      tipo_dia_domingo      tipo_dia_festivo
#> Min.      :0.0000  Min.      :0.0000  Min.      :0.0000  Min.      :0.00000
#> 1st Qu.   :0.0000  1st Qu.   :0.0000  1st Qu.   :0.0000  1st Qu.   :0.00000
#> Median    :0.0000  Median    :0.0000  Median    :0.0000  Median    :0.00000
#> Mean      :0.1601  Mean      :0.1392  Mean      :0.1377  Mean      :0.04392

```

```
#> 3rd Qu.:0.0000 3rd Qu.:0.0000 3rd Qu.:0.0000 3rd Qu.:0.00000
#> Max. :1.0000 Max. :1.0000 Max. :1.0000 Max. :1.00000
#>
#> temporada_primavera temporada_verano temporada_otoño
#> Min. :0.0000 Min. :0.0000 Min. :0.0000
#> 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:0.0000
#> Median :0.0000 Median :0.0000 Median :0.0000
#> Mean :0.2777 Mean :0.2417 Mean :0.2351
#> 3rd Qu.:1.0000 3rd Qu.:0.0000 3rd Qu.:0.0000
#> Max. :1.0000 Max. :1.0000 Max. :1.0000
#>
```

Partición

Entrenamiento 2021–2024, validación 2025, como decidió el equipo (#54, #55). `sima_scores` ya trae `particion` calculada así desde el PCA — se reutiliza en vez de recalcularla a partir de `fecha`, para garantizar que el PCA y los modelos de clasificación usan exactamente la misma frontera y que ninguno vio 2025 durante el ajuste.

```
table(sima_disc$particion)
#>
#> entrenamiento validacion
#> 16008 1340

sima_train <- sima_disc |> filter(particion == "entrenamiento")
sima_valid <- sima_disc |> filter(particion == "validacion")

range(sima_train$fecha)
#> [1] "2021-01-01 UTC" "2024-12-31 UTC"
range(sima_valid$fecha)
#> [1] "2025-01-01 UTC" "2025-06-30 UTC"
```

Limitación de la partición (cuantificada en docs/05_estacionalidad_ozono.pdf): como 2025 termina el 30 de junio, la validación es 52.3 % primavera, 32.2 % invierno, 15.5 % verano y 0 % otoño, contra un entrenamiento repartido casi por igual (23.1–26.0 %). La tasa base de excedencia pasa de 29.31 % a 41.50 %, 12.2 puntos que vienen del calendario y no del modelo. El AUC es menos sensible a la tasa base que la exactitud, lo que amortigua el problema pero no lo elimina — por eso la exactitud no se usa como métrica de decisión más adelante.

```
mean(sima_train$excede_anio_5, na.rm = TRUE)
#> [1] 0.2946622
mean(sima_valid$excede_anio_5, na.rm = TRUE)
#> [1] 0.4154079
```

Regresión logística

Respuesta `excede_anio_5`; predictores las tres componentes retenidas en #54 más los 12 dummies (zona, tipo_día, temporada) del paso anterior. Se arma la fórmula a partir de los nombres de columna en vez de escribirla a mano, para que quede ligada a los dummies que de verdad existen en `sima_disc` — si cambia el catálogo de zonas, la fórmula lo sigue sin que haya que tocarla.

```
predictores <- c("PC1", "PC2", "PC3",
                 grep("^zona_|^tipo_dia_|^temporada_", names(sima_disc), value =
                   TRUE))
formula_log <- reformulate(predictores, response = "excede_anio_5")
formula_log
#> excede_anio_5 ~ PC1 + PC2 + PC3 + zona_Centro + zona_Noroeste +
#>      zona_Norte + zona_Sur + zona_Sureste + zona_Suroeste + tipo_dia_sabado +
#>      tipo_dia_domingo + tipo_dia_festivo + temporada_primavera +
#>      temporada_verano + temporada_otoño
```

Ajuste sobre `sima_train` únicamente — `sima_valid` no participa del ajuste, solo de la evaluación:

```
modelo_log <- glm(formula_log, data = sima_train, family = binomial)
summary(modelo_log)
#>
#> Call:
#> glm(formula = formula_log, family = binomial, data = sima_train)
#>
#> Coefficients:
#>              Estimate Std. Error z value Pr(>|z|)
#> (Intercept)    -2.97495     0.08022  -37.086   < 2e-16 ***
#> PC1              0.38774     0.01310   29.603   < 2e-16 ***
#> PC2              0.45995     0.01633   28.166   < 2e-16 ***
#> PC3              0.19840     0.01909   10.394   < 2e-16 ***
#> zona_Centro      0.94794     0.08312   11.404   < 2e-16 ***
#> zona_Noroeste     1.20900     0.07319   16.518   < 2e-16 ***
#> zona_Norte        0.27217     0.07973    3.414 0.000641 ***
#> zona_Sur          1.07865     0.08674   12.435   < 2e-16 ***
#> zona_Sureste      0.64178     0.06905    9.294   < 2e-16 ***
#> zona_Suroeste     1.15601     0.07352   15.723   < 2e-16 ***
#> tipo_dia_sabado   0.06150     0.05955    1.033 0.301711
#> tipo_dia_domingo  0.32715     0.06060    5.399 6.72e-08 ***
#> tipo_dia_festivo  0.09908     0.10505    0.943 0.345611
#> temporada_primavera 1.63104     0.07034   23.189   < 2e-16 ***
#> temporada_verano  1.00484     0.08019   12.531   < 2e-16 ***
#> temporada_otoño   1.44644     0.06859   21.089   < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> (Dispersion parameter for binomial family taken to be 1)
```

```
#>
#> Null deviance: 18991 on 15661 degrees of freedom
#> Residual deviance: 15267 on 15646 degrees of freedom
#> (346 observations deleted due to missingness)
#> AIC: 15299
#>
#> Number of Fisher Scoring iterations: 5
```

Razones de momios

La tabla que cuenta la historia (issue #55): `exp(coeficiente)` convierte la escala logit a razón de momios, e IC 95% viene de `broom::tidy` con `conf.int = TRUE` (Wald, no perfil de verosimilitud — más rápido y suficiente para reportar signo y magnitud).

```
library(broom)

momios_log <- tidy(modelo_log, exponentiate = TRUE, conf.int = TRUE) |>
  filter(term != "(Intercept)")
momios_log
#> # A tibble: 15 x 7
#>   term                estimate std.error statistic  p.value conf.low
#>   <chr>                <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
#>   <dbl>
#> 1 PC1                  1.47     0.0131     29.6  1.37e-192    1.44
#>   1.51
#> 2 PC2                  1.58     0.0163     28.2  1.51e-174    1.53
#>   1.64
#> 3 PC3                  1.22     0.0191     10.4  2.65e- 25    1.17
#>   1.27
#> 4 zona_Centro          2.58     0.0831     11.4  3.98e- 30    2.19
#>   3.04
#> 5 zona_Noroeste        3.35     0.0732     16.5  2.71e- 61    2.90
#>   3.87
#> 6 zona_Norte           1.31     0.0797      3.41  6.41e-  4    1.12
#>   1.53
#> 7 zona_Sur             2.94     0.0867     12.4  1.68e- 35    2.48
#>   3.49
#> 8 zona_Sureste         1.90     0.0691      9.29  1.48e- 20    1.66
#>   2.18
#> 9 zona_Suroeste        3.18     0.0735     15.7  1.05e- 55    2.75
#>   3.67
#> 10 tipo_dia_sabado      1.06     0.0595      1.03  3.02e-  1    0.946
#>   1.19
#> 11 tipo_dia_domingo     1.39     0.0606      5.40  6.72e-  8    1.23
#>   1.56
```



```
#> 12 tipo_dia_festivo      1.10    0.105    0.943 3.46e- 1    0.897
↪ 1.35
#> 13 temporada_primavera  5.11    0.0703   23.2  5.86e-119   4.45
↪ 5.87
#> 14 temporada_verano     2.73    0.0802   12.5  5.03e- 36    2.34
↪ 3.20
#> 15 temporada_otoño      4.25    0.0686   21.1  1.00e- 98    3.72
↪ 4.86
```

Razones de momios por componente

Los tres ejes retenidos en #54, con su nombre interpretativo (no solo “PC1/PC2/PC3”) porque ese es justo el requisito que #54 le impone a esta tabla: sin nombre, una razón de momios sobre un componente es ilegible.

```
nombres_pc <- c(PC1 = "Carga primaria de combustión",
                 PC2 = "Forzamiento fotoquímico",
                 PC3 = "Estancamiento atmosférico")

momios_pc <- momios_log |>
  filter(term %in% names(nombres_pc)) |>
  mutate(eje = nombres_pc[term], .before = 1) |>
  select(eje, termino = term, momios = estimate,
         ic_inf = conf.low, ic_sup = conf.high, p.value)

momios_pc
#> # A tibble: 3 x 6
#>   eje                termino momios ic_inf ic_sup  p.value
#>   <chr>              <chr>    <dbl> <dbl> <dbl>    <dbl>
#> 1 Carga primaria de combustión PC1      1.47  1.44  1.51 1.37e-192
#> 2 Forzamiento fotoquímico      PC2      1.58  1.53  1.64 1.51e-174
#> 3 Estancamiento atmosférico    PC3      1.22  1.17  1.27 2.65e- 25
```


Cada razón de momios es **por desviación estándar** del componente, no por unidad arbitraria — así lo dejó #54 al construir `sima_scores` (puntuaciones ya estandarizadas del PCA), y es lo que hace comparables los tres momios entre sí pese a que las cargas originales tengan escalas distintas.

```
library(ggplot2)

fig_momios <- ggplot(momios_pc, aes(x = momios, y = reorder(eje, momios))) +
  geom_vline(xintercept = 1, linetype = "dashed", colour = "grey60") +
  geom_pointrange(aes(xmin = ic_inf, xmax = ic_sup), colour = "#2c7fb8", linewidth
    ↪ = 0.8) +
  geom_text(aes(label = sprintf("%.2f", momios)), vjust = -1, size = 3.5) +
  labs(title = "Razones de momios por componente",
       subtitle = "Excedencia MDA8 > 51 ppb - IC 95%",
       x = "Razón de momios", y = NULL) +
```

```
theme_minimal()

fig_momios
```



```
ggsave("../reports/figuras/momios_componentes.pdf", fig_momios,
        width = 6, height = 3.6, units = "in")
```

Los tres quedan por encima de 1 con el intervalo lejos de esa línea: subir una desviación estándar en cualquiera de los tres ejes se asocia con mayores momios de excedencia, controlando por zona y calendario. El de mayor efecto es el forzamiento fotoquímico, seguido de la combustión primaria — consistente con que el ozono es un contaminante secundario que necesita tanto precursores como las condiciones para formarse fotoquímicamente, no solo lo primero.

Evaluación en validación: AUC, sensibilidad, especificidad

Nunca exactitud — con 41.50 % de excedencia base en validación, un clasificador constante ya acierta bien sin distinguir nada.

```
library(pROC)

p_valid <- predict(modelo_log, newdata = sima_valid, type = "response")
roc_log <- roc(sima_valid$excede_anio_5, p_valid, quiet = TRUE)

auc(roc_log)
#> Area under the curve: 0.8928
```

Criterio de logro del issue: AUC 0.75 en validación. Umbral de clasificación para sensibilidad/especificidad y matriz de confusión — el que maximiza sensibilidad + especificidad (Youden), declarado explícitamente en vez de asumir 0.5:

```
umbral_log <- coords(roc_log, "best", best.method = "youden", ret = "threshold")
umbral_log <- as.numeric(umbral_log)
umbral_log
#> [1] 0.2883406

pred_log <- factor(p_valid >= umbral_log, levels = c(FALSE, TRUE),
                  labels = c("no_excede", "excede"))
obs_log <- factor(sima_valid$excede_anio_5, levels = c(0, 1),
                 labels = c("no_excede", "excede"))

matriz_log <- table(observado = obs_log, predicho = pred_log)
matriz_log
#>           predicho
#> observado no_excede excede
#> no_excede      638    136
#> excede         93    457

coords(roc_log, umbral_log, ret = c("sensitivity", "specificity"))
#> sensitivity specificity
#> 1    0.8309091    0.8242894
```


Curva ROC y matriz de confusión

Estas figuras son solo del modelo logístico; cuando se agregue el discriminante lineal, la curva ROC se rehace comparando ambos en una sola figura ([reports/figuras/roc_modelos.pdf](#), issue #55) en vez de duplicar dos figuras separadas — por eso esta versión se guarda con nombre provisional ([roc_log.pdf](#)) y se retira cuando exista la comparativa.

```
library(ggplot2)

fig_roc_log <- ggroc(roc_log, linewidth = 1, colour = "#2c7fb8") +
  geom_abline(intercept = 1, slope = 1, linetype = "dashed", colour = "grey60") +
  annotate("text", x = 0.25, y = 0.1,
          label = sprintf("AUC = %.3f", auc(roc_log)), size = 4) +
  labs(title = "Curva ROC - regresión logística (validación 2025)",
       x = "Especificidad", y = "Sensibilidad") +
  coord_equal() +
  theme_minimal()

fig_roc_log
```



```
ggsave("../reports/figuras/roc_log.pdf", fig_roc_log,
        width = 6, height = 3.6, units = "in")
```

Matriz de confusión al umbral de Youden, como conteos y como proporción por fila (observado):


```
matriz_prop <- as.data.frame(matriz_log) |>
  group_by(observado) |>
  mutate(prop = Freq / sum(Freq))

fig_matriz_log <- ggplot(matriz_prop, aes(x = predicho, y = observado, fill =
  ↪ prop)) +
  geom_tile(colour = "white") +
  geom_text(aes(label = sprintf("%d\n(%.1f%%)", Freq, prop * 100)),
            colour = "white", fontface = "bold") +
  scale_fill_gradient(low = "#9ecae1", high = "#08519c", limits = c(0, 1),
                     guide = "none") +
  labs(title = "Matriz de confusión - regresión logística (validación 2025)",
       subtitle = sprintf("Umbral = %.3f (Youden)", umbral_log),
       x = "Predicho", y = "Observado") +
  theme_minimal()

fig_matriz_log
```

Matriz de confusión – regresión logística (validación 2025)

Umbral = 0.288 (Youden)



```
ggsave("../reports/figuras/matriz_confusion_log.pdf", fig_matriz_log,
        width = 6, height = 3.6, units = "in")
```

Análisis de umbral

Cada punto de la curva ROC es un umbral distinto; esta tabla lo hace explícito para un puñado de candidatos, en vez de comprometerse solo con el de Youden. Se incluye exactitud a propósito, para mostrar por qué **no** se usa como criterio: sube con el umbral más alto (clasifica casi todo como “no excede”, la clase mayoritaria) mientras la sensibilidad se desploma — exactamente el efecto que el checklist de la issue #55 advierte.

```
candidatos <- c(youden = umbral_log, `0.5` = 0.5,
                tasa_base_train = mean(sima_train$excede_anio_5, na.rm = TRUE),
                tasa_base_valid = mean(sima_valid$excede_anio_5, na.rm = TRUE))

tabla_umbrales <- coords(roc_log, candidatos,
                        ret = c("threshold", "sensitivity", "specificity",
                               ↪ "accuracy")) |>
  mutate(criterio = names(candidatos), .before = 1)

tabla_umbrales
#>               criterio threshold sensitivity specificity accuracy
#> youden               youden 0.2883406   0.8309091  0.8242894 0.8270393
#> 0.5                  0.5 0.5000000   0.5181818  0.9418605 0.7658610
#> tasa_base_train tasa_base_train 0.2946622   0.8127273  0.8281654 0.8217523
#> tasa_base_valid tasa_base_valid 0.4154079   0.6290909  0.9198966 0.7990937
```

Sensibilidad y especificidad se mueven en direcciones opuestas al mover el umbral — no hay un punto que maximice ambas a la vez, por eso Youden (maximizar su suma) es un criterio razonable por defecto y no un óptimo universal: si el costo de una excedencia no detectada fuera mucho mayor que el de una falsa alarma, convendría un umbral más bajo que sacrifique especificidad por sensibilidad.