

Regresión logística y análisis discriminante

Issue #55 — MA2003B, equipo 7

Tabla de contenidos

Unión con la matriz de diseño	3
Catóricas: referencia explícita y dummies k−1	4
Partición	6
Regresión logística	7
Razones de momios	8
Razones de momios por componente	9
Evaluación en validación: AUC, sensibilidad, especificidad	11
Análisis de umbral	12
Análisis discriminante lineal	12
Verificación de supuestos	12
Ajuste	14
Evaluación en validación	15
Comparación de los dos modelos	15
Curvas ROC de ambos modelos	17
Matrices de confusión	18
Limitaciones	20

```
library(nanoparquet)
library(dplyr)

sima_scores <- read_parquet("../data/processed/pca_puntuaciones_diarias.parquet")
sima_modelado <- read_parquet("../data/processed/sima_diario_modelado.parquet")

# fecha es hora local de pared sin zona horaria (ver CLAUDE.md); nanoparquet la
# lee como UTC y R la despliega en America/Monterrey, corriéndola 6 horas.
# Fijar el atributo, no convertir (as.POSIXct(tz=) sí correría los datos).
attr(sima_scores$fecha, "tzone") <- "UTC"
attr(sima_modelado$fecha, "tzone") <- "UTC"

summary(sima_scores)
#>      estacion      fecha      particion
#> Length :17348 Min. :2021-01-01 00:00:00 Length :17348
#> N.unique : 15 1st Qu.:2022-03-23 00:00:00 N.unique : 2
```

```

#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-21 05:57:50 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#> PC1 PC2 PC3
#> Min. :-6.879315 Min. :-6.568987 Min. :-10.85356
#> 1st Qu.: -1.443756 1st Qu.: -1.074870 1st Qu.: -0.78362
#> Median : -0.183288 Median : 0.147917 Median : -0.02443
#> Mean :-0.009084 Mean : 0.004186 Mean : 0.01801
#> 3rd Qu.: 1.365239 3rd Qu.: 1.252383 3rd Qu.: 0.82063
#> Max. : 6.676396 Max. : 5.551524 Max. : 4.62946
summary(sima_modelado)
#> estacion fecha zona
#> Length :23931 Min. :2021-01-01 00:00:00 Length :23931
#> N.unique : 15 1st Qu.:2022-03-04 00:00:00 N.unique : 7
#> N.blank : 0 Median :2023-04-25 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-04-15 06:31:43 Min.nchar: 3
#> Max.nchar: 4 3rd Qu.:2024-05-28 00:00:00 Max.nchar: 8
#> Max. :2025-06-30 00:00:00
#>
#> msnm anio mes temporada
#> Min. :334.0 Min. :2021 Min. : 1.000 Length :23931
#> 1st Qu.:432.0 1st Qu.:2022 1st Qu.: 3.000 N.unique : 4
#> Median :520.0 Median :2023 Median : 6.000 N.blank : 0
#> Mean :517.5 Mean :2023 Mean : 6.188 Min.nchar: 5
#> 3rd Qu.:568.0 3rd Qu.:2024 3rd Qu.: 9.000 Max.nchar: 9
#> Max. :702.0 Max. :2025 Max. :12.000
#>
#> tipo_dia festivo fin_de_semana TOUT_max
#> Length :23931 Min. :0.0000 Min. :0.0000 Min. : -0.55
#> N.unique : 4 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:24.76
#> N.blank : 0 Median :0.0000 Median :0.0000 Median :30.17
#> Min.nchar: 6 Mean :0.0435 Mean :0.2862 Mean :28.84
#> Max.nchar: 9 3rd Qu.:0.0000 3rd Qu.:1.0000 3rd Qu.:33.93
#> Max. :1.0000 Max. :1.0000 Max. :47.58
#> NAs :1272
#> SR_acum NO_06_09 NO2_06_09 NOX_06_09
#> Min. : 0.000 Min. : 0.500 Min. : 0.00 Min. : 0.55
#> 1st Qu.: 2.214 1st Qu.: 5.725 1st Qu.: 9.65 1st Qu.: 16.68
#> Median : 3.590 Median : 11.175 Median : 15.00 Median : 26.85
#> Mean : 3.475 Mean : 20.855 Mean : 17.02 Mean : 37.69
#> 3rd Qu.: 4.808 3rd Qu.: 24.375 3rd Qu.: 22.20 3rd Qu.: 46.55
#> Max. :23.791 Max. :379.300 Max. :119.42 Max. :443.45
#> NAs :1018 NAs :1598 NAs :1624 NAs :1584
#> CO_06_09 WSR_media WSR_min PRS_media
#> Min. : 0.0000 Min. : 0.4367 Min. : 0.100 Min. :681.3
#> 1st Qu.: 0.7602 1st Qu.: 6.2698 1st Qu.: 1.700 1st Qu.:709.8
#> Median : 1.2900 Median : 8.2625 Median : 2.700 Median :714.4

```

```

#> Mean      : 1.4283      Mean      : 8.6782      Mean      : 3.154      Mean      :715.3
#> 3rd Qu.: 1.9225      3rd Qu.: 10.3917      3rd Qu.: 4.100      3rd Qu.:721.6
#> Max.       :11.3925      Max.       :147.6317      Max.       :129.300      Max.       :747.9
#> NAs        :1554      NAs        :959          NAs        :959          NAs        :751
#>      RH_media      RH_min_diurna      viento_u_media      viento_v_media
#> Min.       : 0.9874      Min.       : 0.00      Min.       : -115.158      Min.       : -98.9563
#> 1st Qu.:47.1250      1st Qu.:25.00      1st Qu.: -7.129      1st Qu.: -1.9403
#> Median :57.6250      Median :36.00      Median : -4.124      Median : 0.5571
#> Mean      :56.6028      Mean      :37.06      Mean      : -4.245      Mean      : 0.2831
#> 3rd Qu.:67.2083      3rd Qu.:48.00      3rd Qu.: -1.479      3rd Qu.: 2.6366
#> Max.       :99.3889      Max.       :95.00      Max.       : 31.490      Max.       : 39.1337
#> NAs        :2067      NAs        :1995      NAs        :1387      NAs        :1387
#>      PM10_media      PM2.5_media      SO2_media      llovio
#> Min.       : 4.00      Min.       : 2.182      Min.       : 0.5045      Min.       :0.00000
#> 1st Qu.: 40.51      1st Qu.: 12.812      1st Qu.: 3.1208      1st Qu.:0.00000
#> Median : 54.69      Median : 18.169      Median : 4.1333      Median :0.00000
#> Mean      : 60.18      Mean      : 20.524      Mean      : 4.7485      Mean      :0.08185
#> 3rd Qu.: 73.82      3rd Qu.: 25.602      3rd Qu.: 5.7250      3rd Qu.:0.00000
#> Max.       :317.87      Max.       :167.979      Max.       :61.7750      Max.       :1.00000
#> NAs        :805      NAs        :5229      NAs        :1720      NAs        :706
#>      MDA8      ventanas_validas      O3_max_1h      excede_anio_1
#> Min.       : 2.344      Min.       : 0.00      Min.       : 1.00      Min.       :0.0000
#> 1st Qu.: 33.375      1st Qu.:24.00      1st Qu.: 39.00      1st Qu.:0.0000
#> Median : 43.125      Median :24.00      Median : 53.00      Median :0.0000
#> Mean      : 44.610      Mean      :22.87      Mean      : 55.73      Mean      :0.1065
#> 3rd Qu.: 54.000      3rd Qu.:24.00      3rd Qu.: 69.00      3rd Qu.:0.0000
#> Max.       :147.875      Max.       :24.00      Max.       :265.00      Max.       :1.0000
#> NAs        :1402      NAs        :709      NAs        :1402
#> excede_anio_3      excede_anio_5      excede_1h
#> Min.       :0.0000      Min.       :0.000      Min.       :0.0000
#> 1st Qu.:0.0000      1st Qu.:0.000      1st Qu.:0.0000
#> Median :0.0000      Median :0.000      Median :0.0000
#> Mean      :0.1604      Mean      :0.307      Mean      :0.0799
#> 3rd Qu.:0.0000      3rd Qu.:1.000      3rd Qu.:0.0000
#> Max.       :1.0000      Max.       :1.000      Max.       :1.0000
#> NAs        :1402      NAs        :1402

```

Unión con la matriz de diseño

Las puntuaciones del PCA (`sima_scores`) solo traen `estacion`, `fecha`, `particion` y las tres componentes. Zona, calendario y la variable respuesta viven en `sima_modelado`, así que se unen por (`estacion`, `fecha`).

```

sima_disc <- sima_scores |>
  inner_join(
    sima_modelado |>

```

```

    select(estacion, fecha, zona, tipo_dia, temporada, excede_anio_5),
    by = c("estacion", "fecha")
)

stopifnot(nrow(sima_disc) == nrow(sima_scores))
summary(sima_disc)
#>      estacion      fecha      particion
#> Length :17348 Min. :2021-01-01 00:00:00 Length :17348
#> N.unique : 15 1st Qu.:2022-03-23 00:00:00 N.unique : 2
#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-21 05:57:50 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#>
#>      PC1      PC2      PC3      zona
#> Min. :-6.879315 Min. :-6.568987 Min. :-10.85356 Length :17348
#> 1st Qu.: -1.443756 1st Qu.: -1.074870 1st Qu.: -0.78362 N.unique : 7
#> Median :-0.183288 Median : 0.147917 Median : -0.02443 N.blank : 0
#> Mean :-0.009084 Mean : 0.004186 Mean : 0.01801 Min.nchar: 3
#> 3rd Qu.: 1.365239 3rd Qu.: 1.252383 3rd Qu.: 0.82063 Max.nchar: 8
#> Max. : 6.676396 Max. : 5.551524 Max. : 4.62946
#>
#>      tipo_dia      temporada      excede_anio_5
#> Length :17348 Length :17348 Min. :0.0000
#> N.unique : 4 N.unique : 4 1st Qu.:0.0000
#> N.blank : 0 N.blank : 0 Median :0.0000
#> Min.nchar: 6 Min.nchar: 5 Mean :0.3041
#> Max.nchar: 9 Max.nchar: 9 3rd Qu.:1.0000
#> Max. :1.0000
#> NAs :362

```

Categorías: referencia explícita y dummies k—1

Referencia por variable (issue #55):

- **zona: Noreste**, la de menor tasa de excedencia (19.0 %, docs/05_estacionalidad_ozono.pdf) — baseline de menor riesgo.
- **tipo_dia: laborable**, el nivel más frecuente y el orden natural de NIVELES_TIPO_DIA en src/agregacion_diaria.py.
- **temporada: invierno**, temporada de menor actividad fotoquímica.

festivo no se agrega aparte: por construcción (src/agregacion_diaria.py, marcar_calendario) tipo_dia == "festivo" es idéntico a festivo == 1 — son la misma indicadora. Incluir ambas duplicaría la columna y generaría colinealidad perfecta; la dummy tipo_dia_festivo ya la cubre.

```

sima_disc <- sima_disc |>
  mutate(

```

```

    zona = relevel(factor(zona), ref = "Noreste"),
    tipo_dia = factor(tipo_dia,
        levels = c("laborable", "sabado", "domingo", "festivo")
    ),
    temporada = factor(temporada,
        levels = c("invierno", "primavera", "verano", "otoño")
    )
)

dummies <- model.matrix(~ zona + tipo_dia + temporada, data = sima_disc)[, -1]
colnames(dummies) <- gsub("^zona|^tipo_dia|^temporada", "", colnames(dummies))
colnames(dummies) <- c(
    paste0("zona_", colnames(dummies)[1:6]),
    paste0("tipo_dia_", colnames(dummies)[7:9]),
    paste0("temporada_", colnames(dummies)[10:12])
)

sima_disc <- cbind(sima_disc, dummies)
stopifnot(ncol(dummies) == 12) # 6 zona + 3 tipo_dia + 3 temporada
summary(sima_disc)
#>      estacion      fecha      particion
#> Length :17348 Min. :2021-01-01 00:00:00 Length :17348
#> N.unique : 15 1st Qu.:2022-03-23 00:00:00 N.unique : 2
#> N.blank : 0 Median :2023-03-09 00:00:00 N.blank : 0
#> Min.nchar: 2 Mean :2023-03-21 05:57:50 Min.nchar: 10
#> Max.nchar: 4 3rd Qu.:2024-03-05 00:00:00 Max.nchar: 13
#> Max. :2025-06-30 00:00:00
#>
#>      PC1      PC2      PC3      zona
#> Min. :-6.879315 Min. :-6.568987 Min. :-10.85356 Noreste :3152
#> 1st Qu.: -1.443756 1st Qu.: -1.074870 1st Qu.: -0.78362 Centro :1488
#> Median :-0.183288 Median : 0.147917 Median : -0.02443 Noroeste:2402
#> Mean :-0.009084 Mean : 0.004186 Mean : 0.01801 Norte :2072
#> 3rd Qu.: 1.365239 3rd Qu.: 1.252383 3rd Qu.: 0.82063 Sur :1346
#> Max. : 6.676396 Max. : 5.551524 Max. : 4.62946 Sureste :4111
#> Suroeste:2777
#>      tipo_dia      temporada      excede_anio_5      zona_Centro
#> laborable:11782 invierno :4259 Min. :0.0000 Min. :0.00000
#> sabado : 2415 primavera:4817 1st Qu.:0.0000 1st Qu.:0.00000
#> domingo : 2389 verano :4193 Median :0.0000 Median :0.00000
#> festivo : 762 otoño :4079 Mean :0.3041 Mean :0.08577
#> 3rd Qu.:1.0000 3rd Qu.:0.00000
#> Max. :1.0000 Max. :1.00000
#> NAs :362
#> zona_Noroeste zona_Norte zona_Sur zona_Sureste
#> Min. :0.0000 Min. :0.0000 Min. :0.00000 Min. :0.000
#> 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:0.00000 1st Qu.:0.000
#> Median :0.0000 Median :0.0000 Median :0.00000 Median :0.000

```

```
#> Mean      :0.1385    Mean      :0.1194    Mean      :0.07759    Mean      :0.237
#> 3rd Qu.:0.0000    3rd Qu.:0.0000    3rd Qu.:0.00000    3rd Qu.:0.000
#> Max.       :1.0000    Max.       :1.0000    Max.       :1.00000    Max.       :1.000
#>
#> zona_Suroeste    tipo_dia_sabado    tipo_dia_domingo    tipo_dia_festivo
#> Min.      :0.0000    Min.      :0.0000    Min.      :0.0000    Min.      :0.00000
#> 1st Qu.:0.0000    1st Qu.:0.0000    1st Qu.:0.0000    1st Qu.:0.00000
#> Median :0.0000    Median :0.0000    Median :0.0000    Median :0.00000
#> Mean      :0.1601    Mean      :0.1392    Mean      :0.1377    Mean      :0.04392
#> 3rd Qu.:0.0000    3rd Qu.:0.0000    3rd Qu.:0.0000    3rd Qu.:0.00000
#> Max.       :1.0000    Max.       :1.0000    Max.       :1.0000    Max.       :1.00000
#>
#> temporada_primavera    temporada_verano    temporada_otoño
#> Min.      :0.0000    Min.      :0.0000    Min.      :0.0000
#> 1st Qu.:0.0000    1st Qu.:0.0000    1st Qu.:0.0000
#> Median :0.0000    Median :0.0000    Median :0.0000
#> Mean      :0.2777    Mean      :0.2417    Mean      :0.2351
#> 3rd Qu.:1.0000    3rd Qu.:0.0000    3rd Qu.:0.0000
#> Max.       :1.0000    Max.       :1.0000    Max.       :1.0000
#>
```

Partición

Entrenamiento 2021–2024, validación 2025, como decidió el equipo (#54, #55). `sima_scores` ya trae `particion` calculada así desde el PCA — se reutiliza en vez de recalcularla a partir de `fecha`, para garantizar que el PCA y los modelos de clasificación usan exactamente la misma frontera y que ninguno vio 2025 durante el ajuste.

```
table(sima_disc$particion)
#>
#> entrenamiento    validacion
#>           16008           1340

sima_train <- sima_disc |> filter(particion == "entrenamiento")
sima_valid <- sima_disc |> filter(particion == "validacion")

range(sima_train$fecha)
#> [1] "2021-01-01 UTC" "2024-12-31 UTC"
range(sima_valid$fecha)
#> [1] "2025-01-01 UTC" "2025-06-30 UTC"
```

Limitación de la partición (cuantificada en docs/05_estacionalidad_ozono.pdf): como 2025 termina el 30 de junio, la validación es 52.3 % primavera, 32.2 % invierno, 15.5 % verano y 0 % otoño, contra un entrenamiento repartido casi por igual (23.1–26.0 %). La tasa base de excedencia pasa de 29.31 % a 41.50 %, 12.2 puntos que vienen del calendario y no del modelo. El AUC es menos

sensible a la tasa base que la exactitud, lo que amortigua el problema pero no lo elimina — por eso la exactitud no se usa como métrica de decisión más adelante.

```
mean(sima_train$excede_anio_5, na.rm = TRUE)
#> [1] 0.2946622
mean(sima_valid$excede_anio_5, na.rm = TRUE)
#> [1] 0.4154079
```

Regresión logística

Respuesta `excede_anio_5`; predictores las tres componentes retenidas en #54 más los 12 dummies (zona, tipo_día, temporada) del paso anterior. Se arma la fórmula a partir de los nombres de columna en vez de escribirla a mano, para que quede ligada a los dummies que de verdad existen en `sima_disc` — si cambia el catálogo de zonas, la fórmula lo sigue sin que haya que tocarla.

```
predictores <- c(
  "PC1", "PC2", "PC3",
  grep("^zona_|^tipo_dia_|^temporada_", names(sima_disc), value = TRUE)
)
formula_log <- reformulate(predictores, response = "excede_anio_5")
formula_log
#> excede_anio_5 ~ PC1 + PC2 + PC3 + zona_Centro + zona_Noroeste +
#>      zona_Norte + zona_Sur + zona_Sureste + zona_Suroeste + tipo_dia_sabado +
#>      tipo_dia_domingo + tipo_dia_festivo + temporada_primavera +
#>      temporada_verano + temporada_otoño
```

Ajuste sobre `sima_train` únicamente — `sima_valid` no participa del ajuste, solo de la evaluación:

```
modelo_log <- glm(formula_log, data = sima_train, family = binomial)
summary(modelo_log)
#>
#> Call:
#> glm(formula = formula_log, family = binomial, data = sima_train)
#>
#> Coefficients:
#>
#>             Estimate Std. Error z value Pr(>|z|)
#> (Intercept)   -2.97495    0.08022  -37.086 < 2e-16 ***
#> PC1             0.38774    0.01310   29.603 < 2e-16 ***
#> PC2             0.45995    0.01633   28.166 < 2e-16 ***
#> PC3             0.19840    0.01909   10.394 < 2e-16 ***
#> zona_Centro    0.94794    0.08312   11.404 < 2e-16 ***
#> zona_Noroeste   1.20900    0.07319   16.518 < 2e-16 ***
#> zona_Norte      0.27217    0.07973    3.414 0.000641 ***
#> zona_Sur        1.07865    0.08674   12.435 < 2e-16 ***
#> zona_Sureste    0.64178    0.06905    9.294 < 2e-16 ***
#> zona_Suroeste   1.15601    0.07352   15.723 < 2e-16 ***
```

```
#> tipo_dia_sabado      0.06150      0.05955      1.033 0.301711
#> tipo_dia_domingo     0.32715      0.06060      5.399 6.72e-08 ***
#> tipo_dia_festivo      0.09908      0.10505      0.943 0.345611
#> temporada_primavera  1.63104      0.07034     23.189 < 2e-16 ***
#> temporada_verano      1.00484      0.08019     12.531 < 2e-16 ***
#> temporada_otoño      1.44644      0.06859     21.089 < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> (Dispersion parameter for binomial family taken to be 1)
#>
#>      Null deviance: 18991  on 15661  degrees of freedom
#> Residual deviance: 15267  on 15646  degrees of freedom
#> (346 observations deleted due to missingness)
#> AIC: 15299
#>
#> Number of Fisher Scoring iterations: 5
```

Razones de momios

La tabla que cuenta la historia (issue #55): `exp(coeficiente)` convierte la escala logit a razón de momios, e IC 95% viene de `broom::tidy` con `conf.int = TRUE` (Wald, no perfil de verosimilitud — más rápido y suficiente para reportar signo y magnitud).

```
library(broom)

momios_log <- tidy(modelo_log, exponentiate = TRUE, conf.int = TRUE) |>
  filter(term != "(Intercept)")
momios_log
#> # A tibble: 15 x 7
#>   term                estimate std.error statistic    p.value conf.low
#>   <chr>                <dbl>     <dbl>     <dbl>    <dbl>    <dbl>
#>   <dbl>
#> 1 PC1                  1.47      0.0131      29.6  1.37e-192    1.44
#>   1.51
#> 2 PC2                  1.58      0.0163      28.2  1.51e-174    1.53
#>   1.64
#> 3 PC3                  1.22      0.0191      10.4  2.65e- 25    1.17
#>   1.27
#> 4 zona_Centro          2.58      0.0831      11.4  3.98e- 30    2.19
#>   3.04
#> 5 zona_Noroeste        3.35      0.0732      16.5  2.71e- 61    2.90
#>   3.87
#> 6 zona_Norte           1.31      0.0797       3.41  6.41e-  4    1.12
#>   1.53
```



```

#> 7 zona_Sur 2.94 0.0867 12.4 1.68e- 35 2.48
↪ 3.49
#> 8 zona_Sureste 1.90 0.0691 9.29 1.48e- 20 1.66
↪ 2.18
#> 9 zona_Suroeste 3.18 0.0735 15.7 1.05e- 55 2.75
↪ 3.67
#> 10 tipo_dia_sabado 1.06 0.0595 1.03 3.02e- 1 0.946
↪ 1.19
#> 11 tipo_dia_domingo 1.39 0.0606 5.40 6.72e- 8 1.23
↪ 1.56
#> 12 tipo_dia_festivo 1.10 0.105 0.943 3.46e- 1 0.897
↪ 1.35
#> 13 temporada_primavera 5.11 0.0703 23.2 5.86e-119 4.45
↪ 5.87
#> 14 temporada_verano 2.73 0.0802 12.5 5.03e- 36 2.34
↪ 3.20
#> 15 temporada_otoño 4.25 0.0686 21.1 1.00e- 98 3.72
↪ 4.86

```

Razones de momios por componente

Los tres ejes retenidos en #54, con su nombre interpretativo (no solo “PC1/PC2/PC3”) porque ese es justo el requisito que #54 le impone a esta tabla: sin nombre, una razón de momios sobre un componente es ilegible.

```

nombres_pc <- c(
  PC1 = "Carga primaria de combustión",
  PC2 = "Forzamiento fotoquímico",
  PC3 = "Estancamiento atmosférico"
)

momios_pc <- momios_log |>
  filter(term %in% names(nombres_pc)) |>
  mutate(eje = nombres_pc[term], .before = 1) |>
  select(eje,
    termino = term, momios = estimate,
    ic_inf = conf.low, ic_sup = conf.high, p.value
  )
momios_pc
#> # A tibble: 3 x 6
#>   eje termino momios ic_inf ic_sup p.value
#>   <chr>      <chr>   <dbl> <dbl> <dbl>   <dbl>
#> 1 Carga primaria de combustión PC1      1.47  1.44  1.51 1.37e-192
#> 2 Forzamiento fotoquímico PC2      1.58  1.53  1.64 1.51e-174
#> 3 Estancamiento atmosférico PC3      1.22  1.17  1.27 2.65e- 25


```

Cada razón de momios es **por desviación estándar** del componente, no por unidad arbitraria — así lo dejó #54 al construir `sima_scores` (puntuaciones ya estandarizadas del PCA), y es lo que hace comparables los tres momios entre sí pese a que las cargas originales tengan escalas distintas.

```
library(ggplot2)

fig_momios <- ggplot(momios_pc, aes(x = momios, y = reorder(eje, momios))) +
  geom_vline(xintercept = 1, linetype = "dashed", colour = "grey60") +
  geom_pointrange(aes(xmin = ic_inf, xmax = ic_sup), colour = "#2c7fb8",
    ↪ linewidth = 0.8) +
  geom_text(aes(label = sprintf("%.2f", momios)), vjust = -1, size = 3.5) +
  labs(
    title = "Razones de momios por componente",
    subtitle = "Excedencia MDA8 > 51 ppb - IC 95%",
    x = "Razón de momios", y = NULL
  ) +
  theme_minimal()

fig_momios
```



```
ggsave("../reports/figuras/momios_componentes.pdf", fig_momios,
  width = 6, height = 3.6, units = "in"
)
```

Los tres quedan por encima de 1 con el intervalo lejos de esa línea: subir una desviación estándar en cualquiera de los tres ejes se asocia con mayores momios de excedencia, controlando por zona y calendario. El de mayor efecto es el forzamiento fotoquímico, seguido de la combustión primaria — consistente con que el ozono es un contaminante secundario que necesita tanto precursores como las condiciones para formarse fotoquímicamente, no solo lo primero.

Evaluación en validación: AUC, sensibilidad, especificidad

Nunca exactitud — con 41.50 % de excedencia base en validación, un clasificador constante ya acierta bien sin distinguir nada.

```
library(pROC)

p_valid <- predict(modelo_log, newdata = sima_valid, type = "response")
roc_log <- roc(sima_valid$excede_anio_5, p_valid, quiet = TRUE)

auc(roc_log)
#> Area under the curve: 0.8928
```

Criterio de logro del issue: AUC 0.75 en validación. Umbral de clasificación para sensibilidad/especificidad y matriz de confusión — el que maximiza sensibilidad + especificidad (Youden), declarado explícitamente en vez de asumir 0.5:

```
umbral_log <- coords(roc_log, "best", best.method = "youden", ret = "threshold")
umbral_log <- as.numeric(umbral_log)
umbral_log
#> [1] 0.2883406

pred_log <- factor(p_valid >= umbral_log,
  levels = c(FALSE, TRUE),
  labels = c("no_excede", "excede")
)
obs_log <- factor(sima_valid$excede_anio_5,
  levels = c(0, 1),
  labels = c("no_excede", "excede")
)

matriz_log <- table(observado = obs_log, predicho = pred_log)
matriz_log
#>           predicho
#> observado no_excede excede
#> no_excede      638    136
#> excede         93    457

coords(roc_log, umbral_log, ret = c("sensitivity", "specificity"))
#> sensitivity specificity
#> 1    0.8309091    0.8242894
```

La curva ROC y la matriz de confusión no se grafican aquí: se construyen más abajo con los dos modelos en una sola figura ([roc_modelos.pdf](#) y [matriz_confusion.pdf](#)), que es como las pide el issue #55. Las versiones provisionales solo del logístico ([roc_log.pdf](#), [matriz_confusion_log.pdf](#)) quedaron retiradas al existir la comparativa.

Análisis de umbral

Cada punto de la curva ROC es un umbral distinto; esta tabla lo hace explícito para un puñado de candidatos, en vez de comprometerse solo con el de Youden. Se incluye exactitud a propósito, para mostrar por qué **no** se usa como criterio: sube con el umbral más alto (clasifica casi todo como “no excede”, la clase mayoritaria) mientras la sensibilidad se desploma — exactamente el efecto que el checklist de la issue #55 advierte.

```
candidatos <- c(
  youden = umbral_log, `0.5` = 0.5,
  tasa_base_train = mean(sima_train$excede_anio_5, na.rm = TRUE),
  tasa_base_valid = mean(sima_valid$excede_anio_5, na.rm = TRUE)
)

tabla_umbrales <- coords(roc_log, candidatos,
  ret = c("threshold", "sensitivity", "specificity", "accuracy")
) |>
  mutate(criterio = names(candidatos), .before = 1)
```

	criterio	threshold	sensitivity	specificity	accuracy
#>	youden	0.2883406	0.8309091	0.8242894	0.8270393
#>	0.5	0.5	0.5000000	0.5181818	0.9418605
#>	tasa_base_train	0.2946622	0.8127273	0.8281654	0.8217523
#>	tasa_base_valid	0.4154079	0.6290909	0.9198966	0.7990937

Sensibilidad y especificidad se mueven en direcciones opuestas al mover el umbral — no hay un punto que maximice ambas a la vez, por eso Youden (maximizar su suma) es un criterio razonable por defecto y no un óptimo universal: si el costo de una excedencia no detectada fuera mucho mayor que el de una falsa alarma, convendría un umbral más bajo que sacrifique especificidad por sensibilidad.

Análisis discriminante lineal

La segunda técnica de `tab:tecnicas` (`reports/secciones/objetivo_tecnicas.tex`) sobre la misma matriz de diseño y la misma respuesta que la logística. El contraste es lo que interesa: el discriminante sí supone normalidad multivariada dentro de cada clase y homocedasticidad entre clases, supuestos que la logística no necesita. Si ambos coinciden, el resultado no depende de esos supuestos; si difieren, la diferencia se lee contra ellos.

Verificación de supuestos

Box-Cox (#52) dejó los predictores originales con $|\text{sesgo}| < 0.5$, y las componentes son combinaciones lineales de esos predictores. Se verifica sobre las puntuaciones, que es donde el supuesto opera, y por clase, que es como lo exige el discriminante:

```

sesgo <- function(x) {
  x <- x[!is.na(x)]
  sum((x - mean(x))^3) / (length(x) * sd(x)^3)
}

sima_train |>
  filter(!is.na(excede_anio_5)) |>
  group_by(excede_anio_5) |>
  summarise(across(c(PC1, PC2, PC3), ~ round(sesgo(.x), 3)), n = n())
#> # A tibble: 2 x 5
#>   excede_anio_5    PC1    PC2    PC3      n
#>   <dbl> <dbl> <dbl> <dbl> <int>
#> 1         0 0.386 -0.256 -0.273 11047
#> 2         1 0.177 -0.143 -0.119  4615

```

Los seis sesgos quedan por debajo de 0.4 en valor absoluto, así que la aproximación a normalidad se sostiene sobre las componentes.

La homocedasticidad es otra historia. No se usa la M de Box: con más de 15,000 observaciones rechaza cualquier diferencia por pequeña que sea, así que su p -valor no informa. Se comparan las matrices de covarianza directamente:

```

cov_por_clase <- function(y) {
  sima_train |>
    filter(excede_anio_5 == y) |>
    dplyr::select(PC1, PC2, PC3) |>
    cov()
}

S0 <- cov_por_clase(0)
S1 <- cov_por_clase(1)

round(sqrt(diag(S1)) / sqrt(diag(S0)), 3) # razón de desviaciones estándar
#>   PC1   PC2   PC3
#> 0.883 0.694 0.924
c(det_no_excede = det(S0), det_excede = det(S1))
#> det_no_excede    det_excede
#>    19.564293      6.102144

```

Las razones son 0.883, 0.694 y 0.924: los días de excedencia son **menos dispersos** que los de no excedencia, sobre todo en el eje fotoquímico (PC2), y la varianza generalizada cae de 19.6 a 6.1. El supuesto de covarianzas iguales no se cumple estrictamente. Se declara aquí y se retoma al comparar los dos modelos, en vez de sustituirlo por un discriminante cuadrático: la issue pide el lineal como contraste de la logística, y cambiar de técnica a medio camino cambiaría lo que se está contrastando.

Un segundo desvío, más grosero: los 12 dummies son binarios, y una indicadora no es normal bajo ninguna transformación. El discriminante lineal es conocido por tolerarlo — el clasificador resultante

sigue siendo una frontera lineal razonable — pero la evidencia de que aquí lo tolera es empírica, y está en la comparación de más abajo, no en el supuesto.

Ajuste

Misma fórmula, misma partición de entrenamiento. Las probabilidades previas se dejan en las proporciones observadas (el comportamiento por defecto de `MASS::lda`) en vez de fijarlas en 0.5: la tasa base de excedencia es información del problema, no un artefacto del muestreo.

`MASS::select` no existe, pero `MASS` sí enmascara otras funciones de `dplyr` al cargarse después; por eso los `select` de aquí en adelante van calificados como `dplyr::select`.

```
library(MASS)

modelo_lda <- lda(formula_log, data = sima_train)
modelo_lda$prior
#>      0      1
#> 0.7053378 0.2946622
```

Coefficientes de la única función discriminante — con dos clases hay $\min(k - 1, p) = 1$:

```
coef_lda <- data.frame(
  termino = rownames(modelo_lda$scaling),
  LD1 = round(as.numeric(modelo_lda$scaling), 4)
)
coef_lda
#>      termino      LD1
#> 1          PC1  0.3232
#> 2          PC2  0.3476
#> 3          PC3  0.1844
#> 4   zona_Centro  0.8131
#> 5  zona_Noroeste  1.0769
#> 6   zona_Norte   0.1633
#> 7   zona_Sur     0.8557
#> 8   zona_Sureste  0.4588
#> 9   zona_Suroeste  1.0434
#> 10 tipo_dia_sabado  0.0438
#> 11 tipo_dia_domingo  0.2629
#> 12 tipo_dia_festivo -0.0704
#> 13 temporada_primavera  1.3919
#> 14 temporada_verano    0.6764
#> 15 temporada_otoño     1.0647
```

El orden y el signo reproducen los de la logística: primavera y otoño pesan más que verano, el Noroeste y el Suroeste son las zonas de mayor riesgo, y entre las componentes manda el forzamiento fotoquímico (PC2) sobre la carga primaria (PC1) y el estancamiento (PC3). Los coeficientes no son razones de momios y no se leen como tales; son la dirección en la que las dos clases se separan al máximo.

Evaluación en validación

Se usa la probabilidad posterior de la clase “excede” como puntaje continuo, para que la ROC sea comparable con la de la logística — no la clase que `predict` asigna por defecto, que ya trae incorporado un umbral de 0.5.

```
p_valid_lda <- predict(modelo_lda, newdata = sima_valid)$posterior[, "1"]
roc_lda <- roc(sima_valid$excede_anio_5, p_valid_lda, quiet = TRUE)

auc(roc_lda)
#> Area under the curve: 0.8928
```

Mismo criterio de umbral que en la logística (Youden), para que la comparación de sensibilidad y especificidad no confunda el efecto del modelo con el de una regla de corte distinta:

```
umbral_lda <- as.numeric(coords(roc_lda, "best",
  best.method = "youden",
  ret = "threshold"
))
umbral_lda
#> [1] 0.2934236

pred_lda <- factor(p_valid_lda >= umbral_lda,
  levels = c(FALSE, TRUE),
  labels = c("no_excede", "excede")
)
matriz_lda <- table(observado = obs_log, predicho = pred_lda)
matriz_lda
#>           predicho
#> observado no_excede excede
#> no_excede      628    146
#> excede         85    465

coords(roc_lda, umbral_lda, ret = c("sensitivity", "specificity"))
#>   sensitivity specificity
#> 1    0.8454545    0.8113695
```

Comparación de los dos modelos

```
comparacion <- data.frame(
  modelo = c("Regresión logística", "Discriminante lineal"),
  auc = c(as.numeric(auc(roc_log)), as.numeric(auc(roc_lda))),
  umbral = c(umbral_log, umbral_lda),
  sensibilidad = c(
    coords(roc_log, umbral_log, ret = "sensitivity")[[1]],

```

```

        coords(roc_lda, umbral_lda, ret = "sensitivity")[[1]]
    ),
    especificidad = c(
        coords(roc_log, umbral_log, ret = "specificity")[[1]],
        coords(roc_lda, umbral_lda, ret = "specificity")[[1]]
    )
)
comparacion
#>           modelo      auc    umbral sensibilidad especificidad
#> 1  Regresión logística 0.8927719 0.2883406    0.8309091    0.8242894
#> 2 Discriminante lineal 0.8927602 0.2934236    0.8454545    0.8113695

```

Ambos superan el criterio de logro del issue ($AUC > 0.75$) con holgura. La diferencia de AUC se contrasta con la prueba de DeLong, que es la adecuada porque las dos curvas están correlacionadas — se calculan sobre las mismas 1,340 observaciones de validación:

```

roc.test(roc_log, roc_lda, method = "delong")
#>
#> DeLong's test for two correlated ROC curves
#>
#> data:  roc_log and roc_lda
#> Z = 0.011243, p-value = 0.991
#> alternative hypothesis: true difference in AUC is not equal to 0
#> 95 percent confidence interval:
#> -0.00203583  0.00205932
#> sample estimates:
#> AUC of roc1 AUC of roc2
#>  0.8927719  0.8927602

```

```

cor(p_valid, p_valid_lda) # correlación de los puntajes
#> [1] 0.9971151
mean((p_valid >= umbral_log) == (p_valid_lda >= umbral_lda)) # concordancia
#> [1] 0.980597

```

Las dos técnicas son indistinguibles en estos datos: los AUC coinciden hasta el cuarto decimal (0.8928 contra 0.8928, DeLong $p = 0.99$), los puntajes correlacionan a 0.997 y las clasificaciones coinciden en el 98.1 % de los días de validación. Donde difieren es en el reparto de errores: el discriminante detecta ocho excedencias más (sensibilidad 0.845 contra 0.831) a cambio de diez falsas alarmas más (especificidad 0.811 contra 0.824), un intercambio dentro del ruido de muestreo.

Esa coincidencia es el resultado, no un anticlímax. La heterocedasticidad documentada arriba es real y aun así no mueve el desempeño: la frontera que ambos trazan es prácticamente la misma. La lectura que sigue —las razones de momios de la [sección de momios]— no depende entonces del supuesto de normalidad que la logística no hace y el discriminante sí, que era exactamente la razón de ajustar los dos.

Curvas ROC de ambos modelos


Una sola figura con las dos curvas, como pide el issue #55:

```
# El AUC va en la leyenda y no como anotación suelta: el texto no se recorta
# contra el panel y cada curva queda etiquetada con su propio valor.
etiqueta <- function(nombre, r) sprintf("%s (AUC =%.3f)", nombre, auc(r))
rocs <- setNames(
  list(roc_log, roc_lda),
  c(
    etiqueta("Regresión logística", roc_log),
    etiqueta("Discriminante lineal", roc_lda)
  )
)

# Las dos curvas se superponen casi por completo, así que el discriminante va
# punteado: sin eso la de abajo queda invisible y parecería haber una sola.
fig_roc <- ggroc(rocs, aes = c("colour", "linetype"), linewidth = 0.8) +
  geom_abline(intercept = 1, slope = 1, linetype = "dashed", colour = "grey60")
  +
  scale_colour_manual(values = c("#2c7fb8", "#d95f02")) +
  scale_linetype_manual(values = c("solid", "22")) +
  labs(
    title = "Curvas ROC en validación (2025)",
    subtitle = "Excedencia MDA8 > 51 ppb",
    x = "Especificidad", y = "Sensibilidad",
    colour = NULL, linetype = NULL
  ) +
  coord_equal() +
  theme_minimal() +
  theme(
    legend.position = "bottom", legend.direction = "vertical",
    legend.spacing.y = unit(0, "pt")
  )

fig_roc
```

Curvas ROC en validación (2025)
Excedencia MDA8 > 51 ppb



```
ggsave("../reports/figuras/roc_modelos.pdf", fig_roc,
        width = 6, height = 4.2, units = "in"
)
```

Las curvas se superponen en casi todo su recorrido, que es la versión gráfica de la prueba de DeLong.

Matrices de confusión

Las dos matrices al umbral de Youden de cada modelo, en la misma figura y con la misma escala para que se comparen de un vistazo:

```
prop_por_fila <- function(m, modelo) {
  as.data.frame(m) |>
  group_by(observado) |>
  mutate(prop = Freq / sum(Freq)) |>
  ungroup() |>
  mutate(modelo = modelo)
}

matrices <- bind_rows(
  prop_por_fila(matriz_log, sprintf("Logística (umbral%.3f)", umbral_log)),
  prop_por_fila(matriz_lda, sprintf("Discriminante (umbral%.3f)", umbral_lda))
) |>

# bind_rows preserva el orden, pero facet_wrap ordena los paneles por el
# factor: sin fijar los niveles quedarían alfabéticos y el discriminante
# aparecería antes que la logística, al revés de como se leen en el texto.
```

```


mutate(
  modelo = factor(modelo, levels = unique(modelo)),
  across(
    c(observado, predicho),
    ~ factor(.x,
      levels = c("no_excede", "excede"),
      labels = c("No excede", "Excede")
    )
  )
)

fig_matrices <- ggplot(matrices, aes(x = predicho, y = observado, fill = prop)) +
  geom_tile(colour = "white") +
  # El texto se pinta claro sobre las celdas oscuras y oscuro sobre las claras:
  # en blanco fijo, los conteos de las celdas de proporción baja no se leen.
  geom_text(
    aes(
      label = sprintf("%d\n(%.1f%%)", Freq, prop * 100),
      colour = prop > 0.5
    ),
    fontface = "bold", size = 3, show.legend = FALSE
  ) +
  facet_wrap(~modelo) +
  scale_fill_gradient(
    low = "#deebf7", high = "#08519c", limits = c(0, 1),
    guide = "none"
  ) +
  scale_colour_manual(values = c(`FALSE` = "#08306b", `TRUE` = "white")) +
  labs(
    title = "Matrices de confusión en validación (2025)",
    x = "Predicho", y = "Observado"
  ) +
  theme_minimal()

fig_matrices

```

Matrices de confusión en validación (2025)



```
ggsave("../reports/figuras/matriz_confusion.pdf", fig_matrices,
        width = 6, height = 3.2, units = "in"
)
```

Limitaciones

Autocorrelación. Las 15 estaciones de un mismo día comparten el clima sinóptico y los días consecutivos correlacionan entre sí, de modo que las 17,002 filas día-estación que entran al ajuste y la validación no son observaciones independientes: la n efectiva está mucho más cerca de los 1,642 días distintos que cubre la serie. Los errores estándar de `momios_log` y los p -valores de `summary(modelo_log)` son, por lo tanto, optimistas — los intervalos de confianza reales son más anchos que los reportados. No se corrige: agregar a día-AMM devolvería la independencia temporal pero eliminaría la dimensión espacial, que es justamente donde están los contrastes de zona que el modelo encuentra significativos. La decisión es declararlo. Vale la pena notar que el AUC de validación no se ve afectado por esto: se calcula sobre 2025, que el modelo no vio, y no depende de ningún error estándar.

Sin COV, ninguna afirmación de mecanismo. El SIMA no mide compuestos orgánicos volátiles, así que los ejes se describen como *consistentes con* combustión primaria, forzamiento fotoquímico o estancamiento, nunca como una atribución de régimen NO_x-COV. Una razón de momios de 1.58 sobre PC2 dice que los días con más forzamiento fotoquímico tienen mayores momios de excedencia; no dice cuál de los dos precursores limita la formación de ozono, y esa pregunta no es contestable con estos datos.

Modelo explicativo, no de pronóstico. Los predictores son del mismo día que la respuesta. El modelo describe qué condiciones acompañan a una excedencia; no anticipa el ozono de mañana con los datos de hoy, y por eso no se validó como serie de tiempo.

Partición estacionalmente desbalanceada. Ya cuantificada arriba: la validación de 2025 no tiene otoño y le sobra primavera. El AUC amortigua el sesgo de tasa base, pero las cifras de sensibilidad y especificidad se leen sobre una validación más cargada de días propensos a excedencia que un año completo.

Verificación espacial pendiente. El reajuste por zona para ver si las razones de momios de las componentes se mueven entre zonas está marcado como opcional en el issue #55 y no se realizó. Queda como extensión natural.