

Verificación de supuestos del modelo autorregresivo logístico

MA2003B, equipo 7 — nowcasting de excedencia diaria

Tabla de contenidos

0. Construcción de la serie de área metropolitana	2
0.1 La respuesta binaria y el umbral	3
1. Cuántos rezagos de y_t entran al predictor	4
2. Estacionariedad	5
3. Ausencia de separación perfecta	7
4. Especificación correcta del <i>link</i>	9
5. Ergodicidad de la cadena subyacente	10
6. Por qué la respuesta tiene que ser binaria y no la fracción	11
7. ¿Alcanza el AR(1) o queda dependencia serial?	11
8. Criterios de aceptación	12
9. Qué se lleva el modelo, y qué queda declarado	13

El objetivo de modelado es la **clasificación contemporánea** (*nowcasting*): dado lo que se observó hoy —los tres puntajes factoriales del día— decidir si hoy es un día de excedencia. El modelo candidato es la logística autorregresiva

$$\text{logit } P(y_t = 1 \mid \mathcal{F}_{t-1}, x_t) = x_t' \beta + \sum_{i=1}^p \alpha_i y_{t-i},$$

donde x_t son los factores del mismo día más los armónicos del calendario, y el pasado observado entra directo por los rezagos y_{t-i} . El pronóstico a días futuros queda para después; es otro modelo y otra validación.

Este documento **no ajusta el modelo final**: verifica que sus supuestos se sostengan sobre estos datos antes de gastar el esfuerzo. Son cinco preguntas, más dos que salieron del propio diagnóstico:

1. cuántos rezagos de y_t entran al predictor,
2. estacionariedad,
3. ausencia de separación perfecta,
4. especificación correcta del *link*,
5. ergodicidad de la cadena subyacente,
6. si la respuesta puede ser la fracción de estaciones o tiene que ser binaria,

7. si queda dependencia serial después del término autorregresivo.

09_extraccion_factorial.pdf produjo los puntajes; serie_tiempo_factores.pdf caracterizó su comportamiento temporal y estableció la decisión que este documento hereda sin reabrir: **se trabaja sobre la serie de área metropolitana**, no sobre el panel día-estación. La razón está ahí y es doble — la cobertura por estación es insuficiente (solo 3 de 15 superan 85 %) y la correlación entre estaciones el mismo día es alta (0.49 a 0.86), así que promediar es agregación legítima y no mezcla de señales independientes.

0. Construcción de la serie de área metropolitana

Se reconstruye la misma serie de serie_tiempo_factores.pdf §2. Se repite aquí en vez de leer un intermedio guardado porque ese documento no persistió la serie agregada, y reconstruirla cuesta segundos.

```
library(nanoparquet)
library(dplyr)

af <- read_parquet("../data/processed/af_puntajes_diarios.parquet")
di <- read_parquet("../data/processed/sima_transformado_diario.parquet")

# Las marcas de tiempo son hora local de pared sin zona (ver CLAUDE.md).
# nanoparquet las lee como UTC y R las despliega en America/Monterrey, lo que
# las correría 6 h. Se fija el atributo, no se convierte.
attr(af$fecha, "tzone") <- "UTC"
attr(di$fecha, "tzone") <- "UTC"

# F1/F2/F3 en el orden de NOMBRES de 09_extraccion_factorial.qmd.
af <- rename(af, comb = F1, vent = F2, foto = F3)

m <- inner_join(af, select(di, estacion, fecha, excede_anio_5),
                by = c("estacion", "fecha")) |>
  filter(if_all(c(comb, vent, foto, excede_anio_5), \(v) !is.na(v)))

cat(sprintf("dia-estacion completos:%s\nprevalencia dia-estacion:%.4f\n",
            format(nrow(m), big.mark = ","), mean(m$excede_anio_5)))
#> dia-estacion completos: 17,029
#> prevalencia dia-estacion: 0.3035
```

La respuesta de origen, excede_anio_5, es el escenario principal de modelado: MDA8 por encima de 51 ppb. Al agregar por día quedan el conteo de estaciones que exceden (k) y el de estaciones que reportan (n), que no es constante.

```
area <- m |>
  group_by(fecha) |>
  summarise(comb = mean(comb), vent = mean(vent), foto = mean(foto),
            k = sum(excede_anio_5), n = n_distinct(estacion), .groups = "drop")
```

```
# Reindexar contra el calendario completo deja los huecos explicitos antes de
# tocarlos: sin esto, un dia sin ninguna estacion desaparece en silencio y los
# rezagos de la seccion 1 saltarian sobre el sin avisar.
cal <- data.frame(fecha = seq(min(m$fecha), max(m$fecha), by = "day"))
A <- left_join(cal, area, by = "fecha")
A$frac <- A$k / A$n

cat(sprintf("dias de calendario:%s\ndias sin ninguna estacion:%d (%s)\n",
            format(nrow(A), big.mark = ","), sum(is.na(A$comb)),
            paste(format(A$fecha[is.na(A$comb)], "%Y-%m-%d"), collapse = ", ")))
#> dias de calendario: 1,642
#> dias sin ninguna estacion: 1 (2021-02-16)
```

Un solo día, 2021-02-16, se queda sin cobertura: 0.06 % del calendario. Se interpola linealmente por la misma razón que en `serie_tiempo_factores.pdf` —los rezagos exigen una rejilla regular— y se deja documentado, no se trata como si no hubiera pasado.

```
interp <- function(v) {
  i <- which(!is.na(v))
  approx(i, v[i], seq_along(v), rule = 2)$y
}
for (v in c("comb", "vent", "foto", "frac")) A[[v]] <- interp(A[[v]])

A$anio <- as.integer(format(A$fecha, "%Y"))
doy <- as.integer(format(A$fecha, "%j"))
A$s1 <- sin(2 * pi * doy / 365.25); A$c1 <- cos(2 * pi * doy / 365.25)
A$s2 <- sin(4 * pi * doy / 365.25); A$c2 <- cos(4 * pi * doy / 365.25)

round(sapply(A[c("comb", "vent", "foto", "frac", "n")],
             \(v) c(media = mean(v, na.rm = TRUE), sd = sd(v, na.rm = TRUE),
                    min = min(v, na.rm = TRUE), max = max(v, na.rm = TRUE))), 3)
#>      comb vent foto frac      n
#> media -0.073 -0.008 -0.012 0.30 10.377
#> sd      0.895 0.679 1.123 0.35 2.821
#> min     -2.502 -2.570 -3.228 0.00 1.000
#> max      2.949 2.040 2.766 1.00 15.000
```

Los armónicos de periodo anual y semianual entran como covariables desde ahora. No son decoración: la sección 2 muestra que sin ellos la serie no cumple estacionariedad y el supuesto se cae.

0.1 La respuesta binaria y el umbral

`frac` es la **fracción** de estaciones que exceden, no una indicadora. La sección 6 muestra por qué no puede usarse directamente. Para el modelo binario hay que dicotomizarla, y el corte es una decisión sustantiva —qué cuenta como “día de excedencia para el área metropolitana”— no estadística.

```

umbrales <- c("cualquiera (frac > 0)" = 1e-9,
             "un cuarto (frac >= 0.25)" = 0.25,
             "mayoria (frac >= 0.5)" = 0.5)
round(sapply(umbrales, \(u) mean(A$frac >= u)), 3)
#>      cualquiera (frac > 0) un cuarto (frac >= 0.25)      mayoria (frac >= 0.5)
#>                0.570                0.421                0.316

```

Se adopta **frac >= 0.5**: el día es de excedencia si la mayoría de las estaciones que reportaron ese día excedieron. Dos razones. La prevalencia resultante, 0.316, es prácticamente la del panel día-estación original (0.3035), así que el evento agregado conserva la tasa base del evento que se quiere modelar. Y el criterio es robusto a la cobertura variable: al ser una proporción, no premia a los días en que reportaron más estaciones, como sí haría un conteo. El corte “cualquiera excede” llevaría la prevalencia a 0.570 y convertiría el problema en otro —la pregunta pasaría a ser si *alguna* estación del área tuvo un mal día, que es un evento mucho más frecuente y menos informativo.

```

A$y <- as.integer(A$frac >= 0.5)
for (p in 1:7) A[[paste0("y", p)]] <- dplyr::lag(A$y, p)

# El ajuste usa 2021-2024 y deja 2025 para validacion, igual que #54 y #55.
# Se piden los 7 rezagos completos para que los modelos de la seccion 1 se
# comparen sobre EXACTAMENTE las mismas filas: comparar AIC entre ajustes con
# distinto n no significa nada.
TR <- filter(A, anio <= 2024, !is.na(y7))
cat(sprintf("entrenamiento: %s dias (%d-%d), prevalencia%.3f\n",
           format(nrow(TR), big.mark = ","), min(TR$anio), max(TR$anio),
           mean(TR$y)))
#> entrenamiento: 1,454 dias (2021-2024), prevalencia 0.301

```

1. Cuántos rezagos de y_t entran al predictor

Dos lecturas independientes. La PACF de la serie cruda sugiere el orden por la vía descriptiva; el criterio de información lo confirma **condicionando a las covariables**, que es lo que importa: parte de la persistencia de y_t puede ser sólo la persistencia de la meteorología que la produce, y en ese caso los rezagos sobrarían.

```

round(pacf(A$y, lag.max = 10, plot = FALSE)$acf[1:10], 3)
#> [1] 0.464 0.101 0.056 0.062 0.043 0.039 0.044 0.013 0.009 0.038

```

```

base <- "y ~ comb + vent + foto + s1 + c1 + s2 + c2"
tabla <- NULL
anterior <- NULL
for (p in 0:7) {
  f <- if (p == 0) base else paste(base, "+", paste0("y", 1:p, collapse = " + "))
  g <- glm(as.formula(f), binomial, TR)
  s <- coef(summary(g))
}

```

```

tabla <- rbind(tabla, data.frame(
  p = p,
  AIC = AIC(g), BIC = BIC(g),
  coef = if (p == 0) NA else s[paste0("y", p), 1],
  z = if (p == 0) NA else s[paste0("y", p), 3],
  LR = if (p == 0) NA else anterior$deviance - g$deviance))
anterior <- g
}
print(transform(tabla, AIC = round(AIC, 1), BIC = round(BIC, 1),
  coef = round(coef, 3), z = round(z, 2), LR = round(LR, 2)),
  row.names = FALSE)
#>  p      AIC      BIC    coef      z      LR
#>  0 1199.0 1241.2      NA      NA      NA
#>  1 1129.3 1176.8  1.348  8.44 71.72
#>  2 1128.3 1181.1  0.306  1.74  3.00
#>  3 1130.2 1188.3  0.050  0.28  0.08
#>  4 1131.5 1194.9  0.151  0.84  0.70
#>  5 1133.1 1201.7 -0.117 -0.64  0.41
#>  6 1134.9 1208.8 -0.081 -0.44  0.19
#>  7 1136.7 1215.9  0.078  0.42  0.17

```

Se cumple, con $p = 1$. La PACF cae de 0.464 a 0.101 en el lag 2 y a ruido de ahí en adelante: corta después del primer rezago, la firma de un AR(1). El BIC coincide y se minimiza en $p = 1$; el AIC está empatado entre $p = 1$ y $p = 2$, pero el segundo rezago no alcanza significancia ($z = 1.74$) y del tercero en adelante los coeficientes son indistinguibles de cero.

Lo que importa más que el orden: el primer rezago **sobrevive a las covariables contemporáneas**. Con los tres factores y los cuatro armónicos ya en el modelo, agregar y_{t-1} produce una razón de verosimilitud de 71.7 sobre 1 grado de libertad y un coeficiente de +1.35 ($z = 8.4$). La persistencia día a día no es un reflejo de que la meteorología sea persistente: es dependencia genuina que el modelo necesita. Ese es el argumento que justifica la parte autorregresiva.

2. Estacionariedad

Conviene separar dos cosas que suelen confundirse. Una serie **binaria y acotada** no puede tener raíz unitaria: un paseo aleatorio es no acotado por construcción, así que aplicarle una prueba de Dickey-Fuller a y_t responde una pregunta que ya tiene respuesta. Lo que sí puede fallar, y es lo que hay que probar, es que el proceso sea **homogéneo en el tiempo**: que $P(y_t | y_{t-1}, x_t)$ no cambie de forma a lo largo de los cuatro años.

Sobre los tres factores —que sí son continuos y no acotados— la prueba de raíz unitaria sí corresponde.

```

# ADF con constante y sin tendencia, escrito a mano. Se implementa en vez de
# agregar `tseries` a renv.lock: son ocho líneas, el lockfile es contrato del
# equipo y `snapshot()` está prohibido en este repo. Mismo criterio que llevo a
# escribir src/factorial.py en lugar de depender de factor_analyzer.

```

```
#
# dx_t = a + rho * x_{t-1} + sum_i gamma_i dx_{t-i} + e_t
#
# H0: rho = 0 (hay raíz unitaria). El estadístico es el t de rho, que NO sigue
# una t de Student: se compara contra los valores críticos de Dickey-Fuller
# (MacKinnon), -2.86 al 5% para el caso con constante y n grande.
adf <- function(x, max_lag = 12) {
  mejor <- NULL
  for (L in 0:max_lag) {
    d <- diff(x)
    idx <- (L + 1):length(d)
    X <- cbind(rezago = x[idx],
               if (L > 0) sapply(1:L, \ (i) d[idx - i]) else NULL)
    fit <- lm(d[idx] ~ X)
    if (is.null(mejor) || AIC(fit) < mejor$aic)
      mejor <- list(aic = AIC(fit), L = L, t = coef(summary(fit))[2, 3])
  }
  mejor
}

VC5 <- -2.86
do.call(rbind, lapply(c("comb", "vent", "foto", "frac"), \ (v) {
  r <- adf(A[[v]])
  data.frame(serie = v, t_ADF = round(r$t, 2), rezagos = r$L,
             veredicto = ifelse(r$t < VC5, "rechaza raíz unitaria", "NO rechaza"))
})) |> print(row.names = FALSE)
#> serie t_ADF rezagos veredicto
#> comb -4.66 12 rechaza raíz unitaria
#> vent -5.42 12 rechaza raíz unitaria
#> foto -5.53 12 rechaza raíz unitaria
#> frac -11.55 4 rechaza raíz unitaria
```

Las cuatro series rechazan la raíz unitaria con holgura. No hay que diferenciar nada.

La marginal, en cambio, **no es estacionaria**, y por un margen que no se puede ignorar:

```
round(tapply(A$y, format(A$fecha, "%m"), mean), 3)
#> 01 02 03 04 05 06 07 08 09 10 11 12
#> 0.090 0.277 0.542 0.433 0.561 0.347 0.169 0.250 0.400 0.363 0.183 0.089
round(tapply(A$y, A$anio, mean), 3)
#> 2021 2022 2023 2024 2025
#> 0.274 0.282 0.249 0.396 0.442
```

De 0.090 en diciembre a 0.561 en mayo: un factor de seis dentro del año. Y un escalón entre 2023 (0.249) y 2024–2025 (0.396, 0.442). Ninguno de los dos invalida el modelo, pero los dos obligan a que el ciclo esté **en el predictor**: la estacionariedad que la logística autorregresiva necesita es la de $y_t \mid x_t$, no la de y_t . Por eso los armónicos entran desde la sección 0 y no como refinamiento posterior.

Queda probar que, ya condicionando, el proceso sea homogéneo. La prueba directa es si los coeficientes cambian entre el primer periodo y el segundo.

```
A$tardio <- as.integer(A$anio >= 2024)
TR$tardio <- as.integer(TR$anio >= 2024)

F0 <- y ~ comb + vent + foto + s1 + c1 + s2 + c2 + y1
g0 <- glm(F0, binomial, TR)

# Se separa el nivel de la persistencia: no es lo mismo que 2024 tenga mas dias
# de excedencia (nivel) a que la cadena se vuelva mas pegajosa (persistencia).
gn <- glm(update(F0, . ~ . + tardio), binomial, TR)
gi <- glm(update(F0, . ~ . + tardio + y1:tardio), binomial, TR)

data.frame(
  hipotesis = c("cambio de nivel (tardio)", "cambio de persistencia (y1:tardio)"),
  LR = round(c(g0$deviance - gn$deviance, gn$deviance - gi$deviance), 2),
  p = round(pchisq(c(g0$deviance - gn$deviance, gn$deviance - gi$deviance),
                    1, lower.tail = FALSE), 4)) |> print(row.names = FALSE)
#>               hipotesis      LR      p
#> cambio de nivel (tardio) 10.51 0.0012
#> cambio de persistencia (y1:tardio) 0.23 0.6320

cat(sprintf("\nb(y_t-1): 2021-2023 =%.3f ; 2024 =%.3f\n",
            coef(gi)["y1"], coef(gi)["y1"] + coef(gi)["y1:tardio"]))
#>
#> b(y_t-1): 2021-2023 = +1.250 ; 2024 = +1.420
```

Se cumple a medias, y hay que declararlo. La *dinámica* es homogénea: el coeficiente autorregresivo pasa de +1.25 a +1.42 entre los dos periodos, una diferencia que no es significativa ($p = 0.63$). La estructura de dependencia temporal que el modelo supone es la misma en 2021 que en 2024.

Lo que sí cambia es el **nivel**: la indicadora de 2024 en adelante aporta $LR = 10.51$, $p = 0.0012$. Es un escalón, no una deriva —una tendencia lineal en el tiempo no resulta significativa ($p = 0.77$) precisamente porque el cambio es abrupto y no gradual—, y los tres factores no lo absorben. Con estos datos no se puede decidir si es un cambio en las emisiones, un cambio de instrumentación en la red, o un par de años meteorológicamente atípicos cuya señal no llega a los quince predictores del bloque factorial. Queda como limitación del modelo, no como impedimento: el ajuste sobre 2021–2024 promedia los dos regímenes y la validación de 2025 dirá cuánto cuesta.

3. Ausencia de separación perfecta

La separación se delata sola: el algoritmo de Fisher no converge o converge a coeficientes que crecen sin límite, con errores estándar que explotan al mismo ritmo. Se revisan las tres firmas —convergencia, magnitud, probabilidades ajustadas— y además el traslape empírico, que es la causa y no el síntoma.

```

cat(sprintf("convergio:%s   iteraciones:%d\n", g0$converged, g0$iter))
#> convergio: TRUE   iteraciones: 6
round(coef(summary(g0)), 4)
#>
#> Estimate Std. Error z value Pr(>|z|)
#> (Intercept) -1.7996 0.1062 -16.9416 0.0000
#> comb 0.9057 0.1261 7.1812 0.0000
#> vent -1.0773 0.1540 -6.9968 0.0000
#> foto 1.0476 0.1207 8.6772 0.0000
#> s1 0.2131 0.1063 2.0054 0.0449
#> c1 -0.8904 0.2088 -4.2637 0.0000
#> s2 -0.3782 0.1113 -3.3994 0.0007
#> c2 -0.7274 0.1120 -6.4972 0.0000
#> y1 1.3484 0.1598 8.4399 0.0000

```

```

p_aj <- fitted(g0)
cat(sprintf("|coef| maximo :%.3f\n", max(abs(coef(g0)))))
#> |coef| maximo : 1.800
cat(sprintf("error estandar max :%.3f\n", max(coef(summary(g0))[, 2])))
#> error estandar max : 0.209
cat(sprintf("prob. ajustadas en : [%.4f,%.4f]\n", min(p_aj), max(p_aj)))
#> prob. ajustadas en : [0.0001, 0.9958]

cat("\ntabla y_t x y_{t-1} (una celda vacia implicaria separacion):\n")
#>
#> tabla y_t x y_{t-1} (una celda vacia implicaria separacion):
print(table(`y_{t-1}` = TR$y1, y_t = TR$y))
#>
#> y_t
#> y_{t-1} 0 1
#> 0 851 166
#> 1 165 272

cat("\ntraslape de cada factor entre clases (en desviaciones estandar):\n")
#>
#> traslape de cada factor entre clases (en desviaciones estandar):
round(sapply(c("comb", "vent", "foto"), \(v) {
  r0 <- range(TR[[v]][TR$y == 0]); r1 <- range(TR[[v]][TR$y == 1])
  min(r0[2], r1[2]) - max(r0[1], r1[1])
}), 2)
#> comb vent foto
#> 3.80 3.34 4.48

```

Se cumple, con margen amplio. Convergió en 6 iteraciones; el coeficiente más grande es 1.800 y el error estándar más grande 0.209 —la firma de la separación son coeficientes por encima de 10 con errores estándar del mismo orden, y aquí no hay nada parecido. Las cuatro celdas de la tabla de transición están pobladas, y los tres factores se traslapan entre 3.3 y 4.5 desviaciones estándar. No hace falta corrección de Firth ni verosimilitud penalizada.

4. Especificación correcta del *link*

Dos pruebas complementarias. La comparación entre familias de *link* dice si el logit es la mejor de las opciones disponibles; el *linktest* de Pregibon dice si es adecuado en términos absolutos.

```
round(sapply(c("logit", "probit", "cloglog", "cauchit"),
             \(lk) AIC(glm(F0, binomial(link = lk), TR))), 2)
#>   logit   probit cloglog cauchit
#> 1129.26 1129.49 1163.55 1153.46

# Linktest de Pregibon: se agrega el cuadrado del predictor lineal ajustado. Si
# el link es correcto, ese termino no aporta nada; si aporta, la escala esta mal
# especificada en alguna parte.
eta <- predict(g0)
g2 <- glm(update(F0, . ~ . + I(eta^2)), binomial, TR)
cat(sprintf("linktest: coef(eta^2) =%.4f   LR =%.2f   p =%.4f\n",
            coef(g2)["I(eta^2)"], g0$deviance - g2$deviance,
            pchisq(g0$deviance - g2$deviance, 1, lower.tail = FALSE)))
#> linktest: coef(eta^2) = -0.0863   LR = 8.93   p = 0.0028
```

El logit gana entre las cuatro familias, y por poco frente al probit (1129.26 contra 1129.49) — como es habitual, ambos son casi indistinguibles salvo en las colas. El *cloglog*, que asumiría asimetría, queda 34 puntos de AIC atrás.

Pero el *linktest* **rechaza** ($p = 0.0028$), lo que parecería condenar al logit. No es el *link*. El *linktest* es una prueba de especificación global: detecta cualquier no linealidad omitida, venga del *link* o del predictor. Se separan las dos hipótesis probando primero la curvatura en los factores.

```
gq <- glm(update(F0, . ~ . + I(comb^2) + I(vent^2) + I(foto^2)), binomial, TR)
cat(sprintf("cuadrados de los factores: LR =%.2f   gl = 3   p =%.4f\n",
            g0$deviance - gq$deviance,
            pchisq(g0$deviance - gq$deviance, 3, lower.tail = FALSE)))
#> cuadrados de los factores: LR = 18.90   gl = 3   p = 0.0003
round(coef(summary(gq))[c("I(comb^2)", "I(vent^2)", "I(foto^2)"), 3], 2)
#> I(comb^2) I(vent^2) I(foto^2)
#>   -0.65   -2.21   -3.62

# Repetir el linktest sobre el modelo ya con curvatura: si ahora no rechaza, el
# problema era el predictor y no el link.
eq <- predict(gq)
gq2 <- glm(update(formula(gq), . ~ . + I(eq^2)), binomial, TR)
cat(sprintf("\nlinktest DESPUES de la curvatura: LR =%.2f   p =%.4f\n",
            gq$deviance - gq2$deviance,
            pchisq(gq$deviance - gq2$deviance, 1, lower.tail = FALSE)))
#>
#> linktest DESPUES de la curvatura: LR = 0.28   p = 0.5958
```

```
# Hosmer-Lemeshow por deciles de riesgo, escrito a mano por la misma razon que
# el ADF. Mide calibracion: si las probabilidades predichas corresponden a las
# frecuencias observadas dentro de cada grupo.
gr <- cut(p_aj, quantile(p_aj, 0:10 / 10), include.lowest = TRUE)
HL <- sum((tapply(TR$y, gr, sum) - tapply(p_aj, gr, sum))^2 /
         tapply(p_aj * (1 - p_aj), gr, sum))
cat(sprintf("Hosmer-Lemeshow: X2 = %.2f    gl = 8    p = %.4f\n",
           HL, pchisq(HL, 8, lower.tail = FALSE)))
#> Hosmer-Lemeshow: X2 = 7.86    gl = 8    p = 0.4477
```

Se cumple: el *link* logit es correcto; lo que faltaba era curvatura en el predictor. Agregar los cuadrados de los tres factores mejora el ajuste ($LR = 18.90$, $p = 0.0003$), con la contribución concentrada en el forzamiento fotoquímico ($z = -3.62$) y la ventilación ($z = -2.21$). Y el diagnóstico decisivo: **una vez incluida esa curvatura, el *linktest* deja de rechazar** ($p = 0.60$). Si el problema hubiera sido el *link*, seguiría rechazando.

Los signos negativos son físicamente coherentes: el efecto de ambos factores se satura. Duplicar el viento cuando ya hay viento fuerte no vuelve a dividir la probabilidad de excedencia. La calibración global nunca estuvo en duda — Hosmer-Lemeshow no rechaza ($p = 0.45$) ni siquiera en el modelo sin curvatura.

Consecuencia para el modelo final: los términos cuadráticos de vent y foto deben entrar.

5. Ergodicidad de la cadena subyacente

La cadena de dos estados generada por y_t debe ser irreducible (todos los estados alcanzables), aperiódica (sin ciclos deterministas) y con probabilidades acotadas lejos de 0 y 1 (sin estados absorbentes de facto). Se verifican las tres sobre la matriz de transición empírica.

```
P <- prop.table(table(`y_{t-1}` = TR$y1, y_t = TR$y), 1)
round(P, 3)
#>      y_t
#> y_{t-1}    0    1
#>      0 0.837 0.163
#>      1 0.378 0.622

lambda <- sort(abs(eigen(P)$values), decreasing = TRUE)
cat(sprintf("\n|lambda| = %s\n", paste(round(lambda, 3), collapse = ", ")))
#>
#> |lambda| = 1, 0.459
cat(sprintf("tiempo de mezcla -1/log|lambda_2| = %.1f dias\n", -1 /
  ↪ log(lambda[2])))
#> tiempo de mezcla -1/log|lambda_2| = 1.3 dias

# La distribucion estacionaria es el eigenvector izquierdo de lambda = 1.
e <- eigen(t(P))$vectors[, 1]
```

```

pi <- Re(e / sum(e))
cat(sprintf("estacionaria P(y=1) =%.3f vs empirica%.3f\n",
           pi[2], mean(TR$y)))
#> estacionaria P(y=1) = 0.302 vs empirica 0.301
cat(sprintf("probabilidades ajustadas del modelo en [%.4f,%.4f]\n",
           min(p_aj), max(p_aj)))
#> probabilidades ajustadas del modelo en [0.0001, 0.9958]

```

Se cumple, y con holgura. Las cuatro transiciones se observan, así que la cadena es irreducible; la diagonal es estrictamente positiva (0.837 y 0.622), lo que la hace aperiódica; y el segundo eigenvalor, $|\lambda_2| = 0.459 < 1$, da ergodicidad geométrica. La confirmación numérica es que la distribución estacionaria implicada, $P(y = 1) = 0.302$, coincide con la frecuencia empírica (0.301) hasta la milésima: la cadena ya está en su régimen de equilibrio dentro de la ventana de datos, no en un transitorio.

El tiempo de mezcla, $-1/\log|\lambda_2| \approx 1.3$ días, es la cifra que más dice sobre el alcance del modelo. La memoria del proceso es cortísima, lo que explica por qué el segundo rezago ya no aportaba nada en la sección 1 — y adelanta que un eventual pronóstico a más de dos o tres días va a converger a la climatología del mes, con poca ganancia sobre predecir la tasa base.

6. Por qué la respuesta tiene que ser binaria y no la fracción

Sería tentador modelar `frac` directamente como binomial: k excedencias de n estaciones, con n variable. Eso supondría que las n estaciones de un día son ensayos Bernoulli independientes, y `serie_tiempo_factores.pdf` ya documentó que no lo son: la correlación entre estaciones el mismo día promedia 0.53 en la respuesta. Se cuantifica el costo.

```

B      <- filter(A, anio <= 2024, !is.na(k), n > 0)
p_bar <- sum(B$k) / sum(B$n)
X2     <- sum((B$k - B$n * p_bar)^2 / (B$n * p_bar * (1 - p_bar)))
cat(sprintf("X2 / gl =%.2f (1.0 = binomial exacta)\n", X2 / (nrow(B) - 1)))
#> X2 / gl = 5.97 (1.0 = binomial exacta)
cat(sprintf("factor de inflacion de los errores estandar =%.2f\n",
           sqrt(X2 / (nrow(B) - 1))))
#> factor de inflacion de los errores estandar = 2.44

```

Sobredispersión de casi 6 a 1. Tratar k de n como binomial subestimaría los errores estándar por un factor de $\sqrt{5.97} \approx 2.4$: intervalos de confianza a menos de la mitad de su ancho real y p -valores correspondientemente optimistas. Es la correlación transversal reapareciendo como varianza inflada. Por eso el modelo trabaja sobre la indicadora dicotomizada de la sección 0.1 y no sobre la fracción.

7. ¿Alcanza el AR(1) o queda dependencia serial?

El AR(1) resuelve la dependencia que el modelo supone. Falta ver si resuelve toda la que hay: si los residuales siguen autocorrelacionados, el modelo está mal especificado en su parte temporal.

```

resumen_residual <- function(modelo, etiqueta) {
  ph <- fitted(modelo)
  r <- (TR$y - ph) / sqrt(ph * (1 - ph))          # residual de Pearson
  data.frame(modelo = etiqueta,
             acf1 = round(acf(r, lag.max = 5, plot = FALSE)$acf[2], 3),
             acf2 = round(acf(r, lag.max = 5, plot = FALSE)$acf[3], 3),
             LB7 = round(Box.test(r, lag = 7, type = "Ljung-Box")$p.value, 4),
             LB14 = round(Box.test(r, lag = 14, type = "Ljung-Box")$p.value, 4))
}
rbind(
  resumen_residual(glm(y ~ comb + vent + foto + s1 + c1 + s2 + c2, binomial, TR),
                    "factores + estacionalidad"),
  resumen_residual(g0, "+ y_{t-1}"),
  resumen_residual(gq, "+ y_{t-1} + curvatura")) |> print(row.names = FALSE)
#>               modelo  acf1  acf2    LB7    LB14
#> factores + estacionalidad 0.212 0.134 0.0000 0.0000
#>               + y_{t-1} 0.025 0.098 0.0014 0.0056
#>               + y_{t-1} + curvatura 0.024 0.116 0.0002 0.0008

```

El rezago hace su trabajo sobre el lag 1: la autocorrelación residual cae de 0.212 a 0.025, es decir se elimina. Pero **queda un residuo en el lag 2** (0.098) y Ljung-Box sigue rechazando en el lag 7.

Vale la pena notar que la curvatura de la sección 4 **no ayuda aquí**: mejora el ajuste y arregla el *linktest*, pero deja la autocorrelación de lag 2 igual o ligeramente peor (0.116). No es contradictorio, es la separación limpia entre dos cosas distintas — la curvatura corrige la **forma** de la media condicional, no la **dependencia temporal** de los residuales. Cada problema necesita su propia herramienta.

Ese rechazo de Ljung-Box hay que leerlo con la misma cautela que *serie_tiempo_factores.pdf* aplicó a sus propias pruebas: con $n = 1,454$, la prueba detecta autocorrelaciones triviales. Lo informativo es la magnitud, y 0.098 en el lag 2 es pequeño pero no cero. La lectura honesta es que el AR(1) captura casi toda la dependencia y sobra un residuo de segundo orden que no justifica un segundo rezago —la sección 1 mostró que no es significativo— pero que sí deja espacio para un término de media móvil sobre los residuales, que es exactamente lo que un modelo GLARMA agregaría. Esa es la comparación natural del siguiente paso.

Conviene anticipar una diferencia que se presta a confusión: GLARMA **no** pone y_{t-1} en el predictor. Su estado autorregresivo se construye sobre los *residuales* predictivos, $Z_t = \sum_i \phi_i (Z_{t-i} + e_{t-i}) + \sum_j \theta_j e_{t-j}$, de modo que es un modelo distinto del de este documento y no una extensión suya. Los supuestos verificados aquí son los de la logística autorregresiva de Markov; los de GLARMA son otros —en particular, la estacionariedad se vuelve una condición sobre las raíces del polinomio ARMA, que sólo puede revisarse después de ajustar.

8. Criterios de aceptación

- OK El orden autorregresivo se decide con PACF y con BIC condicionado a las covariables, sobre filas idénticas ($p = 1$)
- OK La estacionariedad se prueba donde corresponde: raíz unitaria en los

factores continuos, homogeneidad temporal en la cadena binaria

PARCIAL La dinamica es homogenea (persistencia estable, $p = 0.63$) pero el nivel da un escalon en 2024 ($p = 0.0012$) que los factores no absorben

OK No hay separacion perfecta: convergencia en 6 iteraciones, $|b|$ max 1.80, cuatro celdas de transicion pobladas, traslape > 3 sd en los tres factores

OK El link logit es correcto; el rechazo del linktest se atribuye a curvatura omitida y desaparece al incluirla ($p = 0.60$)

OK La cadena es irreducible, aperiodica y geometricamente ergodica ($|\lambda_2| = 0.459$), con estacionaria 0.302 vs empirica 0.301

OK La respuesta se dicotomiza en vez de modelarse como fraccion: la sobredispersion binomial es de 5.97

OK La dependencia residual se mide antes y despues del rezago

9. Qué se lleva el modelo, y qué queda declarado

Los cinco supuestos se sostienen. La logística autorregresiva de orden 1 es un modelo defendible para el *nowcasting* de excedencia a nivel área metropolitana, con tres decisiones que este documento deja fijadas:

1. $p = 1$: un solo rezago de la respuesta.
2. **Los armónicos anuales y semianuales son obligatorios**, no opcionales: sin ellos la marginal varía por un factor de seis dentro del año y el supuesto de estacionariedad condicional no se sostiene.
3. **Los términos cuadráticos de vent y foto entran**: sin ellos el *linktest* rechaza la especificación.

Y dos limitaciones que se declaran en vez de corregirse:

El escalón de 2024. El nivel de excedencia sube de forma abrupta a partir de 2024 y los factores no lo explican. El modelo ajustado sobre 2021–2024 promedia dos regímenes; la validación en 2025 —que pertenece al régimen alto— dirá cuánto cuesta ese promedio. No se corrige con una indicadora porque eso equivaldría a ajustar un parámetro al periodo de validación por la puerta de atrás.

La dimensión espacial se perdió. Agregar a área metropolitana es lo que devuelve la independencia temporal y la rejilla regular, pero elimina el contraste entre estaciones y zonas que *analisis_discriminante.pdf* sí aprovecha. Los dos modelos responden preguntas distintas y no se sustituyen: uno clasifica días de área, el otro clasifica día-estación. La comparación de sus AUC no sería una comparación justa.