

Modelación autorregresiva logística: supuestos y nowcasting

MA2003B, equipo 7 — nowcasting de excedencia diaria

Tabla de contenidos

0. Construcción de la serie de área metropolitana	2
0.1 La respuesta binaria y el umbral	3
1. Cuántos rezagos de y_t entran al predictor	4
2. Estacionariedad	5
3. Ausencia de separación perfecta	7
4. Especificación correcta del <i>link</i>	8
5. Ergodicidad de la cadena subyacente	10
6. Por qué la respuesta tiene que ser binaria y no la fracción	10
7. ¿Alcanza el AR(1) o queda dependencia serial?	11
8. El modelo de nowcasting	12
8.1 Cuánto aporta cada pieza	13
8.2 Los coeficientes	14
8.3 Discriminación	15
8.4 El umbral de decisión	16
8.5 Calibración	17
8.6 La serie de 2025	19
8.7 ¿Cuánto de ese 0.927 es real?	20
8.8 ¿Depende el resultado del umbral?	22
9. Criterios de aceptación	23
10. Qué se lleva el reporte	24

El objetivo de modelado es la **clasificación contemporánea** (*nowcasting*): dado lo que se observó hoy —los tres puntajes factoriales del día— decidir si hoy es un día de excedencia. El modelo candidato es la logística autorregresiva

$$\text{logit } P(y_t = 1 \mid \mathcal{F}_{t-1}, x_t) = x_t' \beta + \sum_{i=1}^p \alpha_i y_{t-i},$$

donde x_t son los factores del mismo día más los armónicos del calendario, y el pasado observado entra directo por los rezagos y_{t-i} . El pronóstico a días futuros queda para después; es otro modelo y otra validación.

Antes de ajustarlo se verifica que sus supuestos se sostengan. Son cinco preguntas, más dos que salieron del propio diagnóstico:

1. cuántos rezagos de y_t entran al predictor,
2. estacionariedad,
3. ausencia de separación perfecta,
4. especificación correcta del *link*,
5. ergodicidad de la cadena subyacente,
6. si la respuesta puede ser la fracción de estaciones o tiene que ser binaria,
7. si queda dependencia serial después del término autorregresivo.

09_extraccion_factorial.pdf produjo los puntajes y serie_tiempo_factores.pdf fijó la decisión que este documento hereda sin reabrir: **se trabaja sobre la serie de área metropolitana**, no sobre el panel día-estación. La razón es doble — la cobertura por estación es insuficiente (3 de 15 superan 85 %) y la correlación entre estaciones el mismo día es alta (0.49 a 0.86), así que promediar es agregación legítima y no mezcla de señales independientes.

0. Construcción de la serie de área metropolitana

Se reconstruye la serie de serie_tiempo_factores.pdf §2: ese documento no la persistió y rehacerla cuesta segundos.

```
library(nanoparquet)
library(dplyr)

af <- read_parquet("../data/processed/af_puntajes_diarios.parquet")
di <- read_parquet("../data/processed/sima_transformado_diario.parquet")

# Hora local de pared sin zona: fijar el atributo, no convertir (ver CLAUDE.md).
attr(af$fecha, "tzone") <- "UTC"
attr(di$fecha, "tzone") <- "UTC"

# F1/F2/F3 en el orden de NOMBRES de 09_extraccion_factorial.qmd.
af <- rename(af, comb = F1, vent = F2, foto = F3)

m <- inner_join(af, select(di, estacion, fecha, excede_anio_5),
                by = c("estacion", "fecha")) |>
  filter(if_all(c(comb, vent, foto, excede_anio_5), \(v) !is.na(v)))

cat(sprintf("dia-estacion completos:%s\nprevalencia dia-estacion:%.4f\n",
            format(nrow(m), big.mark = ","), mean(m$excede_anio_5)))
#> dia-estacion completos: 17,029
#> prevalencia dia-estacion: 0.3035
```

La respuesta de origen, `excede_anio_5`, es el escenario principal de modelado: MDA8 por encima de 51 ppb. Al agregar por día quedan el conteo de estaciones que exceden (**k**) y el de estaciones que reportan (**n**), que no es constante.

```

area <- m |>
  group_by(fecha) |>
  summarise(comb = mean(comb), vent = mean(vent), foto = mean(foto),
            k = sum(excede_anio_5), n = n_distinct(estacion), .groups = "drop")

# Reindexar deja los huecos explicitos; si no, los rezagos saltarian sobre ellos.
cal <- data.frame(fecha = seq(min(m$fecha), max(m$fecha), by = "day"))
A <- left_join(cal, area, by = "fecha")
A$frac <- A$k / A$n

cat(sprintf("dias de calendario:%s\ndias sin ninguna estacion:%d (%s)\n",
            format(nrow(A), big.mark = ","), sum(is.na(A$comb)),
            paste(format(A$fecha[is.na(A$comb)], "%Y-%m-%d"), collapse = ", ")))
#> dias de calendario: 1,642
#> dias sin ninguna estacion: 1 (2021-02-16)

```

Un solo día, 2021-02-16, queda sin cobertura (0.06 % del calendario). Se interpola linealmente porque los rezagos exigen rejilla regular, y se deja documentado.

```

interp <- function(v) {
  i <- which(!is.na(v))
  approx(i, v[i], seq_along(v), rule = 2)$y
}
for (v in c("comb", "vent", "foto", "frac")) A[[v]] <- interp(A[[v]])

A$anio <- as.integer(format(A$fecha, "%Y"))
doy <- as.integer(format(A$fecha, "%j"))
A$s1 <- sin(2 * pi * doy / 365.25); A$c1 <- cos(2 * pi * doy / 365.25)
A$s2 <- sin(4 * pi * doy / 365.25); A$c2 <- cos(4 * pi * doy / 365.25)

round(sapply(A[c("comb", "vent", "foto", "frac", "n")],
             \(v) c(media = mean(v, na.rm = TRUE), sd = sd(v, na.rm = TRUE),
                    min = min(v, na.rm = TRUE), max = max(v, na.rm = TRUE))), 3)
#>      comb  vent  foto frac      n
#> media -0.073 -0.008 -0.012 0.30 10.377
#> sd      0.895  0.679  1.123 0.35  2.821
#> min     -2.502 -2.570 -3.228 0.00  1.000
#> max      2.949  2.040  2.766 1.00 15.000

```

Los armónicos anual y semianual entran como covariables desde ahora: la sección 2 muestra que sin ellos no se cumple la estacionariedad.

0.1 La respuesta binaria y el umbral

frac es la **fracción** de estaciones que exceden, no una indicadora. La sección 6 muestra por qué no puede usarse directamente. Para el modelo binario hay que dicotomizarla, y el corte es una decisión sustantiva —qué cuenta como “día de excedencia para el área metropolitana”— no estadística.

```

umbrales <- c("cualquiera (frac > 0)" = 1e-9,
             "un cuarto (frac >= 0.25)" = 0.25,
             "mayoria (frac >= 0.5)" = 0.5)
round(sapply(umbrales, \(u) mean(A$frac >= u)), 3)
#>      cualquiera (frac > 0) un cuarto (frac >= 0.25)      mayoria (frac >= 0.5)
#>                0.570                0.421                0.316

```

Se adopta **frac >= 0.5**: el día es de excedencia si la mayoría de las estaciones que reportaron excedieron. La prevalencia resultante, 0.316, es prácticamente la del panel día-estación (0.3035), así que el evento agregado conserva la tasa base del original; y al ser una proporción no premia a los días con más estaciones reportando, como sí haría un conteo. El corte “cualquiera excede” subiría la prevalencia a 0.570 y cambiaría la pregunta a si *alguna* estación tuvo un mal día, un evento más frecuente y menos informativo.

```

A$y <- as.integer(A$frac >= 0.5)
for (p in 1:7) A[[paste0("y", p)]] <- dplyr::lag(A$y, p)

# Particion 2021-2024 / 2025, igual que #54 y #55. Se exigen los 7 rezagos para
# que la seccion 1 compare AIC sobre filas identicas.
TR <- filter(A, anio <= 2024, !is.na(y7))
cat(sprintf("entrenamiento: %s dias (%d-%d), prevalencia%.3f\n",
            format(nrow(TR), big.mark = ","), min(TR$anio), max(TR$anio),
            mean(TR$y)))
#> entrenamiento: 1,454 dias (2021-2024), prevalencia 0.301

```

1. Cuántos rezagos de y_t entran al predictor

La PACF sugiere el orden por la vía descriptiva; el criterio de información lo confirma **condicionando a las covariables**, que es lo que importa: parte de la persistencia de y_t podría ser sólo la de la meteorología que la produce.

```

round(pacf(A$y, lag.max = 10, plot = FALSE)$acf[1:10], 3)
#> [1] 0.464 0.101 0.056 0.062 0.043 0.039 0.044 0.013 0.009 0.038

```

```

base <- "y ~ comb + vent + foto + s1 + c1 + s2 + c2"
tabla <- NULL
anterior <- NULL
for (p in 0:7) {
  f <- if (p == 0) base else paste(base, "+", paste0("y", 1:p, collapse = " + "))
  g <- glm(as.formula(f), binomial, TR)
  s <- coef(summary(g))
  tabla <- rbind(tabla, data.frame(
    p = p,
    AIC = AIC(g), BIC = BIC(g),
    coef = if (p == 0) NA else s[paste0("y", p), 1],
  ))
}

```

```

    z    = if (p == 0) NA else s[paste0("y", p), 3],
    LR    = if (p == 0) NA else anterior$deviance - g$deviance))
  anterior <- g
}
print(transform(tabla, AIC = round(AIC, 1), BIC = round(BIC, 1),
      coef = round(coef, 3), z = round(z, 2), LR = round(LR, 2)),
      row.names = FALSE)
#>   p    AIC    BIC   coef     z    LR
#> 0 1199.0 1241.2    NA    NA    NA
#> 1 1129.3 1176.8  1.348  8.44 71.72
#> 2 1128.3 1181.1  0.306  1.74  3.00
#> 3 1130.2 1188.3  0.050  0.28  0.08
#> 4 1131.5 1194.9  0.151  0.84  0.70
#> 5 1133.1 1201.7 -0.117 -0.64  0.41
#> 6 1134.9 1208.8 -0.081 -0.44  0.19
#> 7 1136.7 1215.9  0.078  0.42  0.17

```

Se cumple, con $p = 1$. La PACF cae de 0.464 a 0.101 en el lag 2 y a ruido de ahí en adelante: corta después del primer rezago, la firma de un AR(1). El BIC coincide y se minimiza en $p = 1$; el AIC está empatado entre $p = 1$ y $p = 2$, pero el segundo rezago no alcanza significancia ($z = 1.74$) y del tercero en adelante los coeficientes son indistinguibles de cero.

Más importante que el orden: el rezago **sobrevive a las covariables contemporáneas**. Con los factores y los armónicos ya dentro, agregar y_{t-1} da $LR = 71.7$ sobre 1 grado de libertad y un coeficiente de +1.35 ($z = 8.4$). La persistencia día a día no es un reflejo de que la meteorología sea persistente: es dependencia genuina, y es lo que justifica la parte autorregresiva.

2. Estacionariedad

Una serie **binaria y acotada** no puede tener raíz unitaria —un paseo aleatorio es no acotado por construcción—, así que aplicarle Dickey-Fuller a y_t responde una pregunta ya resuelta. Lo que sí puede fallar es que el proceso sea **homogéneo en el tiempo**: que $P(y_t | y_{t-1}, x_t)$ no cambie a lo largo de los cuatro años. Sobre los tres factores, continuos y no acotados, la prueba de raíz unitaria sí corresponde.

```

# ADF a mano (constante, sin tendencia) para no agregar `tseries` al lockfile:
#   dx_t = a + rho*x_{t-1} + sum_i gamma_i dx_{t-i}; H0: rho = 0.
# El t de rho se compara contra Dickey-Fuller (-2.86 al 5%), no contra Student.
adf <- function(x, max_lag = 12) {
  mejor <- NULL
  for (L in 0:max_lag) {
    d <- diff(x)
    idx <- (L + 1):length(d)
    X <- cbind(rezago = x[idx],
      if (L > 0) sapply(1:L, \(i) d[idx - i]) else NULL)
    fit <- lm(d[idx] ~ X)
    if (is.null(mejor) || AIC(fit) < mejor$aic)

```

```

    mejor <- list(aic = AIC(fit), L = L, t = coef(summary(fit))[2, 3])
  }
  mejor
}

VC5 <- -2.86
do.call(rbind, lapply(c("comb", "vent", "foto", "frac"), \(v) {
  r <- adf(A[[v]])
  data.frame(serie = v, t_ADF = round(r$t, 2), rezagos = r$L,
             veredicto = ifelse(r$t < VC5, "rechaza raiz unitaria", "NO rechaza"))
})) |> print(row.names = FALSE)
#>  serie  t_ADF rezagos          veredicto
#>  comb  -4.66      12 rechaza raiz unitaria
#>  vent  -5.42      12 rechaza raiz unitaria
#>  foto  -5.53      12 rechaza raiz unitaria
#>  frac -11.55       4 rechaza raiz unitaria

```

Las cuatro series rechazan la raíz unitaria con holgura. No hay que diferenciar nada.

La marginal, en cambio, **no es estacionaria**, y por un margen que no se puede ignorar:

```

round(tapply(A$y, format(A$fecha, "%m"), mean), 3)
#>  01  02  03  04  05  06  07  08  09  10  11  12
#> 0.090 0.277 0.542 0.433 0.561 0.347 0.169 0.250 0.400 0.363 0.183 0.089
round(tapply(A$y, A$anio, mean), 3)
#> 2021 2022 2023 2024 2025
#> 0.274 0.282 0.249 0.396 0.442

```

De 0.090 en diciembre a 0.561 en mayo: un factor de seis dentro del año. Y un escalón entre 2023 (0.249) y 2024–2025 (0.396, 0.442). Ninguno invalida el modelo, pero ambos obligan a que el ciclo esté **en el predictor**: la estacionariedad que se necesita es la de $y_t | x_t$, no la de y_t .

Queda probar que, ya condicionando, el proceso sea homogéneo.

```

A$tardio <- as.integer(A$anio >= 2024)
TR$tardio <- as.integer(TR$anio >= 2024)

F0 <- y ~ comb + vent + foto + s1 + c1 + s2 + c2 + y1
g0 <- glm(F0, binomial, TR)

# Nivel (mas dias de excedencia) y persistencia (cadena mas pegajosa) son cosas
# distintas y se prueban por separado.
gn <- glm(update(F0, . ~ . + tardio), binomial, TR)
gi <- glm(update(F0, . ~ . + tardio + y1:tardio), binomial, TR)

data.frame(
  hipotesis = c("cambio de nivel (tardio)", "cambio de persistencia (y1:tardio)"),

```

```

LR = round(c(g0$deviance - gn$deviance, gn$deviance - gi$deviance), 2),
p = round(pchisq(c(g0$deviance - gn$deviance, gn$deviance - gi$deviance),
1, lower.tail = FALSE), 4)) |> print(row.names = FALSE)
#>                hipotesis      LR      p
#> cambio de nivel (tardio) 10.51 0.0012
#> cambio de persistencia (y1:tardio) 0.23 0.6320

cat(sprintf("\nb(y_t-1): 2021-2023 = %+.3f ; 2024 = %+.3f\n",
coef(gi)["y1"], coef(gi)["y1"] + coef(gi)["y1:tardio"]))
#>
#> b(y_t-1): 2021-2023 = +1.250 ; 2024 = +1.420

```

Se cumple a medias, y hay que declararlo. La *dinámica* es homogénea: el coeficiente autorregresivo pasa de +1.25 a +1.42 entre los dos periodos, una diferencia que no es significativa ($p = 0.63$). La estructura de dependencia temporal que el modelo supone es la misma en 2021 que en 2024.

Lo que sí cambia es el **nivel**: la indicadora de 2024 en adelante aporta $LR = 10.51$, $p = 0.0012$. Es un escalón, no una deriva —una tendencia lineal no resulta significativa ($p = 0.77$) porque el cambio es abrupto—, y los factores no lo absorben. Con estos datos no se puede decidir si es un cambio de emisiones, de instrumentación, o un par de años atípicos. Queda como limitación, no como impedimento: el ajuste promedia los dos regímenes y la validación dirá cuánto cuesta.

3. Ausencia de separación perfecta

La separación se delata sola: el algoritmo no converge, o lo hace con coeficientes que crecen sin límite y errores estándar que explotan igual. Se revisan esas firmas y el traslape empírico, que es la causa y no el síntoma.

```

cat(sprintf("convergio:%s  iteraciones:%d\n", g0$converged, g0$iter))
#> convergio: TRUE  iteraciones: 6
round(coef(summary(g0)), 4)
#>      Estimate Std. Error  z value Pr(>|z|)
#> (Intercept) -1.7996      0.1062 -16.9416  0.0000
#> comb         0.9057      0.1261   7.1812  0.0000
#> vent        -1.0773      0.1540  -6.9968  0.0000
#> foto         1.0476      0.1207   8.6772  0.0000
#> s1           0.2131      0.1063   2.0054  0.0449
#> c1          -0.8904      0.2088  -4.2637  0.0000
#> s2          -0.3782      0.1113  -3.3994  0.0007
#> c2          -0.7274      0.1120  -6.4972  0.0000
#> y1           1.3484      0.1598   8.4399  0.0000

```

```

p_aj <- fitted(g0)
cat(sprintf("|coef| maximo      :%.3f\n", max(abs(coef(g0)))))
#> |coef| maximo      : 1.800
cat(sprintf("error estandar max :%.3f\n", max(coef(summary(g0))[, 2])))

```

```
#> error estandar max : 0.209
cat(sprintf("prob. ajustadas en : [%.4f,%.4f]\n", min(p_aj), max(p_aj)))
#> prob. ajustadas en : [0.0001, 0.9958]

cat("\ntabla y_t x y_{t-1} (una celda vacia implicaria separacion):\n")
#>
#> tabla y_t x y_{t-1} (una celda vacia implicaria separacion):
print(table(`y_{t-1}` = TR$y1, y_t = TR$y))
#>      y_t
#> y_{t-1}    0    1
#>      0 851 166
#>      1 165 272

cat("\ntraslape de cada factor entre clases (en desviaciones estandar):\n")
#>
#> traslape de cada factor entre clases (en desviaciones estandar):
round(sapply(c("comb", "vent", "foto"), \(v) {
  r0 <- range(TR[[v]][TR$y == 0]); r1 <- range(TR[[v]][TR$y == 1])
  min(r0[2], r1[2]) - max(r0[1], r1[1])
}), 2)
#> comb vent foto
#> 3.80 3.34 4.48
```

Se cumple, con margen amplio. Convergió en 6 iteraciones; el coeficiente mayor es 1.800 y el error estándar mayor 0.209, lejos de la firma de separación (coeficientes por encima de 10 con errores del mismo orden). Las cuatro celdas de la tabla de transición están pobladas y los factores se traslapan entre 3.3 y 4.5 desviaciones estándar. No hace falta Firth ni verosimilitud penalizada.

4. Especificación correcta del *link*

La comparación entre familias dice si el logit es la mejor opción disponible; el *linktest* de Pregibon, si es adecuado en términos absolutos.

```
round(sapply(c("logit", "probit", "cloglog", "cauchit"),
  \(lk) AIC(glm(F0, binomial(link = lk), TR))), 2)
#>   logit   probit cloglog cauchit
#> 1129.26 1129.49 1163.55 1153.46

# Linktest de Pregibon: si el link es correcto, eta^2 no aporta nada.
eta <- predict(g0)
g2 <- glm(update(F0, . ~ . + I(eta^2)), binomial, TR)
cat(sprintf("linktest: coef(eta^2) = %.4f   LR = %.2f   p = %.4f\n",
  coef(g2)["I(eta^2)"], g0$deviance - g2$deviance,
  pchisq(g0$deviance - g2$deviance, 1, lower.tail = FALSE)))
#> linktest: coef(eta^2) = -0.0863   LR = 8.93   p = 0.0028
```


El logit gana: por poco frente al probit (1129.26 contra 1129.49), como es habitual salvo en las colas, y por 34 puntos de AIC frente al cloglog.

Pero el *linktest* **rechaza** ($p = 0.0028$). No es el *link*: el *linktest* es una prueba de especificación global y detecta cualquier no linealidad omitida, venga de donde venga. Se separan las hipótesis probando primero la curvatura en los factores.

```
gq <- glm(update(F0, . ~ . + I(comb^2) + I(vent^2) + I(foto^2)), binomial, TR)
cat(sprintf("cuadrados de los factores: LR = %.2f  gl = 3  p = %.4f\n",
            g0$deviance - gq$deviance,
            pchisq(g0$deviance - gq$deviance, 3, lower.tail = FALSE)))
#> cuadrados de los factores: LR = 18.90  gl = 3  p = 0.0003
round(coef(summary(gq))[c("I(comb^2)", "I(vent^2)", "I(foto^2)"), 3], 2)
#> I(comb^2) I(vent^2) I(foto^2)
#>      -0.65      -2.21      -3.62

# Si ahora no rechaza, el problema era el predictor y no el link.
eq <- predict(gq)
gq2 <- glm(update(formula(gq), . ~ . + I(eq^2)), binomial, TR)
cat(sprintf("\nlinktest DESPUES de la curvatura: LR = %.2f  p = %.4f\n",
            gq$deviance - gq2$deviance,
            pchisq(gq$deviance - gq2$deviance, 1, lower.tail = FALSE)))
#>
#> linktest DESPUES de la curvatura: LR = 0.28  p = 0.5958
```

```
# Hosmer-Lemeshow por deciles de riesgo, a mano por la misma razon que el ADF.
gr <- cut(p_aj, quantile(p_aj, 0:10 / 10), include.lowest = TRUE)
HL <- sum((tapply(TR$y, gr, sum) - tapply(p_aj, gr, sum))^2 /
          tapply(p_aj * (1 - p_aj), gr, sum))
cat(sprintf("Hosmer-Lemeshow: X2 = %.2f  gl = 8  p = %.4f\n",
            HL, pchisq(HL, 8, lower.tail = FALSE)))
#> Hosmer-Lemeshow: X2 = 7.86  gl = 8  p = 0.4477
```

Se cumple: el *link* logit es correcto; lo que faltaba era curvatura en el predictor. Agregar los cuadrados de los tres factores mejora el ajuste ($LR = 18.90$, $p = 0.0003$), con la contribución concentrada en el forzamiento fotoquímico ($z = -3.62$) y la ventilación ($z = -2.21$). Y el diagnóstico decisivo: **una vez incluida esa curvatura, el *linktest* deja de rechazar** ($p = 0.60$). Si el problema hubiera sido el *link*, seguiría rechazando.

Los signos negativos son físicamente coherentes: el efecto de ambos factores se satura —duplicar el viento cuando ya sopla fuerte no vuelve a dividir la probabilidad. La calibración global nunca estuvo en duda: Hosmer-Lemeshow no rechaza ($p = 0.45$) ni siquiera sin curvatura.

Consecuencia para el modelo final: los términos cuadráticos de vent y foto deben entrar.

5. Ergodicidad de la cadena subyacente

La cadena de dos estados debe ser irreducible (todos los estados alcanzables), aperiódica (sin ciclos deterministas) y sin estados absorbentes de facto. Se verifican las tres sobre la matriz de transición empírica.

```
P <- prop.table(table(`y_{t-1}` = TR$y1, y_t = TR$y), 1)
round(P, 3)
#>      y_t
#> y_{t-1}    0    1
#>      0 0.837 0.163
#>      1 0.378 0.622

lambda <- sort(abs(eigen(P)$values), decreasing = TRUE)
cat(sprintf("\n|lambda| = %s\n", paste(round(lambda, 3), collapse = ", ")))
#>
#> |lambda| = 1, 0.459
cat(sprintf("tiempo de mezcla -1/log|lambda_2| = %.1f dias\n", -1 /
  ↪ log(lambda[2])))
#> tiempo de mezcla -1/log|lambda_2| = 1.3 dias

# La distribucion estacionaria es el eigenvector izquierdo de lambda = 1.
e <- eigen(t(P))$vectors[, 1]
pi <- Re(e / sum(e))
cat(sprintf("estacionaria P(y=1) = %.3f    vs empirica %.3f\n",
  pi[2], mean(TR$y)))
#> estacionaria P(y=1) = 0.302    vs empirica 0.301
cat(sprintf("probabilidades ajustadas del modelo en [%.4f, %.4f]\n",
  min(p_aj), max(p_aj)))
#> probabilidades ajustadas del modelo en [0.0001, 0.9958]
```

Se cumple, y con holgura. Las cuatro transiciones se observan (irreducible), la diagonal es estrictamente positiva —0.837 y 0.622— (aperiódica), y el segundo eigenvalor $|\lambda_2| = 0.459 < 1$ da ergodicidad geométrica. La confirmación numérica: la estacionaria implicada, $P(y = 1) = 0.302$, coincide con la empírica (0.301) hasta la milésima, así que la cadena ya está en equilibrio dentro de la ventana de datos.

El tiempo de mezcla, $-1/\log |\lambda_2| \approx 1.3$ días, es la cifra que más dice sobre el alcance del modelo: la memoria es cortísima. Explica que el segundo rezago no aportara nada en la sección 1, y adelanta que un pronóstico a más de dos o tres días convergerá a la climatología del mes.

6. Por qué la respuesta tiene que ser binaria y no la fracción

Sería tentador modelar `frac` como binomial: k excedencias de n estaciones, con n variable. Eso supondría que las estaciones de un día son ensayos Bernoulli independientes, y `serie_tiempo_factores.pdf` documentó que no lo son —la correlación entre estaciones el mismo día promedia 0.53. Se cuantifica el costo.

```

B      <- filter(A, anio <= 2024, !is.na(k), n > 0)
p_bar <- sum(B$k) / sum(B$n)
X2     <- sum((B$k - B$n * p_bar)^2 / (B$n * p_bar * (1 - p_bar)))
cat(sprintf("X2 / g1 =%.2f      (1.0 = binomial exacta)\n", X2 / (nrow(B) - 1)))
#> X2 / g1 = 5.97      (1.0 = binomial exacta)
cat(sprintf("factor de inflacion de los errores estandar =%.2f\n",
            sqrt(X2 / (nrow(B) - 1))))
#> factor de inflacion de los errores estandar = 2.44

```

Sobredispersión de casi 6 a 1. Tratar k de n como binomial subestimaría los errores estándar por un factor de $\sqrt{5.97} \approx 2.4$: intervalos a menos de la mitad de su ancho real. Es la correlación transversal reapareciendo como varianza inflada, y por eso el modelo usa la indicadora dicotomizada de la sección 0.1.

7. ¿Alcanza el AR(1) o queda dependencia serial?

Falta ver si el AR(1) resuelve toda la dependencia que hay: si los residuales siguen autocorrelacionados, la parte temporal está mal especificada.

```

resumen_residual <- function(modelo, etiqueta) {
  ph <- fitted(modelo)
  r <- (TR$y - ph) / sqrt(ph * (1 - ph))          # residual de Pearson
  data.frame(modelo = etiqueta,
              acf1 = round(acf(r, lag.max = 5, plot = FALSE)$acf[2], 3),
              acf2 = round(acf(r, lag.max = 5, plot = FALSE)$acf[3], 3),
              LB7  = round(Box.test(r, lag = 7, type = "Ljung-Box")$p.value, 4),
              LB14 = round(Box.test(r, lag = 14, type = "Ljung-Box")$p.value, 4))
}
rbind(
  resumen_residual(glm(y ~ comb + vent + foto + s1 + c1 + s2 + c2, binomial, TR),
                    "factores + estacionalidad"),
  resumen_residual(g0, "+ y_{t-1}"),
  resumen_residual(gq, "+ y_{t-1} + curvatura")) |> print(row.names = FALSE)
#>               modelo acf1  acf2    LB7    LB14
#> factores + estacionalidad 0.212 0.134 0.0000 0.0000
#>           + y_{t-1} 0.025 0.098 0.0014 0.0056
#>           + y_{t-1} + curvatura 0.024 0.116 0.0002 0.0008

```

El rezago hace su trabajo sobre el lag 1: la autocorrelación residual cae de 0.212 a 0.025. Pero **queda un residuo en el lag 2** (0.098) y Ljung-Box sigue rechazando en el lag 7.

La curvatura de la sección 4 **no ayuda aquí**: arregla el *linktest* pero deja el lag 2 igual o algo peor (0.116). No es contradictorio — la curvatura corrige la **forma** de la media condicional, no la **dependencia temporal** de los residuales.

El rechazo de Ljung-Box se lee con la misma cautela que en *serie_tiempo_factores.pdf*: con $n = 1,454$ detecta autocorrelaciones triviales, así que lo informativo es la magnitud. Un 0.098 es

pequeño pero no cero. El AR(1) captura casi toda la dependencia y sobra un residuo de segundo orden que no justifica un segundo rezago, pero sí deja espacio para un término de media móvil sobre los residuales — lo que agregaría un modelo GLARMA.

Conviene anticipar una confusión frecuente: GLARMA **no** pone y_{t-1} en el predictor. Su estado se construye sobre los *residuales* predictivos, $Z_t = \sum_i \phi_i(Z_{t-i} + e_{t-i}) + \sum_j \theta_j e_{t-j}$, así que es un modelo distinto y no una extensión de éste. Sus supuestos también son otros: la estacionariedad pasa a ser una condición sobre las raíces del polinomio ARMA, revisable sólo después de ajustar.

8. El modelo de nowcasting

Las siete secciones anteriores no dejaron la especificación abierta: la fijaron.

$$\text{logit } P(y_t = 1) = \beta_0 + \underbrace{\beta_1 s_1 + \beta_2 c_1 + \beta_3 s_2 + \beta_4 c_2}_{\text{§2: sin esto no hay estacionariedad}} + \underbrace{\beta_5 \text{ comb} + \beta_6 \text{ vent} + \beta_7 \text{ foto}}_{\text{factores del mismo día}} + \underbrace{\beta_8 \text{ vent}^2 + \beta_9 \text{ foto}^2}_{\text{§4: sin esto el linktest rechaza}} + \underbrace{\alpha y_{t-1}}_{\text{§1: } p=1}$$

El cuadrado de la combustión primaria se deja fuera: en la sección 4 fue el único que no aportó ($z = -0.65$). Se confirma sobre la especificación final.

```
library(pROC)
library(ggplot2)

AZUL <- "#3b6ea5"; ROJO <- "#b5443a"; GRIS <- "#8c8c8c"; CLARO <- "#d9d9d9"

VA <- filter(A, anio == 2025, !is.na(y1))
cat(sprintf("ajuste 2021-2024: %s dias (prevalencia%.3f)\n",
            format(nrow(TR), big.mark = ","), mean(TR$y)))
#> ajuste 2021-2024: 1,454 dias (prevalencia 0.301)
cat(sprintf("validacion 2025 : %s dias (prevalencia%.3f)\n",
            format(nrow(VA), big.mark = ","), mean(VA$y)))
#> validacion 2025 : 181 dias (prevalencia 0.442)

F_final <- y ~ s1 + c1 + s2 + c2 + comb + vent + foto + I(vent^2) + I(foto^2) + y1
modelo <- glm(F_final, binomial, TR)

con_comb2 <- glm(update(F_final, . ~ . + I(comb^2)), binomial, TR)
cat(sprintf("\nagregar I(comb^2): LR =%.2f gl = 1 p =%.4f -> se omite\n",
            modelo$deviance - con_comb2$deviance,
            pchisq(modelo$deviance - con_comb2$deviance, 1, lower.tail = FALSE)))
#>
#> agregar I(comb^2): LR = 0.42 gl = 1 p = 0.5153 -> se omite
```

La validación llega hasta el 30 de junio de 2025, la misma partición de #54 y #55. **Su prevalencia es 0.442 contra 0.301 del ajuste:** al cortarse a mitad de año le sobra primavera —la temporada de ozono— y le falta otoño. Toda métrica que dependa de la tasa base hay que leerla con eso presente.

8.1 Cuánto aporta cada pieza

Un AUC alto no dice si el modelo sirve; hay que compararlo contra lo que se obtendría sin él. Las dos líneas base del *nowcasting* son la **climatología** (sólo el calendario) y la **persistencia** (hoy será como ayer). Se agrega el *skill score* de Brier: 0 es no aportar nada, 1 es predicción perfecta.

```
escalera <- list(
  "1 climatologia" = y ~ s1 + c1 + s2 + c2,
  "2 persistencia" = y ~ y1,
  "3 + factores"    = y ~ s1 + c1 + s2 + c2 + comb + vent + foto,
  "4 + curvatura"   = update(F_final, . ~ . - y1),
  "5 + AR(1) final" = F_final)

comparacion <- do.call(rbind, lapply(names(escalera), function(nm) {
  g <- glm(escalera[[nm]], binomial, TR)
  pva <- predict(g, VA, type = "response")
  # Skill score de Brier contra predecir siempre la tasa base.
  brier <- mean((pva - VA$y)^2)
  base <- mean((mean(TR$y) - VA$y)^2)
  data.frame(modelo = nm, par = length(coef(g)), AIC = round(AIC(g), 1),
    AUC_ajuste = round(as.numeric(auc(roc(TR$y, fitted(g), quiet =
      TRUE))), 3),
    AUC_2025 = round(as.numeric(auc(roc(VA$y, pva, quiet = TRUE))), 3),
    Brier_2025 = round(brier, 4),
    skill = round(1 - brier / base, 3))
}))
print(comparacion, row.names = FALSE)
#>      modelo par    AIC AUC_ajuste AUC_2025 Brier_2025 skill
#> 1 climatologia  5 1650.8    0.692    0.762    0.2085 0.218
#> 2 persistencia  2 1488.4    0.729    0.737    0.1966 0.262
#> 3 + factores   8 1199.0    0.872    0.919    0.1342 0.496
#> 4 + curvatura 10 1182.8    0.878    0.923    0.1245 0.533
#> 5 + AR(1) final 11 1114.8    0.892    0.927    0.1140 0.572
```

Cada bloque aporta. Las líneas base rondan 0.74–0.76 en 2025, el piso contra el que hay que medir. **Los factores son el salto grande:** de 0.762 a 0.919, porque son observaciones del mismo día —ahí está la ventaja del *nowcasting* sobre el pronóstico. La curvatura agrega poco al AUC (0.919 a 0.923) pero mejora el Brier, lo esperable de una corrección de forma: reordena poco y calibra mejor. El AR(1) llega a 0.927 y sube el *skill* de 0.533 a 0.572.

Que el AUC de 2025 (0.927) supere al de ajuste (0.892) llama la atención. La sección 8.7 descarta la explicación intuitiva —el desbalance estacional— y lo atribuye a un efecto de año, además de estimar cuánto de ese 0.927 sobrevive a un año completo.

```
comp_auc <- function(nombre, formula_base) {
  rb <- roc(VA$y, predict(glm(formula_base, binomial, TR), VA, type = "response"),
    quiet = TRUE)
  rf <- roc(VA$y, predict(modelo, VA, type = "response"), quiet = TRUE)
```

```

pr <- roc.test(rf, rb, method = "delong")$p.value
data.frame(contra = nombre, AUC_base = round(as.numeric(auc(rb)), 3),
           AUC_modelo = round(as.numeric(auc(rf)), 3),
           p_DeLong = format.pval(pr, digits = 3))
}
rbind(comp_auc("persistencia", y ~ y1),
      comp_auc("climatologia", y ~ s1 + c1 + s2 + c2)) |> print(row.names = FALSE)
#>      contra AUC_base AUC_modelo p_DeLong
#> persistencia    0.737      0.927 5.08e-12
#> climatologia    0.762      0.927 1.42e-06

```

La prueba de DeLong confirma que la ventaja no es de muestreo: el modelo supera a ambas líneas base con $p < 10^{-5}$.

8.2 Los coeficientes

```

ic <- suppressMessages(confint(modelo))
round(data.frame(OR = exp(coef(modelo)), IC_inf = exp(ic[, 1]), IC_sup = exp(ic[,
  ↪ 2]),
              p = coef(summary(modelo))[, 4]), 4)
#>      OR IC_inf IC_sup      p
#> (Intercept) 0.2310 0.1769 0.2987 0.0000
#> s1          1.2658 1.0231 1.5658 0.0297
#> c1          0.4270 0.2815 0.6426 0.0001
#> s2          0.6577 0.5267 0.8194 0.0002
#> c2          0.5547 0.4406 0.6961 0.0000
#> comb        2.3520 1.8395 3.0339 0.0000
#> vent        0.3171 0.2295 0.4339 0.0000
#> foto        3.6626 2.7187 5.0743 0.0000
#> I(vent^2)    0.7047 0.5127 0.9565 0.0263
#> I(foto^2)    0.6894 0.5606 0.8412 0.0003
#> y1          3.8375 2.8000 5.2726 0.0000

```

Los tres factores apuntan en la dirección que la física predice, y ningún intervalo cruza el 1:

- **Forzamiento fotoquímico**, OR 3.66 por desviación estándar: el efecto más grande de los tres. Más temperatura y radiación, más ozono.
- **Combustión primaria**, OR 2.35: más precursores, más excedencia.
- **Ventilación**, OR 0.32: el viento dispersa. Es el único protector.
- y_{t-1} , OR 3.84: haber excedido ayer casi cuadruplica los momios de exceder hoy. Es lo que justifica que el modelo sea autorregresivo.

Los dos cuadráticos quedan por debajo de 1 (0.70 y 0.69), la saturación que la sección 4 anticipó: el efecto marginal se achica cuando ya hay mucho.

Advertencia heredada de `analisis_discriminante.pdf`: el SIMA no mide compuestos orgánicos volátiles, así que estos ejes se describen como *consistentes con* combustión, ventilación o forzamiento fotoquímico, nunca como una atribución de régimen NO_x-COV.

8.3 Discriminación

```
modelos_roc <- list("Autorregresivo (AR1)" = modelo,
                  "Climatologia"         = glm(y ~ s1 + c1 + s2 + c2, binomial,
                  ↪ TR),
                  "Persistencia"          = glm(y ~ y1, binomial, TR))
etiqueta <- function(nm) {
  r <- roc(VA$y, predict(modelos_roc[[nm]], VA, type = "response"), quiet = TRUE)
  sprintf("%s (AUC%.3f)", nm, as.numeric(auc(r)))
}
curvas <- do.call(rbind, lapply(names(modelos_roc), function(nm) {
  r <- roc(VA$y, predict(modelos_roc[[nm]], VA, type = "response"), quiet = TRUE)
  data.frame(modelo = factor(etiqueta(nm), levels = sapply(names(modelos_roc),
  ↪ etiqueta)),
             fpr = 1 - r$specificities, tpr = r$sensitivities)
}))

fig_roc <- ggplot(curvas, aes(fpr, tpr, color = modelo)) +
  geom_abline(slope = 1, intercept = 0, color = GRIS, linetype = "dotted",
             linewidth = .4) +
  geom_line(linewidth = .7) +
  scale_color_manual(values = c(AZUL, ROJO, GRIS), name = NULL) +
  coord_equal() +
  labs(x = "1 - especificidad", y = "sensibilidad") +
  theme_minimal(base_size = 9) +
  theme(legend.position = c(.98, .02), legend.justification = c(1, 0),
        legend.background = element_rect(fill = "white", color = NA),
        legend.key.height = unit(.8, "lines"),
        panel.grid.minor = element_blank())
ggsave("../reports/figuras/nowcast_roc.pdf", fig_roc, width = 5, height = 3.4)
fig_roc
```




Figura 1: Curvas ROC sobre la validacion de 2025. La diagonal punteada es el clasificador aleatorio. La persistencia produce solo tres vertices porque su predictor es binario.

8.4 El umbral de decisión

0.5 no es la respuesta por defecto cuando el evento no es equiprobable: con una tasa base de 0.30, exigir más de 0.5 sacrifica sensibilidad. El corte se elige por el índice de Youden y **sobre el ajuste**, nunca sobre la validación — escogerlo en 2025 sería calibrar una decisión con los datos de prueba.

```
roc_tr <- roc(TR$y, fitted(modelo), quiet = TRUE)
youden <- coords(roc_tr, "best", best.method = "youden", transpose = FALSE)
umbral <- as.numeric(youden$threshold)
cat(sprintf("umbral de Youden (elegido en 2021-2024):%.3f\n", umbral))
#> umbral de Youden (elegido en 2021-2024): 0.276

metricas <- function(y, p, u) {
  yh <- as.integer(p >= u)
  tp <- sum(yh == 1 & y == 1); tn <- sum(yh == 0 & y == 0)
  fp <- sum(yh == 1 & y == 0); fn <- sum(yh == 0 & y == 1)
  c(sens = tp/(tp+fn), esp = tn/(tn+fp), vpp = tp/(tp+fp), exactitud =
    ↪ (tp+tn)/length(y))
}

p_va <- predict(modelo, VA, type = "response")
round(rbind(
  `u=0.50 ajuste`      = metricas(TR$y, fitted(modelo), 0.5),
  `u=0.50 validacion`  = metricas(VA$y, p_va, 0.5),
  `Youden ajuste`     = metricas(TR$y, fitted(modelo), umbral),
  `Youden validacion` = metricas(VA$y, p_va, umbral)), 3)
```



```
#>          sens    esp   vpp exactitud
#> u=0.50 ajuste    0.660 0.902 0.743    0.829
#> u=0.50 validacion 0.787 0.901 0.863    0.851
#> Youden ajuste    0.831 0.803 0.645    0.812
#> Youden validacion 0.887 0.812 0.789    0.845
```

```
cat("matriz de confusion en 2025, umbral de Youden:\n")
#> matriz de confusion en 2025, umbral de Youden:
print(table(prediccion = as.integer(p_va >= umbral), observado = VA$y))
#>          observado
#> prediccion  0  1
#>          0 82  9
#>          1 19 71
```

El modelo clasifica 2025 con 88.7% de sensibilidad y 81.2% de especificidad. De 80 días de excedencia, detecta 71 y se le escapan 9; de 101 días limpios, acierta 82 y da 19 falsas alarmas.

Los dos cortes representan políticas distintas y vale la pena verlos juntos. Con 0.5 la especificidad sube a 0.901 pero la sensibilidad cae a 0.787: nueve falsas alarmas menos, a cambio de ocho días de excedencia más sin detectar, 17 en vez de 9. Para una aplicación de calidad del aire, donde el costo de no avisar de un día malo supera al de una alerta de más, el corte de Youden es el defendible. La decisión es de política pública, no estadística, y se deja explícita en vez de esconderla en un 0.5 por omisión.

8.5 Calibración

El AUC sólo mide **orden**. Que las probabilidades signifiquen lo que dicen es otra pregunta, y para un *nowcasting* que se comunicaría como “hoy hay 70 % de probabilidad de excedencia” es la que importa.

```
calib <- data.frame(p = p_va, y = VA$y) |>
  mutate(bin = cut(p, quantile(p, 0:5/5), include.lowest = TRUE)) |>
  group_by(bin) |>
  summarise(predicho = mean(p), observado = mean(y), n = n(),
            ee = sqrt(mean(y) * (1 - mean(y)) / n()), .groups = "drop")
print(as.data.frame(round(calib[, -1], 3)), row.names = FALSE)
#>   predicho observado  n    ee
#>   0.004      0.000 37 0.000
#>   0.066      0.056 36 0.038
#>   0.295      0.444 36 0.083
#>   0.650      0.806 36 0.066
#>   0.895      0.917 36 0.046

fig_cal <- ggplot(calib, aes(predicho, observado)) +
  geom_abline(slope = 1, intercept = 0, color = CLARO, linewidth = .4) +
  geom_errorbar(aes(ymin = pmax(0, observado - 1.96*ee),
```

```

      ymax = pmin(1, observado + 1.96*ee)),
      width = .02, color = GRIS, linewidth = .4) +
geom_point(color = AZUL, size = 2.2) +
coord_equal(xlim = c(0, 1), ylim = c(0, 1)) +
labs(x = "probabilidad predicha (media del quintil)",
     y = "frecuencia observada") +
theme_minimal(base_size = 9) + theme(panel.grid.minor = element_blank())
ggsave("../reports/figuras/nowcast_calibracion.pdf", fig_cal, width = 4.2, height
↪ = 3.4)
fig_cal

```




Figura 2: Calibracion en 2025 por quintiles de riesgo. Los puntos por encima de la diagonal indican subprediccion; las barras son intervalos binomiales del 95 %.

```

cat(sprintf("media predicha%.3f vs prevalencia observada%.3f\n",
            mean(p_va), mean(VA$y)))
#> media predicha 0.380 vs prevalencia observada 0.442

```

El modelo subpredice en 2025, y de forma sistemática. La media predicha es 0.380 contra 0.442 observado, y los quintiles centrales son los peores: donde el modelo dice 0.295, la frecuencia real es 0.444. Los extremos están bien —el quintil bajo predice 0.004 y observa 0.000; el alto predice 0.895 y observa 0.917.

La causa está diagnosticada desde la sección 2: **es el escalón de 2024**. El ajuste promedia el régimen bajo (2021–2023, tasa base 0.25–0.28) con el alto, y 2025 pertenece al alto; el desbalance estacional empuja en la misma dirección.

No se corrige: recalibrar el intercepto contra 2025 mejoraría el número y destruiría la validación. La discriminación, que no depende de la tasa base, no está afectada.

8.6 La serie de 2025

```
MESES <- c("ene", "feb", "mar", "abr", "may", "jun", "jul")
cortes <- as.POSIXct(paste0("2025-", sprintf("%02d", 1:7), "-01"), tz = "UTC")
serie <- data.frame(fecha = VA$fecha, p = p_va, y = VA$y)

fig_serie <- ggplot(serie, aes(fecha)) +
  geom_hline(yintercept = umbral, color = ROJO, linetype = "dashed", linewidth =
    ↪ .4) +
  geom_point(aes(y = y, color = "Excedencia observada"), size = .7, alpha = .6) +
  geom_line(aes(y = p, color = "Probabilidad predicha"), linewidth = .5) +
  annotate("text", x = max(serie$fecha) - 86400 * 6, y = umbral + .09,
    label = sprintf("umbral%.2f", umbral), hjust = 1, size = 2.6, color =
    ↪ ROJO) +
  scale_color_manual(values = c("Probabilidad predicha" = AZUL,
    "Excedencia observada" = GRIS), name = NULL) +
  scale_x_datetime(breaks = cortes, labels = MESES) +
  scale_y_continuous(breaks = c(0, .5, 1)) +
  labs(x = NULL, y = "P(excedencia)") +
  theme_minimal(base_size = 9) +
  theme(legend.position = "top", panel.grid.minor = element_blank(),
    legend.margin = margin(0, 0, -6, 0))
ggsave("../reports/figuras/nowcast_serie_2025.pdf", fig_serie, width = 6, height =
  ↪ 2.8)
fig_serie
```




Figura 3: Probabilidad predicha por el modelo contra la excedencia observada, validacion 2025. La linea roja es el umbral de Youden fijado en el ajuste.

Enero y la primera mitad de febrero son limpios y el modelo los da por limpios; de marzo a mayo la probabilidad oscila entre casi 0 y casi 1 día con día, no en una meseta estacional; junio baja. Esas

oscilaciones rápidas son el aporte de los factores contemporáneos: el modelo no predice la temporada, distingue días dentro de la temporada — lo que la climatología no puede hacer.

8.7 ¿Cuánto de ese 0.927 es real?

Un AUC de 0.927 sobre 181 días hay que auditarlo antes de reportarlo. Dos sospechas que conviene no confundir: **ruido de muestreo** (80 eventos es poco) y artefacto de la **ventana estacional** (2025 se corta el 30 de junio).

```
ic_auc <- ci_auc(roc(VA$y, p_va, quiet = TRUE), method = "delong")
cat(sprintf("AUC 2025 = %.3f   IC 95%% DeLong [%.3f, %.3f]   n = %d, %d eventos\n",
            ic_auc[2], ic_auc[1], ic_auc[3], nrow(VA), sum(VA$y)))
#> AUC 2025 = 0.927   IC 95% DeLong [0.891, 0.964]   n = 181, 80 eventos
```

El intervalo abarca casi ocho centésimas: el punto estimado no se lee con tres decimales de confianza.

Para aislar la ventana estacional hace falta una comparación donde sólo cambie el calendario. Se usa validación cruzada **dejando un año fuera** y se calcula, sobre cada año predicho por un modelo que no lo vio, el AUC del año completo y el de su ventana enero-junio.

```
Ap <- filter(A, !is.na(y1))
Ap$mes <- as.integer(format(Ap$fecha, "%m"))

# Al dejar 2021 fuera el modelo ve años posteriores. Para un pronostico seria
# trampa; aqui se mide heterogeneidad entre años, no uso operativo.
fuera_de_muestra <- lapply(2021:2025, function(Y) {
  va <- filter(Ap, anio == Y)
  list(anio = Y, y = va$y, mes = va$mes,
       p = predict(glm(F_final, binomial, filter(Ap, anio != Y)), va,
                    type = "response"))
})

auc_de <- function(o, filtro) {
  if (length(unique(o$y[filtro])) < 2) return(NA)
  as.numeric(auc(roc(o$y[filtro], o$p[filtro], quiet = TRUE)))
}

tabla_anios <- do.call(rbind, lapply(fuera_de_muestra, function(o) data.frame(
  anio = o$anio, n = length(o$y), prevalencia = round(mean(o$y), 3),
  AUC_completo = round(auc_de(o, rep(TRUE, length(o$y))), 3),
  AUC_ene_jun = round(auc_de(o, o$mes <= 6), 3),
  AUC_jul_dic = round(auc_de(o, o$mes >= 7), 3))))
print(tabla_anios, row.names = FALSE)
#>   anio    n prevalencia AUC_completo AUC_ene_jun AUC_jul_dic
#> 2021 364      0.275      0.846      0.816      0.886
#> 2022 365      0.282      0.881      0.852      0.920
#> 2023 365      0.249      0.870      0.836      0.933
#> 2024 366      0.396      0.920      0.926      0.897
```

```
#> 2025 181      0.442      0.928      0.928      NA

cmp <- tabla_anios[tabla_anios$anio <= 2024, ]
cat(sprintf("\nefecto de la ventana ene-jun sobre el año completo:%+.3f\n",
            mean(cmp$AUC_ene_jun) - mean(cmp$AUC_completo)))
#>
#> efecto de la ventana ene-jun sobre el año completo: -0.022
```

(El renglón de 2025 da 0.928 y no el 0.927 de la sección 8.1 porque aquí el ajuste sólo requiere y1 y entran seis días más. La diferencia es de una milésima.)

La ventana estacional no infla el AUC; lo deprime ligeramente. Restringirse a enero–junio cuesta 0.022 puntos en promedio, porque el segundo semestre trae noviembre y diciembre con prevalencia de 0.09 — días tan sistemáticamente limpios que el modelo los ordena sin dificultad. La intuición de que “a 2025 le sobra primavera y por eso es más fácil” resulta falsa al medirla.

Lo que sí distingue a 2025 es **el año**, no el calendario:

```
agrupado <- do.call(rbind, lapply(fuera_de_muestra[1:4],
                                \o) data.frame(y = o$y, p = o$p)))
r_ag <- roc(agrupado$y, agrupado$p, quiet = TRUE)
ic_ag <- ci.auc(r_ag, method = "delong")
cat(sprintf("AUC agrupado 2021-2024 (%d dias, 4 años completos, fuera de
  ↪ muestra)\n",
            nrow(agrupado)))
#> AUC agrupado 2021-2024 (1460 días, 4 años completos, fuera de muestra)
cat(sprintf("  =%.3f   IC 95%% [%.3f,%.3f]\n", ic_ag[2], ic_ag[1], ic_ag[3]))
#>    = 0.878   IC 95% [0.860, 0.897]
```

Los años 2021–2023 quedan entre 0.846 y 0.881; 2024 y 2025 en 0.920 y 0.928 — el corte coincide con el escalón de la sección 2. Antes de aceptarlo como efecto real hay que descartar la explicación mecánica: que la mayor prevalencia de 2024–25 facilite la clasificación.

```
set.seed(7)
d24 <- fuera_de_muestra[[4]]
objetivo <- tabla_anios$prevalencia[1] # prevalencia de 2021
n_pos <- round(objetivo * sum(d24$y == 0) / (1 - objetivo))
sim <- replicate(400, {
  i <- c(sample(which(d24$y == 1), n_pos), which(d24$y == 0))
  as.numeric(auc(roc(d24$y[i], d24$p[i], quiet = TRUE)))
})
cat(sprintf("AUC 2024 original%.3f -> submuestreado a la prevalencia de 2021:%.3f
  ↪ [%.3f,%.3f]\n",
            tabla_anios$AUC_completo[4], mean(sim),
            quantile(sim, .025), quantile(sim, .975)))
#> AUC 2024 original 0.920 -> submuestreado a la prevalencia de 2021: 0.919
  ↪ [0.899, 0.940]
```

No es la prevalencia: el AUC de 2024 no se mueve al igualarle la tasa base de 2021. La cobertura tampoco —2025 es el año con **menos** estaciones reportando por día y aun así el de AUC más alto. El efecto de año queda como observación empírica sin mecanismo identificado, igual que el escalón que lo acompaña.

Falta la pregunta directa: **qué habría dado 2025 completo**. No se observa, pero se acota pegando sus meses con el segundo semestre de cada año disponible, todos fuera de muestra.

```
e25 <- fuera_de_muestra[[5]]
do.call(rbind, lapply(fuera_de_muestra[1:4], function(o) {
  k <- o$mes >= 7
  data.frame(anio_sintetico = sprintf("ene-jun 2025 + jul-dic%d", o$anio),
             n = length(e25$y) + sum(k),
             AUC = round(as.numeric(auc(roc(c(e25$y, o$y[k]),
                                           c(e25$p, o$p[k]), quiet = TRUE))), 3))
})) |> print(row.names = FALSE)
#>      anio_sintetico    n    AUC
#> ene-jun 2025 + jul-dic 2021 365 0.916
#> ene-jun 2025 + jul-dic 2022 365 0.926
#> ene-jun 2025 + jul-dic 2023 365 0.933
#> ene-jun 2025 + jul-dic 2024 365 0.919
```

Los cuatro años sintéticos caen entre 0.916 y 0.933. **Completar el calendario no baja el AUC de 2025**, lo confirma alrededor de 0.92.

Salen dos cifras, según la pregunta:

- **Un año completo en condiciones como las de 2024–2025: 0.92.** La ventana truncada no infla nada.
- **Un año futuro cualquiera: 0.878, IC 95 % [0.860, 0.897]**, con rango año a año de 0.846 a 0.928.

La segunda es la que debe reportarse como estimación de generalización. El 0.927 no es incorrecto —es el desempeño sobre el periodo de validación preestablecido— pero es el extremo optimista de un rango, y presentarlo solo daría una impresión falsa de precisión. La diferencia entre 0.93 y 0.88 es la magnitud del efecto de año, la limitación principal de este modelo.

8.8 ¿Depende el resultado del umbral?

La sección 0.1 fijó `frac >= 0.5` como definición de día de excedencia y la presentó como decisión sustantiva. Falta saber si el modelo cambia de historia con otra definición.

```
sensibilidad <- do.call(rbind, lapply(c(1e-9, 0.25, 0.5, 0.75), function(u) {
  S <- A
  S$y <- as.integer(S$frac >= u)
  S$y1 <- lag(S$y, 1)
  tr <- filter(S, anio <= 2024, !is.na(y1)); va <- filter(S, anio == 2025)
  g <- glm(F_final, binomial, tr)
```

```

pv <- predict(g, va, type = "response")
data.frame(umbral = if (u < 0.01) "frac > 0" else sprintf("frac >=%.2f", u),
  prevalencia = round(mean(tr$y), 3),
  AUC_2025 = round(as.numeric(auc(roc(va$y, pv, quiet = TRUE))), 3),
  OR_y1 = round(exp(coef(g)["y1"]), 2),
  OR_foto = round(exp(coef(g)["foto"]), 2),
  OR_vent = round(exp(coef(g)["vent"]), 2))
)))
print(sensibilidad, row.names = FALSE)
#>      umbral prevalencia AUC_2025 OR_y1 OR_foto OR_vent
#>      frac > 0      0.568   0.945  3.81   2.44   0.44
#>      frac >= 0.25    0.409   0.935  3.20   3.28   0.35
#>      frac >= 0.50    0.301   0.928  3.80   3.66   0.32
#>      frac >= 0.75    0.163   0.901  6.66   4.00   0.27

```

No depende. El AUC va de 0.901 a 0.945 según el umbral, y las razones de momios conservan signo y orden de magnitud: el rezago entre 3.2 y 6.7, el forzamiento fotoquímico entre 2.4 y 4.0, la ventilación siempre protectora. El umbral cambia la prevalencia del evento, no lo que el modelo dice de él. La elección de 0.5 queda como decisión de definición, no como supuesto del que dependa el resultado.

9. Criterios de aceptación

Supuestos

- OK El orden autorregresivo se decide con PACF y con BIC condicionado a las covariables, sobre filas idénticas ($p = 1$)
- OK La estacionariedad se prueba donde corresponde: raíz unitaria en los factores continuos, homogeneidad temporal en la cadena binaria
- PARCIAL La dinámica es homogénea (persistencia estable, $p = 0.63$) pero el nivel da un escalón en 2024 ($p = 0.0012$) que los factores no absorben
- OK No hay separación perfecta: convergencia en 6 iteraciones, $|b|$ max 1.80, cuatro celdas de transición pobladas, traslape > 3 sd en los tres factores
- OK El link logit es correcto; el rechazo del linktest se atribuye a curvatura omitida y desaparece al incluirla ($p = 0.60$)
- OK La cadena es irreducible, aperiódica y geométricamente ergódica ($|\lambda_2| = 0.459$), con estacionaria 0.302 vs empírica 0.301
- OK La respuesta se dicotomiza en vez de modelarse como fracción: la sobredispersión binomial es de 5.97
- OK La dependencia residual se mide antes y después del rezago

Modelo

- OK La especificación se deriva de los diagnósticos, no se elige a mano
- OK Se compara contra dos líneas base de nowcasting (climatología y persistencia), con prueba de DeLong sobre la validación
- OK El umbral de decisión se fija en el ajuste, nunca en la validación
- OK Se reporta discriminación (AUC 0.927) y calibración por separado

OK El AUC se audita: IC de DeLong, validacion cruzada por anio, y anios completos sinteticos para aislar el efecto de la ventana estacional

OK Se distingue el desempeno en la particion (0.927) de la estimacion de generalizacion (0.878 [0.860, 0.897])

OK La subprediccion en 2025 se cuantifica y se explica, no se corrige recalibrando contra los datos de prueba

OK El umbral de dicotomizacion se somete a sensibilidad: AUC 0.90-0.95 y razones de momios estables en cuatro definiciones

10. Qué se lleva el reporte

El modelo funciona. Sobre 2025, que no vio, alcanza un AUC de 0.927 con 88.7 % de sensibilidad y 81.2 % de especificidad, y supera de forma significativa a la climatología (0.762, $p = 1.4 \times 10^{-6}$) y a la persistencia (0.737, $p = 5.1 \times 10^{-12}$). El *skill score* de Brier es 0.572. **Pero la cifra que debe reportarse como generalización es 0.878, IC 95 % [0.860, 0.897]:** el 0.927 es el extremo optimista de un rango que va de 0.846 a 0.928 según el año (§8.7).

Tres decisiones de especificación salidas de los diagnósticos, no del tanteo:

1. $p = 1$: un solo rezago de la respuesta (§1).
2. **Los armónicos anual y semianual son obligatorios** (§2): sin ellos la marginal varía por un factor de seis dentro del año.
3. **Los cuadrados de vent y foto entran, el de comb no** (§4 y §8): los dos primeros hacen pasar el *linktest*; el tercero no aporta ($p = 0.52$).

Y cinco limitaciones que se declaran en vez de corregirse:

El escalón de 2024 y la subpredicción que produce. El nivel de excedencia sube abruptamente desde 2024 y los factores no lo explican. El ajuste promedia dos regímenes y 2025 pertenece al alto: media predicha 0.380 contra 0.442 observado. No se corrige con una indicadora ni recalibrando el intercepto, porque sería ajustar un parámetro al periodo de validación.

El efecto de año. Los años 2024–25 son genuinamente más predecibles que 2021–2023, y no por prevalencia ni por cobertura: ambas explicaciones se descartan en §8.7. Es la limitación principal, y la que separa el 0.93 del 0.88.

La partición está estacionalmente desbalanceada. 2025 termina el 30 de junio, así que le sobra primavera y le falta otoño, lo que contribuye a la subpredicción. Lo que **no** explica es el AUC alto: restringirse a enero–junio cuesta 0.022 puntos en lugar de regalarlos.

La dimensión espacial se perdió. Agregar a área metropolitana devuelve la independencia temporal y la rejilla regular, pero elimina el contraste entre estaciones y zonas que *analisis_discriminante.pdf* sí aprovecha. Los dos modelos responden preguntas distintas —días de área contra día-estación— y comparar sus AUC no sería justo.

Esto es nowcasting, no pronóstico. Los factores son del mismo día que la respuesta: el modelo dice si hoy es día de excedencia, no anticipa el ozono de mañana. La extensión exige rezagar los factores y volver a validar, y §5 adelanta el techo: con un tiempo de mezcla de 1.3 días, más allá de dos o tres días la predicción converge a la climatología del mes.

Queda abierto el término de media móvil sobre los residuales —el residuo de lag 2 de §7 es el argumento para probarlo—, que es lo que agregaría un GLARMA. Requiere `renv::install("glarma")` seguido de `renv::record()`, nunca `snapshot()`.