

Posicion no central y forma

Issue #37 — MA2003B, equipo 7

Tabla de contenidos

Cuartiles y límites IQR	2
Boxplots	3
O3 y MDA8 por estación	5
Histogramas con densidad superpuesta	6

```
library(nanoparquet)
sth <- read_parquet("../data/processed/sima_transformado_horario.parquet")
head(sth)
```

	fecha	estacion	anio	O3	CO	NO2	NOX	PM10
1	2021-01-01 00:00:00	CE	2021	NA	NA	NA	NA	NA
2	2021-01-01 01:00:00	CE	2021	0.25275648	2.498112	NA	NA	0.4763621
3	2021-01-01 02:00:00	CE	2021	0.03505242	2.494212	NA	NA	0.1257665
4	2021-01-01 03:00:00	CE	2021	0.14695591	2.532811	NA	NA	0.1842673
5	2021-01-01 04:00:00	CE	2021	0.14695591	2.607484	NA	NA	0.4011814
6	2021-01-01 05:00:00	CE	2021	-0.21104241	2.521323	NA	NA	0.5486148

	PM2.5	TOUT	PRS	WSR	viento_u	viento_v	hora	mes
1	NA	NA	NA	NA	NA	NA	0	1
2	1.556242	-1.852320	-0.5880603	0.08335598	-0.48390850	-0.3057850	1	1
3	1.614059	-1.958949	-0.5445906	-0.61575400	0.07839821	-0.5578165	2	1
4	1.761888	-2.047096	-0.5120317	-0.51036741	0.69238216	-0.8393230	3	1
5	2.046093	-2.097684	-0.4903464	-1.11239933	0.57121418	-0.5461699	4	1
6	1.665086	-2.147238	-0.4903464	-1.18602563	0.42218249	-0.4904014	5	1

	dia_semana	fin_de_semana	temporada	O3_8h	outlier_O3	outlier_CO	outlier_NO2
1	4	0	invierno	NA	0	0	0
2	4	0	invierno	NA	0	1	0
3	4	0	invierno	NA	0	1	0
4	4	0	invierno	NA	0	1	0
5	4	0	invierno	NA	0	1	0
6	4	0	invierno	NA	0	1	0

	outlier_NOX	outlier_PM10	outlier_PM2.5	outlier_TOUT	outlier_PRS	outlier_WSR
1	0	0	0	0	0	0
2	0	0	0	0	0	0

3	0	0	0	0	0	0
4	0	0	1	0	0	0
5	0	0	1	0	0	0
6	0	0	0	0	0	0
llovió						
1	0					
2	0					
3	0					
4	0					
5	0					
6	0					

Cuartiles y límites IQR

Para O3, CO, NO2, NOX, PM10, PM2.5, TOUT, PRS y WSR los cuartiles y límites IQR **no se recalculan aquí**: se reusan los que ya produjo el criterio de outliers de la #13 (docs/log_limpieza.md, sección 7), guardados en `data/processed/resumen_outliers.csv`. Ese archivo solo publica `limite_inf` y `limite_sup` (los límites de $1.5 \times \text{IQR}$ usados para marcar outliers), así que Q1, Q3 e IQR se recuperan de ellos por álgebra —no por un nuevo cálculo sobre los datos crudos—, despejando el mismo criterio de $1.5 \times \text{IQR}$ que ya se aplicó:

$$\text{limite_inf} = Q_1 - 1.5 \cdot \text{IQR}, \quad \text{limite_sup} = Q_3 + 1.5 \cdot \text{IQR} \Rightarrow \text{IQR} = \frac{\text{limite_sup} - \text{limite_inf}}{4}$$

RAINF y WDR quedan fuera de esta tabla por la misma razón documentada en la #13: WDR es circular (un cuartil sobre grados no tiene sentido) y RAINF está inflada de ceros (su IQR es 0 y marcaría como atípica toda la lluvia registrada).

```
resumen_outliers <- read.csv("../data/processed/resumen_outliers.csv")

cuartiles_iqr <- within(resumen_outliers, {
  iqr <- (limite_sup - limite_inf) / 4
  q1 <- round(limite_inf + 1.5 * iqr, 2)
  q3 <- round(limite_sup - 1.5 * iqr, 2)
  iqr <- round(iqr, 2)
})[, c("variable", "q1", "q3", "iqr", "limite_inf", "limite_sup")]

cuartiles_iqr
```

	variable	q1	q3	iqr	limite_inf	limite_sup
1	O3	13.00	37.00	24.00	-23.00	73.00
2	CO	0.71	1.83	1.11	-0.96	3.50
3	NO2	6.90	19.70	12.80	-12.30	38.90
4	NOX	10.95	30.70	19.75	-18.68	60.33
5	PM10	35.00	74.00	39.00	-23.50	132.50

6	PM2.5	10.00	26.74	16.74	-15.11	51.85
7	TOUT	18.49	28.39	9.90	3.64	43.24
8	PRS	709.70	721.70	12.00	691.70	739.70
9	WSR	4.70	11.60	6.90	-5.65	21.95

Agregando los 03_8h y viento_u, viento_v. sth (el parquet cargado arriba) ya está transformado (Box-Cox + z-score, #14): su sesgo es ~ 0 por construcción y calcular un IQR sobre esa escala no describiría la variable real, además de duplicar en otra forma la tabla de sesgos que ya vive en `transformaciones.tex`. Por eso estas tres variables —y todo lo que sigue en boxplots e histogramas— se leen del dataset horario **limpio, sin transformar** (`sima_limpio_horario.csv`), igual que el criterio IQR de `resumen_outliers.csv` que se reusó arriba también es sobre esa escala.

```
sh <- data.table::fread(
  "../data/processed/sima_limpio_horario.csv",
  select = c(
    "estacion", "03", "CO", "NO2", "NOX", "PM10", "PM2.5",
    "TOUT", "RAINF", "PRS", "WSR", "viento_u", "viento_v", "03_8h"
  )
)

calcular_iqr <- function(x) {
  q <- quantile(x, probs = c(0.25, 0.75), na.rm = TRUE)
  iqr <- q[[2]] - q[[1]]
  data.frame(
    q1 = round(q[[1]], 2),
    q3 = round(q[[2]], 2),
    iqr = round(iqr, 2),
    limite_inf = round(q[[1]] - 1.5 * iqr, 2),
    limite_sup = round(q[[2]] + 1.5 * iqr, 2)
  )
}
```

```
nuevas <- do.call(rbind, lapply(c("03_8h", "viento_u", "viento_v"), function(v) {
  cbind(variable = v, calcular_iqr(sh[[v]]))
}))
head(nuevas)
```

	variable	q1	q3	iqr	limite_inf	limite_sup
1	03_8h	15.44	35.75	20.31	-15.03	66.22
2	viento_u	-8.56	0.21	8.77	-21.73	13.37
3	viento_v	-3.38	3.98	7.36	-14.41	15.01

Boxplots

El boxplot combinado de todas las variables en una sola escala ya existe en la sección de transformaciones (`reports/figuras/boxplot_variables_originales.png`) y ahí se usa para justificar el

escalamiento, no para leer cuartiles por variable — con PRS en ~700 y viento_u/viento_v en un rango de -5 a 5, una sola escala aplana el resto de las cajas. Aquí se hace una rejilla de boxplots individuales, uno por variable en sus unidades originales, que es lo que permite leer Q1/Q3/mediana/bigotes de cada una.


```
diario <- read.csv("../data/processed/sima_limpio_diario.csv")

medidas <- c(
  "O3", "CO", "NO2", "NOX", "PM10", "PM2.5", "TOUT", "PRS", "WSR", "O3_8h",
  "viento_u", "viento_v"
)
valores <- c(as.list(sh[, ..medidas]), list(RAINF = sh$RAINF, MDA8 = diario$MDA8))
```

```
pdf("../reports/figuras/boxplots_medidas.pdf", width = 10, height = 9)
par(mfrow = c(4, 4), mar = c(2, 4, 2, 1))
for (v in names(valores)) {
  boxplot(valores[[v]], main = v, ylab = v)
}
dev.off()
```

pdf
2

```
par(mfrow = c(4, 4), mar = c(2, 4, 2, 1))
for (v in names(valores)) {
  boxplot(valores[[v]], main = v, ylab = v)
}
```




O3 y MDA8 por estación

```
pdf("../reports/figuras/boxplot_o3_por_estacion.pdf", width = 9, height = 5)
boxplot(O3 ~ estacion, data = sh, main = "O3 por estación", xlab = "Estación",
  ↪ ylab = "O3 (ppb)", las = 2)
dev.off()
```

pdf
2

```
boxplot(O3 ~ estacion, data = sh, main = "O3 por estación", xlab = "Estación",
  ↪ ylab = "O3 (ppb)", las = 2)
```




```
pdf("../reports/figuras/boxplot_mda8_por_estacion.pdf", width = 9, height = 5)
boxplot(MDA8 ~ estacion, data = diario, main = "MDA8 por estación", xlab =
  ↪ "Estación", ylab = "MDA8 (ppb)", las = 2)
dev.off()
```

pdf
2

```
boxplot(MDA8 ~ estacion, data = diario, main = "MDA8 por estación", xlab =
  ↪ "Estación", ylab = "MDA8 (ppb)", las = 2)
```

MDA8 por estación



Histogramas con densidad superpuesta

Mismo criterio de la #14 para marcar simetría: $|\text{sesgo}(x)| < 0.5$. La rejilla de 14 paneles en escala original no se puede leer bien para `viento_u/viento_v`: unos cuantos valores extremos estiran el eje x hasta ± 150 mientras que el grueso de la masa vive entre -20 y 20 , así que cada panel individual queda como una espiga aplastada.

`RAINF` se excluye de este gráfico por la misma razón que en la sección de cuartiles: está inflada de ceros, así que su densidad estandarizada es una espiga angosta que domina el eje y aplasta el resto de las curvas a una línea plana.

Para comparar la forma (no la escala) de las 13 variables restantes en un solo gráfico, cada una se estandariza a z-score ($(x - \bar{x})/s$) **solo para este eje**, no es la transformación Box-Cox de la #14 — al ser una transformación lineal, estandarizar no cambia el sesgo de la variable, solo la pone en una escala comparable. Esto es distinto de `reports/figuras/densidad_variables_escaladas.pdf` (transformaciones.qmd), que muestra las densidades **después** de Box-Cox, cuando el sesgo ya se corrigió a ~ 0 ; aquí se ve la asimetría real, sin corregir, superpuesta.

```
library(moments)

estandarizar <- function(x) {
  x <- na.omit(x)
  (x - mean(x)) / sd(x)
}

valores_sup <- valores[names(valores) != "RAINF"]

sesgos <- sapply(valores_sup, function(x) skewness(na.omit(x)))
densidades <- lapply(valores_sup, function(x) density(estandarizar(x)))
paleta <- rainbow(length(densidades))
etiquetas <- sprintf("%s (sesgo=%.2f)", names(valores_sup), sesgos)
```

```


# Las colas largas de PM2.5/CO/viento estiran el z-score hasta  $\pm 47$ ; con ese rango
# todas las curvas se aplastan en una espiga sobre 0. Se recorta el eje x solo
  ↪ para
# que la forma del cuerpo de cada distribucion sea legible -el sesgo de la leyenda
# ya viene de density() sobre los datos completos, sin recortar.
xr <- c(-5, 10)
yr <- range(sapply(densidades, function(d) range(d$y[d$x >= xr[1] & d$x <=
  ↪ xr[2]])))

graficar_densidades_superpuestas <- function() {
  plot(densidades[[1]],
    main = "Densidad de las medidas horarias, MDA8 y viento (estandarizadas)",
    xlab = "z-score (solo para comparar formas; eje recortado, ver nota
      ↪ arriba)",
    col = paleta[1], xlim = xr, ylim = yr, lwd = 2
  )
  for (i in seq_along(densidades)[-1]) lines(densidades[[i]], col = paleta[i],
    ↪ lwd = 2)
  legend("topright", legend = etiquetas, col = paleta, lty = 1, lwd = 2, cex =
    ↪ 0.55, ncol = 2)
}

graficar_densidades_superpuestas()

```

ensidad de las medidas horarias, MDA8 y viento (estandariz



z-score (solo para comparar formas; eje recortado, ver nota arriba)

```

pdf("../reports/figuras/densidad_medidas_superpuesta.pdf", width = 9, height = 7)
graficar_densidades_superpuestas()
dev.off()

```

pdf

