

Tendencias y correlación

Issue #37 — MA2003B, equipo 7

Tabla de contenidos

```
library(nanoparquet)
data <- read_parquet("../data/processed/sima_transformado_horario.parquet")
head(data)
```

	fecha	estacion	anio		O3	CO	NO	NO2	NOX		S02
1	2021-01-01 00:00:00	CE	2021		NA	NA	NA	NA	NA		NA
2	2021-01-01 01:00:00	CE	2021	0.25010331	2.452431	NA	NA	NA	NA	-0.2833112	
3	2021-01-01 02:00:00	CE	2021	0.03433794	2.448905	NA	NA	NA	NA	-0.2833112	
4	2021-01-01 03:00:00	CE	2021	0.14524491	2.483781	NA	NA	NA	NA	-0.1049215	
5	2021-01-01 04:00:00	CE	2021	0.14524491	2.551081	NA	NA	NA	NA	-0.1621681	
6	2021-01-01 05:00:00	CE	2021	-0.20956537	2.473407	NA	NA	NA	NA	-0.1049215	
	PM10	PM2.5	TOUT		RH	SR		PRS		WSR	
1	NA	NA	NA		NA	NA		NA		NA	
2	0.5267335	1.585102	-1.892526	0.4602215	0.4231546	-0.6053260		0.1037203			
3	0.1775012	1.643249	-2.000378	0.6095411	0.4121832	-0.5613783		-0.6033042			
4	0.2357745	1.791923	-2.089535	0.7601282	0.4066762	-0.5284566		-0.4967245			
5	0.4518451	2.077752	-2.140703	0.8105984	0.4066762	-0.5065272		-1.1055719			
6	0.5987052	1.694568	-2.190824	0.9119416	0.4011551	-0.5065272		-1.1800317			
	viento_u	viento_v	hora	mes	dia_semana	fin_de_semana	temporada	O3_8h			
1	NA	NA	0	1		4		0	invierno	NA	
2	-0.50371096	-0.3151120	1	1		4		0	invierno	NA	
3	0.07148524	-0.5720327	2	1		4		0	invierno	NA	
4	0.69954326	-0.8590000	3	1		4		0	invierno	NA	
5	0.57559781	-0.5601601	4	1		4		0	invierno	NA	
6	0.42314993	-0.5033098	5	1		4		0	invierno	NA	
	outlier_O3	outlier_CO	outlier_NO	outlier_NO2	outlier_NOX	outlier_S02					
1	0	0	0	0	0	0					
2	0	1	0	0	0	0					
3	0	1	0	0	0	0					
4	0	1	0	0	0	0					
5	0	1	0	0	0	0					
6	0	1	0	0	0	0					

	outlier_PM10	outlier_PM2.5	outlier_TOUT	outlier_RH	outlier_PRS	outlier_WSR
1	0	0	0	0	0	0
2	0	0	0	0	0	0
3	0	0	0	0	0	0
4	0	1	0	0	0	0
5	0	1	0	0	0	0
6	0	0	0	0	0	0

	llovio
1	0
2	0
3	0
4	0
5	0
6	0

```
library(dplyr)
```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
# 12 variables
variables <- data %>%
  select(
    O3, CO, NO2, NOX, PM10, PM2.5, TOUT, PRS, WSR,
    viento_u, viento_v, O3_8h
  )

# Moda
moda <- function(x) {
  x <- x[!is.na(x)]
  valores <- unique(x)
  valores[which.max(tabulate(match(x, valores)))]
}

# Tabla consolidada
tabla_resumen <- data.frame(
  Variable = names(variables),
  Promedio = sapply(variables, mean, na.rm = TRUE),
```

```

    Mediana = sapply(variables, median, na.rm = TRUE),
    Moda = "No aplica",
    Rango = sapply(variables, function(x) diff(range(x, na.rm = TRUE))),
    Varianza = sapply(variables, var, na.rm = TRUE),
    Desv_Estandar = sapply(variables, sd, na.rm = TRUE)
)

# Resultados redondeados
tabla_resumen[, c(
  "Promedio", "Mediana", "Rango",
  "Varianza", "Desv_Estandar"
)] <-
  round(tabla_resumen[, c(
    "Promedio", "Mediana", "Rango",
    "Varianza", "Desv_Estandar"
  )], 3)

tabla_resumen

```

	Variable	Promedio	Mediana	Moda	Rango	Varianza	Desv_Estandar
O3	O3	0	0.034	No aplica	7.727	1	1
CO	CO	0	0.017	No aplica	7.775	1	1
NO2	NO2	0	-0.033	No aplica	7.638	1	1
NOX	NOX	0	-0.052	No aplica	9.067	1	1
PM10	PM10	0	-0.010	No aplica	10.853	1	1
PM2.5	PM2.5	0	0.008	No aplica	10.906	1	1
TOUT	TOUT	0	0.041	No aplica	7.060	1	1
PRS	PRS	0	-0.082	No aplica	22.702	1	1
WSR	WSR	0	0.065	No aplica	11.629	1	1
viento_u	viento_u	0	-0.015	No aplica	45.151	1	1
viento_v	viento_v	0	-0.016	No aplica	49.474	1	1
O3_8h	O3_8h	0	0.003	No aplica	7.476	1	1

Las variables analizadas ya fueron previamente estandarizadas, por lo que presentan medias cercanas a 0, varianzas cercanas a 1 y desviaciones estándar cercanas a 1. Por esta razón, las diferencias entre variables se aprecian principalmente en medidas como la mediana, moda y rango.

Ya que las 12 variables analizadas son continuas, no se calculó la moda clásica, ya que los valores pueden no repetirse exactamente. Se reportan como “No aplica”.

```

library(dplyr)
library(ggplot2)

# 12 variables cuantitativas
variables <- data %>%
  select(
    O3, CO, NO2, NOX, PM10, PM2.5, TOUT, PRS, WSR,

```

```

        viento_u, viento_v, 03_8h
    )

# Matriz de correlación de Pearson
matriz_cor <- cor(
    variables,
    use = "pairwise.complete.obs",
    method = "pearson"
)

round(matriz_cor, 2)

```

	03	CO	NO2	NOX	PM10	PM2.5	TOUT	PRS	WSR	viento_u
03	1.00	-0.12	-0.35	-0.43	-0.02	-0.05	0.52	-0.04	0.43	-0.30
CO	-0.12	1.00	0.25	0.26	0.33	0.31	-0.15	-0.15	-0.10	0.05
NO2	-0.35	0.25	1.00	0.89	0.39	0.35	-0.27	-0.12	-0.34	0.27
NOX	-0.43	0.26	0.89	1.00	0.38	0.37	-0.31	-0.05	-0.37	0.30
PM10	-0.02	0.33	0.39	0.38	1.00	0.62	0.09	-0.14	-0.03	0.08
PM2.5	-0.05	0.31	0.35	0.37	0.62	1.00	0.05	-0.12	-0.17	0.06
TOUT	0.52	-0.15	-0.27	-0.31	0.09	0.05	1.00	-0.20	0.38	-0.28
PRS	-0.04	-0.15	-0.12	-0.05	-0.14	-0.12	-0.20	1.00	-0.14	0.10
WSR	0.43	-0.10	-0.34	-0.37	-0.03	-0.17	0.38	-0.14	1.00	-0.46
viento_u	-0.30	0.05	0.27	0.30	0.08	0.06	-0.28	0.10	-0.46	1.00
viento_v	0.10	-0.03	-0.06	-0.07	-0.05	0.01	0.14	0.00	0.09	-0.17
03_8h	0.69	-0.08	-0.23	-0.35	-0.07	-0.10	0.45	-0.08	0.36	-0.29

	viento_v	03_8h
03	0.10	0.69
CO	-0.03	-0.08
NO2	-0.06	-0.23
NOX	-0.07	-0.35
PM10	-0.05	-0.07
PM2.5	0.01	-0.10
TOUT	0.14	0.45
PRS	0.00	-0.08
WSR	0.09	0.36
viento_u	-0.17	-0.29
viento_v	1.00	0.17
03_8h	0.17	1.00

```

library(ggcorrplot)

mapa_calor <- ggcorrplot(
    matriz_cor,
    method = "square",
    type = "lower",
    lab = TRUE,


```

```

lab_size = 3,
hc.order = TRUE,
colors = c("dodgerblue3", "lavender", "deeppink"),
title = "Mapa de calor de correlaciones"
)

mapa_calor

```



```

ggsave("../reports/figuras/mapa_calor_correlacion.pdf", plot = mapa_calor, width =
  8, height = 7)

```

```

pares_cor <- as.data.frame(as.table(matriz_cor))

pares_cor <- pares_cor %>%
  filter(Var1 != Var2) %>%
  mutate(
    par = paste(pmin(as.character(Var1), as.character(Var2)),
      pmax(as.character(Var1), as.character(Var2)),
      sep = " - "
    )
  ) %>%
  distinct(par, .keep_all = TRUE) %>%
  arrange(desc(abs(Freq)))

pares_cor

```

Var1	Var2	Freq	par
------	------	------	-----

1	NOX	NO2	0.893200016	NO2 - NOX
2	03_8h	03	0.686238274	03 - 03_8h
3	PM2.5	PM10	0.624478659	PM10 - PM2.5
4	TOUT	03	0.519694803	03 - TOUT
5	viento_u	WSR	-0.457759241	viento_u - WSR
6	03_8h	TOUT	0.448623419	03_8h - TOUT
7	WSR	03	0.433565209	03 - WSR
8	NOX	03	-0.428687607	NOX - 03
9	PM10	NO2	0.387007455	NO2 - PM10
10	PM10	NOX	0.383621431	NOX - PM10
11	WSR	TOUT	0.379449337	TOUT - WSR
12	WSR	NOX	-0.368685092	NOX - WSR
13	PM2.5	NOX	0.367012800	NOX - PM2.5
14	03_8h	WSR	0.355326441	03_8h - WSR
15	PM2.5	NO2	0.354361412	NO2 - PM2.5
16	03_8h	NOX	-0.348669011	NOX - 03_8h
17	NO2	03	-0.347506109	NO2 - 03
18	WSR	NO2	-0.336061619	NO2 - WSR
19	PM10	CO	0.331352079	CO - PM10
20	TOUT	NOX	-0.306561049	NOX - TOUT
21	PM2.5	CO	0.305137613	CO - PM2.5
22	viento_u	03	-0.301497937	03 - viento_u
23	viento_u	NOX	0.295257870	NOX - viento_u
24	03_8h viento_u		-0.291108419	03_8h - viento_u
25	viento_u	TOUT	-0.277805476	TOUT - viento_u
26	TOUT	NO2	-0.271974464	NO2 - TOUT
27	viento_u	NO2	0.269746703	NO2 - viento_u
28	NOX	CO	0.255004088	CO - NOX
29	NO2	CO	0.252270887	CO - NO2
30	03_8h	NO2	-0.232825927	NO2 - 03_8h
31	PRS	TOUT	-0.195652942	PRS - TOUT
32	viento_v viento_u		-0.172420168	viento_u - viento_v
33	WSR	PM2.5	-0.170406850	PM2.5 - WSR
34	03_8h viento_v		0.165357337	03_8h - viento_v
35	PRS	CO	-0.150685498	CO - PRS
36	TOUT	CO	-0.147058441	CO - TOUT
37	PRS	PM10	-0.142990747	PM10 - PRS
38	WSR	PRS	-0.142284029	PRS - WSR
39	viento_v	TOUT	0.136804563	TOUT - viento_v
40	CO	03	-0.118045665	CO - 03
41	PRS	PM2.5	-0.116828962	PM2.5 - PRS
42	PRS	NO2	-0.115396919	NO2 - PRS
43	WSR	CO	-0.103687350	CO - WSR
44	03_8h	PM2.5	-0.101869345	03_8h - PM2.5
45	viento_v	03	0.101139542	03 - viento_v
46	viento_u	PRS	0.097095701	PRS - viento_u
47	viento_v	WSR	0.089028083	viento_v - WSR
48	TOUT	PM10	0.086988243	PM10 - TOUT

49	viento_u	PM10	0.080454268	PM10 - viento_u
50	O3_8h	CO	-0.080222174	CO - O3_8h
51	O3_8h	PRS	-0.077917261	O3_8h - PRS
52	viento_v	NOX	-0.073918548	NOX - viento_v
53	O3_8h	PM10	-0.071484463	O3_8h - PM10
54	viento_u	PM2.5	0.062936437	PM2.5 - viento_u
55	viento_v	NO2	-0.057989578	NO2 - viento_v
56	PM2.5	O3	-0.054512512	O3 - PM2.5
57	viento_u	CO	0.053965658	CO - viento_u
58	PRS	NOX	-0.049247623	NOX - PRS
59	TOUT	PM2.5	0.048703342	PM2.5 - TOUT
60	viento_v	PM10	-0.046903377	PM10 - viento_v
61	PRS	O3	-0.043900441	O3 - PRS
62	viento_v	CO	-0.033724697	CO - viento_v
63	WSR	PM10	-0.033294463	PM10 - WSR
64	PM10	O3	-0.023629899	O3 - PM10
65	viento_v	PM2.5	0.005320722	PM2.5 - viento_v
66	viento_v	PRS	0.003047096	PRS - viento_v

El mapa de calor muestra una correlación positiva alta entre NO2 y NOX, lo que indica posible multicolinealidad entre estos dos. También destacan las relaciones entre O3 y O3_8h, PM10 y PM2.5 y O3 y TOUT. Por otro lado, O3 presenta una relación negativa moderada con NOX. Estas correlaciones muestran que existen grupos de variables relacionadas, lo que justifica aplicar técnicas como PCA para reducir dimensionalidad y estudiar su estructura conjunta.