

Tendencias y correlación

Issue #37 — MA2003B, equipo 7

Tabla de contenidos

```
library(nanoparquet)
data <- read_parquet("../data/processed/sima_transformado_horario.parquet")
head(data)
```

	fecha	estacion	anio	O3	CO	NO2	NOX	PM10
1	2021-01-01 00:00:00	CE	2021	NA	NA	NA	NA	NA
2	2021-01-01 01:00:00	CE	2021	0.25275648	2.498112	NA	NA	0.4763621
3	2021-01-01 02:00:00	CE	2021	0.03505242	2.494212	NA	NA	0.1257665
4	2021-01-01 03:00:00	CE	2021	0.14695591	2.532811	NA	NA	0.1842673
5	2021-01-01 04:00:00	CE	2021	0.14695591	2.607484	NA	NA	0.4011814
6	2021-01-01 05:00:00	CE	2021	-0.21104241	2.521323	NA	NA	0.5486148
	PM2.5	TOUT	PRS	WSR	viento_u	viento_v	hora	mes
1	NA	NA	NA	NA	NA	NA	0	1
2	1.556242	-1.852320	-0.5880603	0.08335598	-0.48390850	-0.3057850	1	1
3	1.614059	-1.958949	-0.5445906	-0.61575400	0.07839821	-0.5578165	2	1
4	1.761888	-2.047096	-0.5120317	-0.51036741	0.69238216	-0.8393230	3	1
5	2.046093	-2.097684	-0.4903464	-1.11239933	0.57121418	-0.5461699	4	1
6	1.665086	-2.147238	-0.4903464	-1.18602563	0.42218249	-0.4904014	5	1
	dia_semana	fin_de_semana	temporada	O3_8h	outlier_O3	outlier_CO	outlier_NO2	
1	4		0 invierno	NA	0		0	
2	4		0 invierno	NA	0		1	0
3	4		0 invierno	NA	0		1	0
4	4		0 invierno	NA	0		1	0
5	4		0 invierno	NA	0		1	0
6	4		0 invierno	NA	0		1	0
	outlier_NOX	outlier_PM10	outlier_PM2.5	outlier_TOUT	outlier_PRS	outlier_WSR		
1	0	0	0	0	0	0	0	
2	0	0	0	0	0	0	0	
3	0	0	0	0	0	0	0	
4	0	0	1	0	0	0	0	
5	0	0	1	0	0	0	0	
6	0	0	0	0	0	0	0	

```
llovio
1      0
2      0
3      0
4      0
5      0
6      0
```

```
library(dplyr)
```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

```
filter, lag
```

The following objects are masked from 'package:base':

```
intersect, setdiff, setequal, union
```

```
# 12 variables
variables <- data %>%
  select(
    O3, CO, NO2, NOX, PM10, PM2.5, TOUT, PRS, WSR,
    viento_u, viento_v, O3_8h
  )

# Moda
moda <- function(x) {
  x <- x[!is.na(x)]
  valores <- unique(x)
  valores[which.max(tabulate(match(x, valores)))]
}

# Tabla consolidada
tabla_resumen <- data.frame(
  Variable = names(variables),
  Promedio = sapply(variables, mean, na.rm = TRUE),
  Mediana = sapply(variables, median, na.rm = TRUE),
  Moda = "No aplica",
  Rango = sapply(variables, function(x) diff(range(x, na.rm = TRUE))),
  Varianza = sapply(variables, var, na.rm = TRUE),
  Desv_Estandar = sapply(variables, sd, na.rm = TRUE)
)
```

```
# Resultados redondeados
tabla_resumen[, c(
  "Promedio", "Mediana", "Rango",
  "Varianza", "Desv_Estandar"
)] <-
  round(tabla_resumen[, c(
    "Promedio", "Mediana", "Rango",
    "Varianza", "Desv_Estandar"
  )], 3)

tabla_resumen
```

	Variable	Promedio	Mediana	Moda	Rango	Varianza	Desv_Estandar
O3	O3	0	0.035	No aplica	7.797	1	1
CO	CO	0	0.037	No aplica	8.342	1	1
NO2	NO2	0	-0.029	No aplica	7.652	1	1
NOX	NOX	0	-0.052	No aplica	9.119	1	1
PM10	PM10	0	0.003	No aplica	10.895	1	1
PM2.5	PM2.5	0	0.016	No aplica	10.844	1	1
TOUT	TOUT	0	0.040	No aplica	6.980	1	1
PRS	PRS	0	-0.071	No aplica	10.648	1	1
WSR	WSR	0	0.045	No aplica	11.499	1	1
viento_u	viento_u	0	-0.010	No aplica	44.140	1	1
viento_v	viento_v	0	-0.013	No aplica	48.533	1	1
O3_8h	O3_8h	0	0.004	No aplica	7.534	1	1

Las variables analizadas ya fueron previamente estandarizadas, por lo que presentan medias cercanas a 0, varianzas cercanas a 1 y desviaciones estándar cercanas a 1. Por esta razón, las diferencias entre variables se aprecian principalmente en medidas como la mediana, moda y rango.

Ya que las 12 variables analizadas son continuas, no se calculó la moda clásica, ya que los valores pueden no repetirse exactamente. Se reportan como “No aplica”.

```
library(dplyr)
library(ggplot2)

# 12 variables cuantitativas
variables <- data %>%
  select(
    O3, CO, NO2, NOX, PM10, PM2.5, TOUT, PRS, WSR,
    viento_u, viento_v, O3_8h
  )

# Matriz de correlación de Pearson
matriz_cor <- cor(
  variables,
  use = "pairwise.complete.obs",
```

```

    method = "pearson"
)

round(matriz_cor, 2)

```

	O3	CO	NO2	NOX	PM10	PM2.5	TOUT	PRS	WSR	viento_u
O3	1.00	-0.11	-0.35	-0.43	-0.02	-0.05	0.51	-0.04	0.43	-0.30
CO	-0.11	1.00	0.25	0.25	0.31	0.30	-0.12	-0.17	-0.10	0.06
NO2	-0.35	0.25	1.00	0.89	0.38	0.35	-0.26	-0.11	-0.34	0.27
NOX	-0.43	0.25	0.89	1.00	0.38	0.37	-0.29	-0.04	-0.37	0.29
PM10	-0.02	0.31	0.38	0.38	1.00	0.62	0.11	-0.15	-0.04	0.08
PM2.5	-0.05	0.30	0.35	0.37	0.62	1.00	0.05	-0.11	-0.18	0.06
TOUT	0.51	-0.12	-0.26	-0.29	0.11	0.05	1.00	-0.20	0.38	-0.28
PRS	-0.04	-0.17	-0.11	-0.04	-0.15	-0.11	-0.20	1.00	-0.15	0.10
WSR	0.43	-0.10	-0.34	-0.37	-0.04	-0.18	0.38	-0.15	1.00	-0.45
viento_u	-0.30	0.06	0.27	0.29	0.08	0.06	-0.28	0.10	-0.45	1.00
viento_v	0.10	-0.03	-0.05	-0.07	-0.04	0.01	0.13	0.00	0.09	-0.18
O3_8h	0.69	-0.07	-0.24	-0.35	-0.06	-0.10	0.45	-0.08	0.36	-0.29

	viento_v	O3_8h
O3	0.10	0.69
CO	-0.03	-0.07
NO2	-0.05	-0.24
NOX	-0.07	-0.35
PM10	-0.04	-0.06
PM2.5	0.01	-0.10
TOUT	0.13	0.45
PRS	0.00	-0.08
WSR	0.09	0.36
viento_u	-0.18	-0.29
viento_v	1.00	0.16
O3_8h	0.16	1.00

```


library(ggcorrplot)

mapa_calor <- ggcorrplot(
  matriz_cor,
  method = "square",
  type = "lower",
  lab = TRUE,
  lab_size = 3,
  hc.order = TRUE,
  colors = c("dodgerblue3", "lavender", "deeppink"),
  title = "Mapa de calor de correlaciones"
)

mapa_calor

```

Mapa de calor de correlaciones



```
ggsave("../reports/figuras/mapa_calor_correlacion.pdf", plot = mapa_calor, width =
  ↪ 8, height = 7)
```

```
pares_cor <- as.data.frame(as.table(matriz_cor))

pares_cor <- pares_cor %>%
  filter(Var1 != Var2) %>%
  mutate(
    par = paste(pmin(as.character(Var1), as.character(Var2)),
      pmax(as.character(Var1), as.character(Var2)),
      sep = " - "
    )
  ) %>%
  distinct(par, .keep_all = TRUE) %>%
  arrange(desc(abs(Freq)))

pares_cor
```

	Var1	Var2	Freq	par
1	NOX	NO2	0.8896879114	NO2 - NOX
2	O3_8h	O3	0.6895545743	O3 - O3_8h
3	PM2.5	PM10	0.6234967382	PM10 - PM2.5
4	TOUT	O3	0.5139507086	O3 - TOUT
5	viento_u	WSR	-0.4547640585	viento_u - WSR
6	O3_8h	TOUT	0.4457748090	O3_8h - TOUT
7	WSR	O3	0.4306767303	O3 - WSR
8	NOX	O3	-0.4253719198	NOX - O3
9	PM10	NO2	0.3826617574	NO2 - PM10

10	WSR	TOUT	0.3794742616	TOUT - WSR
11	PM10	NOX	0.3784937691	NOX - PM10
12	WSR	NOX	-0.3699707019	NOX - WSR
13	PM2.5	NOX	0.3657141605	NOX - PM2.5
14	03_8h	WSR	0.3551148879	03_8h - WSR
15	PM2.5	NO2	0.3536632962	NO2 - PM2.5
16	03_8h	NOX	-0.3485331896	NOX - 03_8h
17	NO2	O3	-0.3454914002	NO2 - O3
18	WSR	NO2	-0.3367785879	NO2 - WSR
19	PM10	CO	0.3107210936	CO - PM10
20	viento_u	O3	-0.2972439178	O3 - viento_u
21	PM2.5	CO	0.2960602513	CO - PM2.5
22	TOUT	NOX	-0.2945363011	NOX - TOUT
23	viento_u	NOX	0.2923919724	NOX - viento_u
24	03_8h viento_u		-0.2908171757	03_8h - viento_u
25	viento_u	TOUT	-0.2782208968	TOUT - viento_u
26	viento_u	NO2	0.2652933997	NO2 - viento_u
27	TOUT	NO2	-0.2632682321	NO2 - TOUT
28	NOX	CO	0.2503938447	CO - NOX
29	NO2	CO	0.2499540559	CO - NO2
30	03_8h	NO2	-0.2353451574	NO2 - 03_8h
31	PRS	TOUT	-0.2036005376	PRS - TOUT
32	WSR	PM2.5	-0.1794642935	PM2.5 - WSR
33	viento_v viento_u		-0.1752494153	viento_u - viento_v
34	PRS	CO	-0.1747019447	CO - PRS
35	03_8h viento_v		0.1588053163	03_8h - viento_v
36	PRS	PM10	-0.1476581347	PM10 - PRS
37	WSR	PRS	-0.1463149601	PRS - WSR
38	viento_v	TOUT	0.1306748686	TOUT - viento_v
39	TOUT	CO	-0.1227205363	CO - TOUT
40	PRS	PM2.5	-0.1148962561	PM2.5 - PRS
41	CO	O3	-0.1098007060	CO - O3
42	TOUT	PM10	0.1077832452	PM10 - TOUT
43	PRS	NO2	-0.1075985278	NO2 - PRS
44	WSR	CO	-0.1031027386	CO - WSR
45	03_8h	PM2.5	-0.0981855470	03_8h - PM2.5
46	viento_u	PRS	0.0977167664	PRS - viento_u
47	viento_v	O3	0.0965375052	O3 - viento_v
48	viento_v	WSR	0.0860972021	viento_v - WSR
49	viento_u	PM10	0.0834051730	PM10 - viento_u
50	03_8h	PRS	-0.0760902115	03_8h - PRS
51	03_8h	CO	-0.0716724707	CO - 03_8h
52	viento_v	NOX	-0.0664791567	NOX - viento_v
53	03_8h	PM10	-0.0639314533	03_8h - PM10
54	viento_u	PM2.5	0.0632651081	PM2.5 - viento_u
55	viento_u	CO	0.0579567557	CO - viento_u
56	TOUT	PM2.5	0.0529688910	PM2.5 - TOUT
57	PM2.5	O3	-0.0525064906	O3 - PM2.5

58	viento_v	NO2	-0.0494522041	NO2 - viento_v
59	viento_v	PM10	-0.0444029871	PM10 - viento_v
60	PRS	O3	-0.0420243716	O3 - PRS
61	PRS	NOX	-0.0417458699	NOX - PRS
62	WSR	PM10	-0.0407388757	PM10 - WSR
63	viento_v	CO	-0.0263535120	CO - viento_v
64	PM10	O3	-0.0155470483	O3 - PM10
65	viento_v	PM2.5	0.0070918124	PM2.5 - viento_v
66	viento_v	PRS	-0.0001014332	PRS - viento_v

El mapa de calor muestra una correlación positiva alta entre NO2 y NOX, lo que indica posible multicolinealidad entre estos dos. También destacan las relaciones entre O3 y O3_8h, PM10 y PM2.5 y O3 y TOUT. Por otro lado, O3 presenta una relación negativa moderada con NOX. Estas correlaciones muestran que existen grupos de variables relacionadas, lo que justifica aplicar técnicas como PCA para reducir dimensionalidad y estudiar su estructura conjunta.