

Transformación y escalamiento de datos

Issue #35 — MA2003B, equipo 7

Tabla de contenidos

Transformaciones y escalamiento de datos	1
Uso de IA en este notebook	14

Transformaciones y escalamiento de datos

```
library(dplyr)
```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
library(nanoparquet)
sima_horario <- read.csv("../data/processed/sima_limpio_horario.csv") |>
  ↪ dplyr::select(-c("WDR")) # no es necesario tener la direccion del viendo si ya
  ↪ se tienen viento_u y viento_v
head(sima_horario)
```

	fecha	estacion	anio	03	CO	NO	NO2	NOX	SO2	PM10	PM2.5	TOUT	RH
1	2021-01-01 00:00:00	CE	2021	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2	2021-01-01 01:00:00	CE	2021	27	4.73	NA	NA	NA	3.3	68	46.00	8.26	67
3	2021-01-01 02:00:00	CE	2021	23	4.72	NA	NA	NA	3.3	55	47.64	7.15	70

```

4 2021-01-01 03:00:00      CE 2021 25 4.82 NA  NA  NA 3.6   57 52.07 6.20 73
5 2021-01-01 04:00:00      CE 2021 25 5.02 NA  NA  NA 3.5   65 61.62 5.64 74
6 2021-01-01 05:00:00      CE 2021 19 4.79 NA  NA  NA 3.6   71 49.13 5.08 76
      SR RAINF    PRS WSR    viento_u    viento_v hora mes dia_semana fin_de_semana
1    NA    NA    NA  NA        NA        NA    0  1         4             0
2 0.167    0 709.7 7.9 -7.7273660 -1.642502    1  1         4             0
3 0.165    0 710.1 4.8 -3.5104978 -3.273592    2  1         4             0
4 0.164    0 710.4 5.2  0.9922068 -5.104461    3  1         4             0
5 0.164    0 710.6 3.2  0.1116784 -3.198051    4  1         4             0
6 0.163    0 710.6 3.0 -0.9767045 -2.836556    5  1         4             0
      temporada 03_8h outlier_03 outlier_CO outlier_NO outlier_NO2 outlier_NOX
1  invierno    NA          0          0          0          0          0
2  invierno    NA          0          1          0          0          0
3  invierno    NA          0          1          0          0          0
4  invierno    NA          0          1          0          0          0
5  invierno    NA          0          1          0          0          0
6  invierno    NA          0          1          0          0          0
      outlier_SO2 outlier_PM10 outlier_PM2.5 outlier_TOUT outlier_RH outlier_PRS
1          0          0          0          0          0          0
2          0          0          0          0          0          0
3          0          0          0          0          0          0
4          0          0          1          0          0          0
5          0          0          1          0          0          0
6          0          0          0          0          0          0
      outlier_WSR
1          0
2          0
3          0
4          0
5          0
6          0

```

```
summary(sima_horario)
```

fecha	estacion	anio	O3
Length :640583	Length :640583	Min. :2021	Min. : 0.50
N.unique : 43824	N.unique : 15	1st Qu.:2022	1st Qu.: 13.00
N.blank : 0	N.blank : 0	Median :2023	Median : 23.00
Min.nchar: 19	Min.nchar: 2	Mean :2023	Mean : 27.01
Max.nchar: 19	Max.nchar: 4	3rd Qu.:2024	3rd Qu.: 37.00
		Max. :2025	Max. :265.00
			NAs :28982

CO	NO	NO2	NOX
Min. : 0.000	Min. : 0.30	Min. : 0.00	Min. : 0.50
1st Qu.: 0.680	1st Qu.: 3.00	1st Qu.: 6.80	1st Qu.: 10.90
Median : 1.140	Median : 5.00	Median : 11.60	Median : 17.40
Mean : 1.312	Mean : 11.84	Mean : 14.74	Mean : 26.43

3rd Qu.: 1.770	3rd Qu.: 10.80	3rd Qu.: 19.60	3rd Qu.: 30.60
Max. :37.000	Max. :500.00	Max. :167.80	Max. :500.00
NAs :43507	NAs :40191	NAs :40502	NAs :40656
S02	PM10	PM2.5	TOUT
Min. : 0.500	Min. : 1.00	Min. : 0.00	Min. : -9.62
1st Qu.: 2.800	1st Qu.: 33.36	1st Qu.: 10.00	1st Qu.:18.74
Median : 3.700	Median : 49.00	Median : 16.67	Median :24.15
Mean : 4.681	Mean : 58.43	Mean : 20.22	Mean :23.38
3rd Qu.: 5.200	3rd Qu.: 72.00	3rd Qu.: 26.00	3rd Qu.:28.46
Max. :404.700	Max. :998.00	Max. :782.00	Max. :47.58
NAs :42202	NAs :17020	NAs :134637	NAs :33422
RH	SR	RAINF	PRS
Min. : 0.00	Min. :0.0000	Min. : 0.0000	Min. :578.0
1st Qu.: 41.00	1st Qu.:0.0000	1st Qu.: 0.0000	1st Qu.:709.9
Median : 59.00	Median :0.0030	Median : 0.0000	Median :714.5
Mean : 56.72	Mean :0.1439	Mean : 0.0352	Mean :715.4
3rd Qu.: 74.00	3rd Qu.:0.2380	3rd Qu.: 0.0000	3rd Qu.:721.7
Max. :100.00	Max. :1.4000	Max. :360.0000	Max. :750.0
NAs :59745	NAs :21443	NAs :19360	NAs :17386
WSR	viento_u	viento_v	hora
Min. : 0.100	Min. : -178.1196	Min. : -177.4876	Min. : 0.0
1st Qu.: 4.700	1st Qu.: -8.4287	1st Qu.: -3.3074	1st Qu.: 6.0
Median : 7.700	Median : -4.1380	Median : 0.2461	Median :12.0
Mean : 8.547	Mean : -4.1720	Mean : 0.2913	Mean :11.5
3rd Qu.: 11.400	3rd Qu.: 0.2478	3rd Qu.: 3.9497	3rd Qu.:17.5
Max. :179.700	Max. : 162.6009	Max. : 160.8832	Max. :23.0
NAs :20760	NAs :30225	NAs :30225	
mes	dia_semana	fin_de_semana	temporada
Min. : 1.00	Min. :0	Min. :0.0000	Length :640583
1st Qu.: 4.00	1st Qu.:1	1st Qu.:0.0000	N.unique : 4
Median : 7.00	Median :3	Median :0.0000	N.blank : 0
Mean : 6.53	Mean :3	Mean :0.2859	Min.nchar: 5
3rd Qu.:10.00	3rd Qu.:5	3rd Qu.:1.0000	Max.nchar: 9
Max. :12.00	Max. :6	Max. :1.0000	
O3_8h	outlier_O3	outlier_CO	outlier_NO
Min. : 0.725	Min. :0.00000	Min. :0.00000	Min. :0.0000
1st Qu.: 15.375	1st Qu.:0.00000	1st Qu.:0.00000	1st Qu.:0.0000
Median : 24.417	Median :0.00000	Median :0.00000	Median :0.0000
Mean : 27.042	Mean :0.02522	Mean :0.02048	Mean :0.1095
3rd Qu.: 36.000	3rd Qu.:0.00000	3rd Qu.:0.00000	3rd Qu.:0.0000
Max. :147.875	Max. :1.00000	Max. :1.00000	Max. :1.0000
NAs :30991			
outlier_NO2	outlier_NOX	outlier_S02	outlier_PM10
Min. :0.00000	Min. :0.00000	Min. :0.00000	Min. :0.00000
1st Qu.:0.00000	1st Qu.:0.00000	1st Qu.:0.00000	1st Qu.:0.00000
Median :0.00000	Median :0.00000	Median :0.00000	Median :0.00000
Mean :0.03579	Mean :0.07855	Mean :0.06432	Mean :0.04657

```
3rd Qu.:0.00000 3rd Qu.:0.00000 3rd Qu.:0.00000 3rd Qu.:0.00000
Max. :1.00000 Max. :1.00000 Max. :1.00000 Max. :1.00000
```

```
outlier_PM2.5 outlier_TOUT outlier_RH outlier_PRS
Min. :0.0000 Min. :0.000000 Min. :0 Min. :0.000000
1st Qu.:0.0000 1st Qu.:0.000000 1st Qu.:0 1st Qu.:0.000000
Median :0.0000 Median :0.000000 Median :0 Median :0.000000
Mean :0.0306 Mean :0.008311 Mean :0 Mean :0.006233
3rd Qu.:0.0000 3rd Qu.:0.000000 3rd Qu.:0 3rd Qu.:0.000000
Max. :1.0000 Max. :1.000000 Max. :0 Max. :1.000000
```

```
outlier_WSR
Min. :0.00000
1st Qu.:0.00000
Median :0.00000
Mean :0.01422
3rd Qu.:0.00000
Max. :1.00000
```

```
str(sima_horario)
```

```
'data.frame': 640583 obs. of 37 variables:
 $ fecha : chr "2021-01-01 00:00:00" "2021-01-01 01:00:00" "2021-01-01 02:00:00" "2021-01-01 03:00:00" ...
 $ estacion : chr "CE" "CE" "CE" "CE" ...
 $ anio : int 2021 2021 2021 2021 2021 2021 2021 2021 2021 2021 2021 ...
 $ O3 : num NA 27 23 25 25 19 20 17 13 15 ...
 $ CO : num NA 4.73 4.72 4.82 5.02 4.79 4.77 4.73 4.76 4.64 ...
 $ NO : num NA NA NA NA NA NA NA NA NA NA ...
 $ NO2 : num NA NA NA NA NA NA NA NA NA NA ...
 $ NOX : num NA NA NA NA NA NA NA NA NA NA ...
 $ SO2 : num NA 3.3 3.3 3.6 3.5 3.6 3.4 3.5 3.3 3.3 ...
 $ PM10 : num NA 68 55 57 65 71 60 57 47 45 ...
 $ PM2.5 : num NA 46 47.6 52.1 61.6 ...
 $ TOUT : num NA 8.26 7.15 6.2 5.64 5.08 4.73 4.68 4.39 4.6 ...
 $ RH : num NA 67 70 73 74 76 78 77 78 76 ...
 $ SR : num NA 0.167 0.165 0.164 0.164 0.163 0.163 0.163 0.163 0.164 ...
 $ RAINF : num NA 0 0 0 0 0 0 0 0 0 ...
 $ PRS : num NA 710 710 710 711 ...
 $ WSR : num NA 7.9 4.8 5.2 3.2 3 2.4 3 4.7 4.5 ...
 $ viento_u : num NA -7.727 -3.51 0.992 0.112 ...
 $ viento_v : num NA -1.64 -3.27 -5.1 -3.2 ...
 $ hora : int 0 1 2 3 4 5 6 7 8 9 ...
 $ mes : int 1 1 1 1 1 1 1 1 1 1 ...
 $ dia_semana : int 4 4 4 4 4 4 4 4 4 4 ...
 $ fin_de_semana: int 0 0 0 0 0 0 0 0 0 0 ...
```

```

$ temporada      : chr  "invierno" "invierno" "invierno" "invierno" ...
$ O3_8h          : num  NA NA NA NA NA ...
$ outlier_O3     : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_CO     : int   0 1 1 1 1 1 1 1 1 1 ...
$ outlier_NO     : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_NO2    : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_NOX    : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_SO2    : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_PM10   : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_PM2.5  : int   0 0 0 1 1 0 0 0 0 0 ...
$ outlier_TOUT   : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_RH     : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_PRS    : int   0 0 0 0 0 0 0 0 0 0 ...
$ outlier_WSR    : int   0 0 0 0 0 0 0 0 0 0 ...

```

Hay variables cuantitativas que tienen escalas diferentes, como O3, que tiene como Min 0.5 y Max de 265, mientras se tienen otras variables con máximos de 37,167,55,998, etc. se considera que se debe hacer un escalamiento.

Se hace una complot de los datos para comparación visual

```

# Las banderas outlier_* son 0/1 y no se transforman. Con 2025 completo
# outlier_RH queda toda en cero, y una columna constante rompe scale().
sima_horario_quant <- sima_horario %>%
  ↪ dplyr::select(-c("estacion","fecha","anio","hora","mes","dia_semana","fin_de_semana","tempo
  ↪ -starts_with("outlier_"))
head(sima_horario_quant)


```

	O3	CO	NO	NO2	NOX	SO2	PM10	PM2.5	TOUT	RH	SR	RAINF	PRS	WSR	viento_u
1	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2	27	4.73	NA	NA	NA	3.3	68	46.00	8.26	67	0.167	0	709.7	7.9	-7.7273660
3	23	4.72	NA	NA	NA	3.3	55	47.64	7.15	70	0.165	0	710.1	4.8	-3.5104978
4	25	4.82	NA	NA	NA	3.6	57	52.07	6.20	73	0.164	0	710.4	5.2	0.9922068
5	25	5.02	NA	NA	NA	3.5	65	61.62	5.64	74	0.164	0	710.6	3.2	0.1116784
6	19	4.79	NA	NA	NA	3.6	71	49.13	5.08	76	0.163	0	710.6	3.0	-0.9767045
	viento_v		O3_8h												
1		NA	NA												
2	-1.642502		NA												
3	-3.273592		NA												
4	-5.104461		NA												
5	-3.198051		NA												
6	-2.836556		NA												

```

boxplot(sima_horario_quant)

```



```
png("../reports/figuras/boxplot_variables_originales.png", width = 1200, height =
  ↪ 800, res = 150)
boxplot(sima_horario_quant)
dev.off()
```

```
quartz_off_screen
2
```

La boxplot confirma la necesidad de escalamiento de las variables. Las distintas variables tienen diferentes unidades y escalas por lo que se lleva a cabo un escalamiento

Se define

$$|\text{skewness}(x_i)| < 0.5 \forall x_i \in \text{dataset } i = 1, 2, \dots, n$$

Entonces:

```
library(moments)
sk <- sima_horario_quant |> apply(2,skewness,na.rm = TRUE)
sk
```

	O3	CO	NO	NO2	NOX	S02
	1.28090748	1.90964370	6.86641798	1.90793938	4.49149963	13.31089539
	PM10	PM2.5	TOUT	RH	SR	RAINF
	3.65568247	5.70248887	-0.43287470	-0.31960108	1.52017450	144.84680453
	PRS	WSR	viento_u	viento_v	O3_8h	
	0.09329036	6.88866330	-1.41653574	-0.49832797	0.96036648	

La mayoría de las variables no cumplen con la regla propuesta, se convierten en candidatos a transformar, a excepción de RAINF, que tiene un sesgo de 144.85, debido a la naturaleza de la precipitación, es una variable inflada de zeros, ni Box-Cox ni Yeo-Johnson funcionarían con esta variable. Para esta variable será mejor crear una nueva llovio que sea la dicotomización de la variable original RAINF

```
sima_horario$llovio <- (as.integer(sima_horario$RAINF > 0))
sima_horario$llovio[is.na(sima_horario$llovio)] <- 0
sample(sima_horario$llovio, 20)
```

```
[1] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
```

```
library(MASS)
```

Attaching package: 'MASS'

The following object is masked from 'package:dplyr':

```
select
```

```
box_cox <- function(x) {
  bc <- boxcox(na.omit(x) ~ 1, plotit = FALSE)
  lambda <- bc$x[which.max(bc$y)]

  if (lambda == 0) log(x) else (x^lambda - 1) / lambda
}
```

```
candidates_bc <- sima_horario_quant |> dplyr::select(-c("RAINF"))
for (col in names(candidates_bc)) {
  x <- candidates_bc[[col]]
  if (any(x <= 0, na.rm = TRUE)) x <- x - min(x, na.rm = TRUE) + 1
  candidates_bc[[col]] <- box_cox(x)
}
head(candidates_bc)
```

	O3	CO	NO	NO2	NOX	S02	PM10	PM2.5	TOUT	RH
1	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA
2	5.626251	1.256407	NA	NA	NA	1.003502	5.249335	4.696360	68.15833	130.9406
3	5.205472	1.255538	NA	NA	NA	1.003502	4.929191	4.746853	61.80307	137.9473
4	5.421759	1.264136	NA	NA	NA	1.063531	4.982610	4.875957	56.54940	145.0134
5	5.421759	1.280726	NA	NA	NA	1.044267	5.180684	5.124162	53.53428	147.3817
6	4.729818	1.261578	NA	NA	NA	1.063531	5.315312	4.791417	50.58084	152.1371
	SR	PRS	WSR	viento_u	viento_v	O3_8h				
1	NA	NA	NA	NA	NA	NA				
2	0.1328629	0.7142129	2.863458	9242.828	1567.161	NA				
3	0.1316012	0.7142129	2.003100	9679.706	1545.520	NA				
4	0.1309680	0.7142130	2.132794	10156.734	1521.349	NA				
5	0.1309680	0.7142130	1.391905	10062.594	1546.520	NA				
6	0.1303331	0.7142130	1.301297	9946.806	1551.309	NA				

```
sk_trs = candidates_bc |> apply(2,skewness,na.rm = TRUE)
sk_trs
```

	O3	CO	NO	NO2	NOX	S02
-0.066259839	0.006480075	-0.008763830	0.019692237	0.002179642	0.003184718	
	PM10	PM2.5	TOUT	RH	SR	PRS
-0.041703678	0.085362267	-0.059961022	-0.168087692	1.016367738	-0.002426538	
	WSR	viento_u	viento_v	O3_8h		
0.096295754	0.751028747	0.615032800	0.011378794			

El sesgo de las variables fue reducido con exito, dada una transformacion de Box-Cox con desplazamiento para tratar las variables con valores negativos.

RAINF es un caso especial, debido a que es una variable con zero inflacion , tiene demasiado sesgo que una transformacion como Box-Cox no puede disminuir, ya se habia hecho una binaria a partir de esta llovio que podria tomarse en cuenta para otros analisis, pero hay que considerar que el uso de variables binarias en algunas tecnicas, como PCA, no es estadisticamente prolijo.

Se reemplazan en `sima_horario` las columnas originales por su version transformada con Box-Cox, y se descarta RAINF (ya representada por llovio), para obtener el dataset final de esta fase.

Se procede al escalamiento de las variables de `candidates_bc`

```
scaled_dt <- candidates_bc |> scale(scale = TRUE, center = TRUE)
head(scaled_dt)
```

	O3	CO	NO	NO2	NOX	S02	PM10	PM2.5	TOUT
[1,]	NA	NA	NA	NA	NA	NA	NA	NA	NA
[2,]	0.25010331	2.452431	NA	NA	NA	-0.2833112	0.5267335	1.585102	-1.892526
[3,]	0.03433794	2.448905	NA	NA	NA	-0.2833112	0.1775012	1.643249	-2.000378
[4,]	0.14524491	2.483781	NA	NA	NA	-0.1049215	0.2357745	1.791923	-2.089535
[5,]	0.14524491	2.551081	NA	NA	NA	-0.1621681	0.4518451	2.077752	-2.140703


```
[6,] -0.20956537 2.473407 NA NA NA -0.1049215 0.5987052 1.694568 -2.190824
      RH      SR      PRS      WSR      viento_u      viento_v      03_8h
[1,]      NA      NA      NA      NA      NA      NA      NA
[2,] 0.4602215 0.4231546 -0.6053260 0.1037203 -0.50371096 -0.3151120 NA
[3,] 0.6095411 0.4121832 -0.5613783 -0.6033042 0.07148524 -0.5720327 NA
[4,] 0.7601282 0.4066762 -0.5284566 -0.4967245 0.69954326 -0.8590000 NA
[5,] 0.8105984 0.4066762 -0.5065272 -1.1055719 0.57559781 -0.5601601 NA
[6,] 0.9119416 0.4011551 -0.5065272 -1.1800317 0.42314993 -0.5033098 NA
```


Distribución superpuesta de las variables ya escaladas:

```
cols <- colnames(scaled_dt)
dens <- lapply(cols, function(c) density(scaled_dt[, c], na.rm = TRUE))
xr <- range(sapply(dens, function(d) range(d$x)))
yr <- range(sapply(dens, function(d) range(d$y)))
paleta <- rainbow(length(cols))

graficar_densidades <- function() {
  plot(dens[[1]], main = "Distribucion de variables escaladas", xlab = "z-score",
    col = paleta[1], xlim = xr, ylim = yr)
  for (i in seq_along(dens)[-1]) lines(dens[[i]], col = paleta[i])
  legend("topright", legend = cols, col = paleta, lty = 1, cex = 0.6)
}

graficar_densidades()
```

Distribucion de variables escaladas





```
pdf("../reports/figuras/densidad_variables_escaladas.pdf", width = 8, height = 6)
graficar_densidades()
dev.off()
```

pdf
2

QQ-plots contra la normal, uno por variable:

```
graficar_qqplots <- function() {  
  par(mfrow = c(4, 3), mar = c(2, 2, 2, 1))  
  for (col in cols) {  
    qqnorm(scaled_dt[, col], main = col)  
    qqline(scaled_dt[, col], col = "red")  
  }  
  par(mfrow = c(1, 1))  
}  
  
graficar_qqplots()
```





```
png("../reports/figuras/qqplots_variables_escaladas.png", width = 1800, height =
  ↳ 2200, res = 200)
graficar_qqplots()
dev.off()
```

quartz_off_screen

2

viento_u y viento_v quedan mucho mas leptocurticas que el resto (curtosis de exceso 37 y 37, contra valores cercanos a 0 en casi todas las demas, ej. PM10 1.1, PM2.5 0.1). Esto no lo corrige Box-Cox: el metodo optimiza simetria (tercer momento), no curtosis (cuarto momento), y el estimado para estas dos variables fue alto (1.9 y 1.5), lo que amplifica en vez de comprimir los valores alejados del centro. Tiene sentido fisico: la mayoría de las horas el viento es tranquilo y con direccion similar (pico central agosto), pero hay rafagas raras con magnitudes mucho mayores (colas pesadas) que Box-Cox no aplanan. Junto con que, con SR (sesgo 1.02, por el bloque de ceros nocturnos), son las unicas variables que no bajaron de $|\text{sesgo}| < 0.5$ tras la transformacion, quedan marcadas como caso a vigilar si el metodo de #15 es sensible a colas pesadas (ej. distancia de Mahalanobis para outliers).

```
sima_horario_transformado <- sima_horario
sima_horario_transformado[colnames(scaled_dt)] <- scaled_dt
sima_horario_transformado <- sima_horario_transformado |> dplyr::select(-RAINF)
head(sima_horario_transformado)
```

	fecha	estacion	anio	03	CO	NO	NO2	NOX	SO2
1	2021-01-01 00:00:00	CE	2021	NA	NA	NA	NA	NA	NA
2	2021-01-01 01:00:00	CE	2021	0.25010331	2.452431	NA	NA	NA	-0.2833112
3	2021-01-01 02:00:00	CE	2021	0.03433794	2.448905	NA	NA	NA	-0.2833112
4	2021-01-01 03:00:00	CE	2021	0.14524491	2.483781	NA	NA	NA	-0.1049215
5	2021-01-01 04:00:00	CE	2021	0.14524491	2.551081	NA	NA	NA	-0.1621681
6	2021-01-01 05:00:00	CE	2021	-0.20956537	2.473407	NA	NA	NA	-0.1049215
	PM10	PM2.5	TOUT	RH	SR	PRS	WSR		
1	NA	NA	NA	NA	NA	NA	NA		
2	0.5267335	1.585102	-1.892526	0.4602215	0.4231546	-0.6053260	0.1037203		
3	0.1775012	1.643249	-2.000378	0.6095411	0.4121832	-0.5613783	-0.6033042		
4	0.2357745	1.791923	-2.089535	0.7601282	0.4066762	-0.5284566	-0.4967245		
5	0.4518451	2.077752	-2.140703	0.8105984	0.4066762	-0.5065272	-1.1055719		
6	0.5987052	1.694568	-2.190824	0.9119416	0.4011551	-0.5065272	-1.1800317		
	viento_u	viento_v	hora	mes	dia_semana	fin_de_semana	temporada	03_8h	
1	NA	NA	0	1	4		0 invierno	NA	
2	-0.50371096	-0.3151120	1	1	4		0 invierno	NA	
3	0.07148524	-0.5720327	2	1	4		0 invierno	NA	
4	0.69954326	-0.8590000	3	1	4		0 invierno	NA	
5	0.57559781	-0.5601601	4	1	4		0 invierno	NA	
6	0.42314993	-0.5033098	5	1	4		0 invierno	NA	
	outlier_03	outlier_CO	outlier_NO	outlier_NO2	outlier_NOX	outlier_SO2			
1	0	0	0	0	0	0			
2	0	1	0	0	0	0			
3	0	1	0	0	0	0			
4	0	1	0	0	0	0			
5	0	1	0	0	0	0			
6	0	1	0	0	0	0			

	outlier_PM10	outlier_PM2.5	outlier_TOUT	outlier_RH	outlier_PRS	outlier_WSR
1	0	0	0	0	0	0
2	0	0	0	0	0	0
3	0	0	0	0	0	0
4	0	1	0	0	0	0
5	0	1	0	0	0	0
6	0	0	0	0	0	0

	llovio
1	0
2	0
3	0
4	0
5	0
6	0

```
write_parquet(sima_horario_transformado,
  ↪ "../data/processed/sima_transformado_horario.parquet")
write_csv(sima_horario_transformado,
  ↪ "../data/processed/sima_transformado_horario.csv", row.names = FALSE)
```

Uso de IA en este notebook

Se uso Claude Code como asistente durante todo el proceso, principalmente de tres formas: (1) depurar código R que fallaba o daba resultados incorrectos sin avisar (ej. `select()` de `dplyr` enmascarado por `library(MASS)`, `names()` en vez de `colnames()` sobre la matriz que devuelve `scale()` -que dejaba `sima_horario_transformado` sin transformar de forma silenciosa-, el shift de Box-Cox que no cubria columnas con valores negativos, y la colision de colores en la grafica de densidad por reciclar solo 8 colores para 12 variables); (2) explicar conceptos estadísticos aplicados a este dataset (diferencia entre normalizar y estandarizar, por que Box-Cox no corrige zero-inflacion ni curtosis, por que WDR como variable circular no deberia tratarse como continua); y (3) escribir funciones y chunks específicos (`box_cox()`, la union de `candidates_bc` con `sima_horario`, las graficas de densidad y Q-Q). Cada hallazgo y cada pieza de código se verifico corriendola contra los datos reales del equipo (`sima_limpio_horario.csv`) antes de incorporarla al notebook -no se acepto ninguna explicacion ni resultado numerico sin reproducirlo primero-, y las decisiones de fondo (que variable dicotomizar, que hacer con WDR, si escalar variables binarias) se discutieron y decidieron en conversacion, no se delegaron a la IA.