

Transformación y escalamiento de datos

Issue #35 — MA2003B, equipo 7

Tabla de contenidos

Transformaciones y escalamiento de datos	1
Uso de IA en este notebook	11

Transformaciones y escalamiento de datos

```
library(dplyr)
```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
library(nanoparquet)
sima_horario <- read.csv("../data/processed/sima_limpio_horario.csv") |>
  ↪ dplyr::select(-c("WDR")) # no es necesario tener la direccion del viendo si ya
  ↪ se tienen viento_u y viento_v
head(sima_horario)
```

	fecha	estacion	anio	03	CO	NO2	NOX	PM10	PM2.5	TOUT	RAINF	PRS
1	2021-01-01 00:00:00	CE	2021	NA	NA	NA	NA	NA	NA	NA	NA	NA
2	2021-01-01 01:00:00	CE	2021	27	4.73	NA	NA	68	46.00	8.26	0	709.7
3	2021-01-01 02:00:00	CE	2021	23	4.72	NA	NA	55	47.64	7.15	0	710.1

```

4 2021-01-01 03:00:00      CE 2021 25 4.82  NA  NA   57 52.07 6.20    0 710.4
5 2021-01-01 04:00:00      CE 2021 25 5.02  NA  NA   65 61.62 5.64    0 710.6
6 2021-01-01 05:00:00      CE 2021 19 4.79  NA  NA   71 49.13 5.08    0 710.6
  WSR   viento_u   viento_v   hora mes dia_semana fin_de_semana temporada 03_8h
1  NA          NA          NA    0  1           4              0 invierno  NA
2 7.9 -7.7273660 -1.642502    1  1           4              0 invierno  NA
3 4.8 -3.5104978 -3.273592    2  1           4              0 invierno  NA
4 5.2  0.9922068 -5.104461    3  1           4              0 invierno  NA
5 3.2  0.1116784 -3.198051    4  1           4              0 invierno  NA
6 3.0 -0.9767045 -2.836556    5  1           4              0 invierno  NA
  outlier_03 outlier_CO outlier_NO2 outlier_NOX outlier_PM10 outlier_PM2.5
1          0          0          0          0          0          0
2          0          1          0          0          0          0
3          0          1          0          0          0          0
4          0          1          0          0          0          1
5          0          1          0          0          0          1
6          0          1          0          0          0          0
  outlier_TOUT outlier_PRS outlier_WSR
1          0          0          0
2          0          0          0
3          0          0          0
4          0          0          0
5          0          0          0
6          0          0          0

```

```
summary(sima_horario)
```

```

      fecha      estacion      anio      03
Length :574343 Length :574343 Min.   :2021 Min.   : 0.50
N.unique : 39408 N.unique :   15 1st Qu.:2022 1st Qu.: 13.00
N.blank  :    0 N.blank :    0 Median :2023 Median : 23.00
Min.nchar:   19 Min.nchar:    2 Mean   :2023 Mean   : 26.92
Max.nchar:   19 Max.nchar:    4 3rd Qu.:2024 3rd Qu.: 37.00
                                Max.   :2025 Max.   :265.00
                                NAs     :25224

      CO      NO2      NOX      PM10
Min.   : 0.000 Min.   : 0.00 Min.   : 0.50 Min.   : 1.00
1st Qu.: 0.710 1st Qu.: 6.90 1st Qu.: 10.95 1st Qu.: 35.00
Median : 1.210 Median : 11.70 Median : 17.50 Median : 51.00
Mean   : 1.356 Mean   : 14.81 Mean   : 26.36 Mean   : 60.19
3rd Qu.: 1.825 3rd Qu.: 19.70 3rd Qu.: 30.70 3rd Qu.: 74.00
Max.   :37.000 Max.   :167.80 Max.   :500.00 Max.   :998.00
NAs    :35361 NAs    :36828 NAs    :35715 NAs    :14113

      PM2.5      TOUT      RAINF      PRS
Min.   : 0.00 Min.   : -9.62 Min.   : 0.00000 Min.   :655.4
1st Qu.: 10.00 1st Qu.:18.49 1st Qu.: 0.00000 1st Qu.:709.7
Median : 17.00 Median :24.01 Median : 0.00000 Median :714.5

```

Mean : 20.53	Mean :23.23	Mean : 0.02056	Mean :715.3
3rd Qu.: 26.74	3rd Qu.:28.39	3rd Qu.: 0.00000	3rd Qu.:721.7
Max. :782.00	Max. :47.58	Max. :360.00000	Max. :750.0
NAs :118049	NAs :26674	NAs :17251	NAs :14271
WSR	viento_u	viento_v	hora
Min. : 0.100	Min. :-178.1196	Min. :-177.4876	Min. : 0.0
1st Qu.: 4.700	1st Qu.: -8.5649	1st Qu.: -3.3773	1st Qu.: 6.0
Median : 7.700	Median : -4.1690	Median : 0.2408	Median :12.0
Mean : 8.678	Mean : -4.2425	Mean : 0.2676	Mean :11.5
3rd Qu.: 11.600	3rd Qu.: 0.2093	3rd Qu.: 3.9794	3rd Qu.:17.5
Max. :179.700	Max. : 162.6009	Max. : 160.8832	Max. :23.0
NAs :19773	NAs :28971	NAs :28971	
mes	dia_semana	fin_de_semana	temporada
Min. : 1.000	Min. :0.000	Min. :0.0000	Length :574343
1st Qu.: 3.000	1st Qu.:1.000	1st Qu.:0.0000	N.unique : 4
Median : 6.000	Median :3.000	Median :0.0000	N.blank : 0
Mean : 6.188	Mean :3.002	Mean :0.2862	Min.nchar: 5
3rd Qu.: 9.000	3rd Qu.:5.000	3rd Qu.:1.0000	Max.nchar: 9
Max. :12.000	Max. :6.000	Max. :1.0000	
03_8h	outlier_03	outlier_CO	outlier_NO2
Min. : 0.725	Min. :0.00000	Min. :0.00000	Min. :0.00000
1st Qu.: 15.438	1st Qu.:0.00000	1st Qu.:0.00000	1st Qu.:0.00000
Median : 24.375	Median :0.00000	Median :0.00000	Median :0.00000
Mean : 26.953	Mean :0.02398	Mean :0.01935	Mean :0.03596
3rd Qu.: 35.750	3rd Qu.:0.00000	3rd Qu.:0.00000	3rd Qu.:0.00000
Max. :147.875	Max. :1.00000	Max. :1.00000	Max. :1.00000
NAs :27103			
outlier_NOX	outlier_PM10	outlier_PM2.5	outlier_TOUT
Min. :0.00000	Min. :0.00000	Min. :0.00000	Min. :0.00000
1st Qu.:0.00000	1st Qu.:0.00000	1st Qu.:0.00000	1st Qu.:0.00000
Median :0.00000	Median :0.00000	Median :0.00000	Median :0.00000
Mean :0.07839	Mean :0.04677	Mean :0.02963	Mean :0.00768
3rd Qu.:0.00000	3rd Qu.:0.00000	3rd Qu.:0.00000	3rd Qu.:0.00000
Max. :1.00000	Max. :1.00000	Max. :1.00000	Max. :1.00000
outlier_PRS	outlier_WSR		
Min. :0.000000	Min. :0.00000		
1st Qu.:0.000000	1st Qu.:0.00000		
Median :0.000000	Median :0.00000		
Mean :0.006033	Mean :0.01376		
3rd Qu.:0.000000	3rd Qu.:0.00000		
Max. :1.000000	Max. :1.00000		

```
str(sima_horario)
```

```
'data.frame': 574343 obs. of 30 variables:
 $ fecha      : chr  "2021-01-01 00:00:00" "2021-01-01 01:00:00" "2021-01-01 02:00:00" "2021-01-01 03:00:00" ...
 $ estacion   : chr  "CE" "CE" "CE" "CE" ...
 $ anio       : int   2021 2021 2021 2021 2021 2021 2021 2021 2021 2021 ...
 $ O3         : num   NA 27 23 25 25 19 20 17 13 15 ...
 $ CO         : num   NA 4.73 4.72 4.82 5.02 4.79 4.77 4.73 4.76 4.64 ...
 $ NO2        : num   NA NA NA NA NA NA NA NA NA NA ...
 $ NOX        : num   NA NA NA NA NA NA NA NA NA NA ...
 $ PM10       : num   NA 68 55 57 65 71 60 57 47 45 ...
 $ PM2.5      : num   NA 46 47.6 52.1 61.6 ...
 $ TOUT       : num   NA 8.26 7.15 6.2 5.64 5.08 4.73 4.68 4.39 4.6 ...
 $ RAINF      : num   NA 0 0 0 0 0 0 0 0 0 ...
 $ PRS        : num   NA 710 710 710 711 ...
 $ WSR        : num   NA 7.9 4.8 5.2 3.2 3 2.4 3 4.7 4.5 ...
 $ viento_u   : num   NA -7.727 -3.51 0.992 0.112 ...
 $ viento_v   : num   NA -1.64 -3.27 -5.1 -3.2 ...
 $ hora       : int    0 1 2 3 4 5 6 7 8 9 ...
 $ mes        : int    1 1 1 1 1 1 1 1 1 1 ...
 $ dia_semana : int    4 4 4 4 4 4 4 4 4 4 ...
 $ fin_de_semana: int    0 0 0 0 0 0 0 0 0 0 ...
 $ temporada  : chr   "invierno" "invierno" "invierno" "invierno" ...
 $ O3_8h      : num   NA NA NA NA NA ...
 $ outlier_O3 : int    0 0 0 0 0 0 0 0 0 0 ...
 $ outlier_CO : int    0 1 1 1 1 1 1 1 1 1 ...
 $ outlier_NO2 : int    0 0 0 0 0 0 0 0 0 0 ...
 $ outlier_NOX : int    0 0 0 0 0 0 0 0 0 0 ...
 $ outlier_PM10 : int    0 0 0 0 0 0 0 0 0 0 ...
 $ outlier_PM2.5: int    0 0 0 1 1 0 0 0 0 0 ...
 $ outlier_TOUT : int    0 0 0 0 0 0 0 0 0 0 ...
 $ outlier_PRS : int    0 0 0 0 0 0 0 0 0 0 ...
 $ outlier_WSR : int    0 0 0 0 0 0 0 0 0 0 ...
```

Hay variables cuantitativas que tienen escalas diferentes, como O3, que tiene como Min 0.5 y Max de 265, mientras se tienen otras variables con máximos de 37,167,55,998, etc. se considera que se debe hacer un escalamiento.

Se hace una complot de los datos para comparación visual

```
sima_horario_quant <- sima_horario %>%
  ↪ dplyr::select(-c("estacion","fecha","anio","hora","mes","dia_semana","fin_de_semana","tempo
head(sima_horario_quant)
```

```
 O3   CO NO2 NOX PM10 PM2.5 TOUT RAINF   PRS WSR   viento_u   viento_v O3_8h
```

```
boxplot(sima_horario_quant)
```



O3	CO	NO2	NOX	PM10	PM2.5
1.2931781	1.8147506	1.9324655	3.6307418	3.6553276	5.8125784
TOUT	RAINF	PRS	WSR	viento_u	viento_v
-0.4177213	238.4555408	0.1020772	6.9439615	-1.4683483	-0.5209155
O3_8h					
0.9737003					

La mayoría de las variables no cumplen con la regla propuesta, se convierten en candidatos a transformar, a excepción de RAINF, que tiene un sesgo de 238.46, debido a la naturaleza de la precipitación, es una variable inflada de zeros, ni Box-Cox ni Yeo-Johnson funcionarían con esta variable. Para esta variable será mejor crear una nueva llovio que sea la dicotomización de la variable original RAINF

```
sima_horario$llovio <- (as.integer(sima_horario$RAINF > 0))
sima_horario$llovio[is.na(sima_horario$llovio)] <- 0
sample(sima_horario$llovio, 20)
```

```
[1] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
```

```
library(MASS)
```

Attaching package: 'MASS'

The following object is masked from 'package:dplyr':

```
select
```

```
box_cox <- function(x) {
  bc <- boxcox(na.omit(x) ~ 1, plotit = FALSE)
  lambda <- bc$x[which.max(bc$y)]

  if (lambda == 0) log(x) else (x^lambda - 1) / lambda
}
```

```
candidates_bc <- sima_horario_quant |> dplyr::select(-c("RAINF"))
for (col in names(candidates_bc)) {
  x <- candidates_bc[[col]]
  if (any(x <= 0, na.rm = TRUE)) x <- x - min(x, na.rm = TRUE) + 1
  candidates_bc[[col]] <- box_cox(x)
}
head(candidates_bc)
```

	O3	CO	NO2	NOX	PM10	PM2.5	TOUT	PRS	WSR
1	NA	NA	NA	NA	NA	NA	NA	NA	NA
2	5.626251	1.358946	NA	NA	5.249335	4.696360	68.15833	0.5882269	2.863458
3	5.205472	1.357911	NA	NA	4.929191	4.746853	61.80307	0.5882269	2.003100
4	5.421759	1.368156	NA	NA	4.982610	4.875957	56.54940	0.5882269	2.132794
5	5.421759	1.387974	NA	NA	5.180684	5.124162	53.53428	0.5882269	1.391905
6	4.729818	1.365106	NA	NA	5.315312	4.791417	50.58084	0.5882269	1.301297
	viento_u	viento_v	O3_8h						
1	NA	NA	NA						
2	9242.828	1567.161	NA						
3	9679.706	1545.520	NA						
4	10156.734	1521.349	NA						
5	10062.594	1546.520	NA						
6	9946.806	1551.309	NA						

```
sk_trs = candidates_bc |> apply(2,skewness,na.rm = TRUE)
sk_trs
```

	O3	CO	NO2	NOX	PM10	PM2.5
	-0.067803824	0.018530235	0.028693551	-0.026059173	-0.064685182	0.077793131
	TOUT	PRS	WSR	viento_u	viento_v	O3_8h
	-0.042733339	0.000777554	0.119713962	0.783719306	0.650433899	0.016148435

El sesgo de las variables fue reducido con exito, dada una transformacion de Box-Cox con desplazamiento para tratar las variables con valores negativos.

RAINF es un caso especial, debido a que es una variable con zero inflacion , tiene demasiado sesgo que una transformacion como Box-Cox no puede disminuir, ya se habia hecho una binaria a partir de esta llovio que podria tomarse en cuenta para otros analisis, pero hay que considerar que el uso de variables binarias en algunas tecnicas, como PCA, no es estadisticamente prolijo.

Se reemplazan en `sima_horario` las columnas originales por su version transformada con Box-Cox, y se descarta RAINF (ya representada por `llovio`), para obtener el dataset final de esta fase.

Se procede al escalamiento de las variables de `candidates_bc`

```
scaled_dt <- candidates_bc |> scale(scale = TRUE, center = TRUE)
head(scaled_dt)
```


	O3	CO	NO2	NOX	PM10	PM2.5	TOUT	PRS
[1,]	NA	NA	NA	NA	NA	NA	NA	NA
[2,]	0.25275648	2.498112	NA	NA	0.4763621	1.556242	-1.852320	-0.5880603
[3,]	0.03505242	2.494212	NA	NA	0.1257665	1.614059	-1.958949	-0.5445906
[4,]	0.14695591	2.532811	NA	NA	0.1842673	1.761888	-2.047096	-0.5120317
[5,]	0.14695591	2.607484	NA	NA	0.4011814	2.046093	-2.097684	-0.4903464
[6,]	-0.21104241	2.521323	NA	NA	0.5486148	1.665086	-2.147238	-0.4903464
	WSR	viento_u	viento_v	O3_8h				

```
[1,]      NA      NA      NA      NA
[2,] 0.08335598 -0.48390850 -0.3057850      NA
[3,] -0.61575400 0.07839821 -0.5578165      NA
[4,] -0.51036741 0.69238216 -0.8393230      NA
[5,] -1.11239933 0.57121418 -0.5461699      NA
[6,] -1.18602563 0.42218249 -0.4904014      NA
```

Distribución superpuesta de las variables ya escaladas:


```
cols <- colnames(scaled_dt)
dens <- lapply(cols, function(c) density(scaled_dt[, c], na.rm = TRUE))
xr <- range(sapply(dens, function(d) range(d$x)))
yr <- range(sapply(dens, function(d) range(d$y)))
paleta <- rainbow(length(cols))
plot(dens[[1]], main = "Distribucion de variables escaladas", xlab = "z-score",
     col = paleta[1], xlim = xr, ylim = yr)
for (i in seq_along(dens)[-1]) lines(dens[[i]], col = paleta[i])
legend("topright", legend = cols, col = paleta, lty = 1, cex = 0.6)
```

Distribucion de variables escaladas



QQ-plots contra la normal, uno por variable:

```
par(mfrow = c(4, 3), mar = c(2, 2, 2, 1))
for (col in cols) {
  qqnorm(scaled_dt[, col], main = col)
  qqline(scaled_dt[, col], col = "red")
}
```

```
par(mfrow = c(1, 1))
```

viento_u y viento_v quedan mucho mas leptocurticas que el resto (curtosis de exceso 38 y 39, contra valores cercanos a 0 en casi todas las demas, ej. PM10 1.2, PM2.5 0.1). Esto no lo corrige

Box-Cox: el metodo optimiza simetria (tercer momento), no curtosis (cuarto momento), y el estimado para estas dos variables fue alto (1.9 y 1.5), lo que amplifica en vez de comprimir los valores alejados del centro. Tiene sentido fisico: la mayoría de las horas el viento es tranquilo y con direccion similar (pico central agosto), pero hay rafagas raras con magnitudes mucho mayores (colas pesadas) que Box-Cox no aplanan. Junto con que ya eran las unicas variables que no bajaron de $|\text{sesgo}| < 0.5$ tras la transformacion, quedan marcadas como caso a vigilar si el metodo de #15 es sensible a colas pesadas (ej. distancia de Mahalanobis para outliers).

```
sima_horario_transformado <- sima_horario
sima_horario_transformado[colnames(scaled_dt)] <- scaled_dt
sima_horario_transformado <- sima_horario_transformado |> dplyr::select(-RAINF)
head(sima_horario_transformado)
```

	fecha	estacion	anio	O3	CO	NO2	NOX	PM10
1	2021-01-01 00:00:00	CE	2021	NA	NA	NA	NA	NA
2	2021-01-01 01:00:00	CE	2021	0.25275648	2.498112	NA	NA	0.4763621
3	2021-01-01 02:00:00	CE	2021	0.03505242	2.494212	NA	NA	0.1257665
4	2021-01-01 03:00:00	CE	2021	0.14695591	2.532811	NA	NA	0.1842673
5	2021-01-01 04:00:00	CE	2021	0.14695591	2.607484	NA	NA	0.4011814
6	2021-01-01 05:00:00	CE	2021	-0.21104241	2.521323	NA	NA	0.5486148
	PM2.5	TOUT	PRS	WSR	viento_u	viento_v	hora	mes
1	NA	NA	NA	NA	NA	NA	0	1
2	1.556242	-1.852320	-0.5880603	0.08335598	-0.48390850	-0.3057850	1	1
3	1.614059	-1.958949	-0.5445906	-0.61575400	0.07839821	-0.5578165	2	1
4	1.761888	-2.047096	-0.5120317	-0.51036741	0.69238216	-0.8393230	3	1
5	2.046093	-2.097684	-0.4903464	-1.11239933	0.57121418	-0.5461699	4	1
6	1.665086	-2.147238	-0.4903464	-1.18602563	0.42218249	-0.4904014	5	1
	dia_semana	fin_de_semana	temporada	O3_8h	outlier_O3	outlier_CO	outlier_NO2	
1	4	0	invierno	NA	0	0	0	
2	4	0	invierno	NA	0	1	0	
3	4	0	invierno	NA	0	1	0	
4	4	0	invierno	NA	0	1	0	
5	4	0	invierno	NA	0	1	0	
6	4	0	invierno	NA	0	1	0	
	outlier_NOX	outlier_PM10	outlier_PM2.5	outlier_TOUT	outlier_PRS	outlier_WSR		
1	0	0	0	0	0	0		
2	0	0	0	0	0	0		
3	0	0	0	0	0	0		
4	0	0	1	0	0	0		
5	0	0	1	0	0	0		
6	0	0	0	0	0	0		
	llovia							
1	0							
2	0							
3	0							
4	0							
5	0							

```
write_parquet(sima_horario_transformado,
  ↪  "../data/processed/sima_transformado_horario.parquet")
write_csv(sima_horario_transformado,
  ↪  "../data/processed/sima_transformado_horario.csv", row.names = FALSE)
```

Uso de IA en este notebook

Se uso Claude Code como asistente durante todo el proceso, principalmente de tres formas: (1) depurar codigo R que fallaba o daba resultados incorrectos sin avisar (ej. `select()` de dplyr enmascarado por `library(MASS)`, `names()` en vez de `colnames()` sobre la matriz que devuelve `scale()` -que dejaba `sima_horario_transformado` sin transformar de forma silenciosa-, el shift de Box-Cox que no cubria columnas con valores negativos, y la colision de colores en la grafica de densidad por reciclar solo 8 colores para 12 variables); (2) explicar conceptos estadisticos aplicados a este dataset (diferencia entre normalizar y estandarizar, por que Box-Cox no corrige zero-inflacion ni curtosis, por que WDR como variable circular no deberia tratarse como continua); y (3) escribir funciones y chunks especificos (`box_cox()`, la union de `candidates_bc` con `sima_horario`, las graficas de densidad y Q-Q). Cada hallazgo y cada pieza de codigo se verifico corriendola contra los datos reales del equipo (`sima_limpio_horario.csv`) antes de incorporarla al notebook -no se acepto ninguna explicacion ni resultado numerico sin reproducirlo primero-, y las decisiones de fondo (que variable dicotomizar, que hacer con WDR, si escalar variables binarias) se discutieron y decidieron en conversacion, no se delegaron a la IA.