

Clasificación de excedencias de ozono en el AMM

Presentación de avance para el socioformador

Equipo 102.07

MA2003B — Aplicación de Métodos Multivariados en Ciencia de Datos

3 de septiembre de 2026

Avance del proyecto tras el cambio de objetivo; no es la presentación final de entrega.


¿Qué buscamos y cómo simplificamos los datos?

El objetivo. Identificar, día por día y por estación, cuándo el aire del Área Metropolitana de Monterrey superó el límite seguro de ozono que marca la norma oficial (**51 ppb**, NOM-020-SSA1-2021), según los contaminantes y el clima de ese mismo día. El modelo **explica** qué condiciones acompañan esos episodios; no **predice** los siguientes.

¿Por qué componentes principales? Muchas de las 15 variables medidas se mueven juntas: NO y NOX, dos contaminantes clave, casi se comportan como uno solo (correlación de 0.94). Para no repetir información, se resumen en 3 grandes ejes:

- *Carga primaria de combustión*: contaminación por quema de combustibles
- *Forzamiento fotoquímico*: qué tan soleado y seco está el día
- *Estancamiento atmosférico*: qué tanto se acumula el aire contaminado

Juntos conservan **55.9 %** de esa información, y alimentan los modelos que siguen.



Varianza explicada por componente.


Regresión logística: primeros resultados

Partición. Entrenamiento con 2021–2024; validación con 2025, fechas que el modelo no vio durante el ajuste.

¿Qué tan bien clasifica? En validación, el modelo distingue los días con y sin excedencia con un AUC de **0.893** — muy por encima de la meta de 0.75. Detecta el **83.1 %** de las excedencias reales (sensibilidad) y descarta correctamente el **82.4 %** de los días sin excedencia (especificidad).

No se usa la exactitud como criterio: 41.5 % de los días-estación de validación excede el umbral, así que un modelo que solo adivinara la clase más común ya luciría bien sin detectar nada real.

De los 3 ejes del ACP, el que más empuja hacia la excedencia es el *forzamiento fotoquímico*, seguido de la *carga primaria de combustión*; el *estancamiento atmosférico* influye menos.



Curva ROC en validación (AUC = 0.893).

Pendiente — issue #55

Faltan los resultados del discriminante (AUC de validación, sensibilidad, especificidad) y la comparación logística vs. discriminante a la luz de sus supuestos: el discriminante lineal asume normalidad multivariada, aproximada por Box-Cox con $|\text{sesgo}| < 0,5$; la regresión logística no la requiere.

Propuesta de cierre

Pendiente — issue #57 (sección de resultados y cierre del reporte). Plan B si el AUC no llega a 0.75: repetir el análisis con el umbral de 65 ppb.