

Clasificación de excedencias de ozono en el AMM

Presentación de avance para el socioformador — versión simple

Equipo 102.07

MA2003B — Aplicación de Métodos Multivariados en Ciencia de Datos

3 de septiembre de 2026

Avance del proyecto tras el cambio de objetivo; no es la presentación final de entrega.


¿Qué buscamos y cómo simplificamos los datos?

El objetivo. Identificar, día por día y por estación, cuándo el aire del Área Metropolitana de Monterrey superó el límite seguro de ozono que marca la norma oficial (**51 ppb**, NOM-020-SSA1-2021), según los contaminantes y el clima de ese mismo día. El modelo **explica** qué condiciones acompañan esos episodios; no **predice** los siguientes.

¿Por qué componentes principales? Muchas de las 15 variables medidas se mueven juntas: NO y NOX, dos contaminantes clave, casi se comportan como uno solo (correlación de 0.94). Para no repetir información, se resumen en 3 grandes ejes:

- *Carga primaria de combustión*: contaminación por quema de combustibles
- *Forzamiento fotoquímico*: qué tan soleado y seco está el día
- *Estancamiento atmosférico*: qué tanto se acumula el aire contaminado

Juntos conservan **55.9 %** de esa información, y alimentan los modelos que siguen.



Varianza explicada por componente.


Regresión logística: primeros resultados

Partición. Entrenamiento con 2021–2024; validación con 2025, fechas que el modelo no vio durante el ajuste.

¿Qué tan bien clasifica? En validación, el modelo distingue los días con y sin excedencia con un AUC de **0.893** — muy por encima de la meta de 0.75. Detecta el **83.1 %** de las excedencias reales (sensibilidad) y descarta correctamente el **82.4 %** de los días sin excedencia (especificidad).

No se usa la exactitud como criterio: 41.5 % de los días-estación de validación excede el umbral, así que un modelo que solo adivinara la clase más común ya luciría bien sin detectar nada real.

De los 3 ejes del ACP, el que más empuja hacia la excedencia es el *forzamiento fotoquímico*, seguido de la *carga primaria de combustión*; el *estancamiento atmosférico* influye menos.



Qué tanto empuja cada eje hacia la excedencia.


¿El discriminante da lo mismo? Comparación y cierre

El discriminante lineal es la otra técnica que probamos. Parte de un supuesto más fuerte que la logística: que los datos siguen una distribución normal y que se dispersan igual en ambos grupos. Lo segundo no se cumple del todo — los días de excedencia varían menos que los de no excedencia —, pero en la práctica no importó.

También alcanza un AUC de **0.893** en validación: detecta el **84.5 %** de las excedencias reales y acierta el **81.1 %** de los días sin excedencia — casi idéntico a la logística.

De hecho, los dos modelos coinciden en el **98.1 %** de sus decisiones, y una prueba estadística no encuentra diferencia real entre sus curvas ROC.

Cierre. Aunque el discriminante rompe uno de sus supuestos, llega prácticamente al mismo resultado que el modelo que no lo necesita. Queda pendiente: los modelos explican qué acompaña una excedencia el mismo día, no predicen el siguiente; y como varias estaciones comparten el mismo clima, los días no son del todo independientes entre sí.



Las dos curvas se superponen casi por completo.